Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 5 - PAO 2026 – II

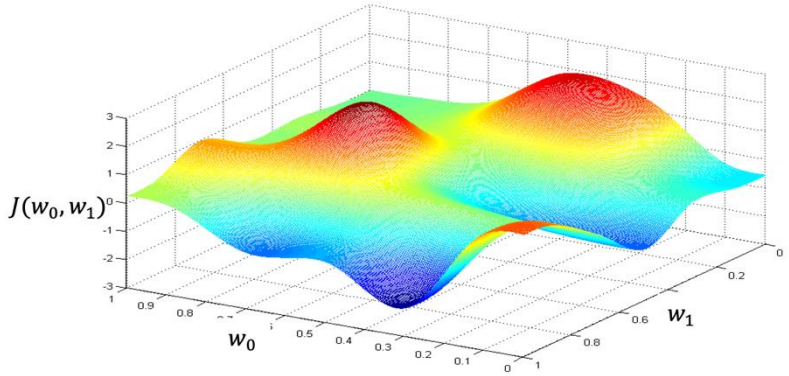
Agenda

1. Aprendizaje autónomo (machine learning) supervisado
    1.1 El algoritmo Gradiente Descendiente
2. Algoritmos lineales:
    2.1 Regresión lineal de una variable
    2.2 Regresión lineal múltiples variables
    2.3 Regresión polinómica
3. Underfitting y Overfitting
    3.1 Regularización

Aprendizaje Supervisado: Gradiente descendiente

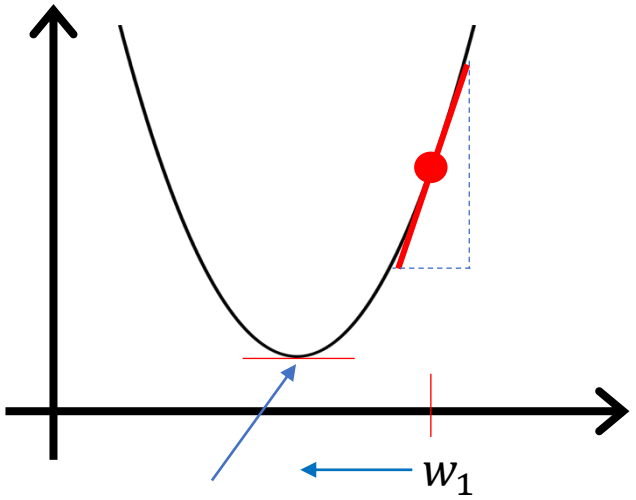
- A través del GD podemos calcular la dirección y la magnitud de los pequeños cambios en los parámetros, y así ajustar de forma iterativa el modelo
- Ese cálculo se realiza a través de la derivada de la función de costo
- Y, la corrección o ajuste del parámetro w_0 sería:

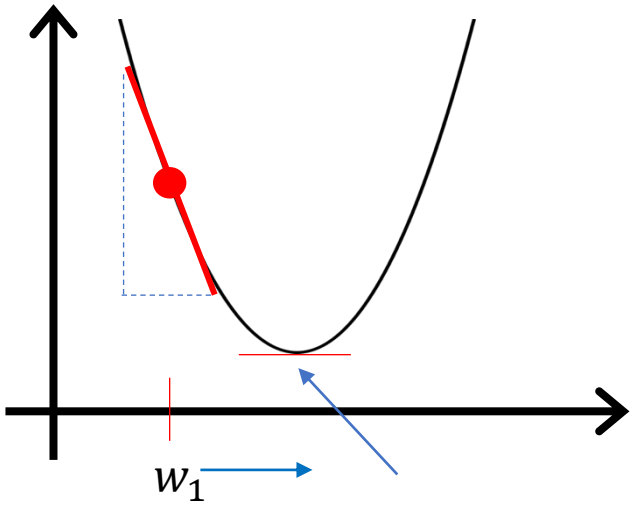
$$W_{j_{nuevo}} = W_{j_{anterior}} - \alpha \frac{d}{dw_j} J(W)$$



Regla de aprendizaje

Algoritmos lineales: Gradiente descendiente





$$w_j = w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1)$$

Por ejemplo la actualización de w_1

$$w_1 = w_1 - \alpha \frac{\partial}{\partial w_1} J(w_1)$$

$$w_1 = w_1 - \alpha(número\ positivo)$$

$$w_1 = w_1 - \alpha \frac{\partial}{\partial w_1} J(w_1)$$

$$w_1 = w_1 - \alpha(número\ negativo)$$

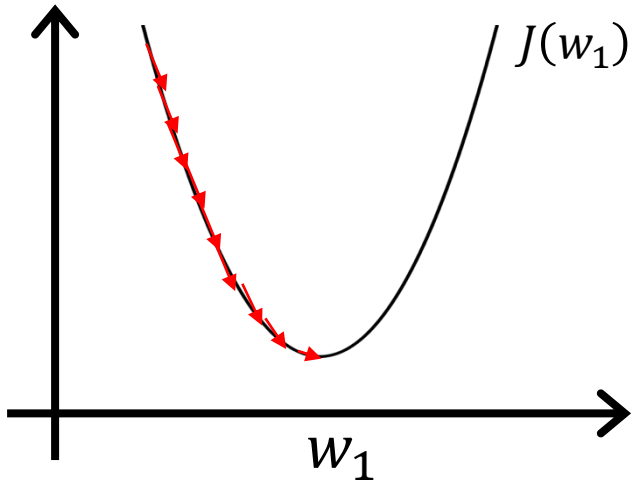
Aprendizaje Supervisado: Gradiente descendiente

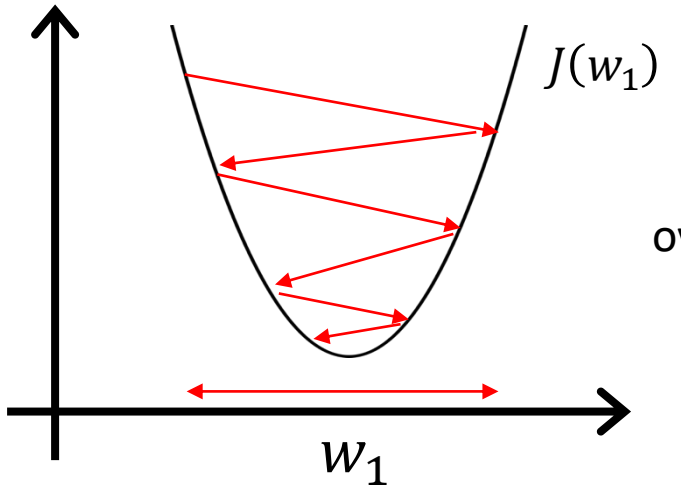
$$w_1 := w_1 - \alpha \frac{\partial}{\partial w_1} J(w_1)$$

velocidad de aprendizaje

- Si α es muy pequeño, GD lento

- Si α es muy grande, GD puede exceder el mínimo; falla la convergencia, o divergir.





overshooting

Algoritmos lineales: Gradiente descendiente

- Regresión lineal de una variable

  $h_w(x) = w_0 + w_1 x$

  Función de error. Por ejemplo: $J(w_0, w_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_w\left(x^{(i)}\right) - y^{(i)} \right)^2$

- Algoritmo Gradiente Descendiente

  Repetir hasta que converja:
  {

  $w_j := w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1)$; ($j$ =0, y j =1 en nuestro ejemplo)

  }

Algoritmos lineales: Gradiente descendiente

Repetir hasta que converja

{

$$w_j := w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1)$$; (j =0, y j =1 en nuestro ejemplo)

}

Reemplazando

$$j = 0: \ \frac{\partial}{\partial w_0} J(w_0, w_1) = \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right)$$

$$j = 1: \ \frac{\partial}{\partial w_1} J(w_0, w_1) = \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right) \cdot X^{(i)}$$

Algoritmos lineales: Gradiente descendiente

Repetir hasta que converja

{

$$w_0 := w_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right)$$

$$w_1 := w_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right) \cdot X^{(i)}$$

}

Actualizar w_0 y w_1 simultáneamente

Aprendizaje Supervisado: LR - Múltiples variables (features)

n

Tamaño pies^2 X_1	Número de dormitorios X_2	Número de pisos X_3	Edad del departamento (meses) X_4	Precio Miles US$ y
210	5	2	45	460
141	3	1	40	232
153	3	2	30	315
85	2	1	36	178
…	…	…	…	…

m

$$X^{(3)} = \begin{bmatrix} 153 \\ 3 \\ 2 \\ 30 \end{bmatrix}$$

$$X_2^{(3)} = 3$$

Donde:

$m = número\ de\ ejemplos$

$n = número\ de\ variables\ (features)$

$X^{(i)} = variables\ de\ entrada\ del\ i^{th}\ ejemplo\ de\ entrenamiento$

$X_j^{(i)} = valor\ de\ la\ variable\ j\ en\ el\ i^{th}\ ejemplo\ de\ entrenamiento$

$y =$ *variable de salida / "target"*

Gradiente descendiente para múltiple variables

Hipótesis: $h_w(x) = w_0\ x_0 + w_1\ x_1 + w_2\ x_2 + \cdots + w_n\, x_n = w^T X$

Parámetros: $w_0 w_1 w_2 \ldots w_n$

Función de costo: $J(w_0, w_1, \ldots, w_n) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right)^2$

Algoritmo Gradiente Descendiente

Repetir hasta que converja

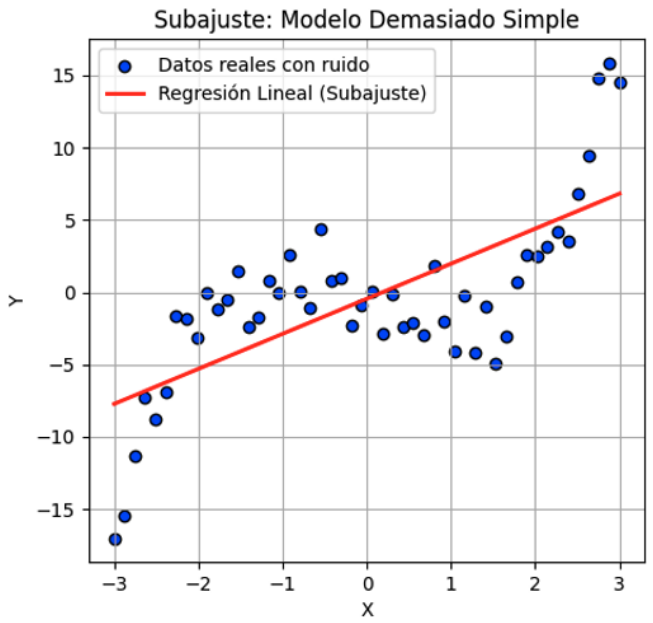
{

$$w_j := w_j - \alpha\ \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right) \cdot x_j^{(i)}$$

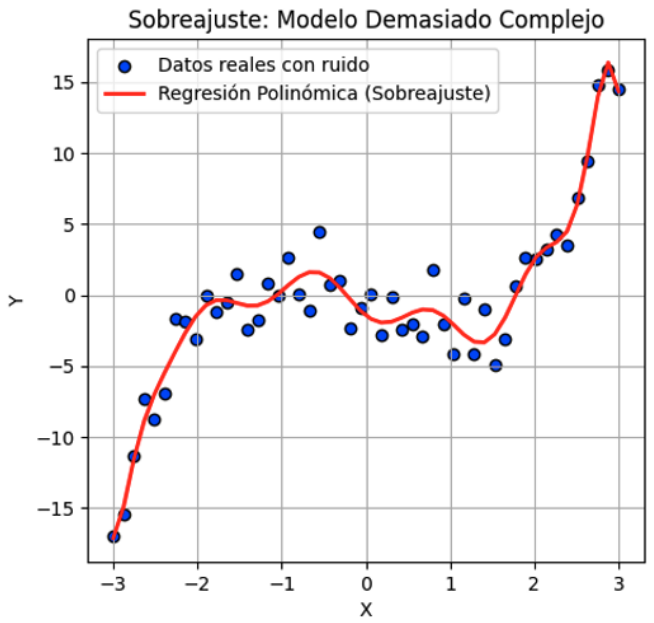
}

Regresión polinómica

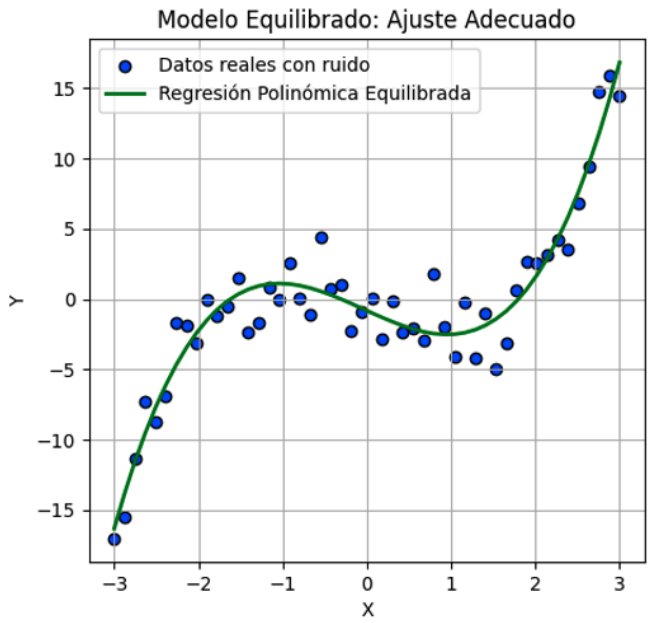
Underfitting



Overfitting



Deseable



Cómo resolver el overfitting

- Opciones:
  - Incrementar el número de ejemplos.
  - Reducir el número de características.
    - Podemos seleccionar manualmente las características que deseamos conservar o a través de reducción de dimensiones, como PCA.
  - Añadir un término de regularización (L1-Lasso, L2-Ridge) a la función de costo.
    - Mantener todas las características, pero reducir la magnitud / valores de los parámetros w_j.
    - Funciona bien cuando tenemos muchas características, y cada una contribuye poco a la predicción.

$$J(W) = \frac{1}{2m}\left[\sum_{i=1}^{m}\left(h_w\left(X^{(i)}\right) - y^{(i)}\right)^2 + \lambda \sum_{j=1}^{n}|w_j|\right]$$

$$J(W) = \frac{1}{2m}\left[\sum_{i=1}^{m}\left(h_w\left(X^{(i)}\right) - y^{(i)}\right)^2 + \lambda \sum_{j=1}^{n} w_j^2\right]$$