Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 6 - PAO 2026 – II

Agenda

1. Ejemplo: Regresión Lineal
2. Regresión Logística
   2.1 Clasificación
   2.2 Regresión Sigmoidal
   2.3 Función de costo
3. Introducción a las Redes Neuronales
   3.1 El Perceptrón

Regresión Lineal - Múltiple variables (features)

- Ejemplo: Supongamos el siguiente data set:

#	x_1	x_2	y
1	4	1	2
2	2	8	-14
3	1	0	1
4	3	2	-1
5	1	4	-7
6	6	7	-8

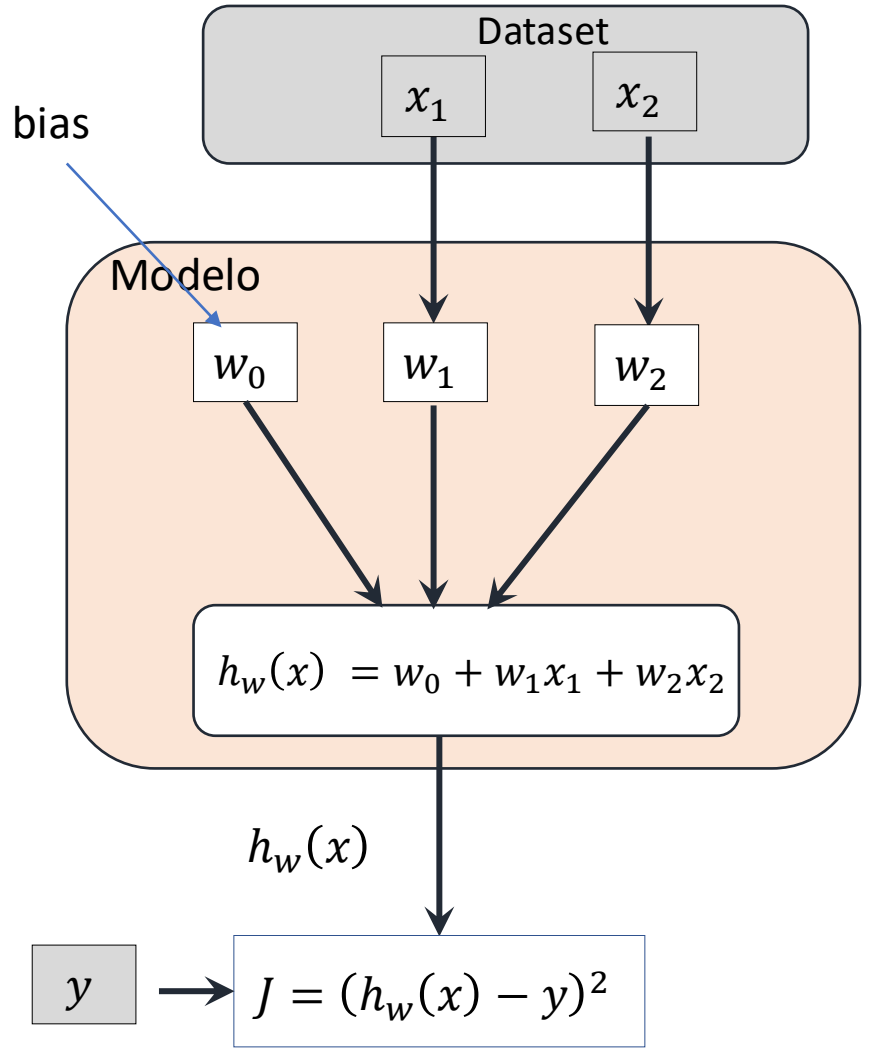
- En este ejemplo la hipótesis sería algo así: $h_w(x) = w_0 + w_1 x_1 + w_2 x_2$

  (w_0 se lo conoce como bias)

- Cómo se actualizan w_0, w_1, y w_2 ?

Regresión Lineal - Múltiple variables (features)

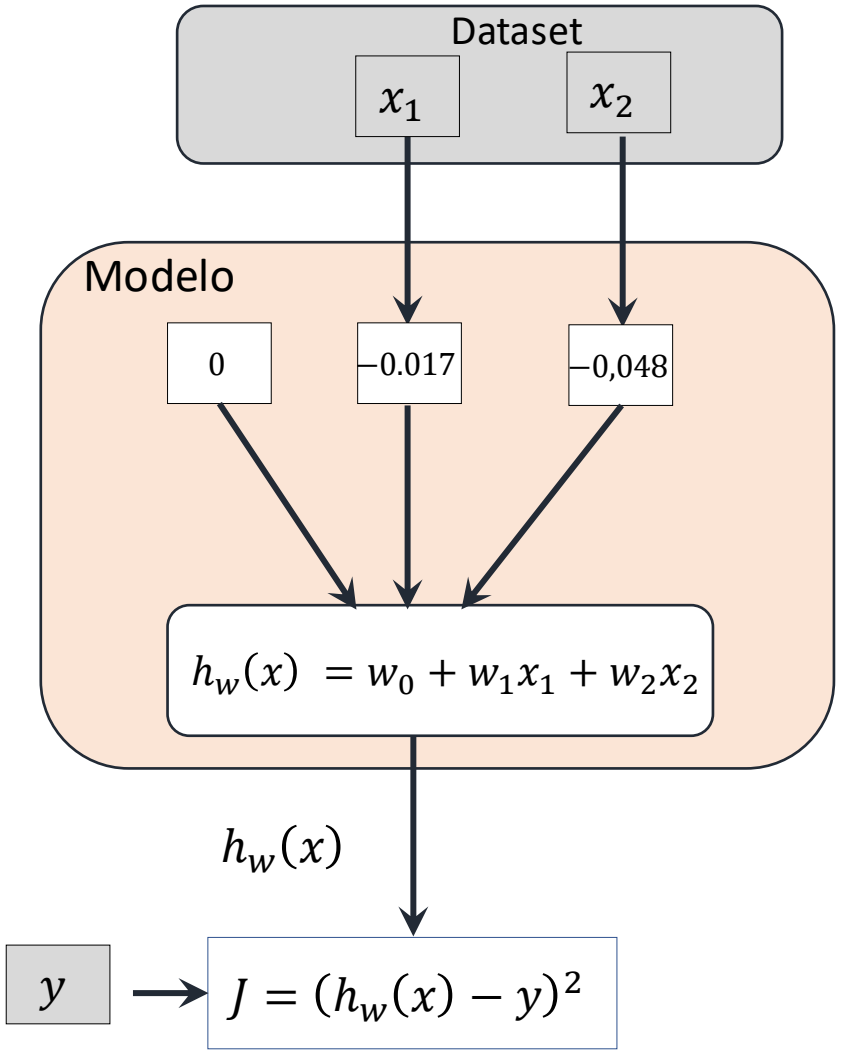
- Para calcular la salida utilizamos propagación hacia adelante (o **forward propagation**, feed forward o forward pass)
- Luego calculamos el error
- Una vez calculado el error tenemos que actualizar los parámetros w utilizando la **regla de aprendizaje**
- Para actualizar los parámetros w, utilizamos propagación hacia atrás (o **back propagation**)
- Durante el entrenamiento la actualización de los parámetros es de forma iterativa



Regresión Lineal - Múltiple variables (features)

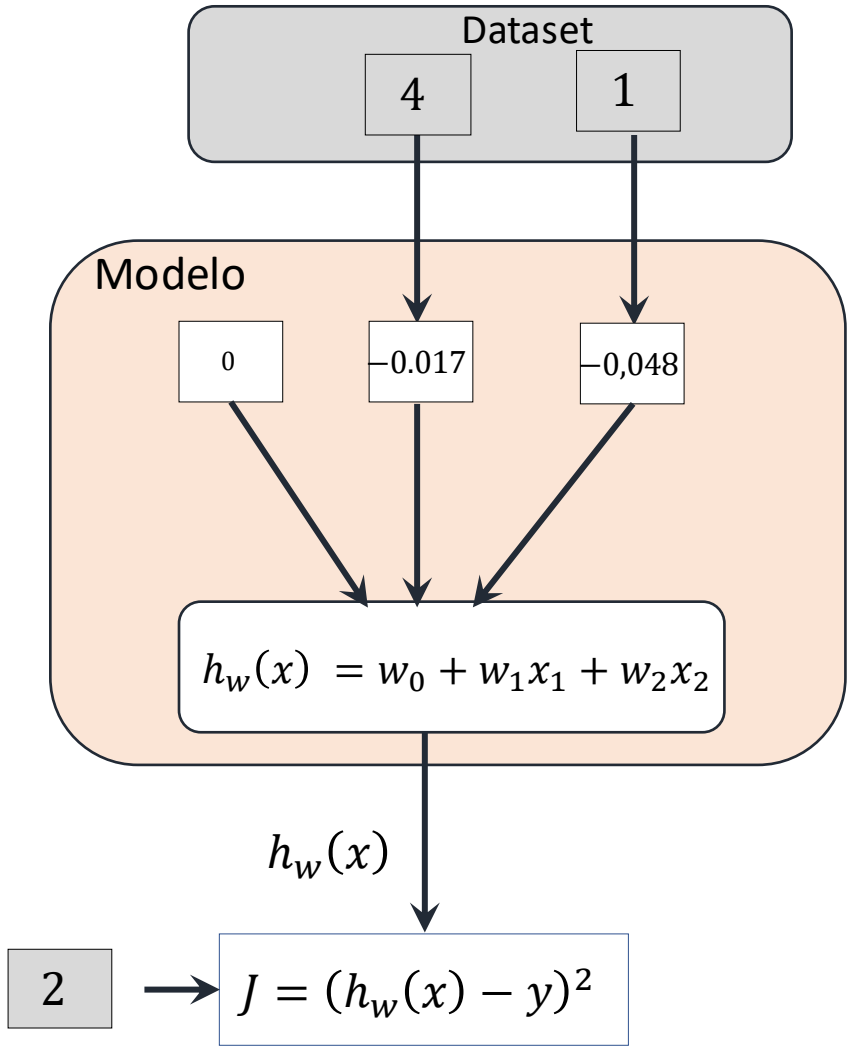
Propagación hacia adelante

- Inicializamos los parámetros o pesos (la primera vez) – el gradiente descendiente trata de actualizar los pesos; por lo tanto, necesitamos que empiece a buscar en algún lugar, estos pesos se conocen como **pesos de inicialización**
- Hay muchas formas de inicializar los pesos (aleatorio, distribución uniforme, distribución normal, distribución normal truncada, etc.)
- Por ejemplo, aleatorio:
  $w_1 = -0.017;\ w_2 = -0.048;\ w_0 = 0$



Regresión Lineal - Múltiple variables (features)

#	x_1	x_2	y
1	4	1	2



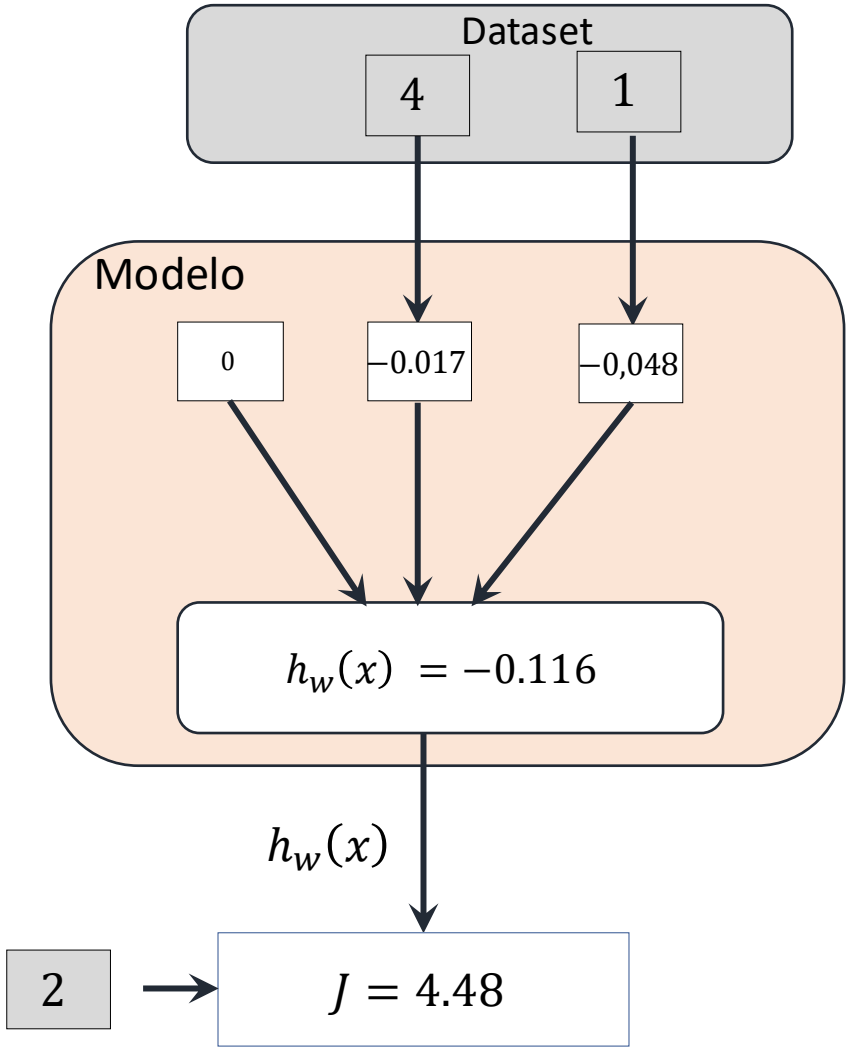
Regresión Lineal - Múltiple variables (features)

Calculamos el error

- ¿Qué tan cerca está $h_w(x)$ del valor real y registrado en el dataset?
- Los comparamos a través de la función de error

$$J = (h_w(x) - y)^2$$
$$= (-0.116 - 2)^2$$
$$= 4.48$$

#	x_1	x_2	y
1	4	1	2

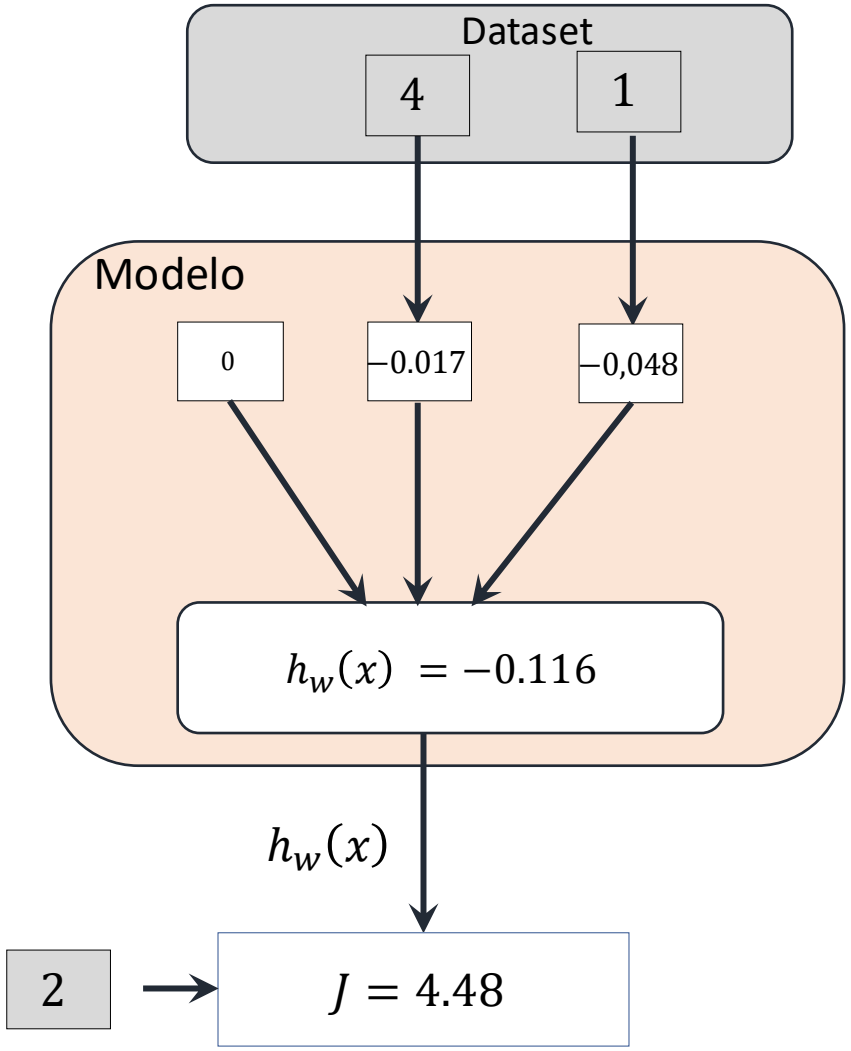


Regresión Lineal - Múltiple variables (features)

Propagación del error hacia atrás (Backpropagation)

- Antes de ajustar los pesos, incluido el bias; es decir, w_1, w_2 y w_0, debemos calcular la magnitud y dirección del error, para eso calculamos todas las derivadas parciales
- Con esos valores hacemos la actualización de los parámetros o pesos (incluido el bias)

$$J = (h_w(x) - y)^2$$
$$h_w(x) = w_0 + w_1 x_1 + w_2 x_2$$



Regresión Lineal - Múltiple variables (features)

- Para actualizar los parámetros w, aplicamos la regla de aprendizaje:

$$w_{j_{nuevo}} = w_{j_{anterior}} - \alpha \frac{\partial J}{\partial w_{j_{anterior}}}$$

$$J = (h_w(x) - y)^2$$
$$h_w(x) = w_0 + w_1 x_1 + w_2 x_2$$

- Donde:

  $w_{j_{nuevo}}$: valor despues de actualizarlo

  $w_{j_{anterior}}$: valor pasado

  α: velocidad de aprendizaje; **asumamos, α = 0.05**

  $\frac{\partial J}{\partial w_j}$: gradiente de w_j; esto es, la derivada parcial de J c.r.a. w_j

- Pero w_j afecta $h_w(x)$, entonces debemos utilizar la regla de la cadena para calcular dicho gradiente:

$$\frac{\partial J}{\partial w_j} = \frac{\partial J}{\partial h_w(x)} \cdot \frac{\partial h_w(x)}{\partial w_j}$$

Regresión Lineal - Múltiple variables (features)

Calculo de las derivadas

Si: $h_w(x) = w_0 + w_1 x_1 + w_2 x_2$

Y: $J = (h_w(x) - y)^2$

1. Derivada parcial de J, c.r.a. $h_w(x)$

$$\frac{\partial J}{\partial h_w(x)} = 2(h_w(x) - y)$$

2. Derivada parcial de $h_w(x)$, c.r.a. w_0

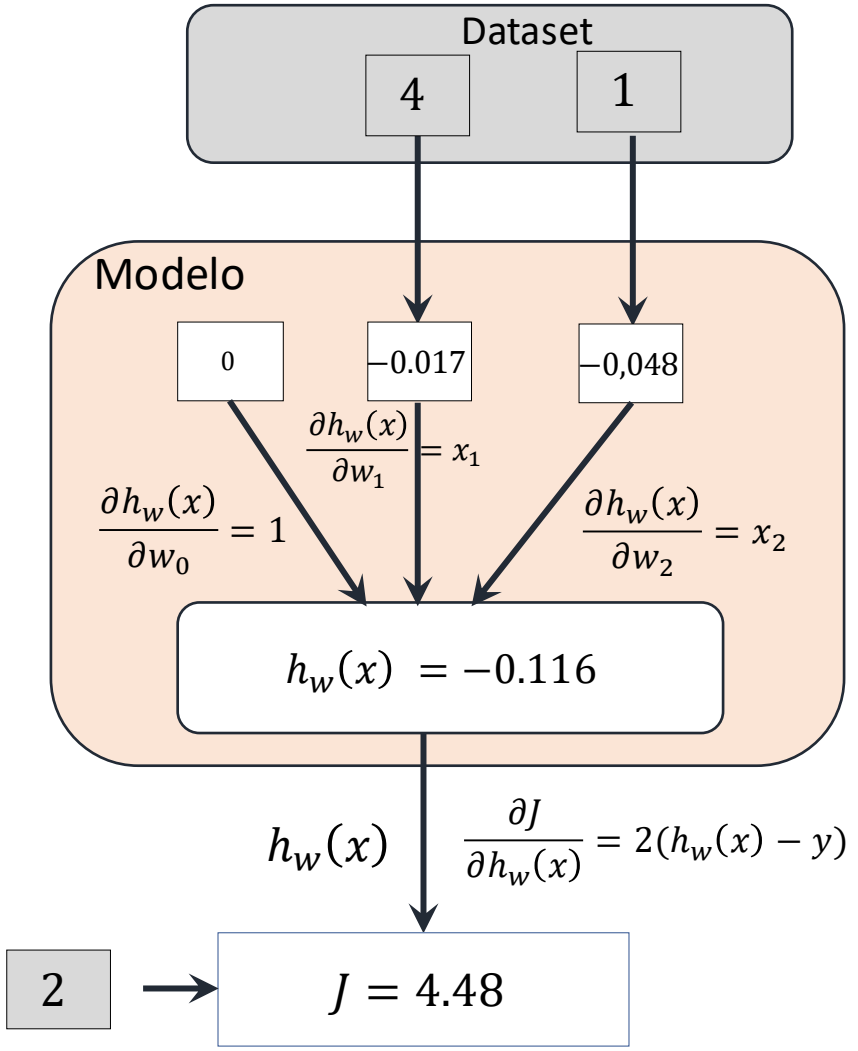
$$\frac{\partial h_w(x)}{\partial w_0} = 1$$

3. Derivada parcial de $h_w(x)$, c.r.a. w_1

$$\frac{\partial h_w(x)}{\partial w_1} = x_1$$

4. Derivada parcial de $h_w(x)$, c.r.a. w_2

$$\frac{\partial h_w(x)}{\partial w_2} = x_2$$



Regresión Lineal - Múltiple variables (features)

- $\frac{\partial J}{\partial h_w(x)} = 2(h_w(x) - y);\ \frac{\partial h_w(x)}{\partial w_0} = 1;\ \frac{\partial h_w(x)}{\partial w_1} = x_1;\ \frac{\partial h_w(x)}{\partial w_2} = x_2$
- $x_1 = 4;\ x_2 = 1;\ y = 2;\ h_w(x) = -0.116; w_0 = 0.0; \alpha = 0.05$
- $w_{0_{nuevo}} = w_{0_{anterior}} - \alpha \frac{\partial J}{\partial w_{0_{anterior}}}$

$$= w_{0_{anterior}} - \alpha \left(\frac{\partial J}{\partial h_w(x)} \cdot \frac{\partial h_w(x)}{\partial w_0} \right)$$

$$= w_{0_{anterior}} - \alpha [2(h_w(x) - y) \cdot 1]$$

$$= 0.0 - 0.05[2(-0.116 - 2) \cdot 1]$$

$$= 0.212$$

Regresión Lineal - Múltiple variables (features)

- La actualización w_1 es:

- $$w_{1nuevo} = w_{1anterior} - \alpha \frac{\partial J}{\partial w_{1anterior}}$$

$$= w_{1anterior} - \alpha \left(\frac{\partial J}{\partial h_w(x)} \cdot \frac{\partial h_w(x)}{\partial w_1} \right)$$

$$= w_{1anterior} - \alpha [2(h_w(x) - y) \cdot x_1]$$

$$= -0.017 - 0.05[2(-0.116 - 2) \cdot 4]$$

$$= 0.829$$

Regresión Lineal - Múltiple variables (features)

- La actualización w_2 es:
- $$w_{2nuevo} = w_{2anterior} - \alpha \frac{\partial J}{\partial w_{2anterior}}$$

$$= w_{2anterior} - \alpha \left(\frac{\partial j}{\partial h_w(x)} \cdot \frac{\partial h_w(x)}{\partial w_2} \right)$$

$$= w_{2anterior} - \alpha [2(h_w(x) - y) \cdot x_2]$$

$$= -0.048 - 0.05[2(-0.116 - 2) \cdot 1]$$

$$= 0.164$$

- Fin del primer mini-batch !.
- **Época** es cuando el modelo ha visto a TODOS los ejemplos del conjunto de datos una vez
- Una época **nunca** es suficiente para que el error converja

Regresión Lineal - Múltiple variables (features)

- El entrenamiento continúa con los siguientes 5 batches

#	x_1	x_2	y
1	4	1	2
2	2	8	-14
3	1	0	1
4	3	2	-1
5	1	4	-7
6	6	7	-8

- Al final el algoritmo encuentra un modelo que luce así:

$$h_w(x) = 3.467 + 9.187x_1 - 2{,}808x_2$$

- Luego de entrenar con todos los (6) mini-batches, el modelo observó todos los ejemplos, es decir una época

Regresión logística: Clasificación

- En RLineal, vimos que: $h_w(x)$ podía predecir valores > 0 o < 0
- Necesitamos un modelo que clasifique: $y = 0$ o $y = 1$
- Una función que pueda predecir valores $0 \leq h_w\ (x) \leq 1$, independientemente del valor x
- Una función que se comporta de esa forma es: La función “Logística”

$$g(z) = \frac{1}{1 + e^{-z}}$$

- De ahí el nombre: Regresión Logística



Clasificación

Regresión logística: Representación de la hipótesis

Modelo de Regresión Logística

Deseamos: $0 \leq h_w\ (x) \leq 1$

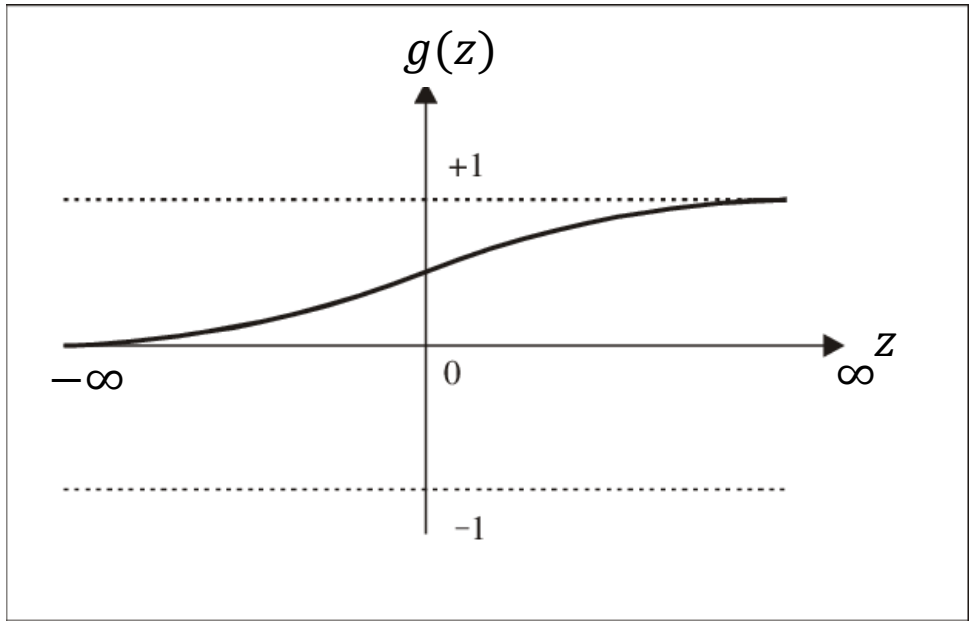
$$g(z) = \frac{1}{1 + e^{-z}}$$

$$z = w^T x$$

Recordar: $h_w(x) = w^T X$

$$h_w(x) = g(w^T x)$$

$$h_w(x) = \frac{1}{1 + e^{-w^T x}}$$



Función Sigmoidal
Función Logística

Regresión logística

Datos de entrenamiento: $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \cdots, (x^{(m)}, y^{(m)})\}$

m ejemplos: $x \in \begin{bmatrix} x_0 \\ x_1 \\ \cdots \\ x_n \end{bmatrix} \mathbb{R}^{n+1}$, $x_0 = 1, y \in \{0, 1\}$

$$h_w(x) = \frac{1}{1 + e^{-w^T x}}$$

Cómo escoger los parámetros w?

Regresión logística: Función de costo

$$J(W) = \frac{1}{m}\sum_{i=1}^{m} Costo\left(h_w\left(x^{(i)}\right), y^{(i)}\right)$$

$$Costo(h_w(x), y) = \begin{cases} -\log(h_w(x)) & Si\ y = 1 \\ -\log(1 - h_w(x)) & Si\ y = 0 \end{cases}$$

En forma simplificada

$$Costo(h_w(x), y) = -ylog\left(h_w(x)\right) - (1 - \mathrm{y})\log(1 - h_w(x))$$

En forma extendida

Notar que $y = 0\ o\ 1$, siempre

Si $y = 1$: $Costo(h_w(x), y) = -log\left(h_w(x)\right)$
Si $y = 0$: $Costo(h_w(x), y) = -\log(1 - h_w(x))$

Regresión logística: Gradiente descendiente

$$J(W) = -\frac{1}{m}\sum_{i=1}^{m} y^{(i)} \log h_w\left(x^{(i)}\right) + \left(1 - y^{(i)}\right) \log\left(1 - h_w\left(x^{(i)}\right)\right)$$

Deseamos: $\min_w J(W)$

Repetir hasta que converja

{

$$w_j := w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1, \dots, w_n)$$

}