Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

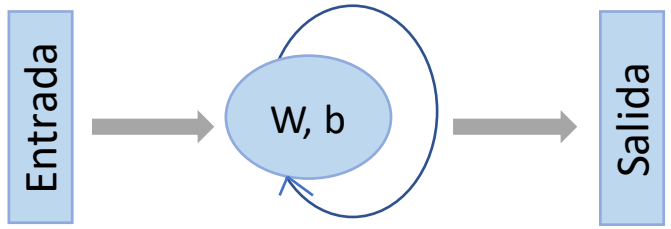
Clase # 15 - PAO 2026 – II

Agenda

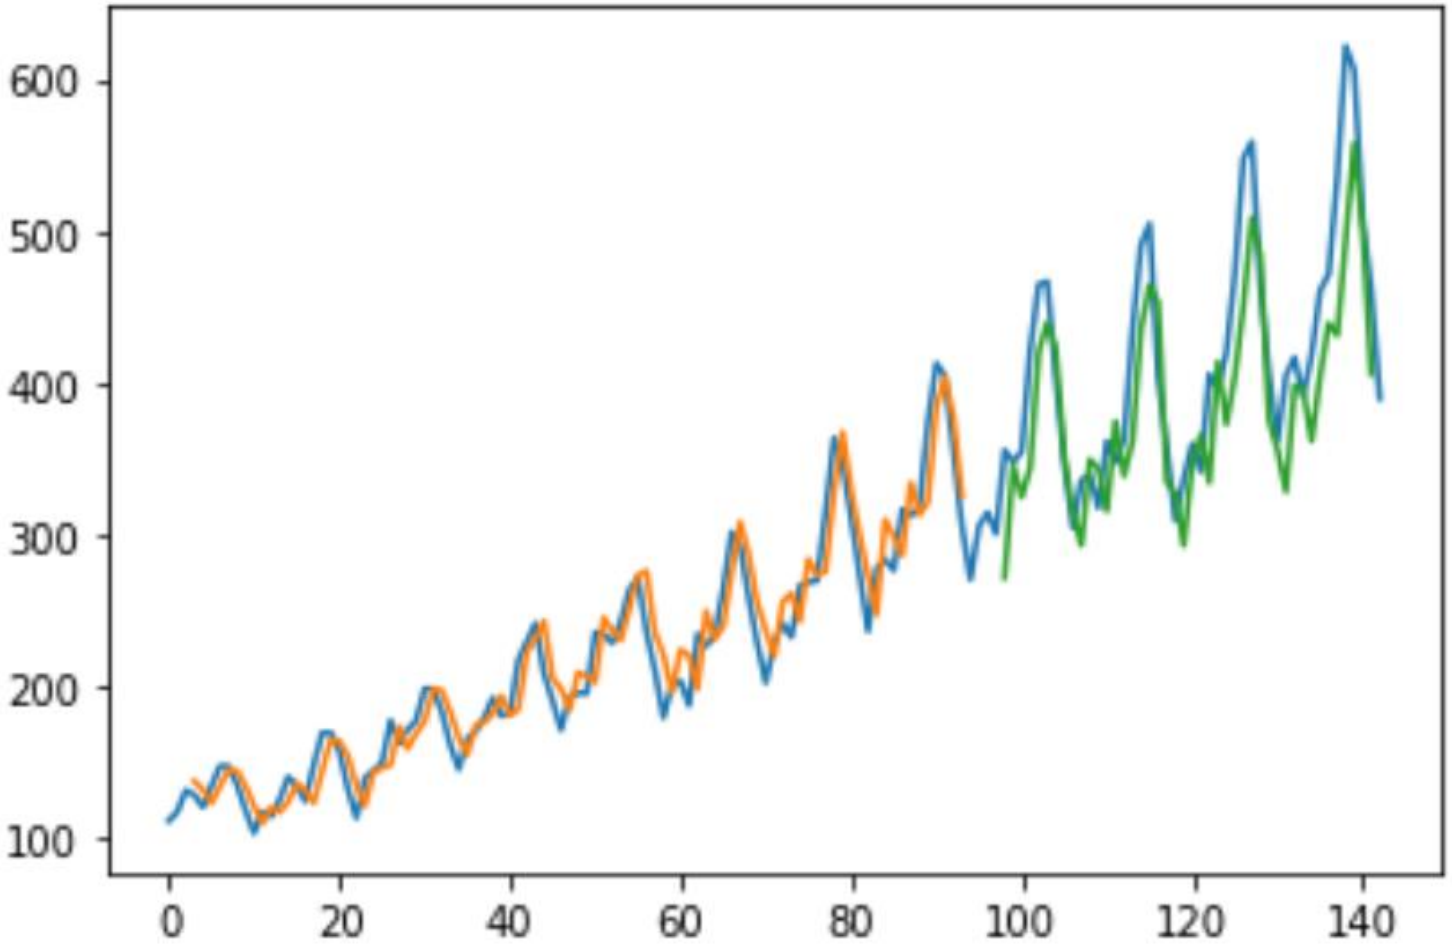
1. Revisión del examen
2. Dónde estamos?
3. Redes Neuronales Recurrentes – RNN
   - 3.1 Qué son cómo funcionan
   - 3.2 Modelo estado – estado
   - 3.3 Arquitecturas de las RNN
   - 3.4 Introducción a NLP
     - Embeddings
     - Ejemplo

Redes neuronales recurrentes

- Es otro tipo de red neuronal que está dominando la solución de problemas, en los que existe secuencias en los datos.
- Estas redes tienen capas con conexiones en forma de lazos, que agregan retroalimentación y memoria a las capas de la red, a lo largo del tiempo.
- Esa memoria permite a este tipo de redes aprender y generalizar a través de secuencias en la entrada, en lugar de patrones individuales.

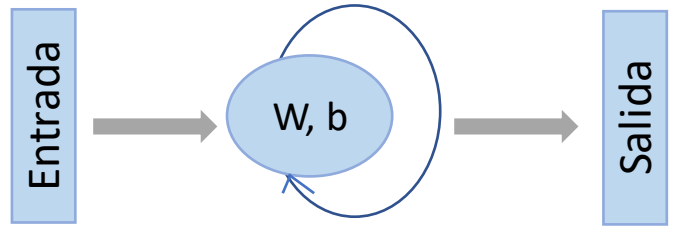


Redes neuronales recurrentes

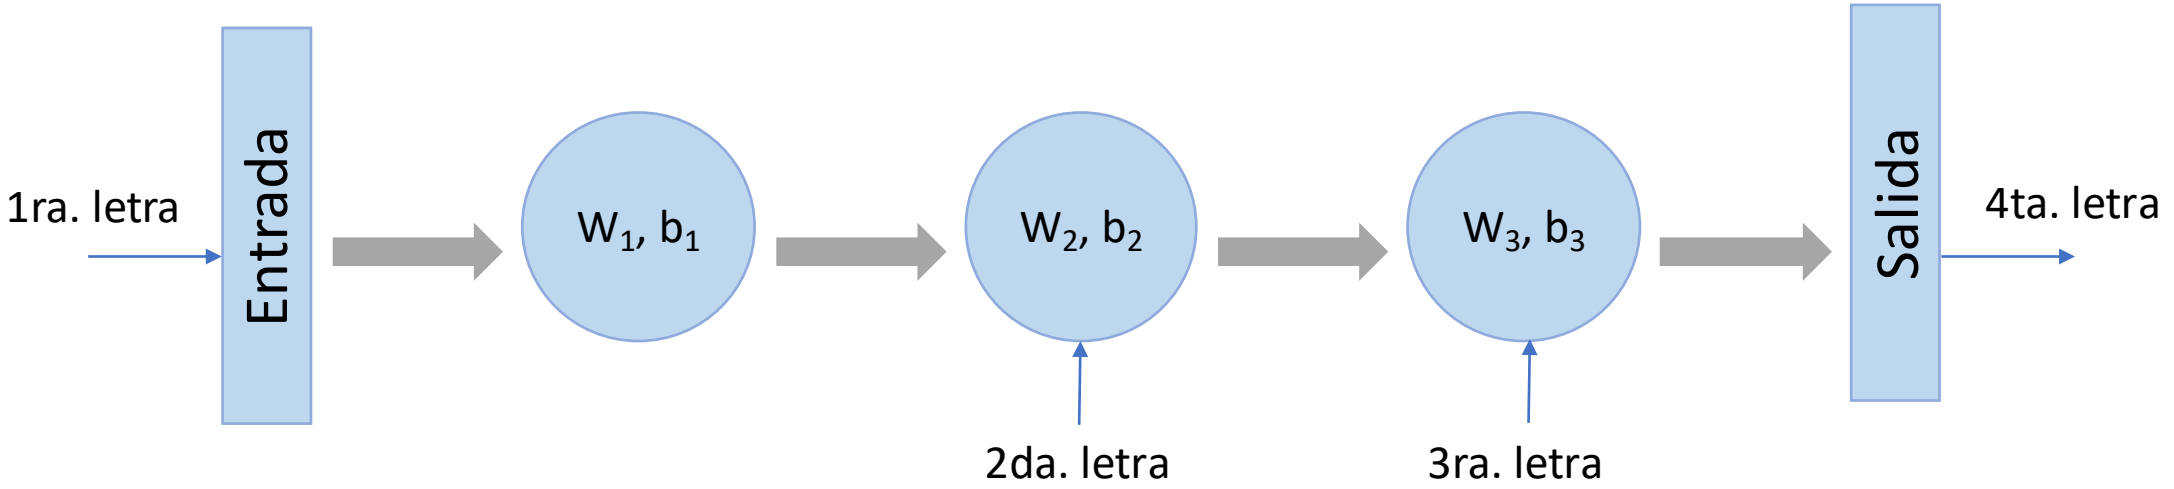


- Los patrones están, no solo en los datos de las señales, pero también en la secuencia de esas señales

Redes neuronales recurrentes



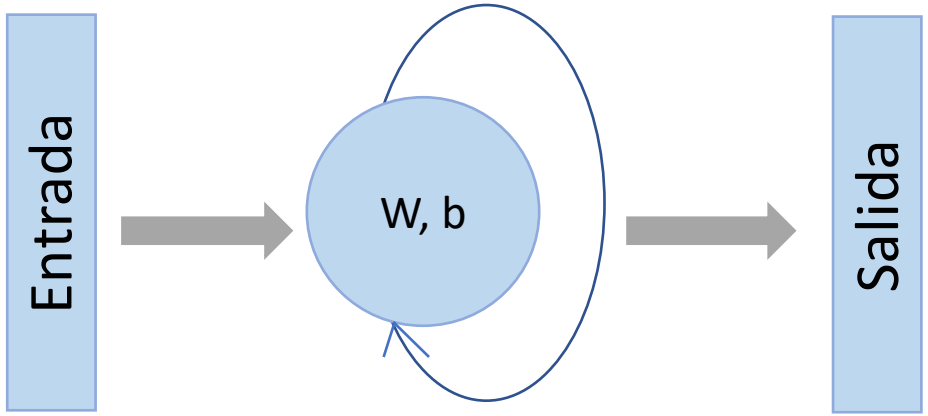
- Cómo funcionan?, por ejemplo en NLP:



- En las RR los pesos y bias de cada capa oculta ya no son independientes.
- Para preservar la memoria, es necesario que los pesos y bias prevalezcan en todas las capas.

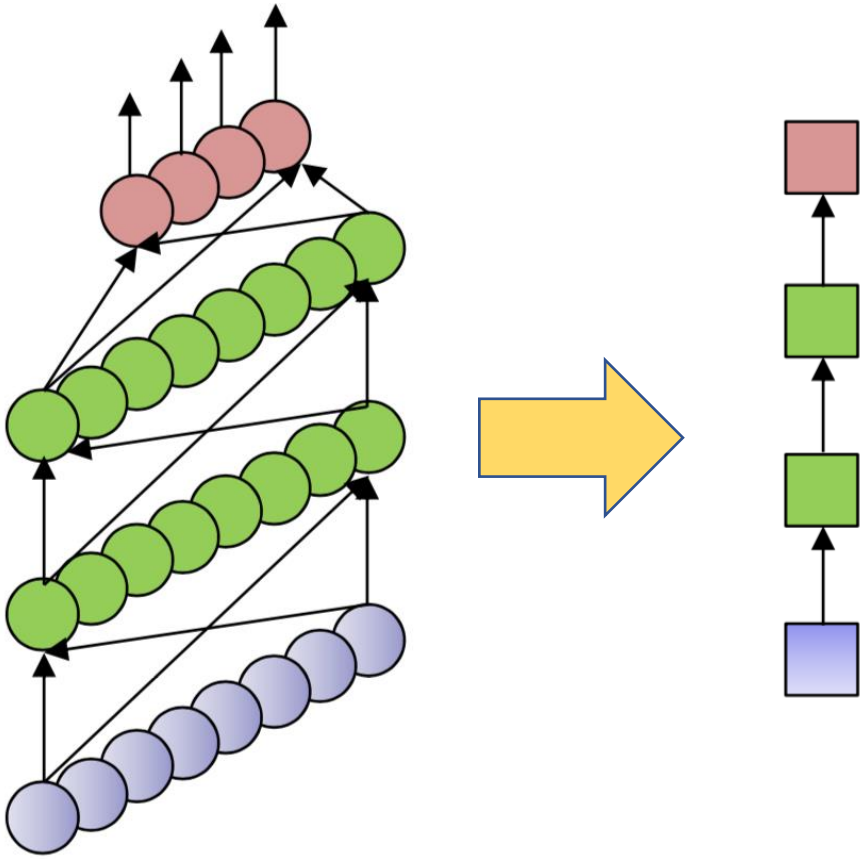
Redes neuronales recurrentes

- Así, es como se proporciona las entradas directamente a las capas ocultas.
- En cada paso, los pesos de la neurona recurrente reflejan la historia acumulada.
- La neurona recurrente almacena el estado de la entrada anterior y se combina con la entrada actual, preservando así la relación de las entradas.



Redes neuronales recurrentes

- En realidad, algo así:



- La entrada en cada momento es un vector.
- Cada capa tiene muchas neuronas:
  - La capa de salida también puede tener muchas neuronas.
- Cada capa de la NN la estamos representando con cajas.
  - Cada caja en realidad representa una capa entera con muchas unidades.

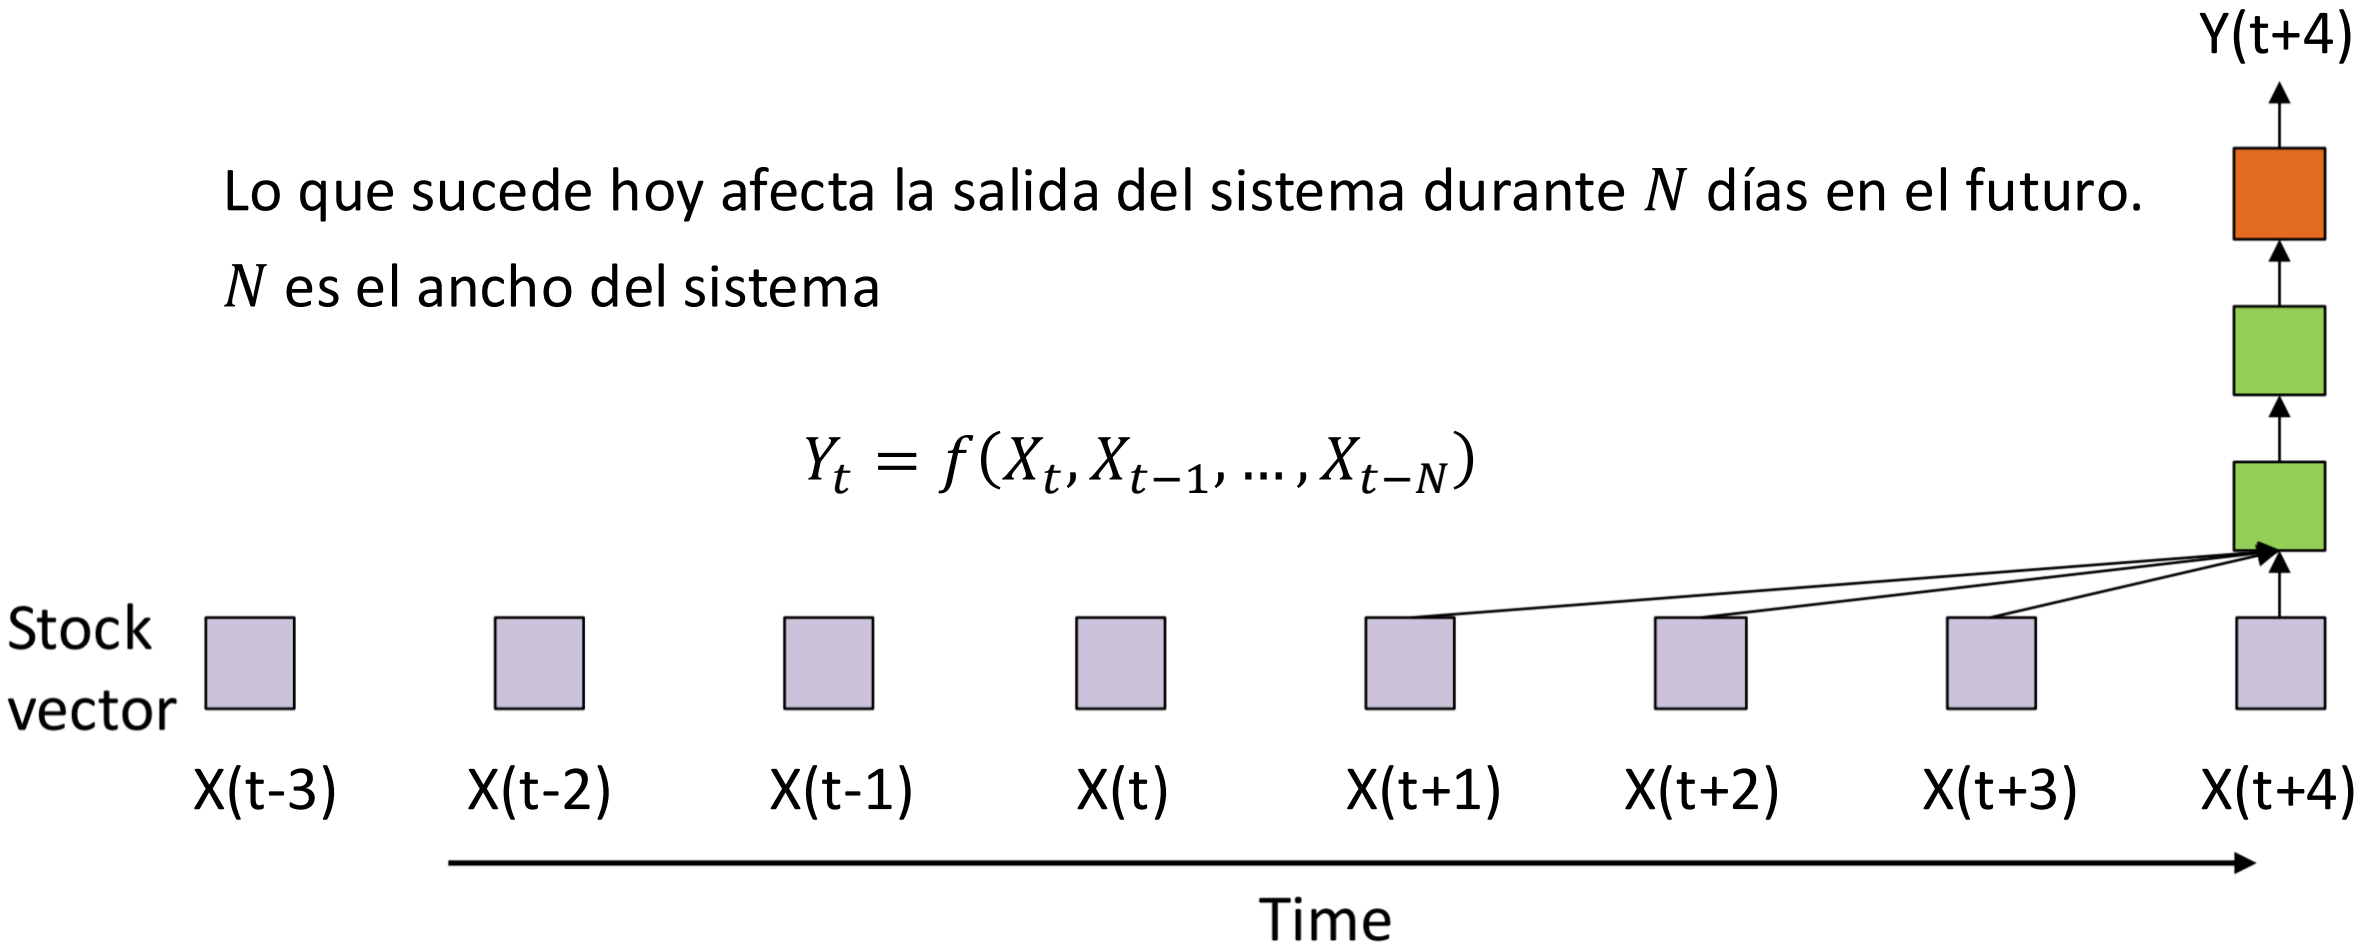
Redes neuronales recurrentes

- Por ejemplo, un predictor de valores de las acciones en la bolsa de valores

Lo que sucede hoy afecta la salida del sistema durante N días en el futuro.

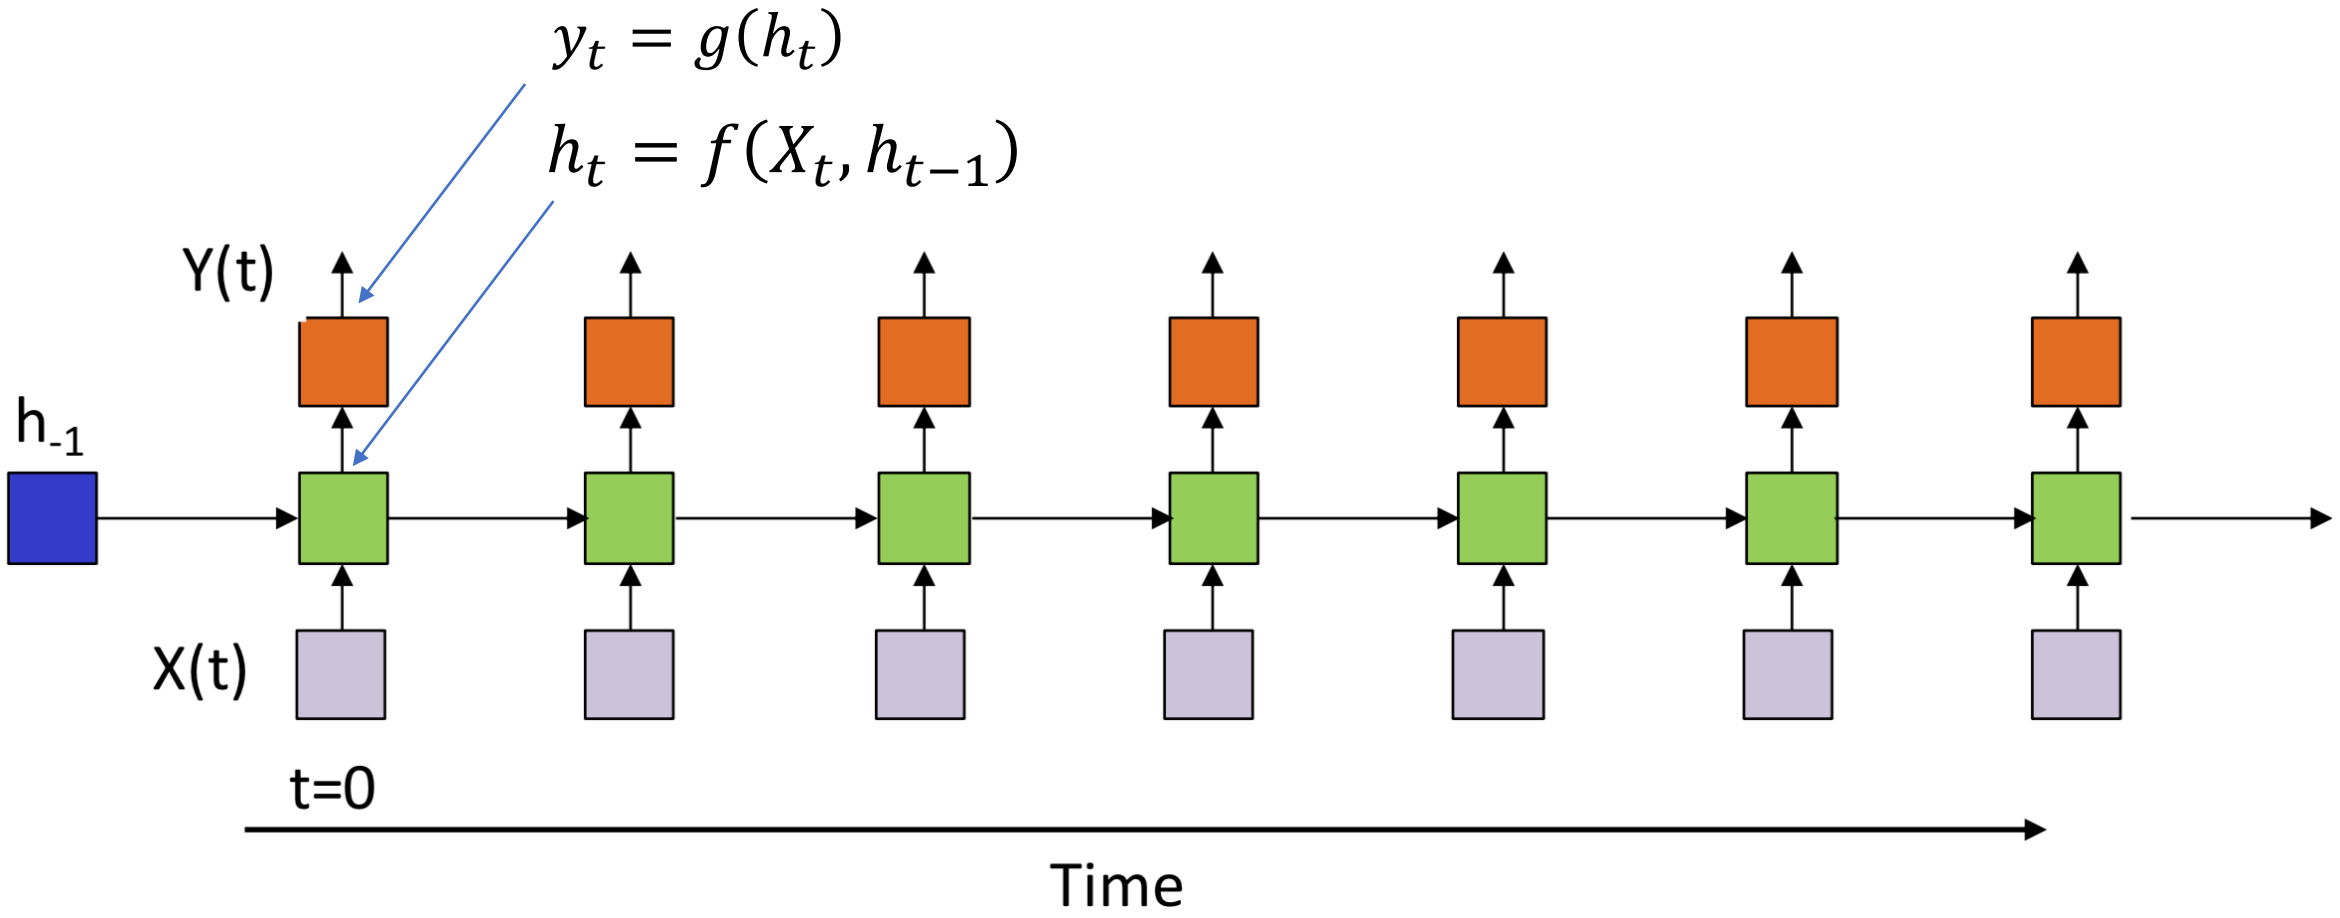
N es el ancho del sistema

$$Y_t = f(X_t, X_{t-1}, \dots, X_{t-N})$$



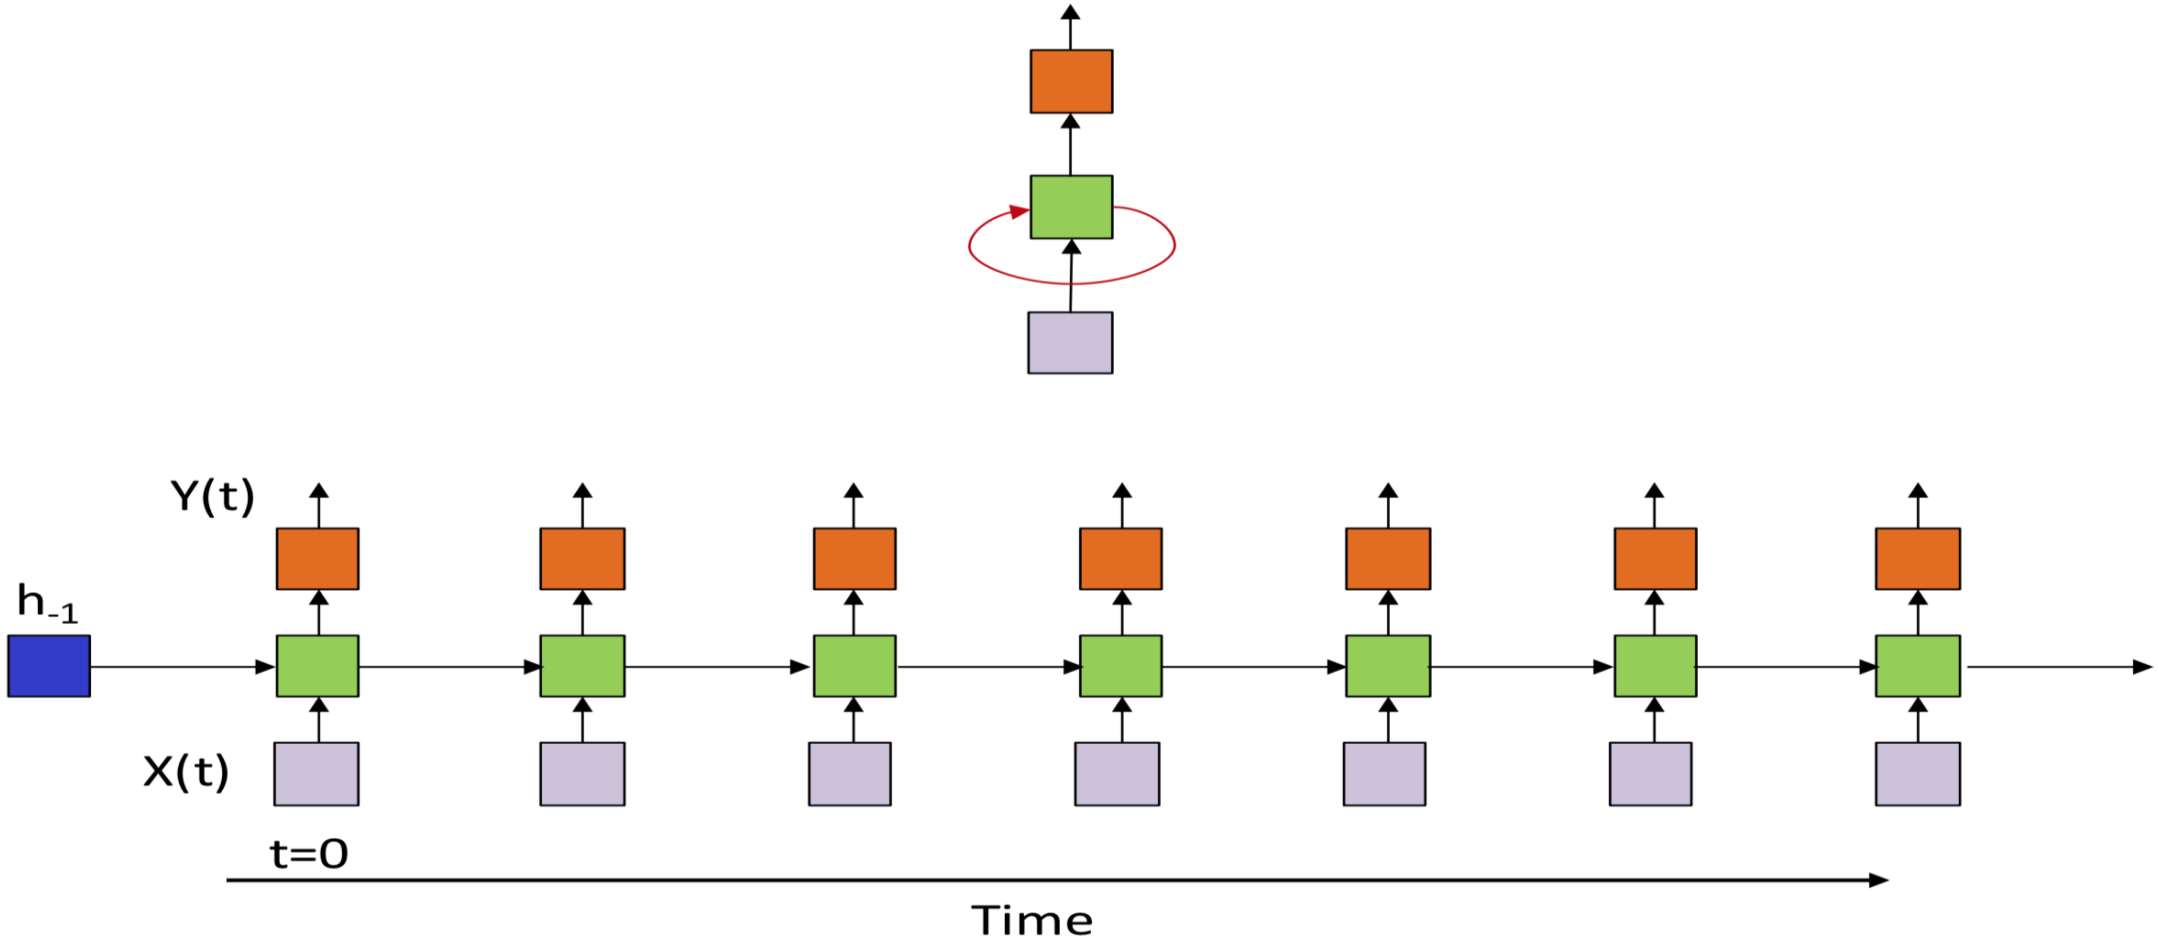
Redes neuronales recurrentes

- El modelo simple *estado-estado*



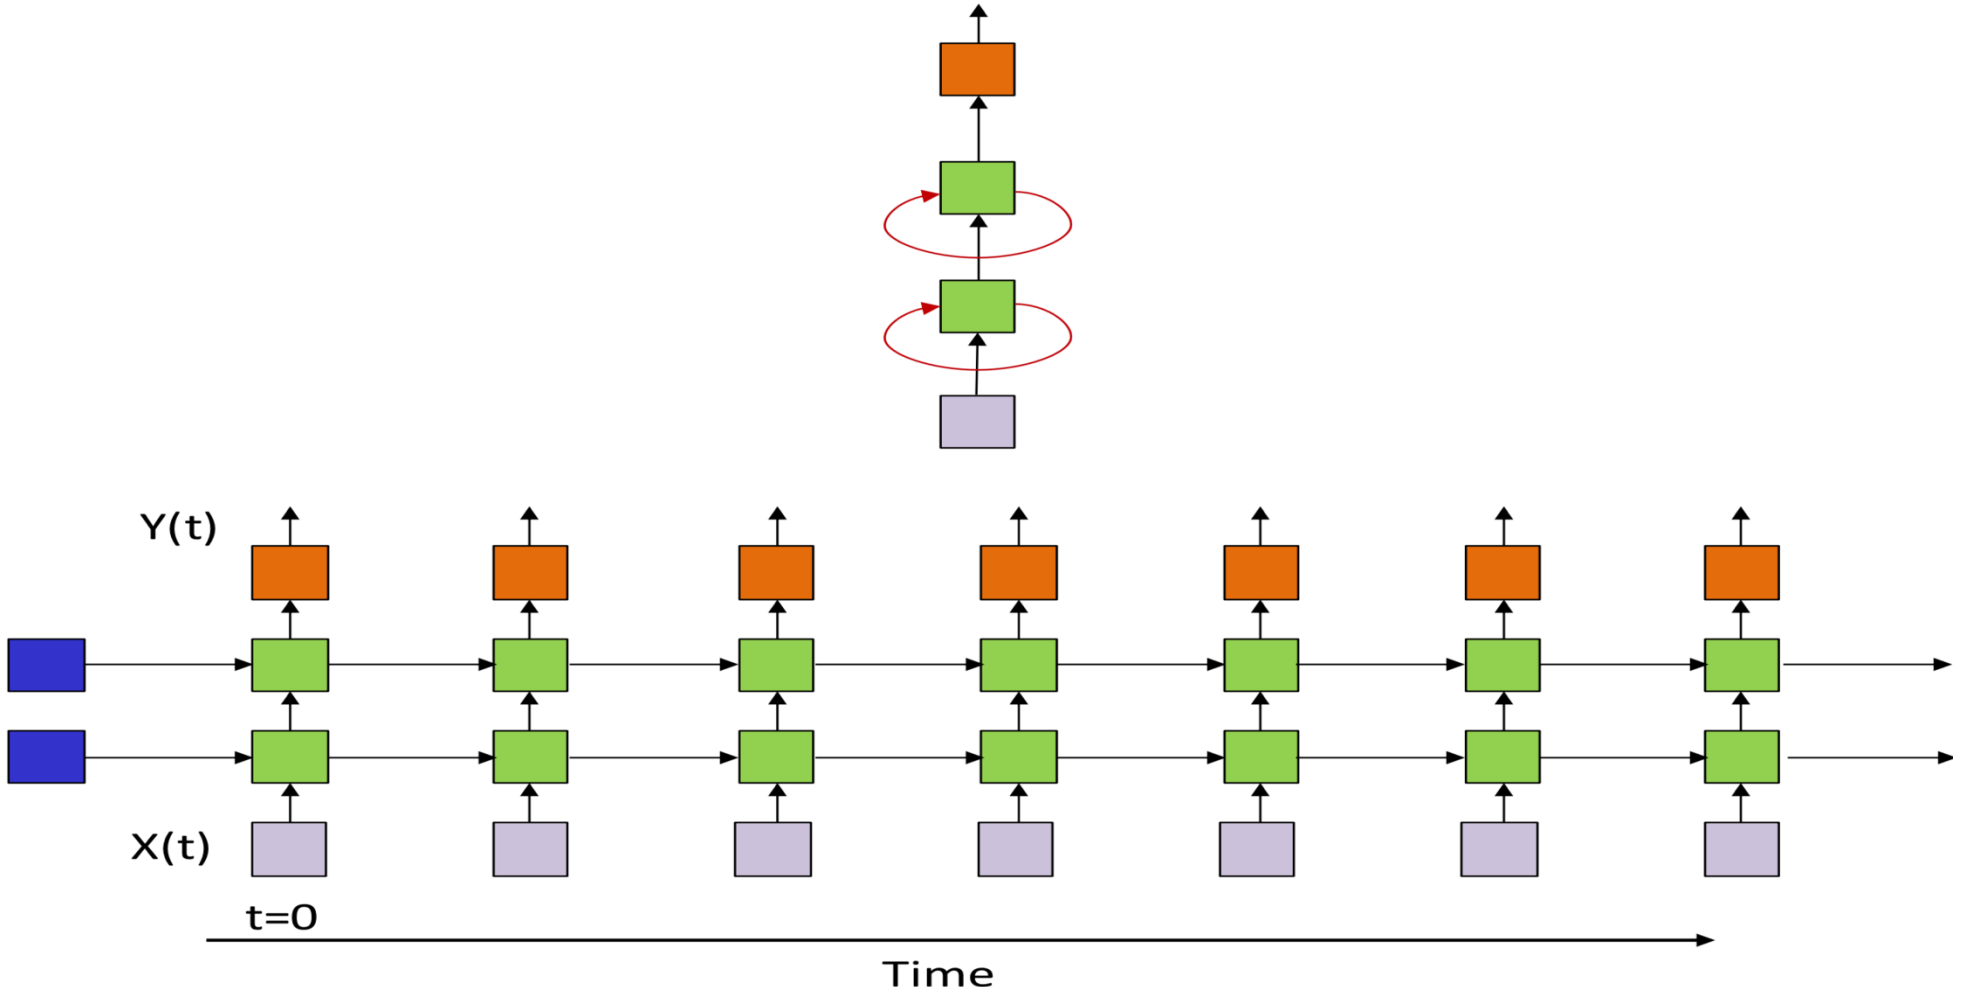
Redes neuronales recurrentes

- Representación simplificada: Una capa escondida



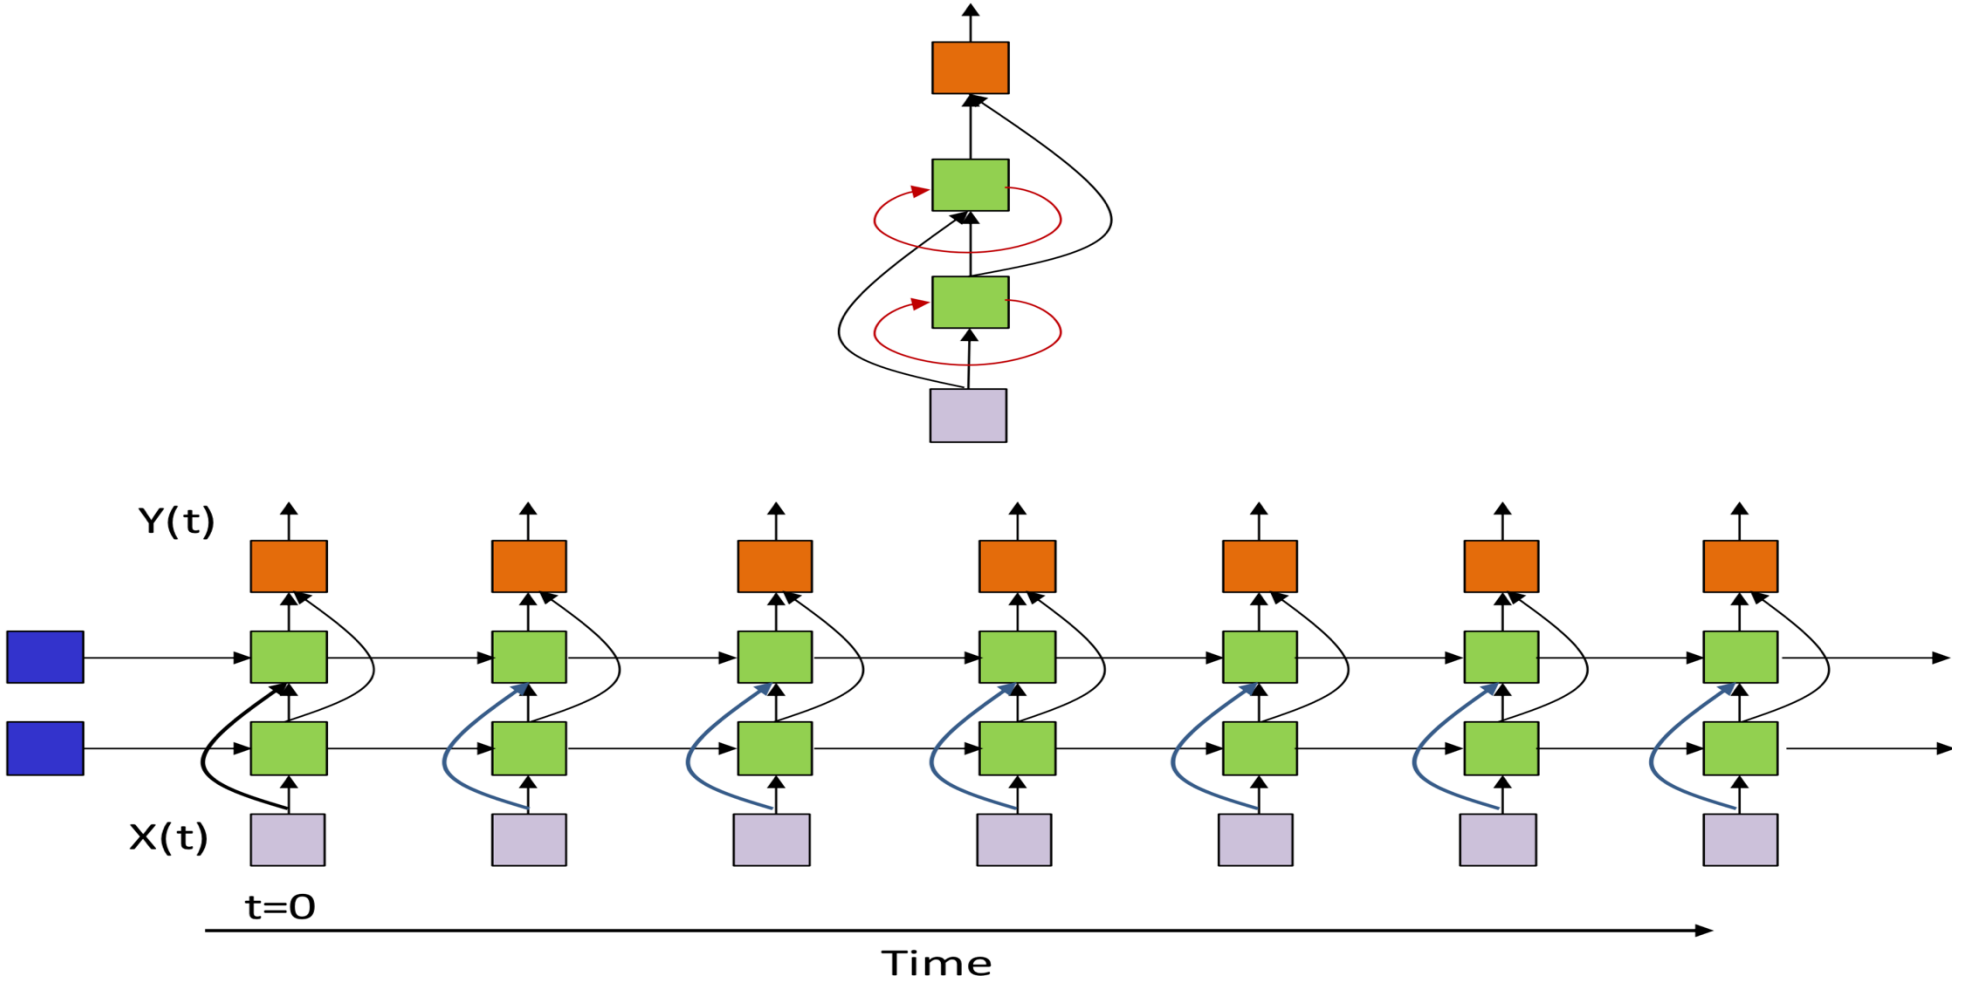
Redes neuronales recurrentes

- Representación simplificada: Multi capa escondida



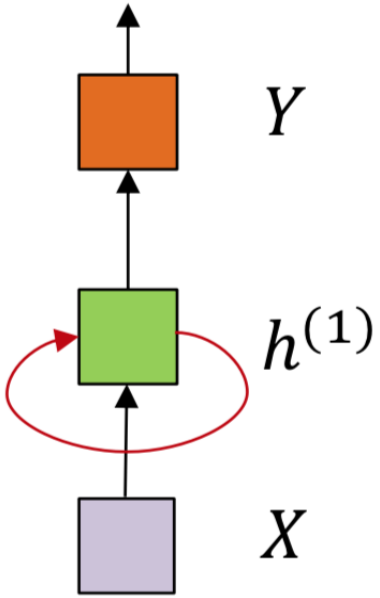
Redes neuronales recurrentes

- Representación simplificada: Multi capa escondida con skip



Redes neuronales recurrentes

- Ecuaciones:



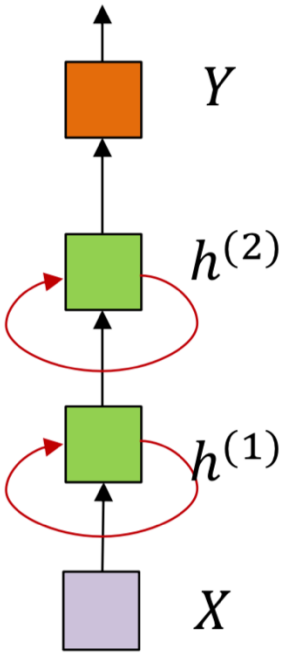
$$Y(t) = f_2\left(\sum_j w_{jk}^{(12)} h_j^{(1)}(t) + b_k^{(1)}, k = 1 \dots M\right)$$

$$h_i^{(1)}(t) = f_1\left(\sum_j w_{ji}^{(01)} X_j(t) + \sum_j w_{ji}^{(11)} h_i^{(1)}(t-1) + b_i^{(1)}\right)$$

- Notar que el superscript indica la capa de la red desde donde proviene la entrada
- Asumiendo la función de salida $f_2()$ - Softmax
- La función de activación en los nodos de la capa escondida $f_1()$ generalmente es *tanh()*
- Recordar cada neurona también tiene como entrada un *bias*

Redes neuronales recurrentes

- Ecuaciones:



$$Y(t) = f_3\left(\sum_j w_{jk}^{(23)} h_j^{(2)}(t) + b_k^{(3)}, k = 1 \dots M\right)$$

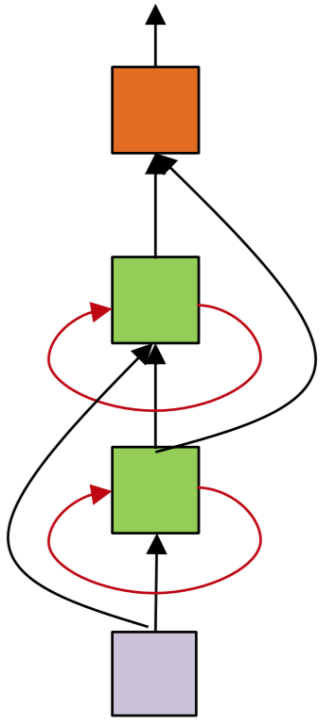
$$h_i^{(2)}(t) = f_2\left(\sum_j w_{ji}^{(12)} h_j^{(1)}(t) + \sum_j w_{ji}^{(22)} h_i^{(2)}(t-1) + b_i^{(2)}\right)$$

$$h_i^{(1)}(t) = f_1\left(\sum_j w_{ji}^{(01)} X_j(t) + \sum_j w_{ji}^{(11)} h_i^{(1)}(t-1) + b_i^{(1)}\right)$$

- Asumiendo la función de salida $f_3()$ - Softmax
- La función de activación en los nodos de la capa escondida $f_k()$ generalmente es *tanh()*
- Recordar cada neurona también tiene como entrada un *bias*

Redes neuronales recurrentes

- Ecuaciones:



$$Y(t) = f_3\left(\sum_j w_{jk}^{(23)} h_j^{(2)}(t) + \sum_j w_{ji}^{(13)} h_i^{(1)}(t) + b_k^{(3)}, k = 1 \dots M\right)$$

$$h_i^{(2)}(t) = f_2\left(\sum_j w_{ji}^{(12)} h_j^{(1)}(t) + \sum_j w_{ji}^{(02)} X_j(t) + \sum_j w_{ji}^{(22)} h_i^{(2)}(t-1) + b_i^{(2)}\right)$$

$$h_i^{(1)}(t) = f_1\left(\sum_j w_{ji}^{(01)} X_j(t) + \sum_j w_{ji}^{(11)} h_i^{(1)}(t-1) + b_i^{(1)}\right)$$

Redes neuronales recurrentes

Modelado del lenguaje

- La base del modelamiento de lenguaje se denomina *n-gran.*
- Un *n-gram* es un conjunto de *n* palabras consecutivas.
- Por ejemplo, en la oración: "Estoy escribiendo un ...", tendríamos los siguientes tipos de *n-grams*:
  - unigrams: ”Estoy", "escribiendo", ”un”.
  - bigrams: "Estoy escribiendo", "escribiendo un”, "un …”
  - trigramas: "Estoy escribiendo un”, "escribiendo un …”
  - 4-grams: "Estoy escribiendo un reporte …”

Redes neuronales recurrentes: Embeddings



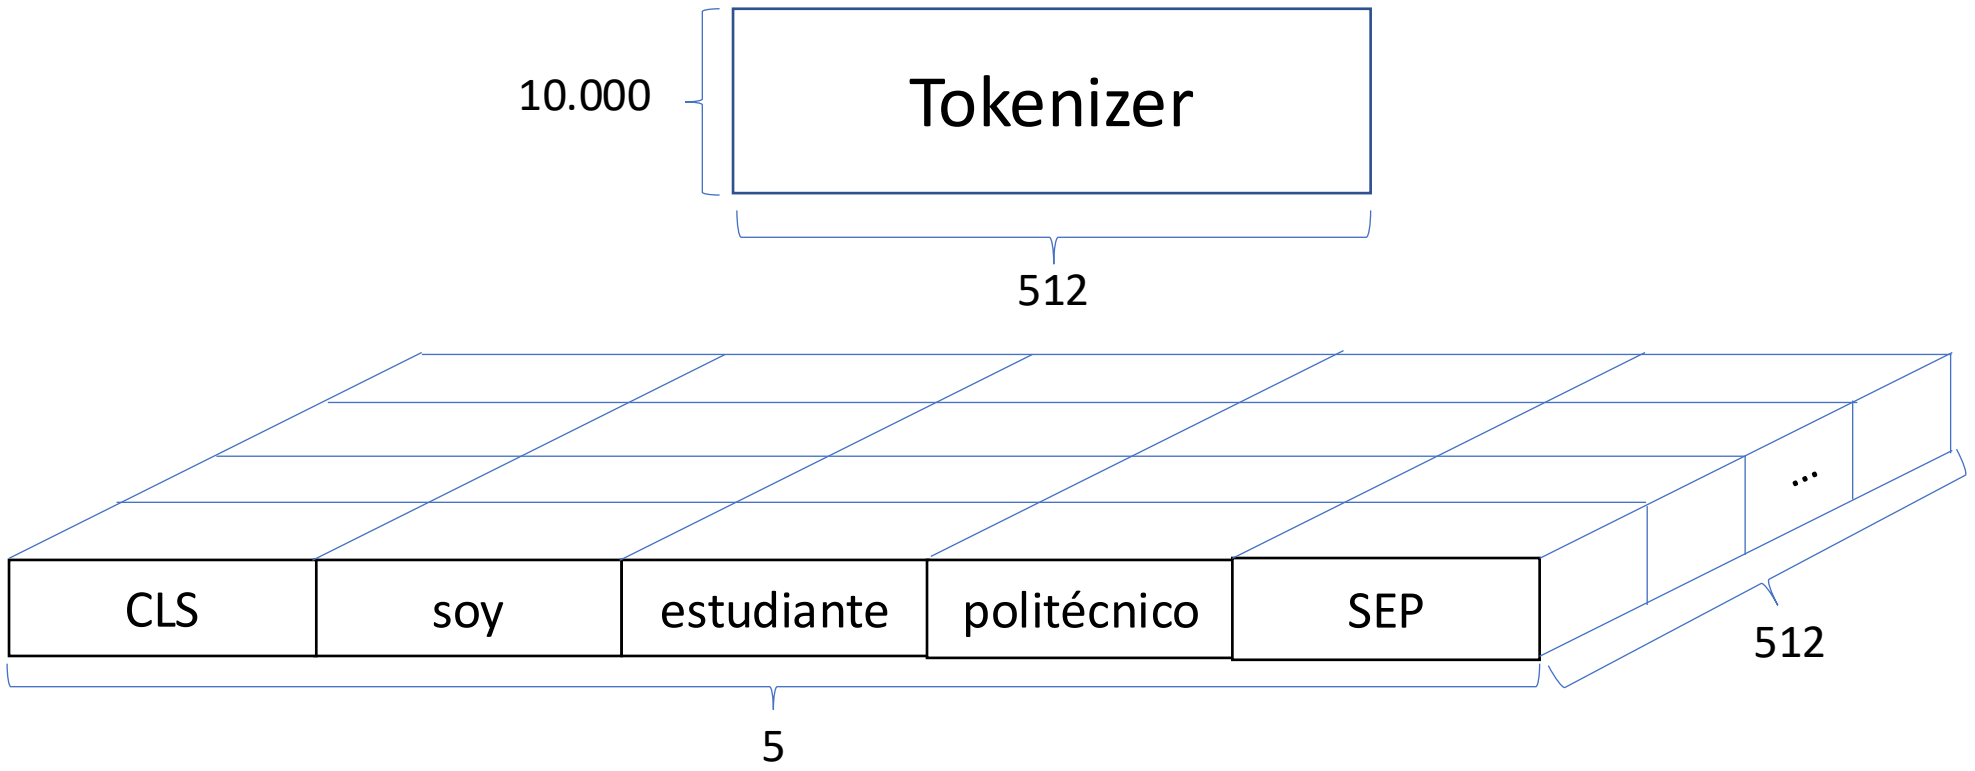
Qué es un embedding?

- Es una representación numérica del texto, donde las palabras con igual significado tienen una representación similar
- Es un vector d-dimensional para cada número o índice de representación de cada palabra
- Si tenemos un diccionario o corpus de 10000 palabras, necesitamos 10000 índices
- Cada palabra tiene un índice único y cada índice tiene un vector embedding

Redes neuronales recurrentes: Embeddings

soy estudiante politécnico — 3 palabras

[CLS], “soy”, “estudiante”, “politécnico”, [SEP] — 5 tokens



Redes neuronales recurrentes: Embeddings

TF-IDF

TF

- Frecuencia de términos: # de veces un término aparece en un documento en comparación con el # total de palabras en el documento.

$$TF = \frac{\text{\# de veces un término aparece en un documento}}{\text{\# total de palabras en el documento}}$$

IDF

- Frecuencia inversa de documentos: Proporción de documentos en el corpus que contienen el término.

$$\text{ID}F = \log\left(\frac{\text{\# de documentos en el corpus}}{\text{\# de documentos en el corpus que contienen el término}}\right)$$

$$\boldsymbol{TF.IDF = TF * IDF}$$

Redes neuronales recurrentes: Embeddings

Tipos de Embeddings:

1. Estáticos:
   - Son números únicos que representan las palabras. Estos pueden ser valores pre-entrenados de las palabras, que luego se podrían usar para entrenar otros modelos. Por ejemplo: Glove (Latent Semantic Analysis-LSA) y word2vec (Continuous Bag-of-Words-CBOW, Skip-Gram) son embeddings estáticos. Están previamente entrenados. Son modelos independientes del contexto, como word2vec o GloVe, generan una representación de cada palabra en el vocabulario.
2. Contextual:
   - Cada palabra en los documentos tiene una representación independiente y continua (vector), que depende de su uso.
   - Por ejemplo: ELMo, BERT son representaciones continuas y se pueden usar en tareas de aprendizaje posteriores.
   - Estos modelos contextuales generan una representación de cada palabra basado en las otras palabras de la oración.

Redes neuronales recurrentes

- Veamos un ejemplo: RNN, para predecir caracteres
- Supongamos que tenemos la cadena de caracteres “amor”; y, luego de ingresar las primeras 3 letras: “a, m, o”, deseamos que la RNN prediga la siguiente letra: “r”.
- En este ejemplo, el vocabulario tiene 4 letras: {a, m, o, r}, y el algoritmo debe reconocer el patrón; recordar que este vocabulario se denomina “Corpus”.
- Veamos cómo esta estructura se utiliza para predecir la siguiente letra en la palabra “amor”.

