Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 4 - PAO 2024 – II

Agenda

1. Aprendizaje autónomo (machine learning)
   1.1 Regresión lineal, de una variable
   1.2 Algoritmo Gradiente Descendiente

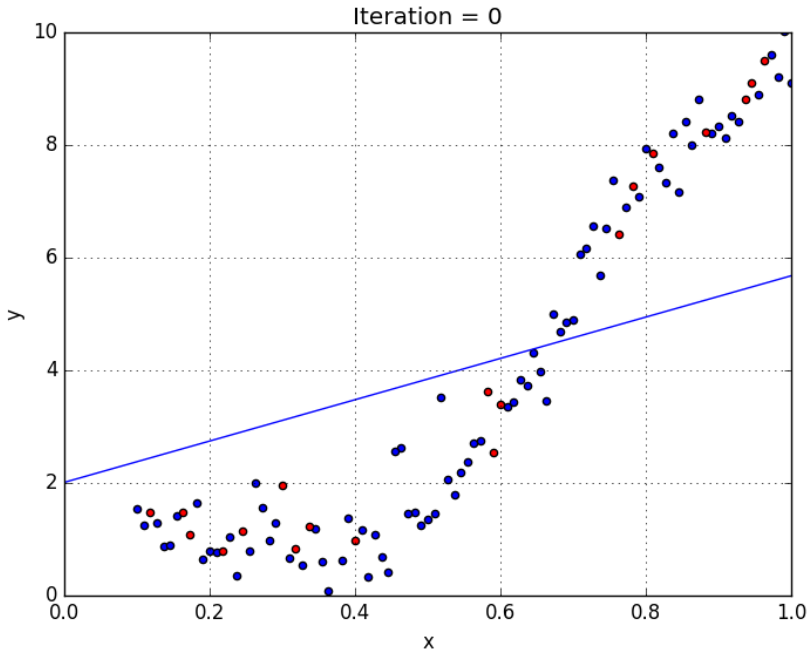
Agenda

1. Introducción al aprendizaje autónomo (machine learning)
   1.1 Regresión lineal, de una variable
   1.2 Algoritmo Gradiente Descendiente
   1.3 Regresión lineal de múltiples variables con aprendizaje supervisado
   1.4 Regresión polinómica con aprendizaje supervisado
   1.5 Ejemplo

- Temas de proyectos:
  - Revisar la lista de proyectos anteriores … NO repetir las ideas
  - Datos locales – pensar en ESPOL

Aprendizaje Supervisado - Algoritmos lineales: Regresión lineal, de una variable

Entonces, en resumen:



Hipótesis:

$$h_w(x) = w_0 + w_1 x$$

Parámetros:

$$w_0, w_1$$

Función de costo:

$$J(w_0, w_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_w\left(x^{(i)}\right) - y^{(i)}\right)^2$$

Objetivo: Minimizar el error con respecto a cada uno de los parámetros

$$\underset{w_0 w_1}{\text{minimizar}}\ J(w_0, w_1)$$

Aprendizaje Supervisado - Algoritmos lineales: Regresión lineal, de una variable

Para una función, como: $J(w_0, w_1)$

Deseamos: $\min_{w_0 w_1} J(w_0, w_1)$

Procedimiento:

- Empezar con valores iniciales w_0, w_1
- Actualizar paso a paso w_0 y w_1 hasta minimizar $J(w_0, w_1)$
- Hasta “posiblemente” llegar al mínimo global

Cómo actualizamos w_0, w_1?

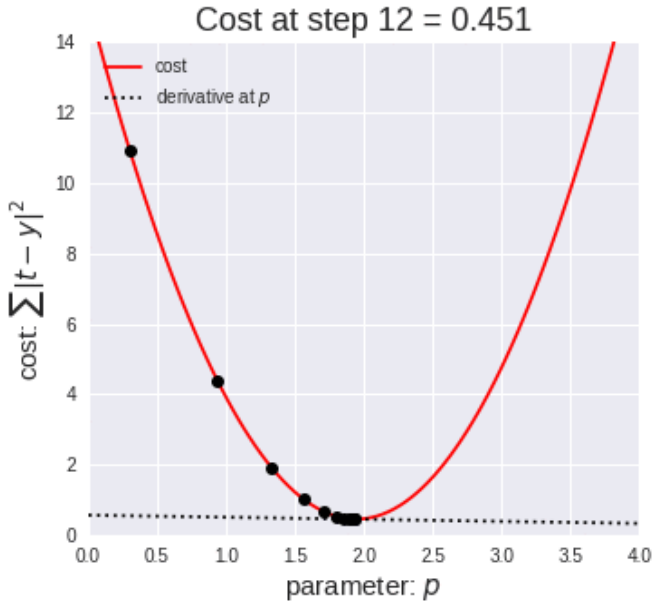
Aprendizaje Supervisado: Gradiente descendiente

- A través del GD podemos calcular la dirección y la magnitud de los pequeños cambios en los parámetros, y así ajustar de forma iterativa el modelo
- Ese cálculo se realiza a través de la derivada de la función de costo
- De manera que la corrección o ajuste del parámetro w_1 sería:

$$W_{1_{nuevo}} = W_{1_{anterior}} - \alpha \frac{d}{dw_1} J(w_1)$$

velocidad de aprendizaje

gradiente



Algoritmos lineales: Gradiente descendiente

- Regresión lineal de una variable

$$h_w(x) = w_0 + w_1 x$$

$$J(w_0, w_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_w\left(x^{(i)}\right) - y^{(i)} \right)^2$$

- Algoritmo Gradiente Descendiente

Repetir hasta que converja:
{

$w_j := w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1)$; ($j$ =0, y j =1 en nuestro ejemplo)

}

Algoritmos lineales: Gradiente descendiente

Repetir hasta que converja

{

$$w_j := w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1)$$; (j =0, y j =1 en nuestro ejemplo)

}

Reemplazando

$$j = 0: \ \frac{\partial}{\partial w_0} J(w_0, w_1) = \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right)$$

$$j = 1: \ \frac{\partial}{\partial w_1} J(w_0, w_1) = \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right) \cdot X^{(i)}$$

Algoritmos lineales: Gradiente descendiente

Repetir hasta que converja

{

$$w_0 := w_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right)$$

$$w_1 := w_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right) \cdot X^{(i)}$$

}

Actualizar w_0 y w_1 simultáneamente

Aprendizaje Supervisado – Un algoritmo básico de aprendizaje: Regresión lineal

Tipos

1. **Regresión lineal** simple o de una variable (n=1): Por ejemplo, determinar la temperatura en una zona, basado en las temperaturas históricas de esa zona
2. **Regresión lineal múltiple** o de varias variables (n>1): Por ejemplo, determinar la temperatura en esa zona, que depende de varias variables o features, como: la presión atmosférica, viento, ubicación, otras
3. **Regresión polinómica**: Es el caso más general de regresión lineal. Asume dependencia polinómica entre las entradas y la salida; incluye términos no lineales como $a_2x_1^2$, $b_3x_1^3$, $b_4x_1x_2$, $b_5x_1^2x_2$, ...