Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 5 - PAO 2024 – II

Agenda

1. Regresión lineal de múltiples variables
2. Regresión polinómica
3. Underfitting y Overfitting
4. Regularización

Aprendizaje Supervisado: LR - Múltiple variables (features)

n

Tamaño pies^2 X_1	Número de dormitorios X_2	Número de pisos X_3	Edad del departamento (meses) X_4	Precio Miles US$ y
210	5	2	45	460
141	3	1	40	232
153	3	2	30	315
85	2	1	36	178
…	…	…	…	…

m

$$X^{(2)} = \begin{bmatrix} 141 \\ 3 \\ 1 \\ 40 \end{bmatrix}$$

$$X_3^{(2)} = 1$$

Donde:

$m = número\ de\ ejemplos$

$n = número\ de\ variables\ (features)$

$X^{(i)} = variables\ de\ entrada\ del\ i^{th}\ ejemplo\ de\ entrenamiento$

$X_j^{(i)}\ valor\ de\ la\ variable\ j\ en\ el\ i^{th}\ ejemplo\ de\ entrenamiento$

Gradiente descendiente para múltiple variables

Hipótesis: $h_w(x) = w^T X = w_0 x_0 + w_1\, x_1 + w_2\, x_2 + \cdots + w_n\, x_n$

Parámetros: $w_0 w_1 w_2 \ldots w_n$

Función de costo: $J(w_0, w_1, \ldots, w_n\,) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right)^2$

Algoritmo Gradiente Descendiente

Repetir hasta que converja

{

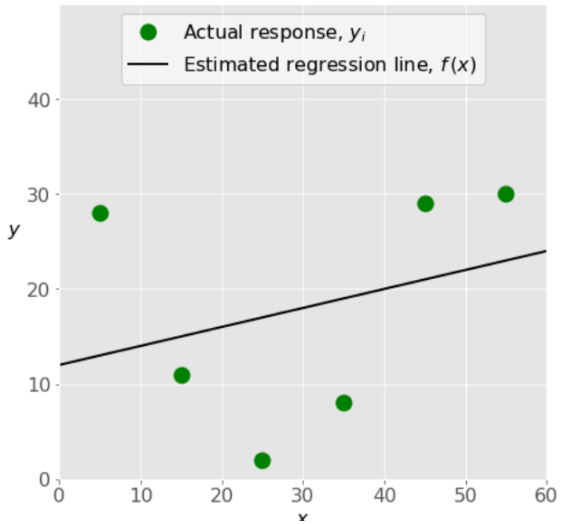
$$w_j := w_j - \alpha\, \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)} \right) \cdot x_j^{(i)}$$

}

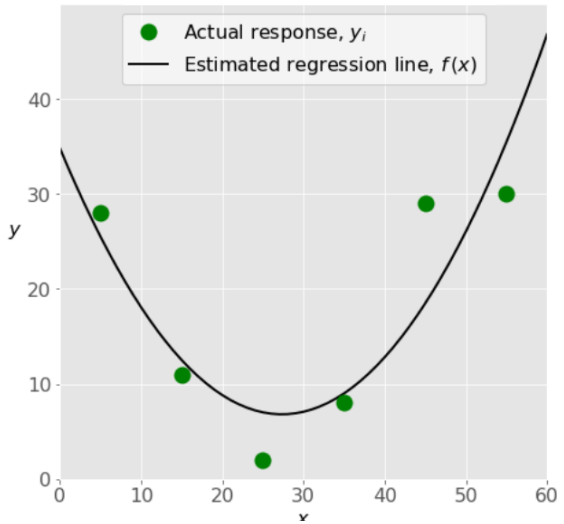
Regresión polinómica

Underfitting

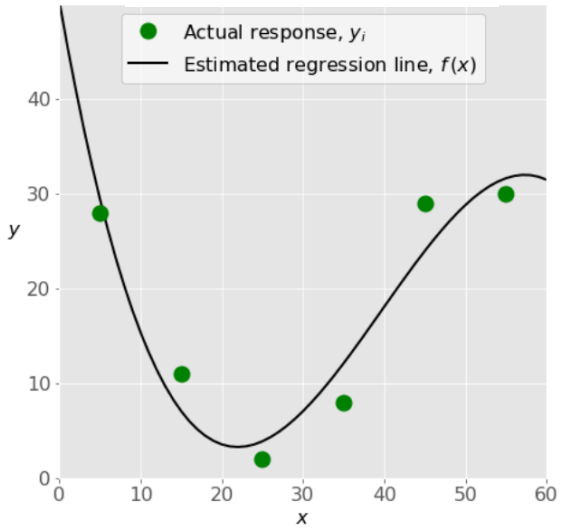
grado 1



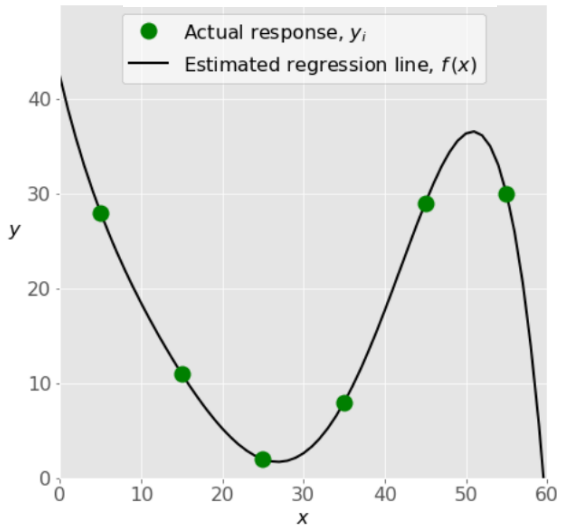
grado 2



grado 3



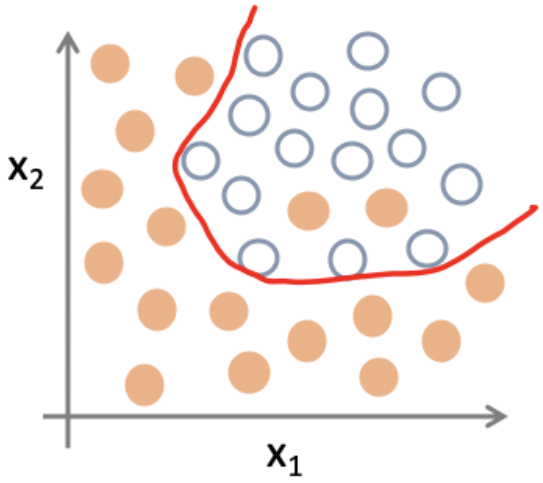
grado 5

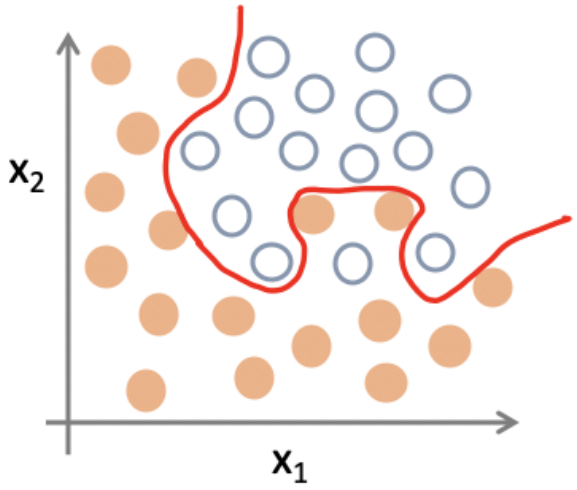


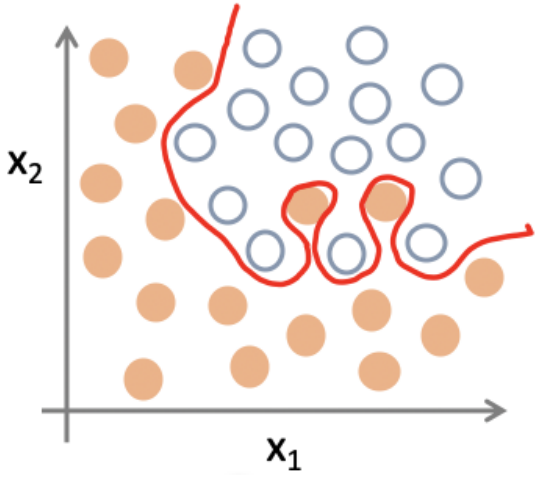
Overfitting

Regularización

Ejemplo: Regresión polinómica







$$h_w(x) = w_0 + w_1\, x_1 + w_2\, x_2 + w_3 x_1 x_2$$

$$h_w(x) = w_0 + w_1\, x_1 + w_2\, x_2 + w_3 x_1^2 + w_4\, x_2^2$$

$$h_w(x) = w_0 + w_1\, x_1 + w_2\, x_1^2 + w_3 x_1^2 x_2 + w_4\, x_1^2 x_1^2 + \ldots$$

Estos modelos requieren un término de regularización

Cómo resolver el overfitting

- Opciones:
  - Reducir el número de características
  - Podemos seleccionar manualmente las características que deseamos conservar o a través de reducción de dimensiones como PCA
  - Añadir un término de regularización (L1, L2) a la función de costo
    - Mantener todas las características, pero reducir la magnitud / valores de los parámetros w_j
    - Funciona bien cuando tenemos muchas características, y cada una contribuye poco a la predicción

$$J(W) = \frac{1}{2m}\left[\sum_{i=1}^{m}\left(h_w\left(X^{(i)}\right) - y^{(i)}\right)^2 + \lambda \sum_{j=1}^{n}|w_j|\right]$$

$$J(W) = \frac{1}{2m}\left[\sum_{i=1}^{m}\left(h_w\left(X^{(i)}\right) - y^{(i)}\right)^2 + \lambda \sum_{j=1}^{n} w_j^2\right]$$