Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 6 - PAO 2024 – II

Agenda

1. Ejemplo de Regresión Lineal
2. Introducción a la Regresión Logística
   2.1 Función de costo
   2.2 Clasificación multi-clase
3. Introducción a las redes neuronales

Regresión logística

Datos de entrenamiento: $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \cdots, (x^{(m)}, y^{(m)})\}$

m ejemplos: $x \in \begin{bmatrix} x_0 \\ x_1 \\ \cdots \\ x_n \end{bmatrix} \mathbb{R}^{n+1}$, $x_0 = 1, y \in \{0, 1\}$

$$h_w(x) = \frac{1}{1 + e^{-w^T x}}$$

Cómo aprendemos los parámetros w?

Regresión logística: Gradiente descendiente

$$J(W) = -\frac{1}{m}\sum_{i=1}^{m} y^{(i)} \log h_w\left(x^{(i)}\right) + \left(1 - y^{(i)}\right) \log\left(1 - h_w\left(x^{(i)}\right)\right)$$

Deseamos: $\min_w J(W)$

Repetir hasta que converja

{

$$w_j := w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1, \ldots, w_n)$$

}

Regresión logística: Gradiente descendiente

$$J(W) = -\frac{1}{m}\sum_{i=1}^{m} y^{(i)} \log h_w\left(x^{(i)}\right) + \left(1 - y^{(i)}\right) \log\left(1 - h_w\left(x^{(i)}\right)\right)$$

Deseamos: $\min_w J(W)$

Repetir hasta que converja

{

$$w_j := w_j - \alpha \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)}\right) \cdot x_j^{(i)}$$

}

Regresión logística: Gradiente descendiente

$$J(W) = -\frac{1}{m}\sum_{i=1}^{m} y^{(i)} \log h_w\left(x^{(i)}\right) + \left(1 - y^{(i)}\right) \log\left(1 - h_w\left(x^{(i)}\right)\right)$$

Deseamos: $\min_w J(W)$

Repetir hasta que converja

{

$$w_j := w_j - \alpha \frac{1}{m} \sum_{i=1}^{m} \left(h_w\left(X^{(i)}\right) - y^{(i)}\right) \cdot x_j^{(i)}$$

}

$$h_w(x) = \frac{1}{1 + e^{-w^T x}}$$

Clasificación multi-clase: Una vs. todas (una vs. el resto)

- Dado que $y = \{0,1 \dots n\}$, dividimos el problema en $n+1$ (+1 porque el índice comienza en 0) problemas de clasificación binaria; en cada uno, predecimos la probabilidad de que "y" corresponda a una de las 2 clases

$$y \in \{0, 1, 2, \dots, n\}$$

$$h_w^{(0)}(x) = P(y = 0|x; w)$$

$$h_w^{(1)}(x) = P(y = 1|x; w)$$

$$\dots$$

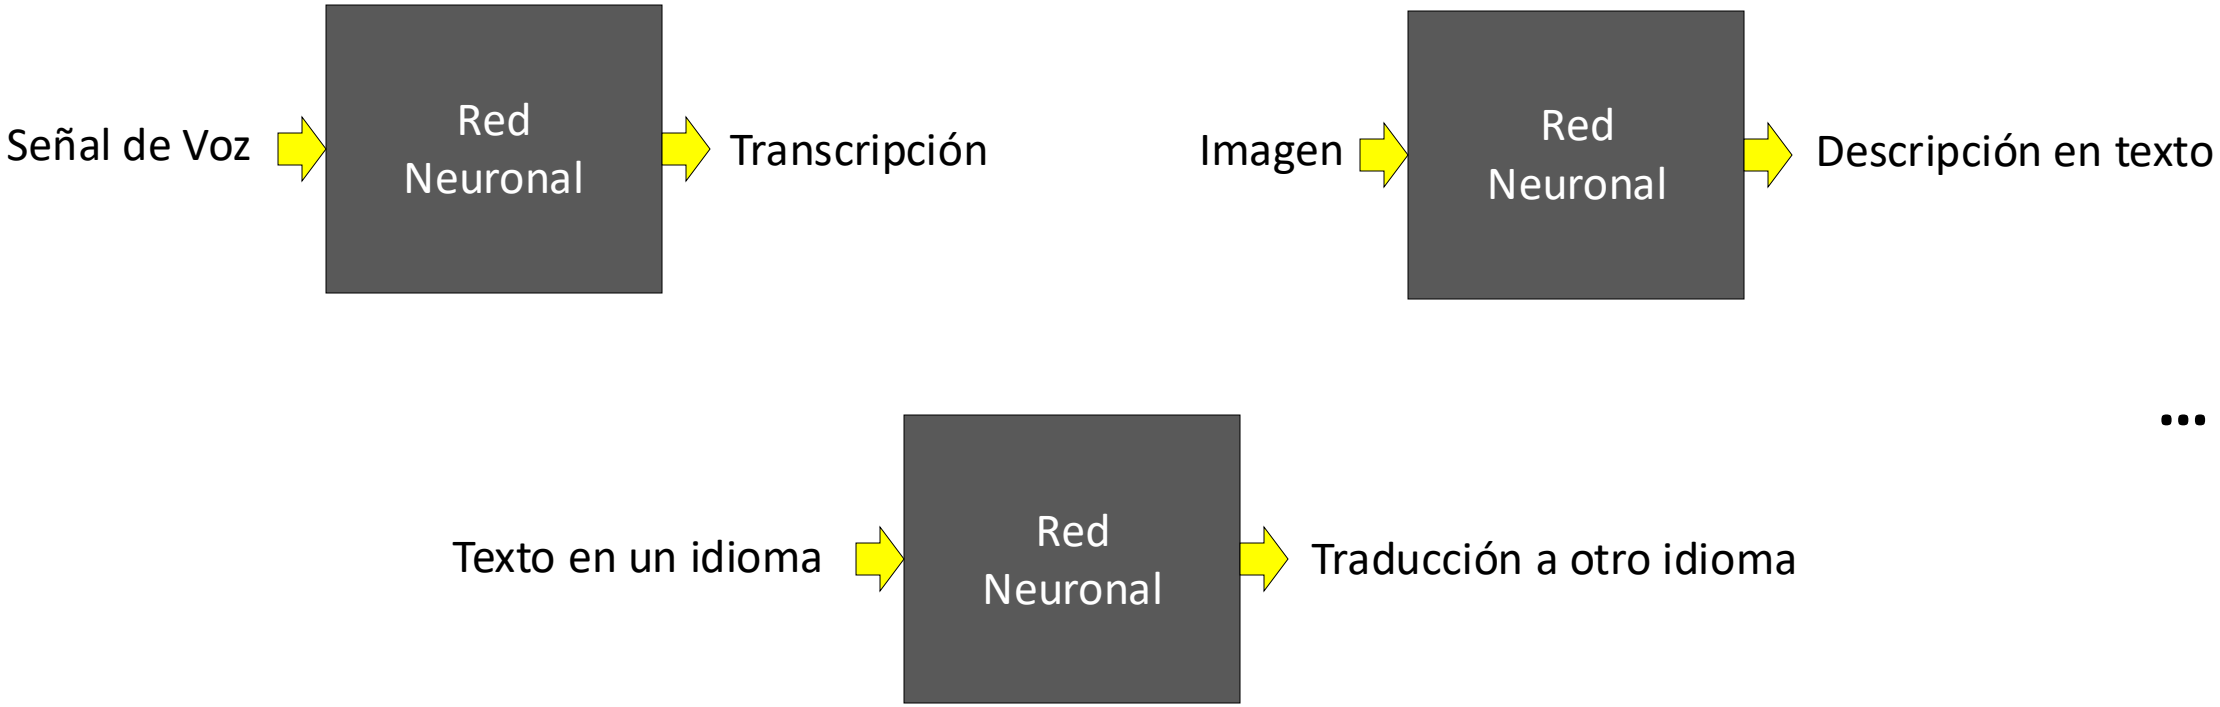
$$h_w^{(n)}(x) = P(y = n|x; w)$$

Predicción = $\max_i \left(h_w^{(i)}(x) \right)$

- Seleccionamos una clase y agrupamos todas las demás en una sola clase
- Hacemos esto repetidamente, aplicando regresión logística binaria a cada caso
- Al final, seleccionamos la hipótesis con el valor más alto

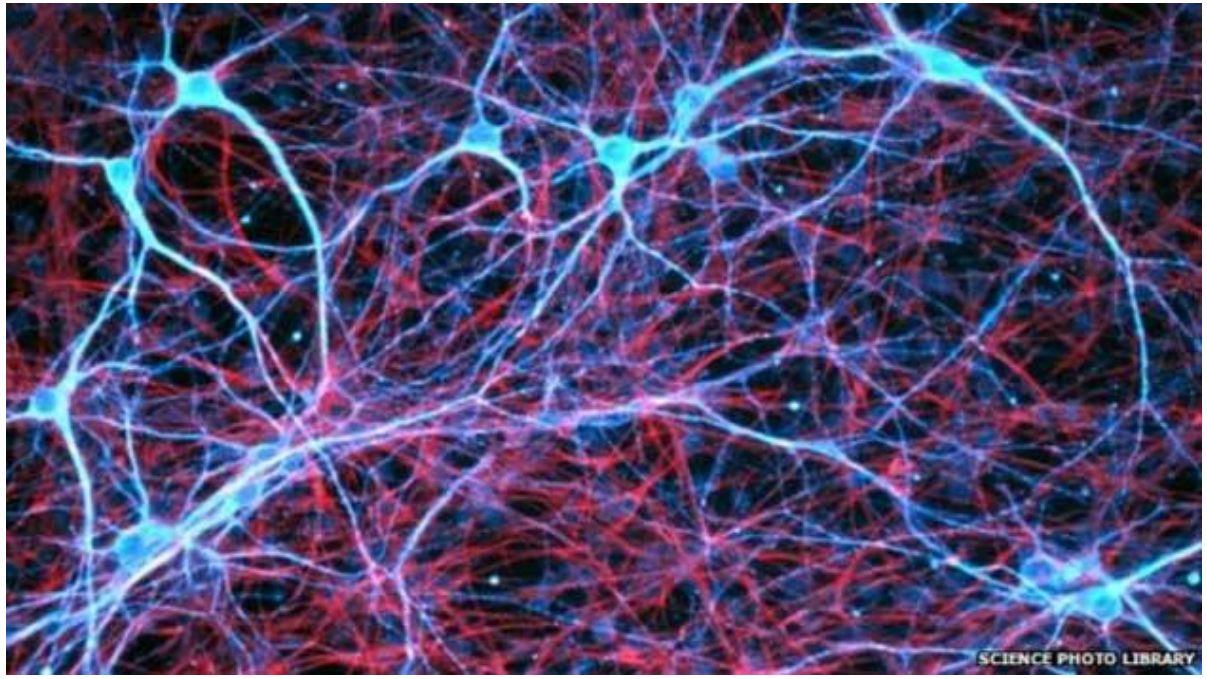
- Para una nueva entrada x, la predicción consiste en seleccionar la clase i con el máximo valor

Que son las redes neuronales?

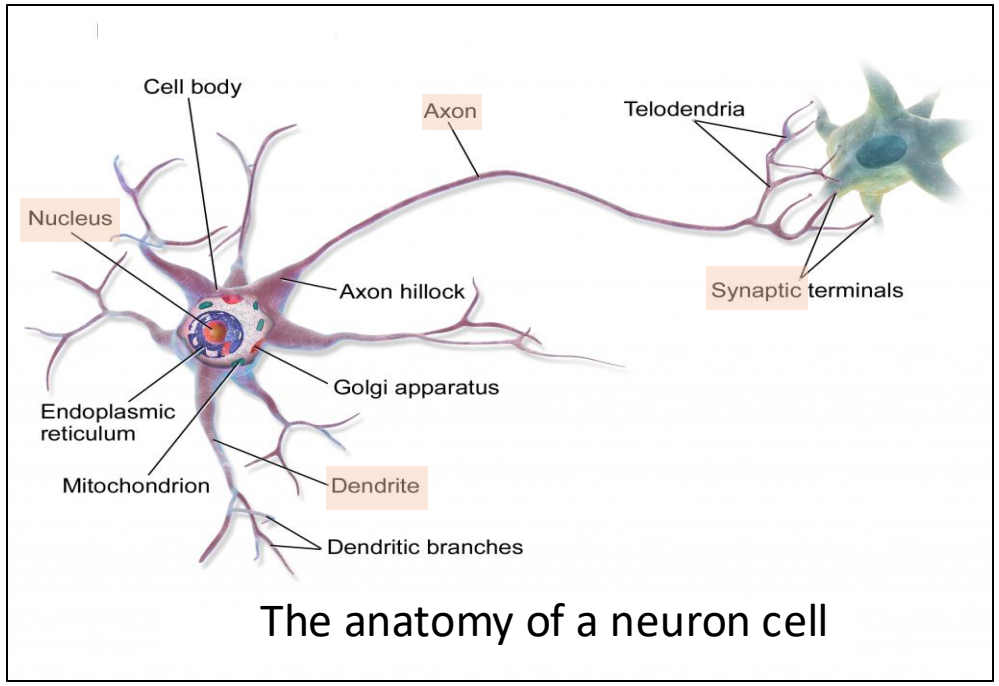


- Qué son esas cajas negras?

El cerebro



Tamado de: https://www.evolving-science.com/



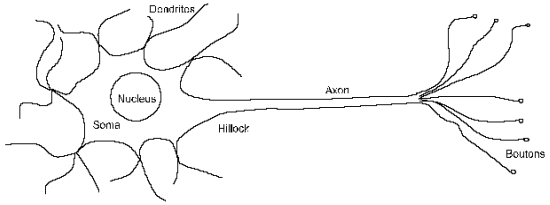
The anatomy of a neuron cell

Tomado de: https://www.medicalsciencenavigator.com/

- Nuestro cerebro está compuesto de redes de neuronas

Neurona biológica – Cómo funciona

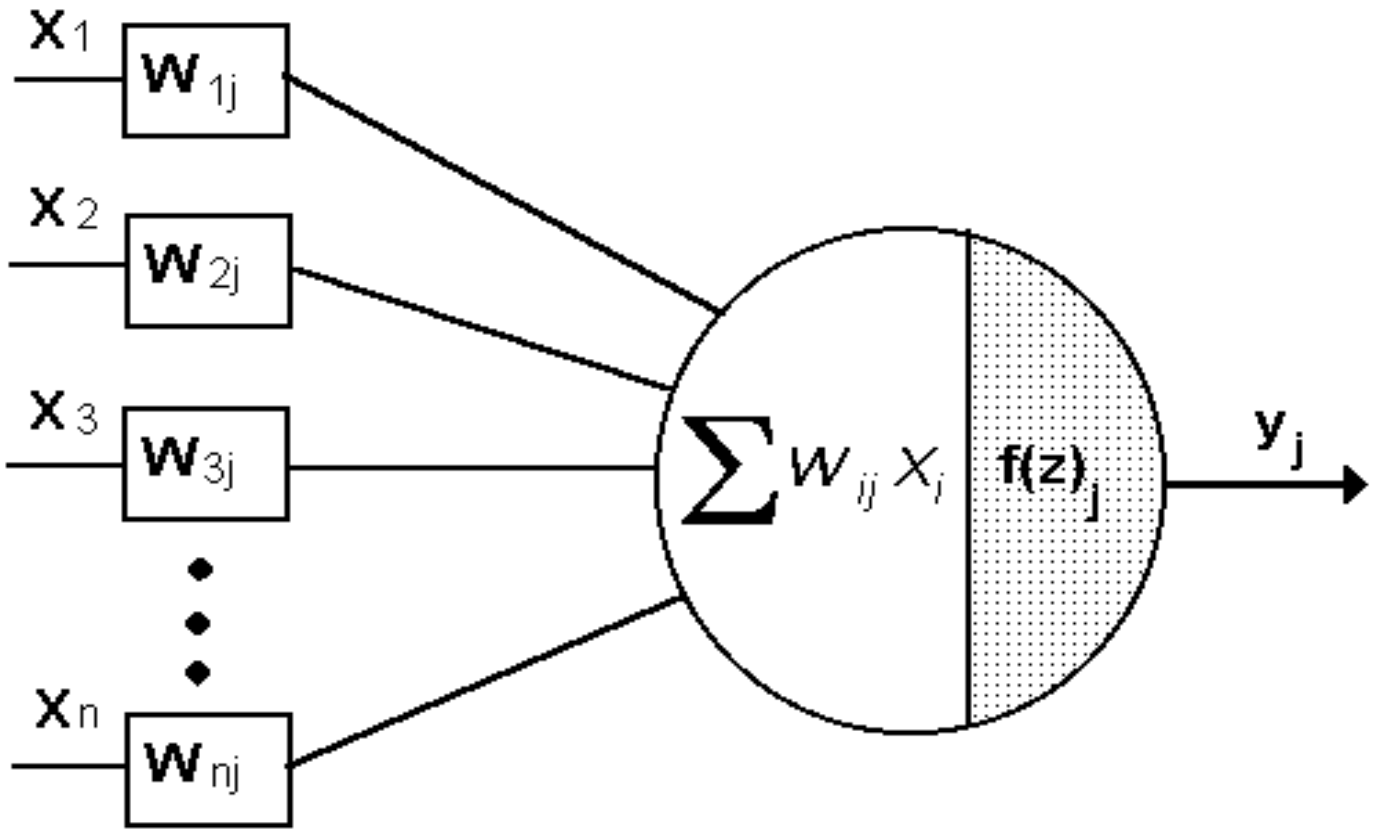
- El cerebro contiene alrededor de 10^{11} ”elementos” altamente interconectados (~10^4 conexiones por elemento), llamados neuronas.
- Los 4 componentes principales a los que nos vamos a referir: dendritas, cuerpo-núcleo de la célula o soma, el axón y la sinapsis.
- Las dendritas constituyen el árbol receptor de la red, cargan el cuerpo de la célula con señales eléctricas.
  - El cuerpo de la célula suma todas esas señales.
  - El axón conduce la señal desde el cuerpo de la célula hacia otras neuronas.



- El punto de “contacto” del axón de una célula con las dendritas de otra célula se conoce como sinapsis.
- La longitud de la sinapsis determina la intensidad de conexión

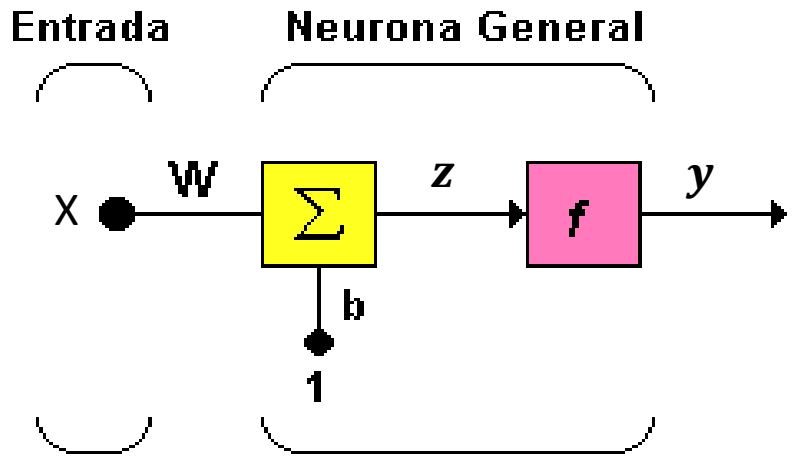
Neurona artificial - Perceptron

Dendritas: Entradas Sinapsis: Pesos Soma: Unidad de activación Axon: Salida



Este modelo es conocido como el Perceptron

Funciones de transferencia:



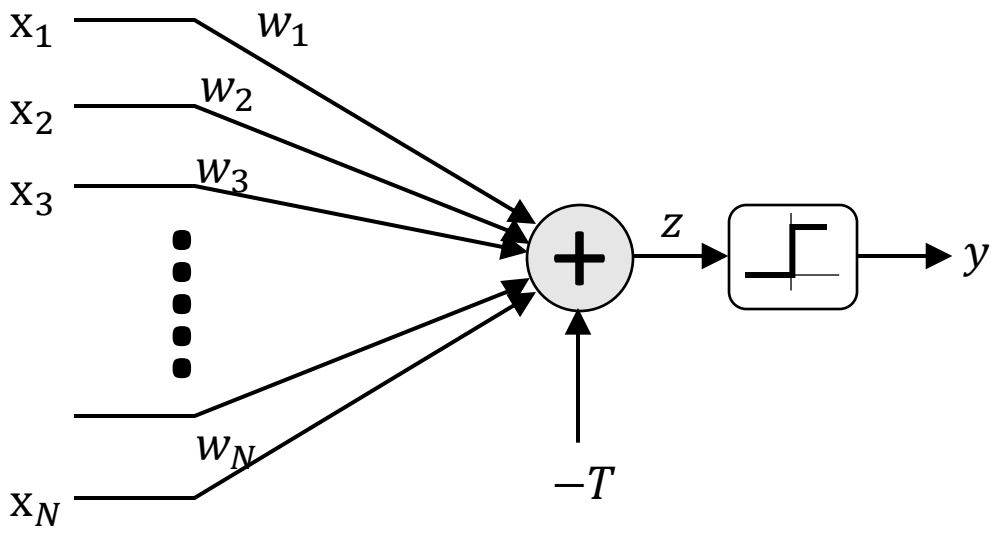
$$y = f(Wx + b)$$

- Las entradas a la neurona / perceptron están representadas por un vector x. En la entrada cada "elemento" representa un componente del vector
- W representa el peso o parámetros w y b es el bias – threshold (ayuda a corregir las dimensiones de la salida z)
- La salida total y, está determinada por la función de transferencia, que puede ser lineal o no de z, y se elige de acuerdo al problema a resolver
- Aunque las redes neuronales artificiales se inspiran en su contraparte biológica, no hay limitaciones en las funciones de salida

El perceptron: Otras funciones de activación

Nombre	Relación Entrada /Salida	Icono	Función
Limitador Fuerte	$a = 0 \quad n < 0$ $a = 1 \quad n \geq 0$		*hardlim*
Limitador Fuerte Simétrico	$a = -1 \quad n < 0$ $a = +1 \quad n \geq 0$		*hardlims*
Lineal Positiva	$a = 0 \quad n < 0$ $a = n \quad 0 \leq n$		*poslin*
Lineal	$a = n$		*purelin*
Lineal Saturado	$a = 0 \quad n < 0$ $a = n \quad 0 \leq n \leq 1$ $a = 1 \quad n > 1$		*satlin*
Lineal Saturado Simétrico	$a = -1 \quad n < -1$ $a = n \quad -1 \leq n \leq 1$ $a = +1 \quad n > 1$		*satlins*
Sigmoidal Logarítmico	$a = \frac{1}{1 + e^{-n}}$		*logsig*
Tangente Sigmoidal Hiperbólica	$a = \frac{e^{n} - e^{-n}}{e^{n} + e^{-n}}$		*tansig*
Competitiva	$a = 1 \quad$ *Neurona con n max* $a = 0 \quad$ *El resto de neuronas*		*compet*

Funciones de transferencia: “hard”

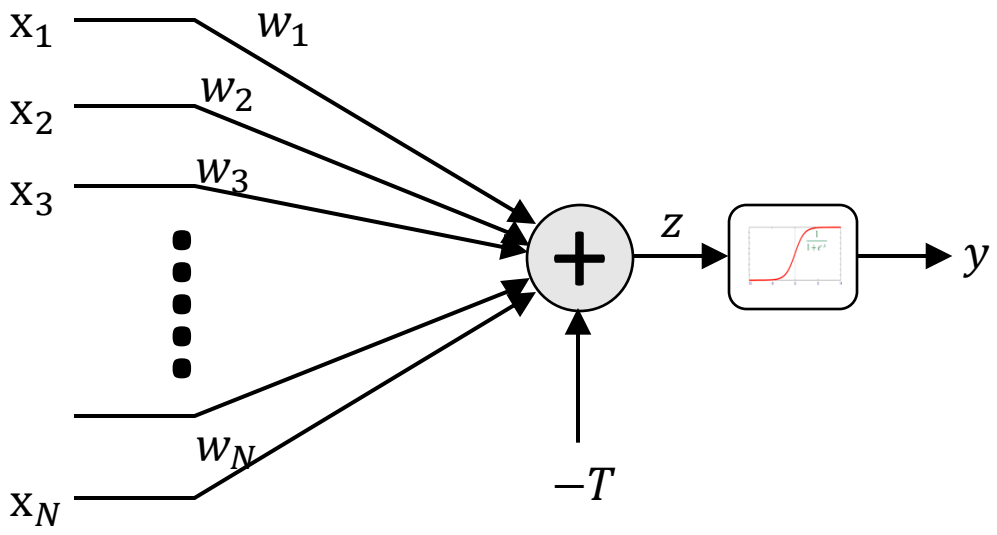


$$z = \sum_i w_i x_i - T$$

$$y = \begin{cases} 1 \ if \ z \geq 0 \\ 0 \quad else \end{cases}$$

- La unidad de activación o umbral
  - “Se activa” si la suma de las entradas (ponderada por los pesos) y el “bias” *T,* es positivo

Funciones de transferencia: “soft”

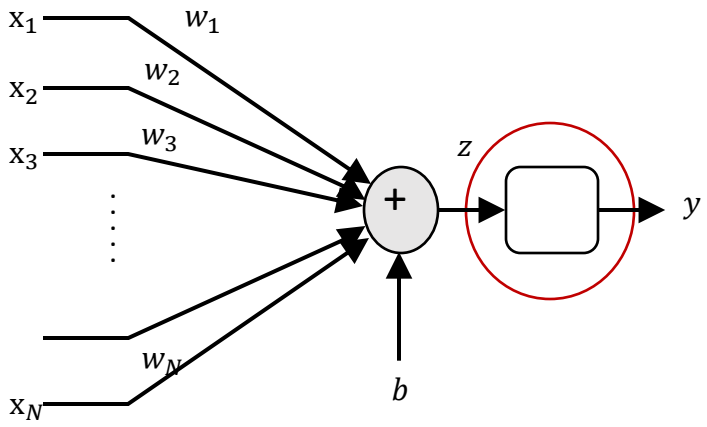


$$z = \sum_i w_i x_i - T$$

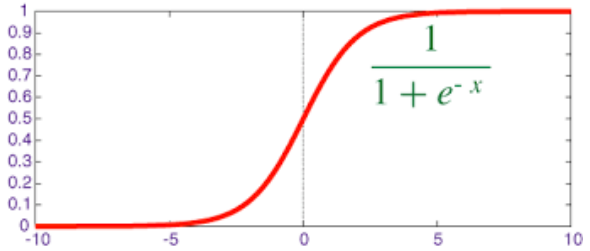
$$y = \frac{1}{1 + e^{(-z)}}$$

- Una función que ”suaviza" la salida en el umbral, es la función de activación Sigmoidal
- Activación: la función actúa sobre la combinación ponderada de las entradas

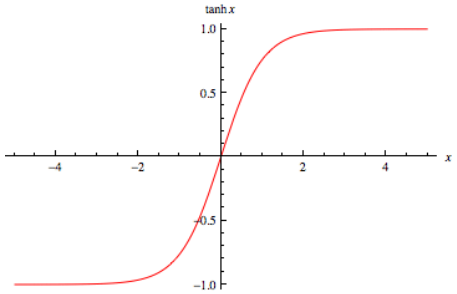
El perceptron: Otras funciones de activación



sigmoid



tanh



Relu

