Artificial Intelligence

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 9 - PAO 2024 – II

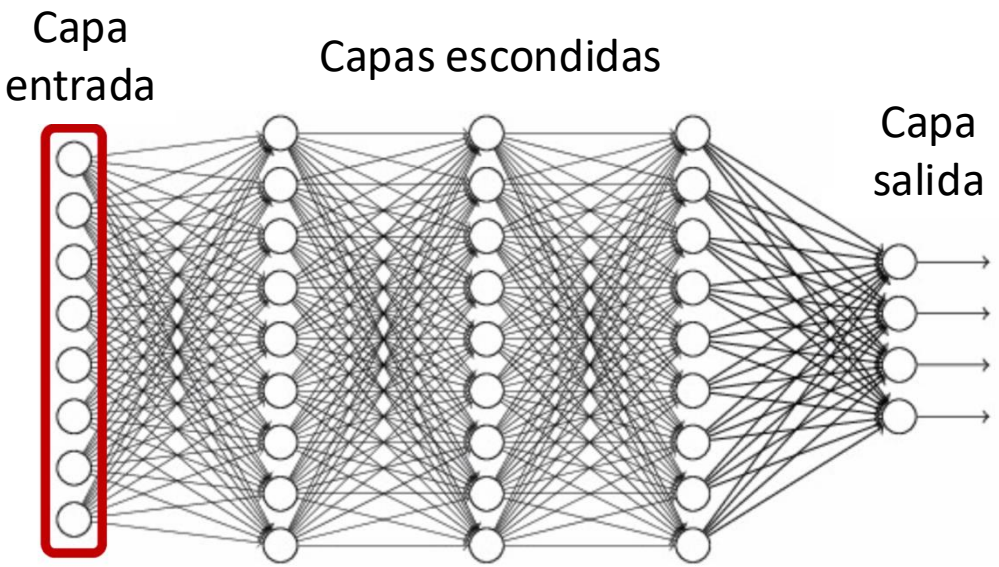
Agenda

1. Aprendizaje en las redes MLP
2. Propagación hacia delante
3. Propagación hacia atrás

Aprendizaje: Gradiente descendiente

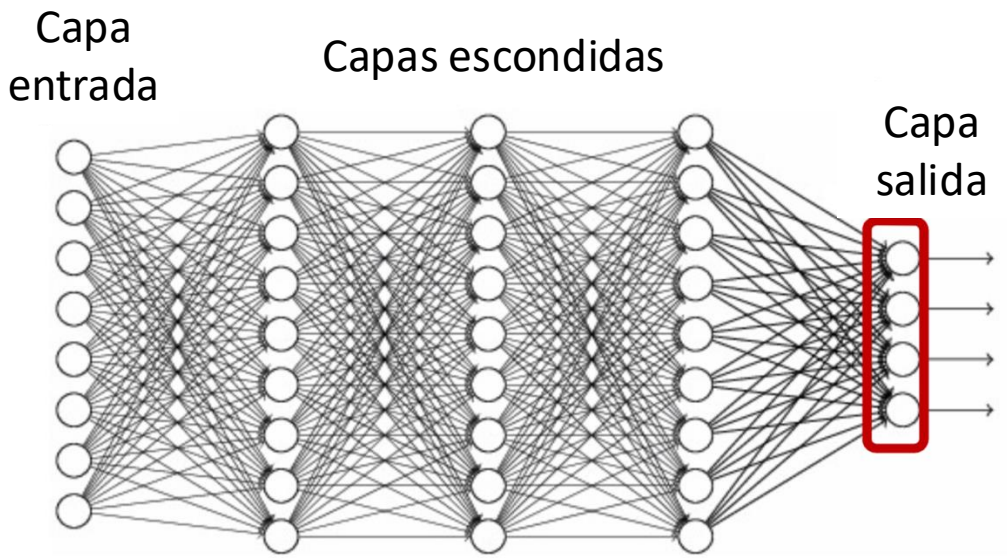
- Hay varios tipos de cálculo del Gradiente Descendiente, difieren en la forma en que manejan los conjuntos de datos:
  1. Batch Gradient Descent: Este método calcula el error, después de haber evaluado el conjunto completo de datos. Es computacionalmente eficiente, pero requiere memoria y no siempre logra los resultados más precisos.
  2. Stochastic Gradient Descent: Este método calcula el error después de cada ejemplo de entrenamiento. Las actualizaciones frecuentes le permiten ver la mejora detallada hasta la convergencia, la tasa de error puede variar.
  3. Mini-Batch Gradient Descent: Este método se usa con frecuencia en redes neuronales profundas, la actualización del error es una combinación del BGD y el SGD. El conjunto de datos se divide en pequeños lotes, y luego evalúa cada uno de los lotes por separado.

Aprendizaje: La entrada



- Vector de números
  - Inclusive un valor escalar; tamaño del vector de entrada 1
  - Vector con valores de pixeles
  - Vector con valores de voz
  - Vector con valores reales representando texto
  - Vector con valores representando la salida de sensores, Otros..

Aprendizaje: La salida



- La salida es un valor real
- Salida es escalar: Una neurona
- Salida es un vector: Tantas neuronas como se requiera en la salida
- $d = [d_1 d_2 \dots d_L]$

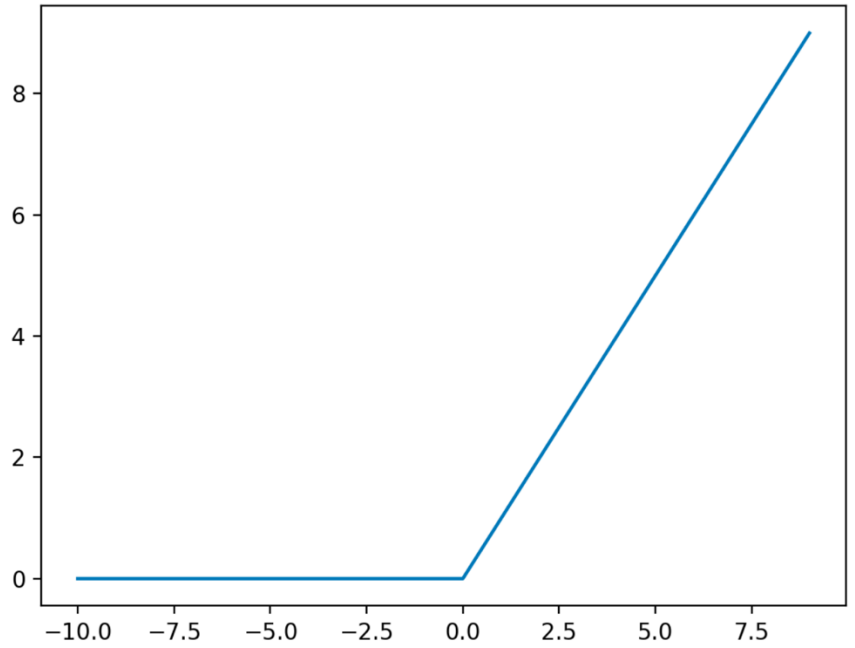
Aprendizaje: Qué es $f()$

Las opciones para unidades ocultas son:

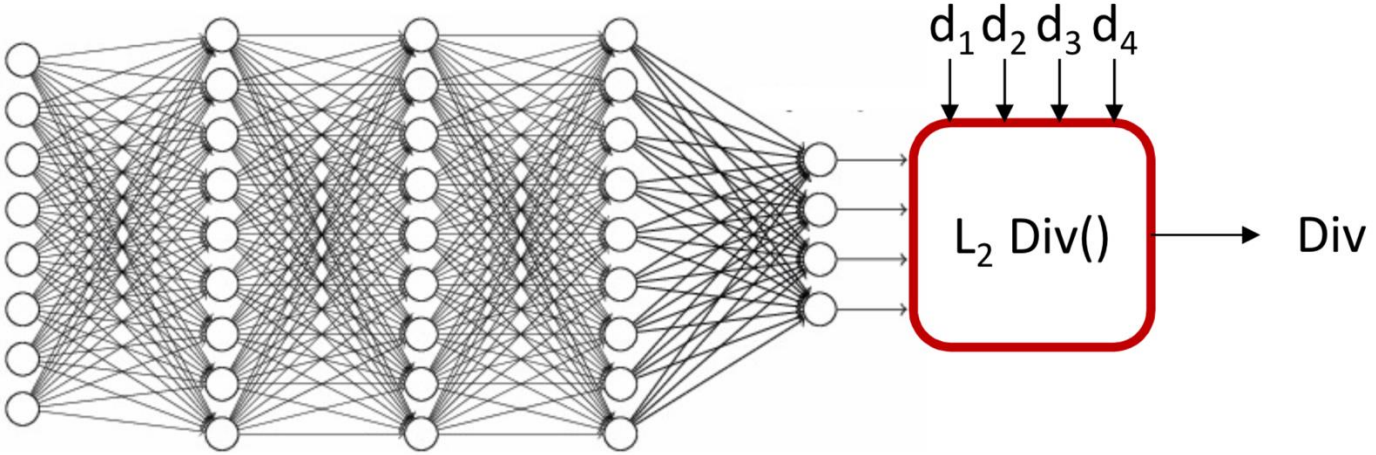
- Unidades lineales rectificadas (Rectified linear units – Relu)

$$g(z) = \max\{0, z\}$$

  - Hay algunas generalizaciones de Relu:
    - Rectificación de valor absoluto
    - ReLU con fugas
    - ReLU paramétrico
    - Unidades Maxout



Aprendizaje: Ejemplos de funciones $div()$

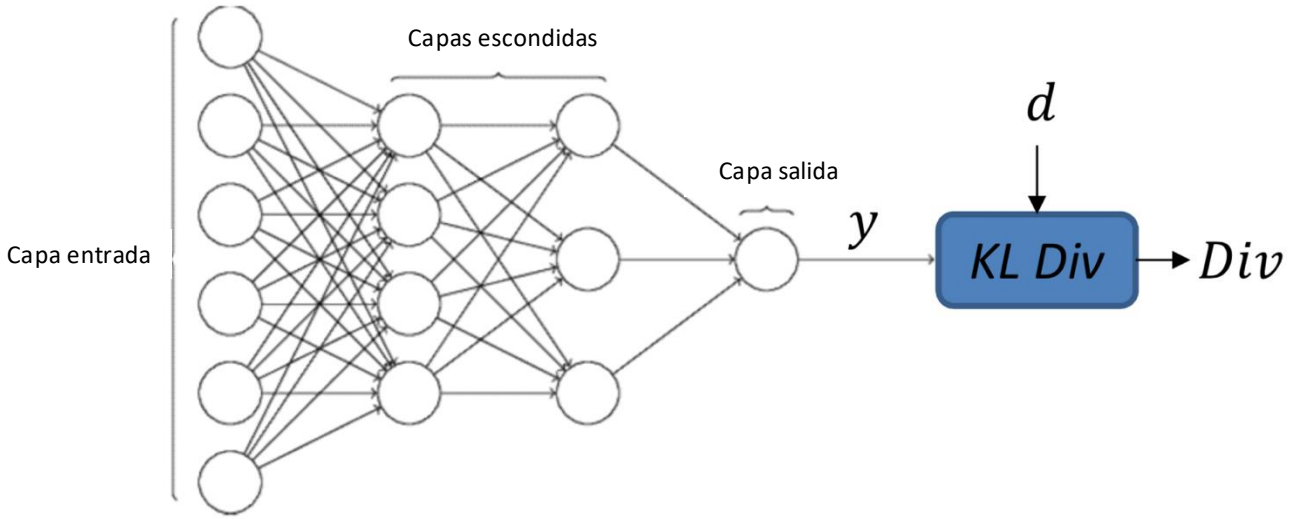


- El cuadrado de la distancia Euclideana entre la salida real y la deseada, conocida como la divergencia L_2 (es popular)

$$Div(Y, d) = \frac{1}{2}\|Y - d\|^2 = \frac{1}{2}\sum_i (y_i - d_i)^2$$

Aprendizaje: Ejemplos de funciones $div()$

- Clasificador binario

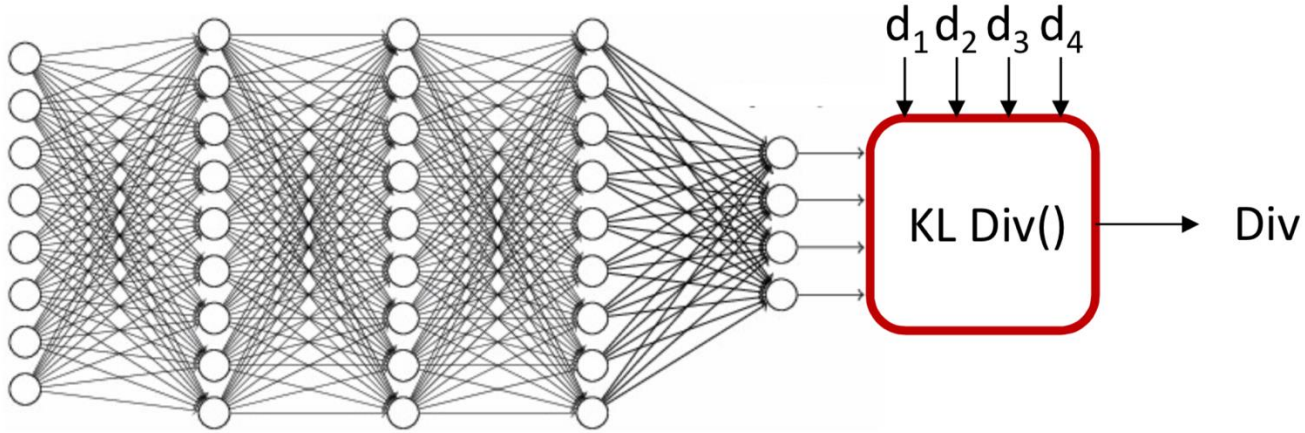


- La salida de un clasificador binario $Y \in [0,1], d\ es\ 0/1.$
- Una función común es el cálculo de la entropía (cross entropy) entre la distribución probabilística de la salida real $[Y, 1-Y]$ y la probabilidad de la salida deseada $[d, 1-d]$

$$Div(Y,d) = -dlogY - (1-d)log(1-Y)$$

Aprendizaje: Ejemplos de funciones $div()$

- Clasificador multi-clase



- La salida deseada es: un vector "one-hot" [00 ... 1 ... 000] con un 1 en la posición c^{th} (para clase c)
  - La salida es la distribución probabilística $[y_1, y_2, \ldots]$
  - La entropía cruzada entre la salida deseada y la salida real:

$$Div(Y, d) = -\sum_i d_i log\ y_i$$