# Artificial Intelligence

**ENRIQUE PELÁEZ Ph.D.**

**Escuela Superior Politécnica del Litoral – ESPOL**

**Facultad de Ingeniería en Electricidad y Computación – FIEC**

Clase # 10 - PAO 2024 – II

# Agenda

1. Algoritmo gradiente descendiente en las redes MLP
2. Corrección del error con Back-propagation

# Aprendizaje: Entrenamiento con GD

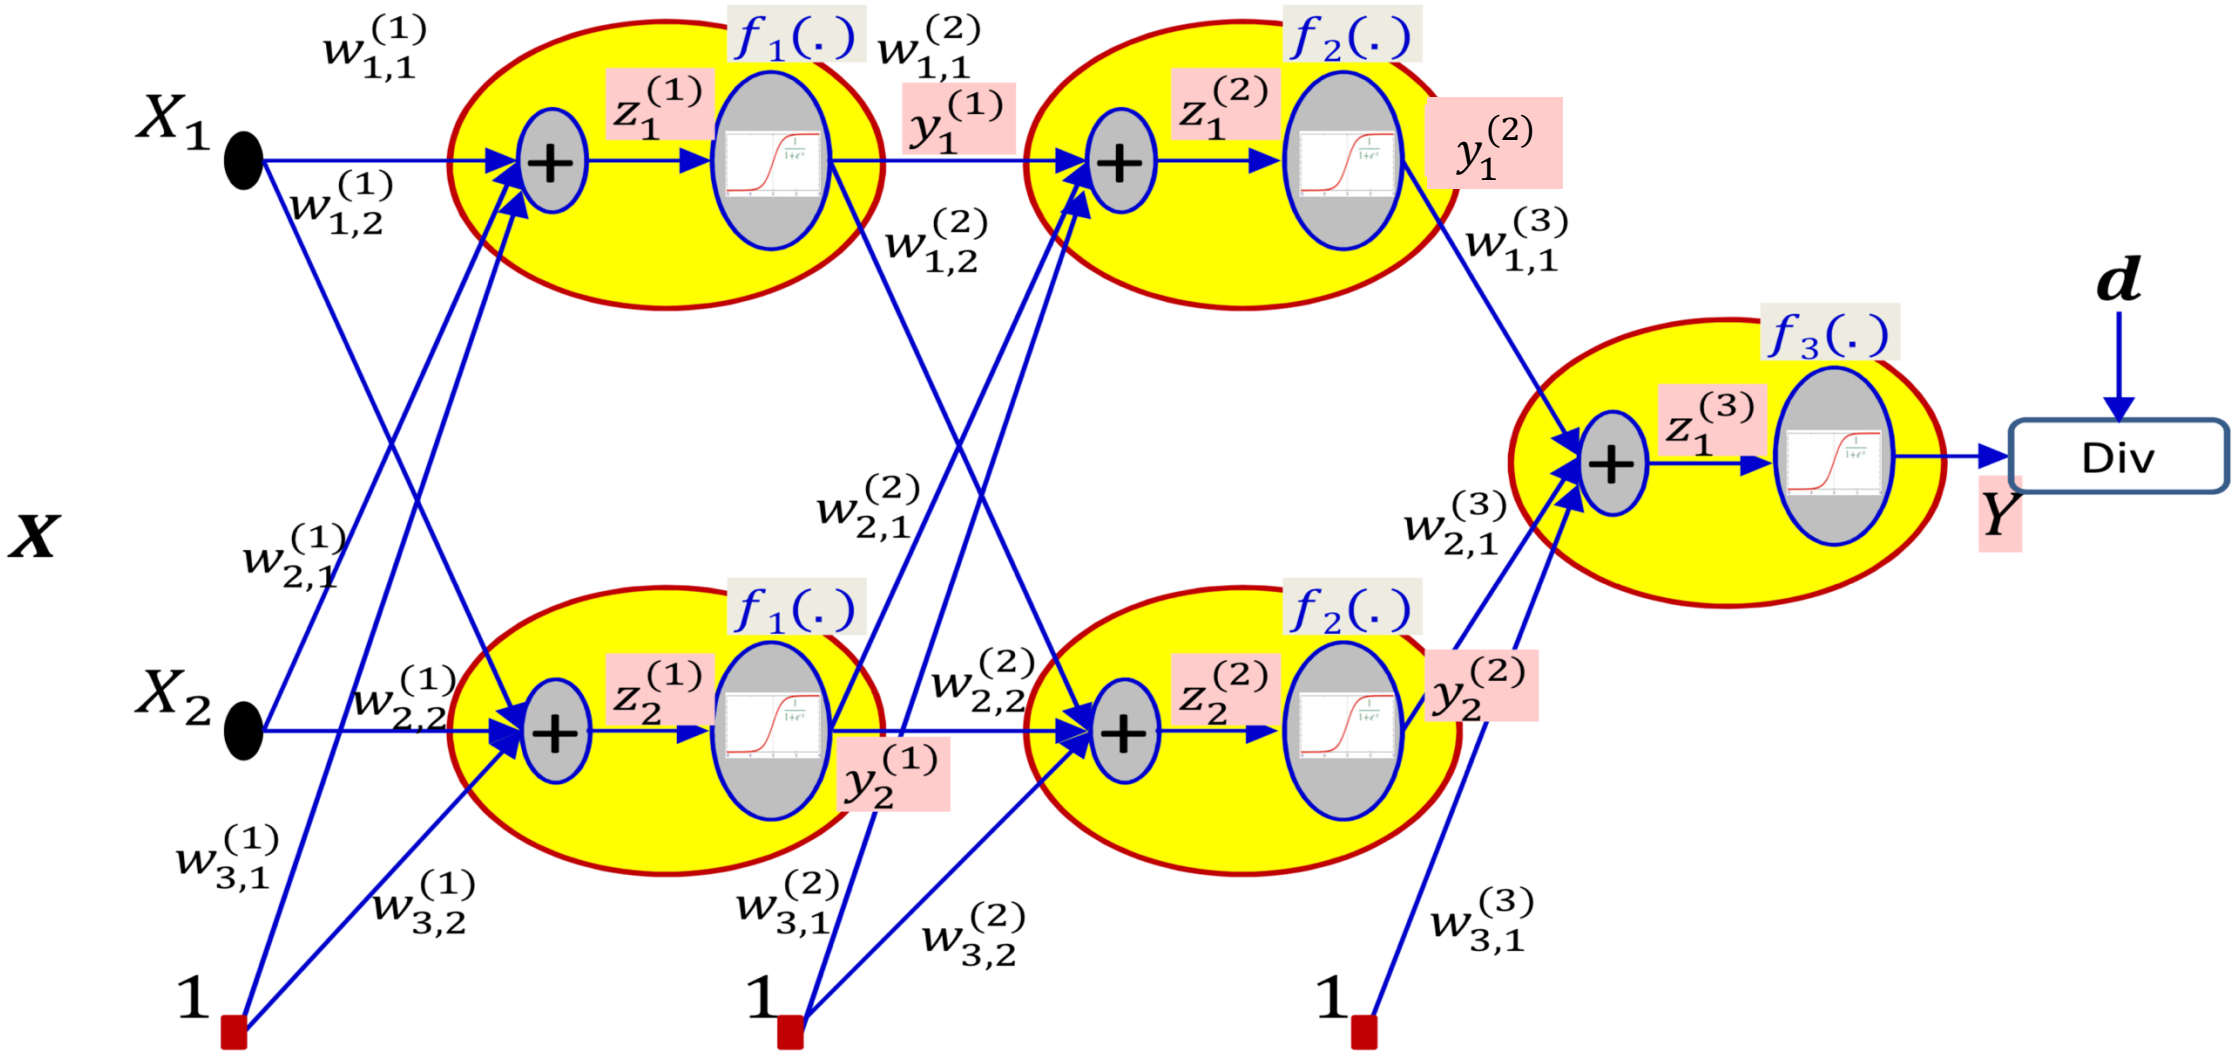
Algoritmo Gradiente Descendiente:

- Inicializar todos los pesos $\left\{W_{i,j}^{(k)}\right\}$
- Realizar:
  - Para todas las $i, j, k$, inicializar $\frac{dError}{dW_{i,j}^{(k)}} = 0$
  - Para todas los ejemplos $t = 1{:}\,T$
    - Para cada capa $k$ y para todas las unidades $i, j$:
      - Calcular: $\frac{dDiv(Y_t, d_t)}{dW_{i,j}^{(k)}}$
      - Calcular: $\frac{dError}{dW_{i,j}^{(k)}} \mathrel{+}= \frac{dDiv(Y_t, d_t)}{dW_{i,j}^{(k)}}$
  - Para cada capa $k$ y para todas las unidades $i, j$:

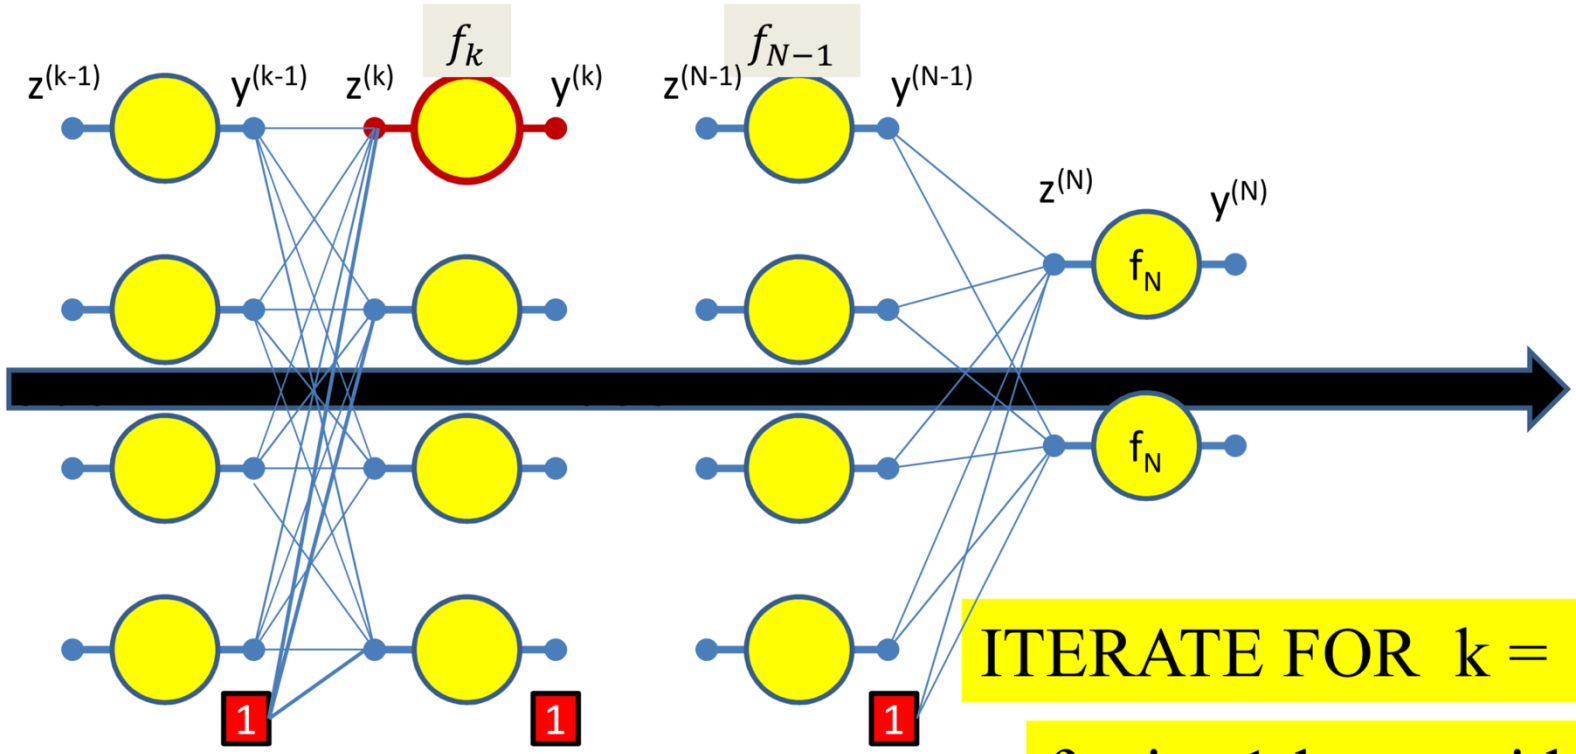
$$W_{i,j}^{(k)} = W_{i,j}^{(k)} - \propto \frac{dError}{dW_{i,j}^{(k)}}$$

  - Hasta que el $Error$ converja

# Aprendizaje:



# Aprendizaje: Forward




ITERATE FOR k = 1:N

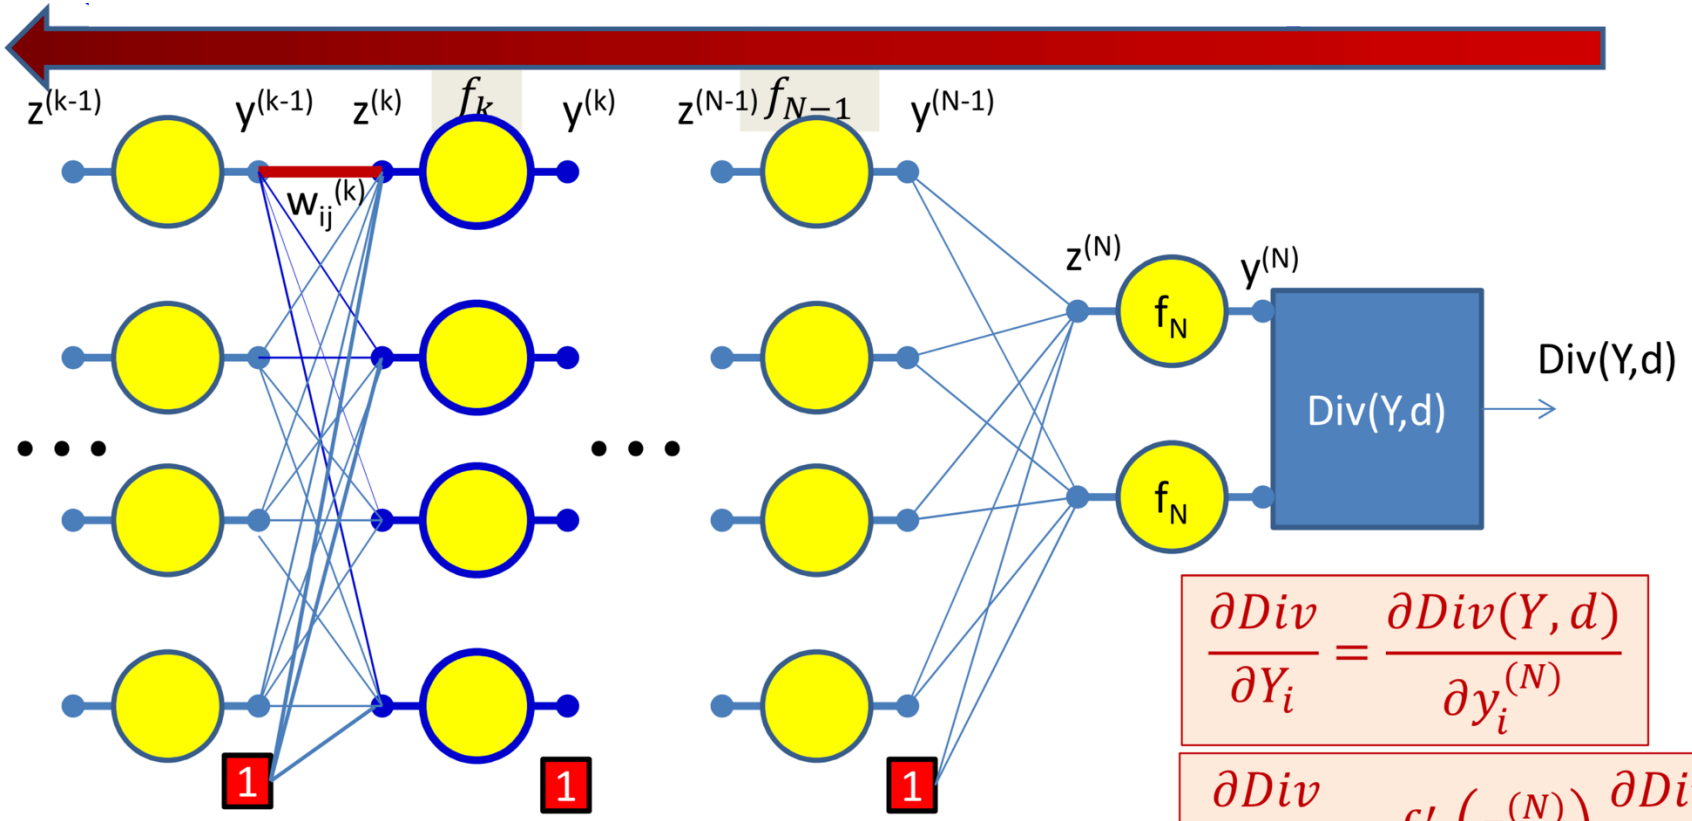
for j = 1:layer-width

$$y_i^{(0)} = x_i$$

$$z_j^{(k)} = \sum_i w_{ij}^{(k)} y_i^{(k-1)}$$

$$y_j^{(k)} = f_k\left(z_j^{(k)}\right)$$

# Aprendizaje: Backward




$$\frac{\partial Div}{\partial w_{ij}^{(k)}} = \frac{\partial z_j^{(k)}}{\partial w_{ij}^{(k)}} \frac{\partial Div}{\partial z_j^{(k)}} = y_i^{(k-1)} \frac{\partial Div}{\partial z_j^{(k)}}$$

$$\frac{\partial Div}{\partial Y_i} = \frac{\partial Div(Y,d)}{\partial y_i^{(N)}}$$

$$\frac{\partial Div}{\partial z_i^{(N)}} = f_N'\left(z_i^{(N)}\right) \frac{\partial Div}{\partial y_i^{(N)}}$$

$$\frac{\partial Div}{\partial y_i^{(k-1)}} = \sum_j w_{ij}^{(k)} \frac{\partial Div}{\partial z_j^{(k)}}$$

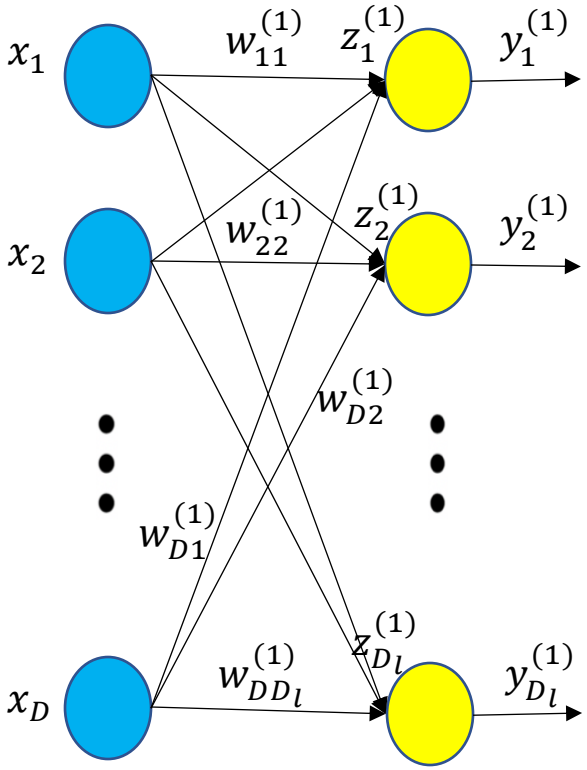
# Aprendizaje: Entrenamiento con BP

- Inicializar todos los pesos $\{W^{(1)}, W^{(2)}, \ldots, W^{(K)}\}$
- Realizar:
  - Inicializar $Error = 0$, Para todas las $i, j, k$, inicializar $\frac{dError}{dW_{i,j}^{(k)}} = 0$
  - Para todas los $t = 1{:}\,T$
    - Para cada capa $k$ y para todas las unidades $i, j$:
      - Paso "Forward":
        - Calcular la salida $Y_t$
        - Calcular $Error \mathrel{+}= Div(Y_t, d_t)$
      - Paso "Backward":
        - Calcular: $\frac{dDiv(Y_t, d_t)}{dW_{i,j}^{(k)}}$
        - Calcular: $\frac{dError}{dW_{i,j}^{(k)}} \mathrel{+}= \frac{dDiv(Y_t, d_t)}{dW_{i,j}^{(k)}}$
  - Para todas las $i, j, k$ actualizar:

$$W_{i,j}^{(k)} = W_{i,j}^{(k)} - \frac{\propto}{T} \frac{dError}{dW_{i,j}^{(k)}}$$

  - Hasta que el $Error$ converja

# Aprendizaje: En Deep Learning – formulación vectorial




$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_D \end{bmatrix} \qquad Z_k = \begin{bmatrix} z_1^{(k)} \\ z_2^{(k)} \\ \vdots \\ z_{D_k}^{(k)} \end{bmatrix} \qquad y_k = \begin{bmatrix} y_1^{(k)} \\ y_2^{(k)} \\ \vdots \\ y_{D_k}^{(k)} \end{bmatrix}$$

$$W = \begin{bmatrix} w_{11}^{(k)} & w_{21}^{(k)} & \cdots & w_{D_k 1}^{(k)} \\ w_{12}^{(k)} & w_{22}^{(k)} & \cdots & w_{D_k 2}^{(k)} \\ \vdots & \vdots & \ddots & \vdots \\ w_{1D_{l+1}}^{(k)} & w_{2D_{l+1}}^{(k)} & \cdots & w_{D_{l+1}D_{l+1}}^{(k)} \end{bmatrix} \qquad b_k = \begin{bmatrix} b_1^{(k)} \\ b_2^{(k)} \\ \vdots \\ b_{D_{l+1}}^{(k)} \end{bmatrix}$$

- El cálculo en forma vectorial de una capa se expresa:

$$Z_k = W_k y_{k-1} + b_k$$
$$y_k = f_k(Z_k)$$

# Aprendizaje: En Deep Learning – formulación vectorial

- La derivada de una función vectorial c.r.a un vector de entrada se llama "Jacobian"
- Es una matriz de derivadas parciales, que tiene la forma:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_M \end{bmatrix} = f\left(\begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_D \end{bmatrix}\right)$$

En notación vectorial

$$\mathbf{y} = f(\mathbf{z})$$

$$J_{\mathbf{y}}(\mathbf{z}) = \begin{bmatrix} \frac{\partial y_1}{\partial z_1} & \frac{\partial y_1}{\partial z_2} & \cdots & \frac{\partial y_1}{\partial z_D} \\ \frac{\partial y_2}{\partial z_1} & \frac{\partial y_2}{\partial z_2} & \cdots & \frac{\partial y_2}{\partial z_D} \\ \cdots & \cdots & \ddots & \cdots \\ \frac{\partial y_M}{\partial z_1} & \frac{\partial y_M}{\partial z_2} & \cdots & \frac{\partial y_M}{\partial z_D} \end{bmatrix}$$

$$\Delta y = J_y(z)\Delta z$$