Artificial Intelligence

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 17 - PAO 2024 – II

Agenda

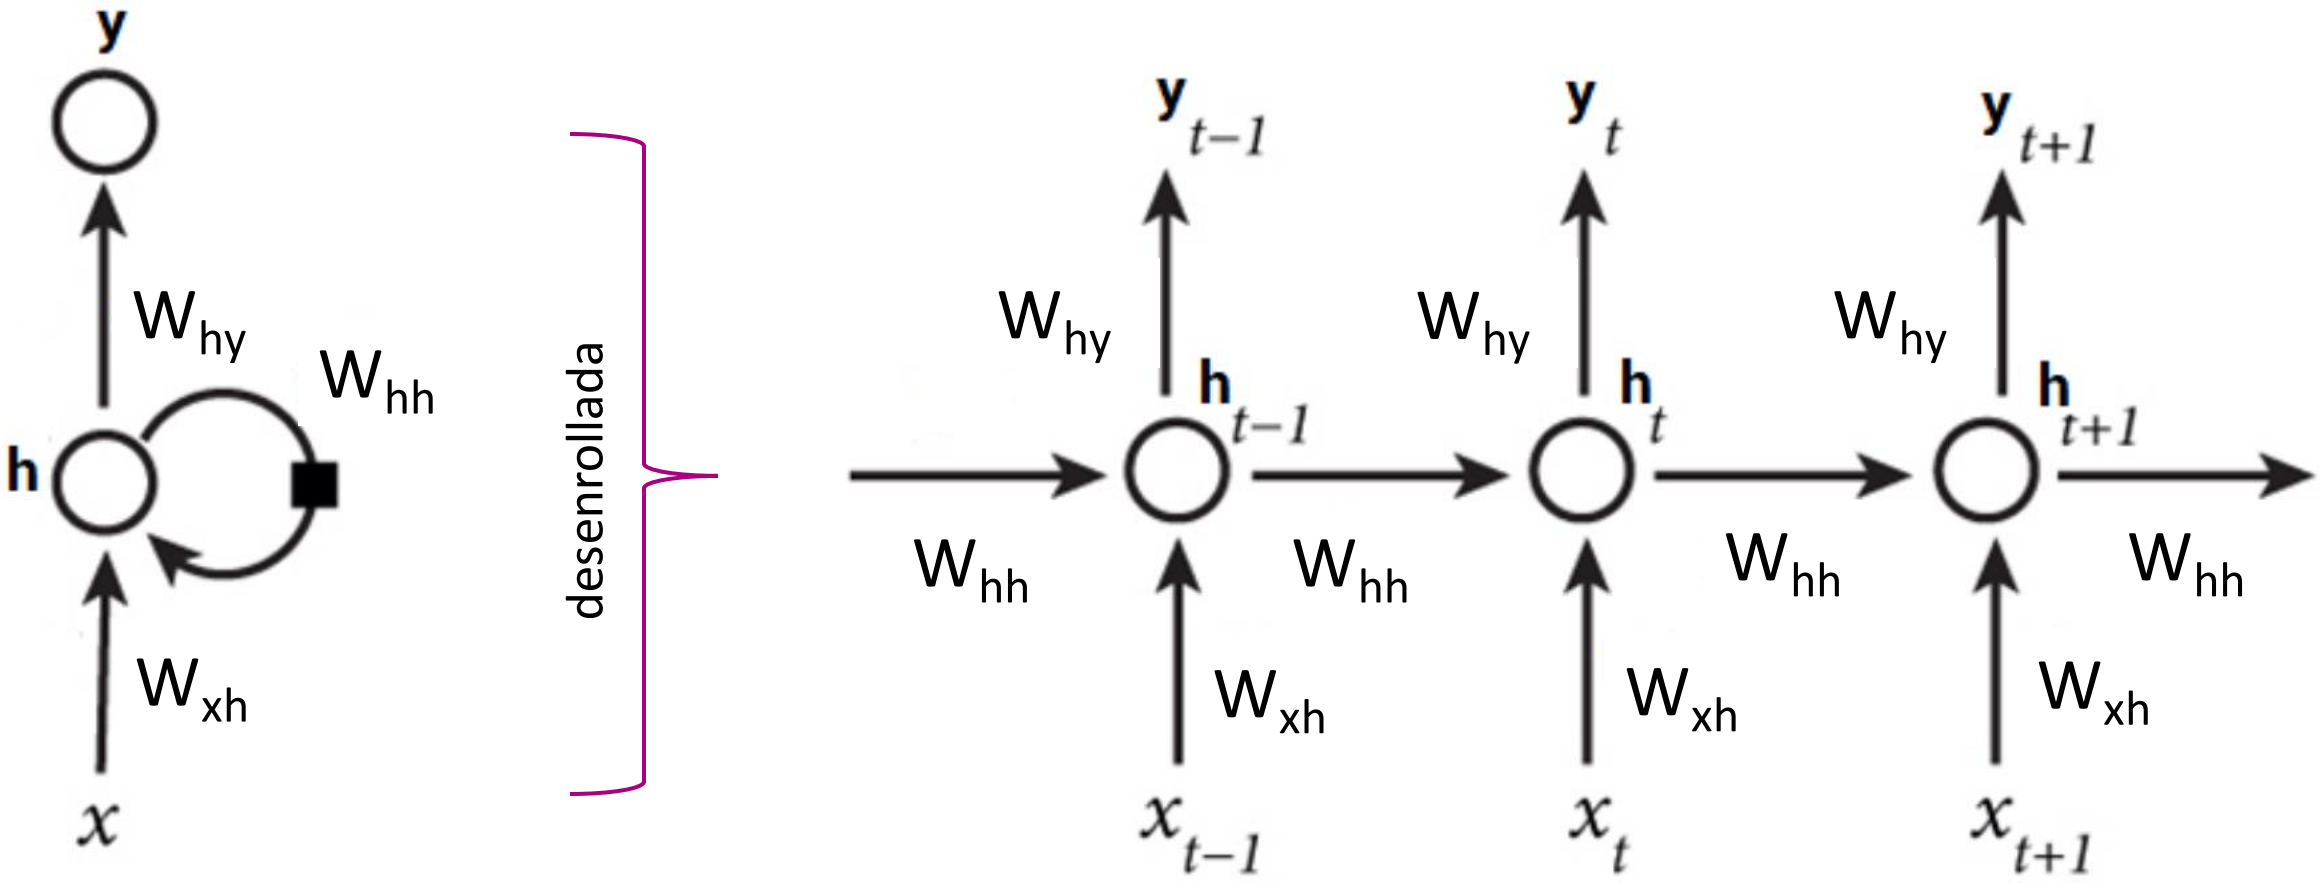
1. Redes neuronales recurrentes
   1.1 Aprendizaje basado en la propagación hacia a través del tiempo – BPTT
   1.2 Desvanecimiento del gradiente
   1.3 Introducción a las redes Long-Short Term Memory.

Redes neuronales recurrentes

- Back propagation en RNN – BPTT
  - Para entender y visualizar la propagación hacia atrás, desenrollemos la capa oculta de la red en todos los pasos de tiempo
  - Recuerde que en una RNN podemos tener o no salidas en cada paso de tiempo
  - En el caso de la propagación hacia delante (forward propagation), las entradas ingresan y avanzan en cada paso de tiempo
  - En la propagación hacia atrás (back propagation), de manera figurativa, retrocedemos en el tiempo para cambiar los pesos, por eso se conoce a esta técnica como propagación hacia atrás a través del tiempo (Back Propagation Through Time - BPTT).

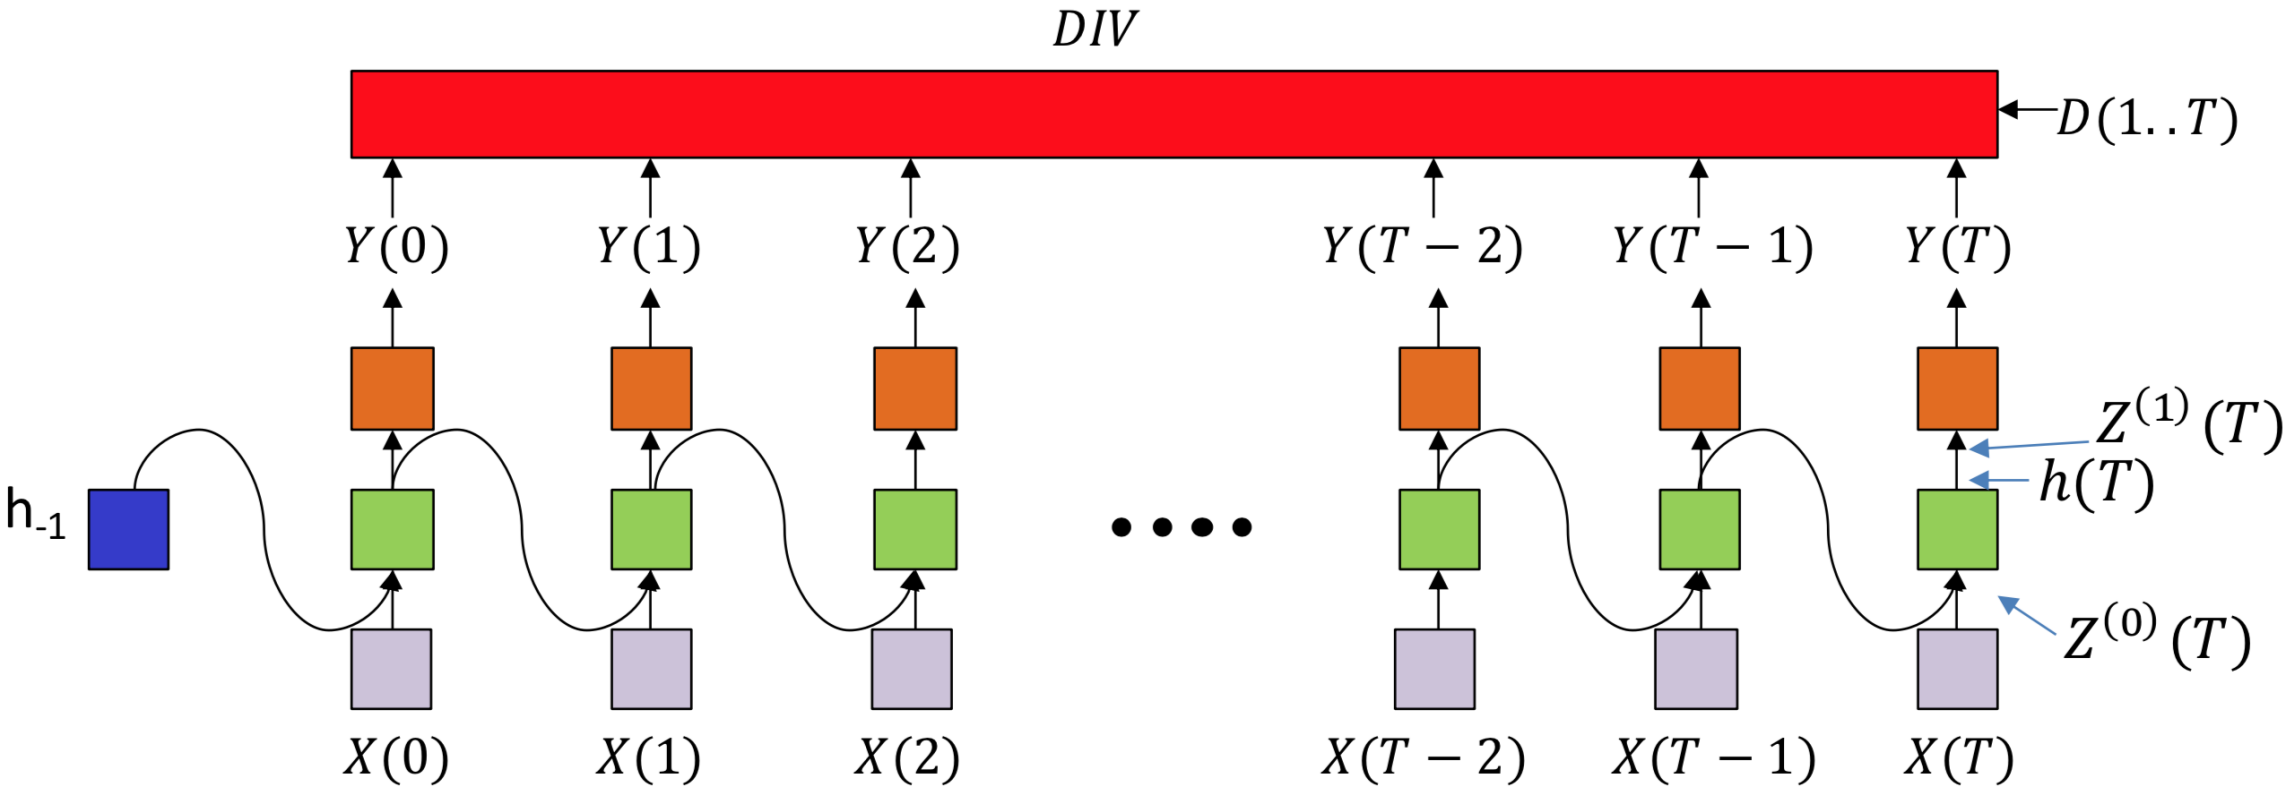
Redes neuronales recurrentes

- RNN desenrollada



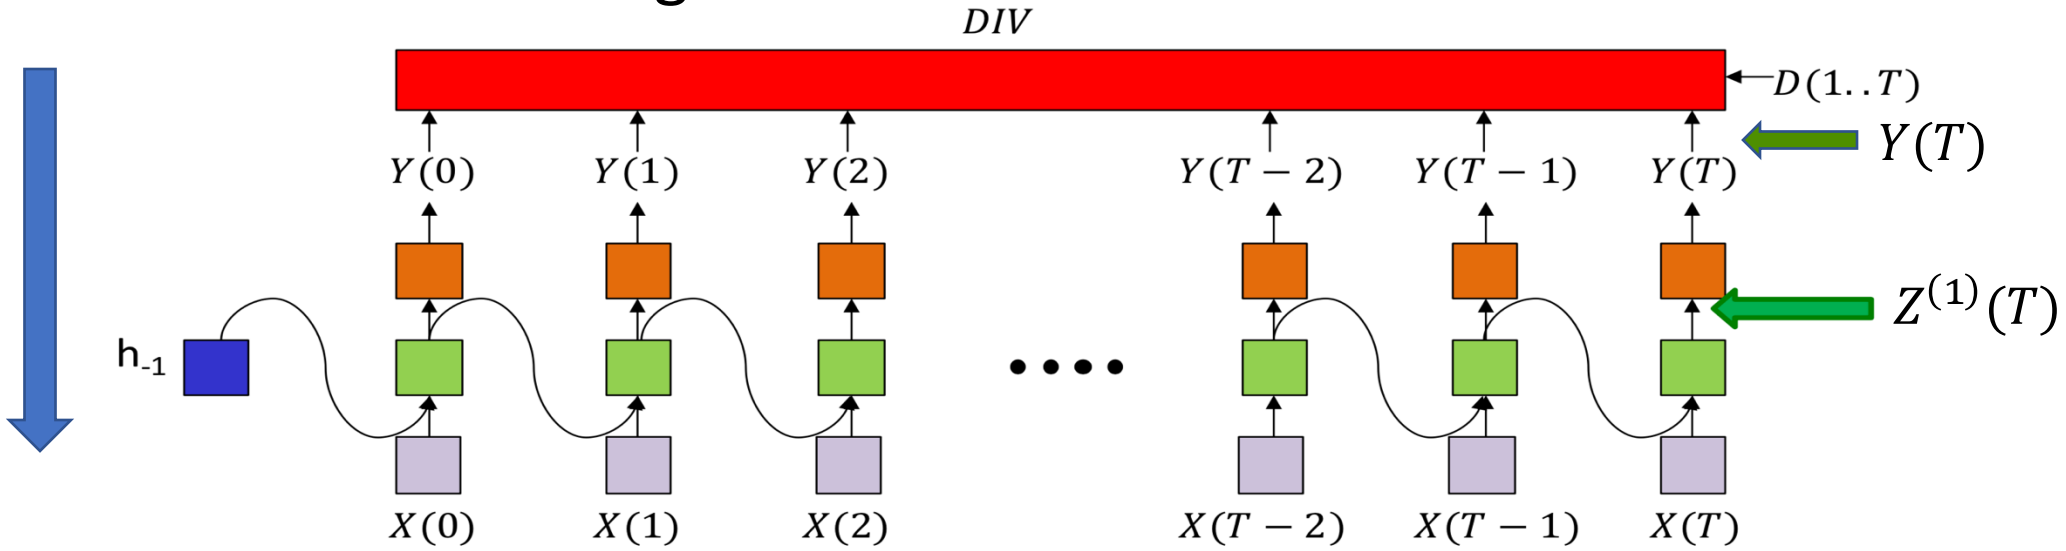
Redes neuronales recurrentes

- Cómo se calcula el gradiente en BPTT



Redes neuronales recurrentes

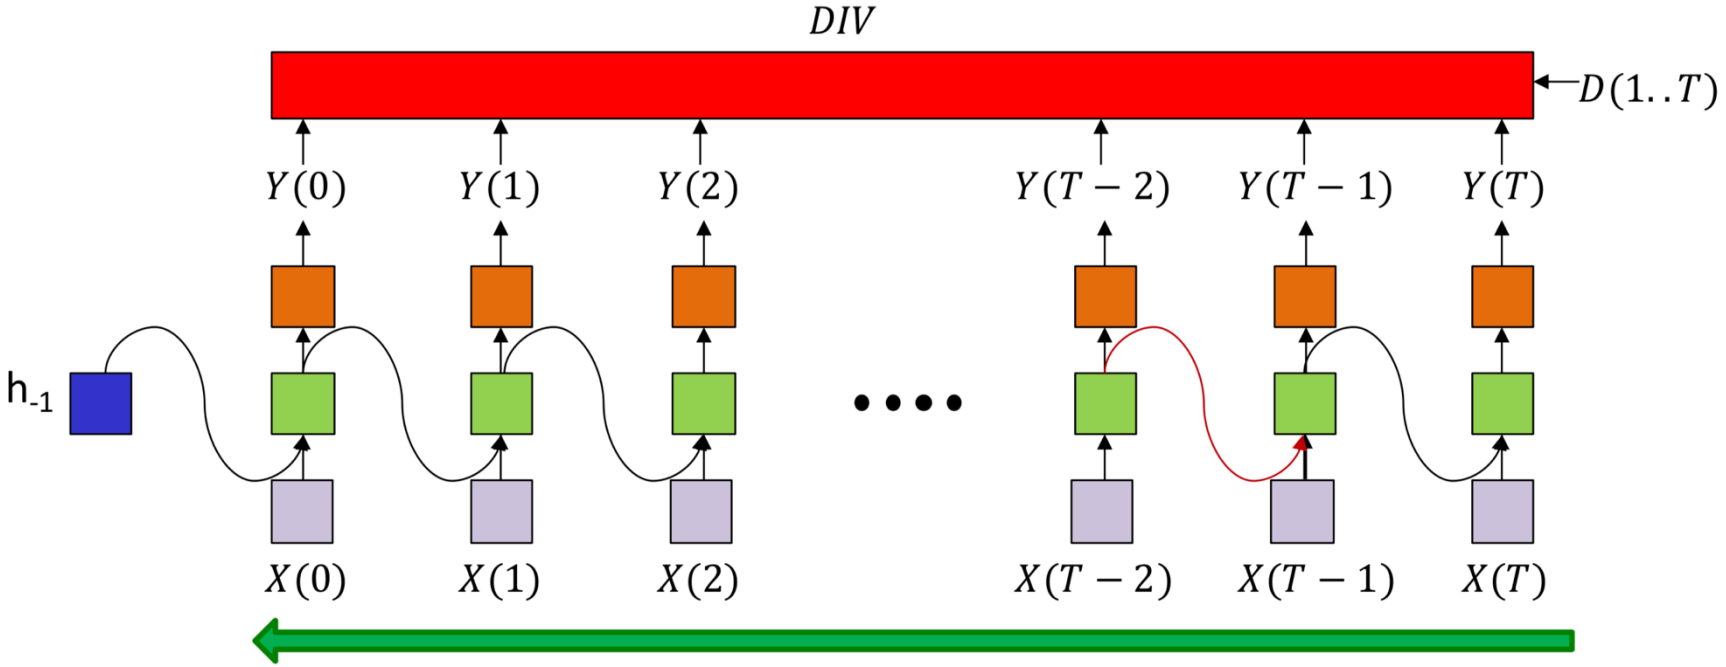
- Cómo se calcula el gradiente en BPTT



- Primer paso: Calcular $\frac{dDIV}{dY_i(T)}$ para todas las i
- Luego: $\frac{dDIV}{dZ_i^{(1)}(T)} = \frac{dDIV}{dY_i(T)} \frac{dY_i(T)}{dZ_i^{(1)}(T)}$
- o el vector: $\frac{dDIV}{dZ_i(T)} = \sum_i \frac{dDIV}{dY_i(T)} \frac{dY_i(T)}{dZ_i^{(1)}(T)}$

Redes neuronales recurrentes

- Cómo se calcula el gradiente en BPTT



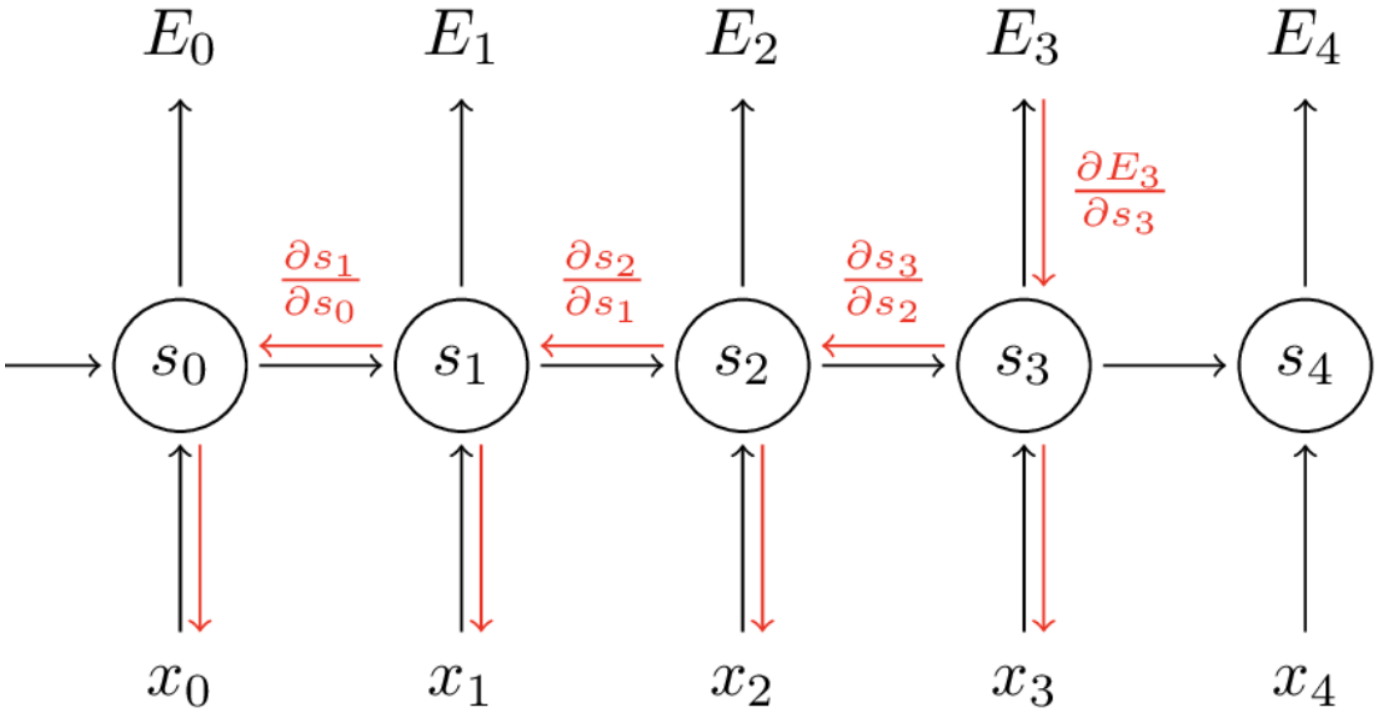
$$\frac{dDIV}{dh_{-1}} = \sum_j w_{ij}^{(11)} \frac{dDIV}{dZ_j^{(1)}(0)}$$

$$\frac{dDIV}{dw_{ij}^{(0)}} = \sum_t \frac{dDIV}{dZ_j^{(0)}(t)} X_i(t)$$

$$\frac{dDIV}{dw_{ij}^{(11)}} = \sum_t \frac{dDIV}{dZ_j^{(0)}(t)} h_i(t-1)$$

Redes neuronales recurrentes

- En otras palabras, debido a que W se usa en cada paso hasta la salida, necesitamos propagar los gradientes de regreso desde la salida a través de la red hasta $t = 0$
- Por ejemplo: la propagación del error desde $t = 3$ es:



Redes neuronales recurrentes

- Por ejemplo, para calcular el error después del tercer paso de tiempo con respecto al primero:

$$\frac{\partial E}{\partial W} = \frac{\partial E}{\partial Y_3} * \frac{\partial Y_3}{\partial h_3} * \frac{\partial h_3}{\partial Y_2} * \frac{\partial Y_2}{\partial h_1} \ldots$$ hasta llegar a $W^{(0)}$

- Vemos que hay una larga dependencia
- Al aplicar la regla de la cadena, si cualquiera de los gradientes se acerca a 0, entonces todos los gradientes se acercarán a 0 exponencialmente de manera rápida, debido a la multiplicación
- Esos estados ya no ayudarían a la red a aprender nada
- Esto se conoce como el problema de **desvanecimiento del gradiente**

Long Short Term Memory Networks - LSTM

- Las redes Long Short Term Memory - LSTM, resuelven este problema, son un tipo especial de RNN
- Son capaces de aprender dependencias a largo plazo
- Fueron propuestas por Hochreiter y Schmidhuber en 1997
- Funcionan bien en una gran variedad de problemas
- Las LSTM también tienen esta estructura tipo secuencial, pero el módulo recurrente tiene una estructura diferente; en lugar de tener una sola capa de red neuronal, tienen múltiples capas, que interactúan de una manera particular
- Las LSTM tienen 3 puertas: Una de entrada, una de olvido y una de salida