Artificial Intelligence

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

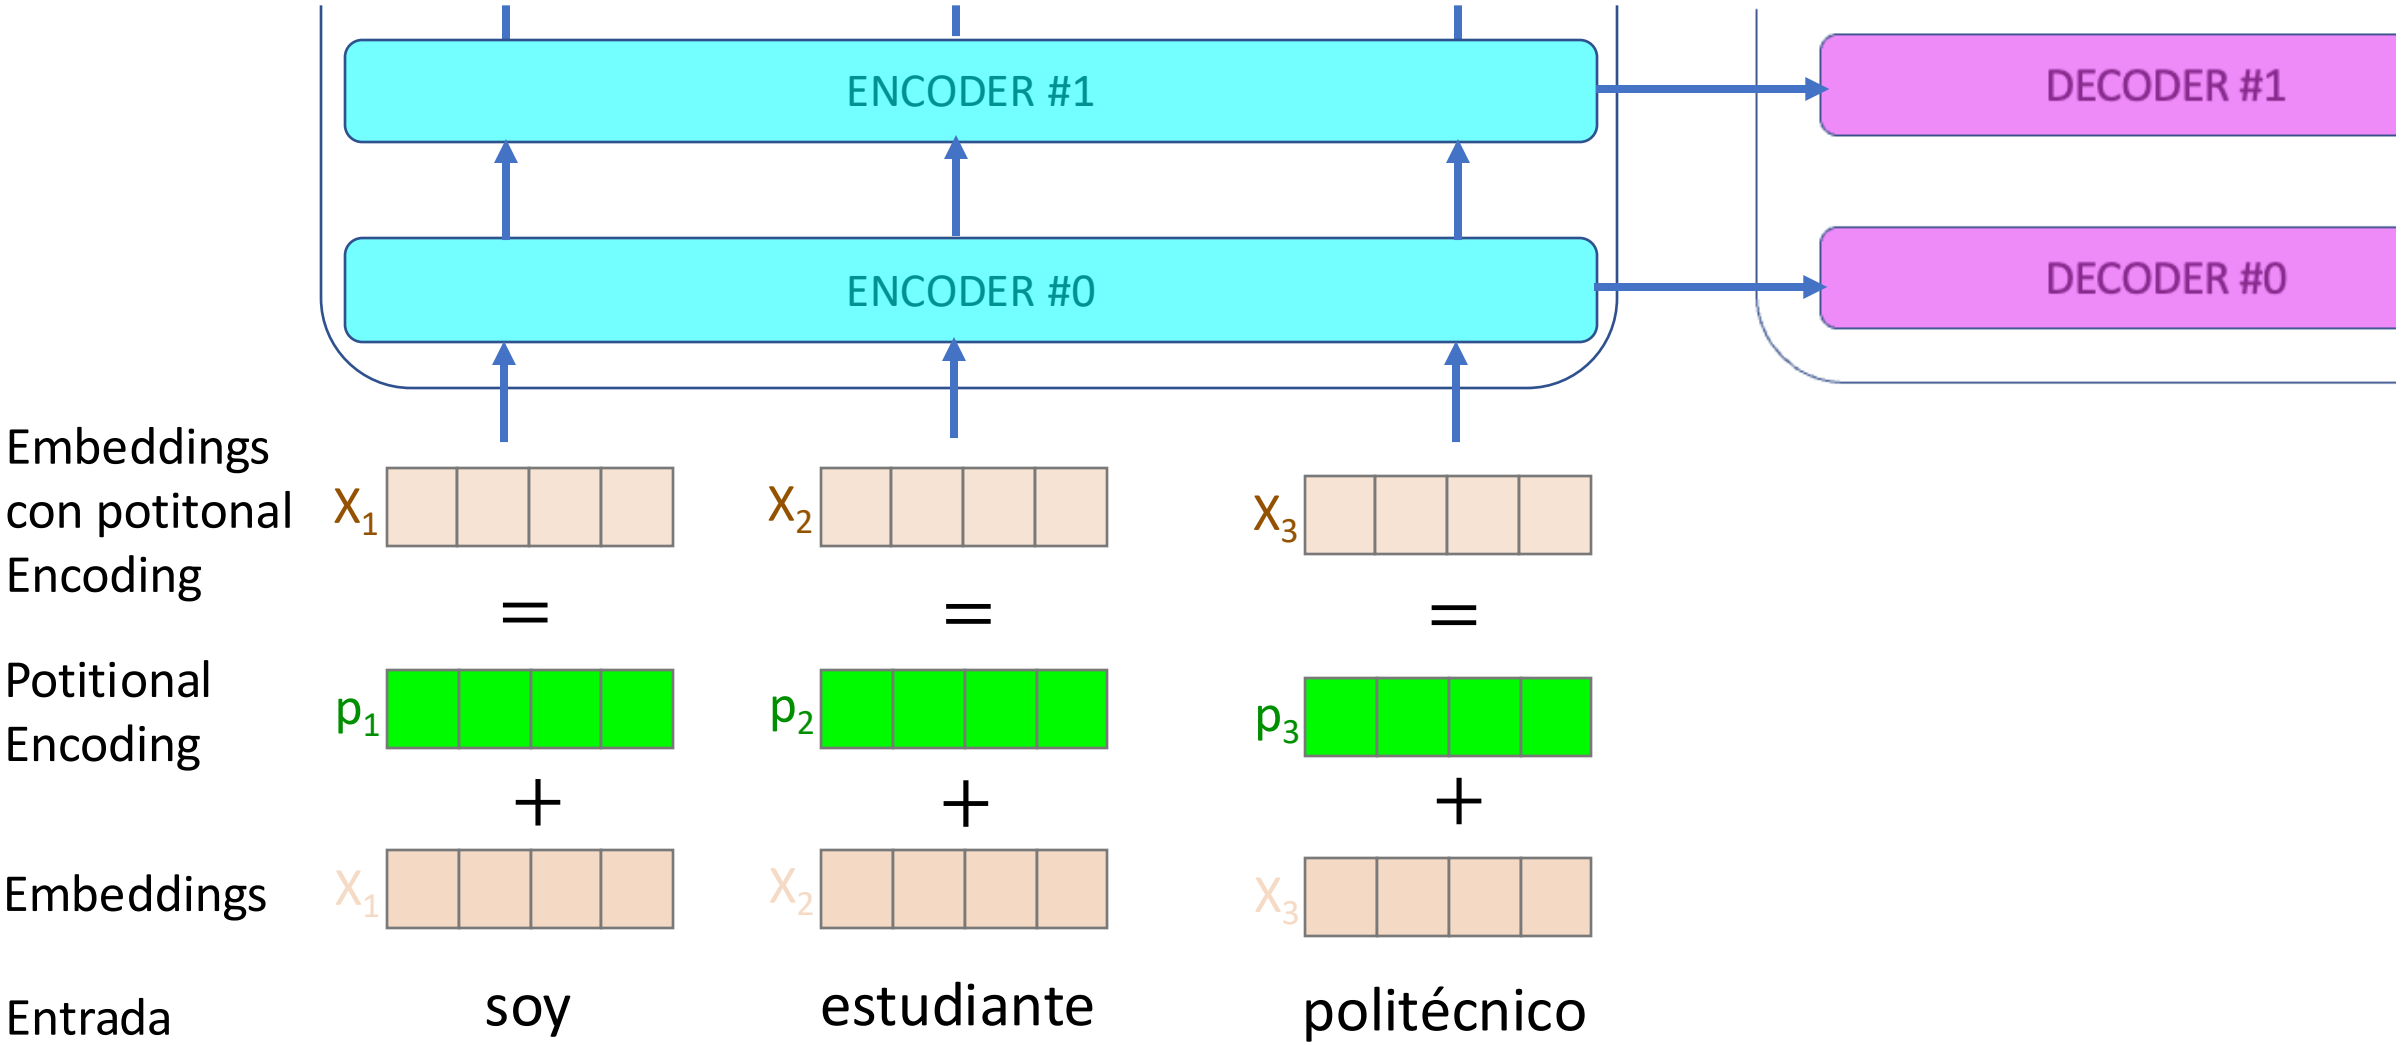
Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 20 - PAO 2024 – II

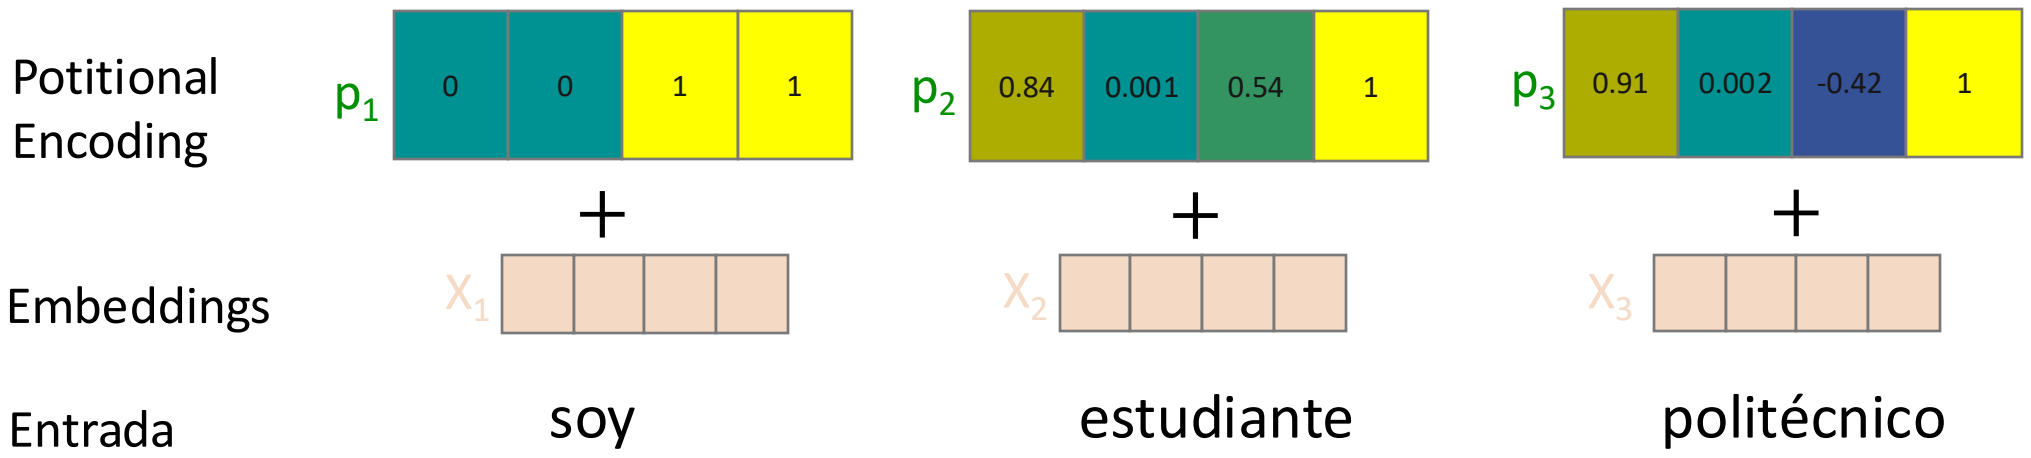
Agenda

1. Transformers
2. Ejemplo sobre embedddings
   2.1 Palabras
   2.2 Posición
3. Métricas de evaluación de modelos en ML-DL

Transformers – Codificación de posición (positional encoding)

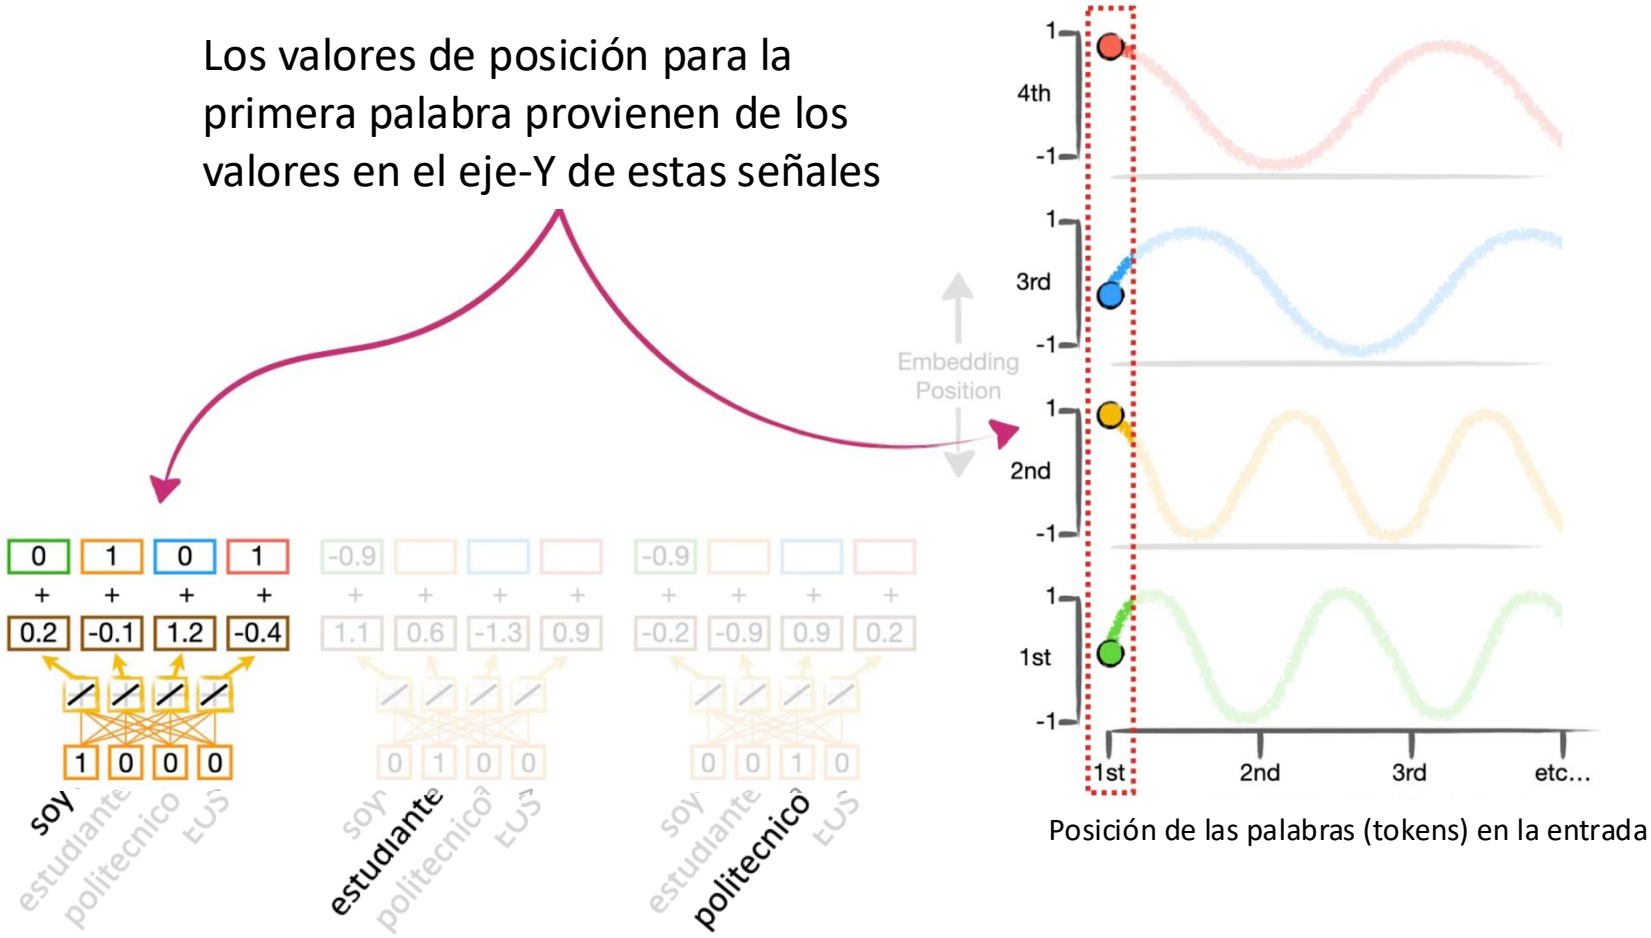


Transformers



Transformers

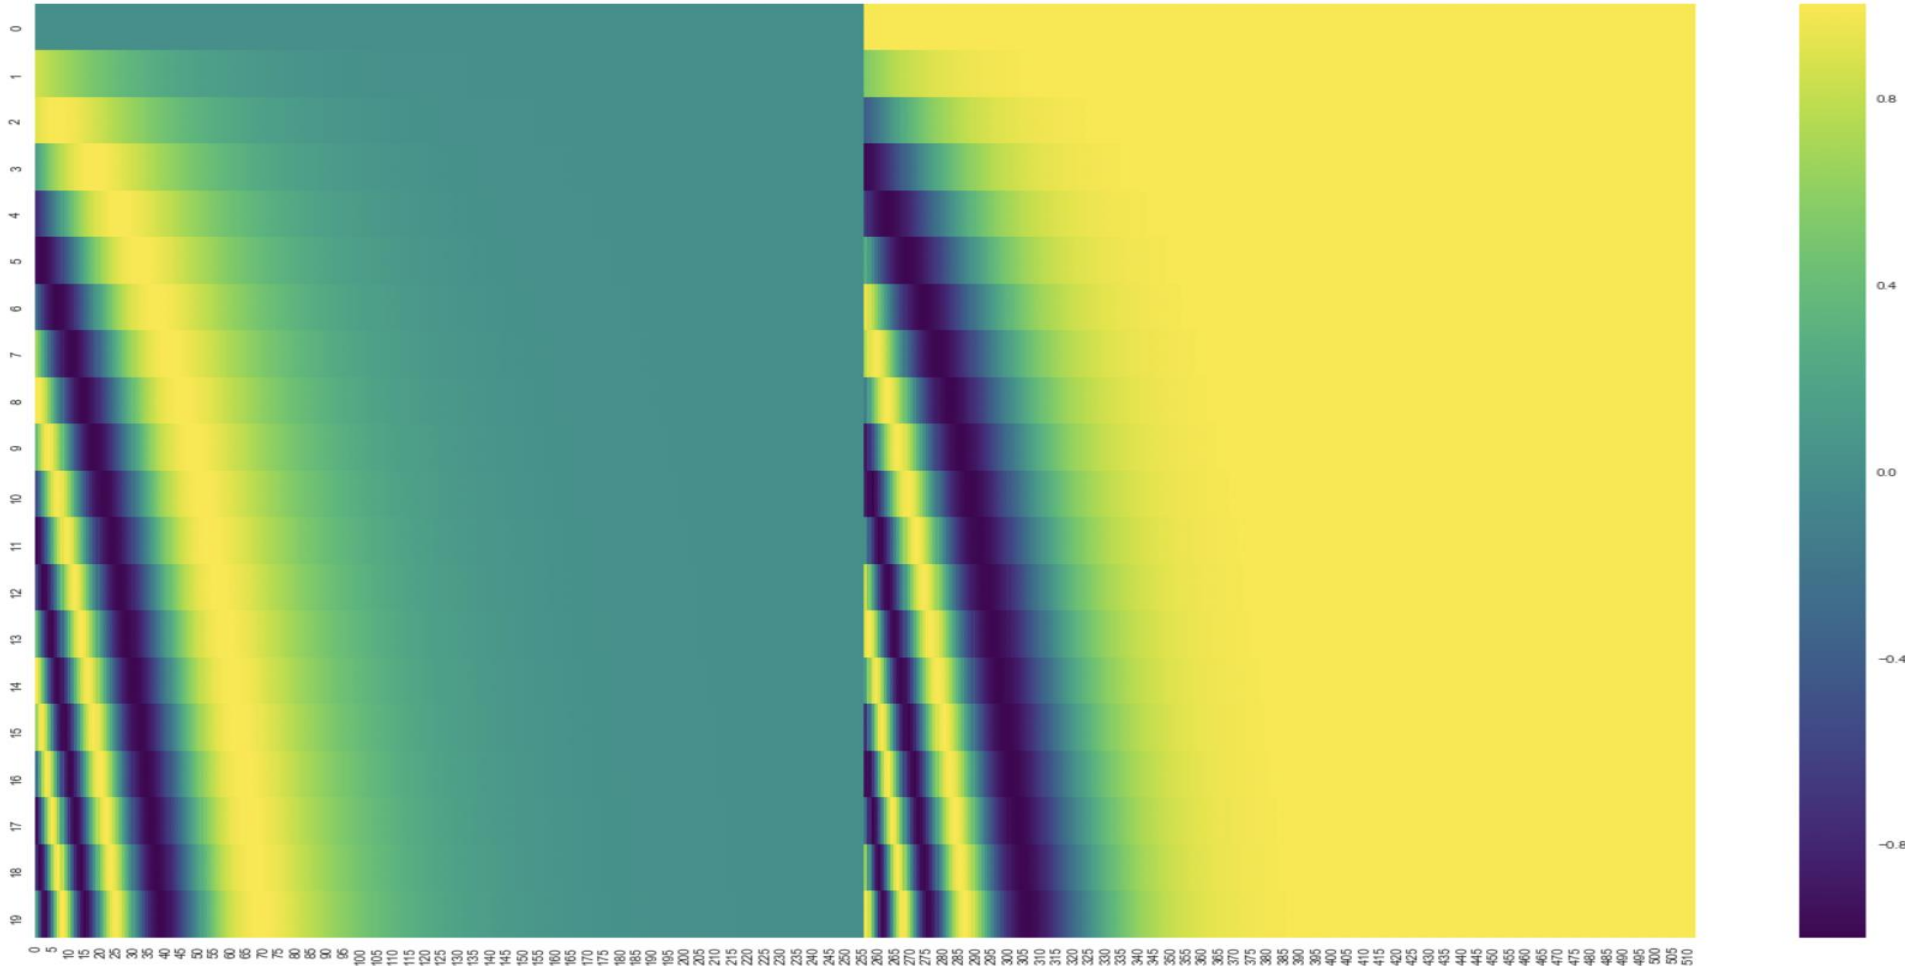
- Por ejemplo, para la primera palabra, el primer valor embedding (en el extremo izquierdo) es 0



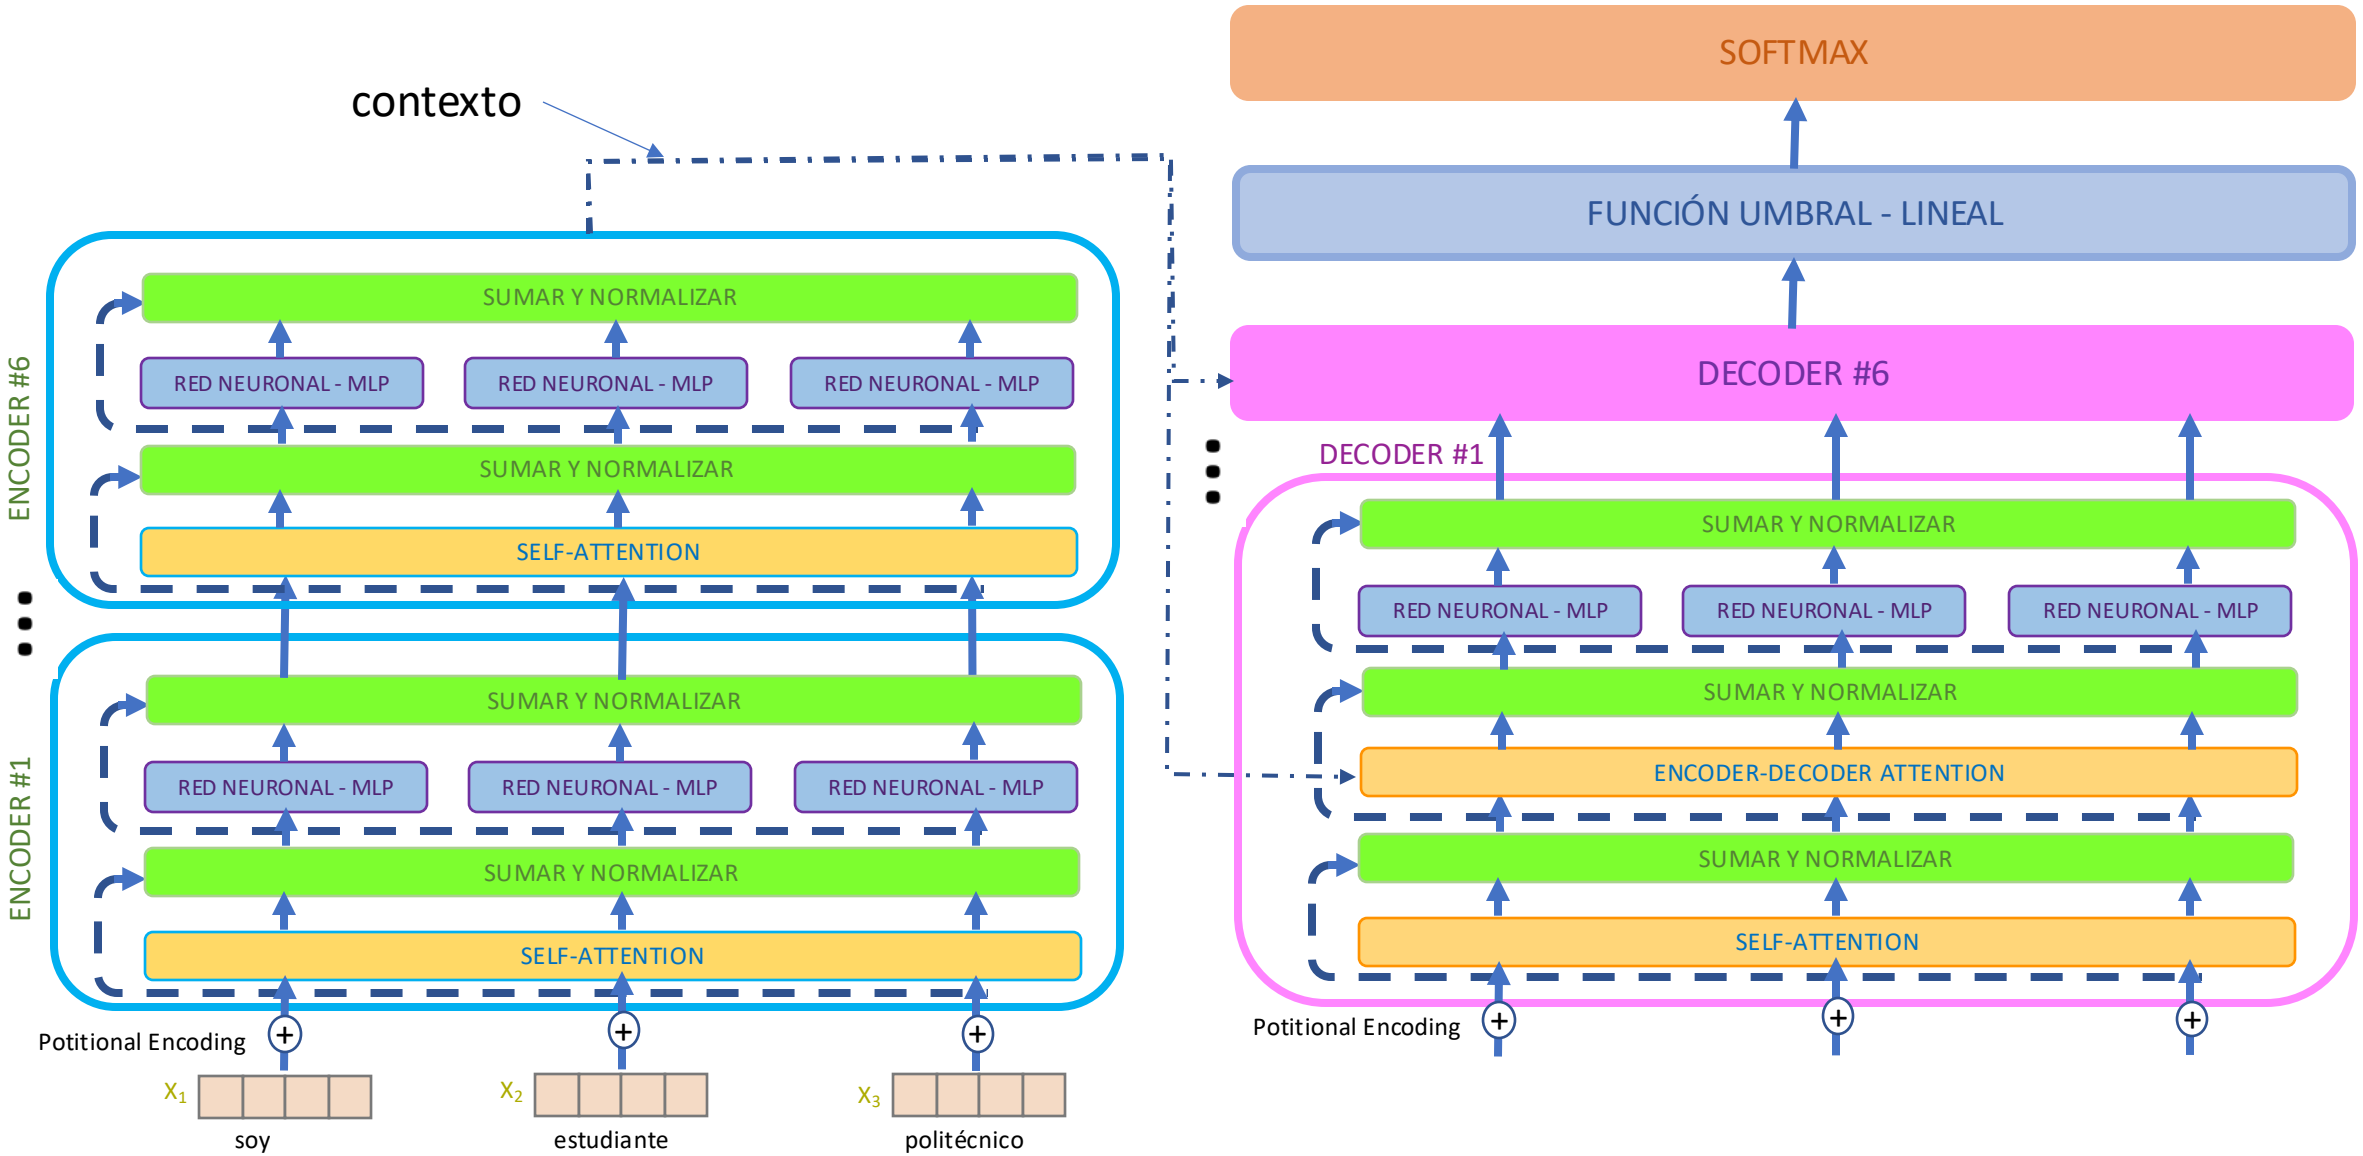
Posición de las palabras (tokens) en la entrada

Transformers

- Por ejemplo, en el embedding posicional para 20 palabras (filas) con un tamaño de 512 (columnas), los valores de la izquierda generados con una función seno; y los derecha con coseno. Luego se concatenan, por fila para formar los vectores de codificación posicional de la entrada.



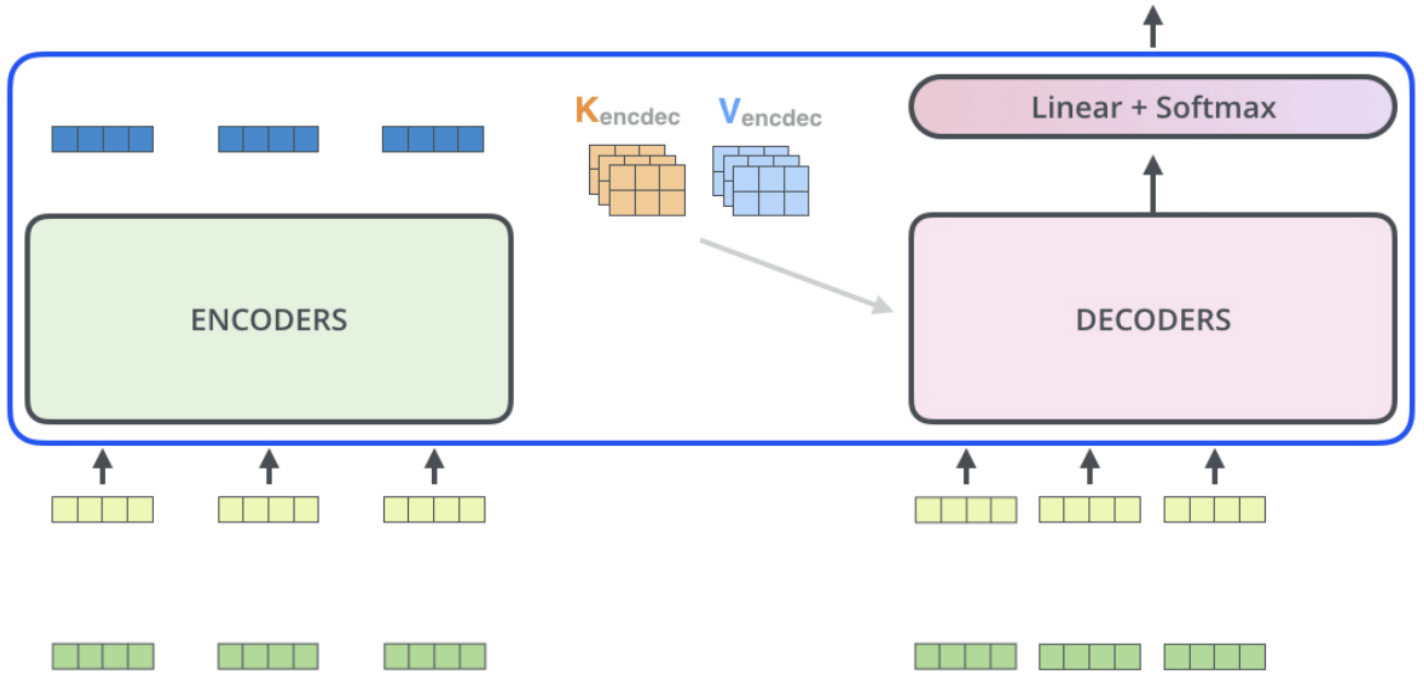
Transformers - decodificador



Transformers

Decoding time step: 1 2 3 4 5 6

Salida: Я студент політехніки <end of sentence>



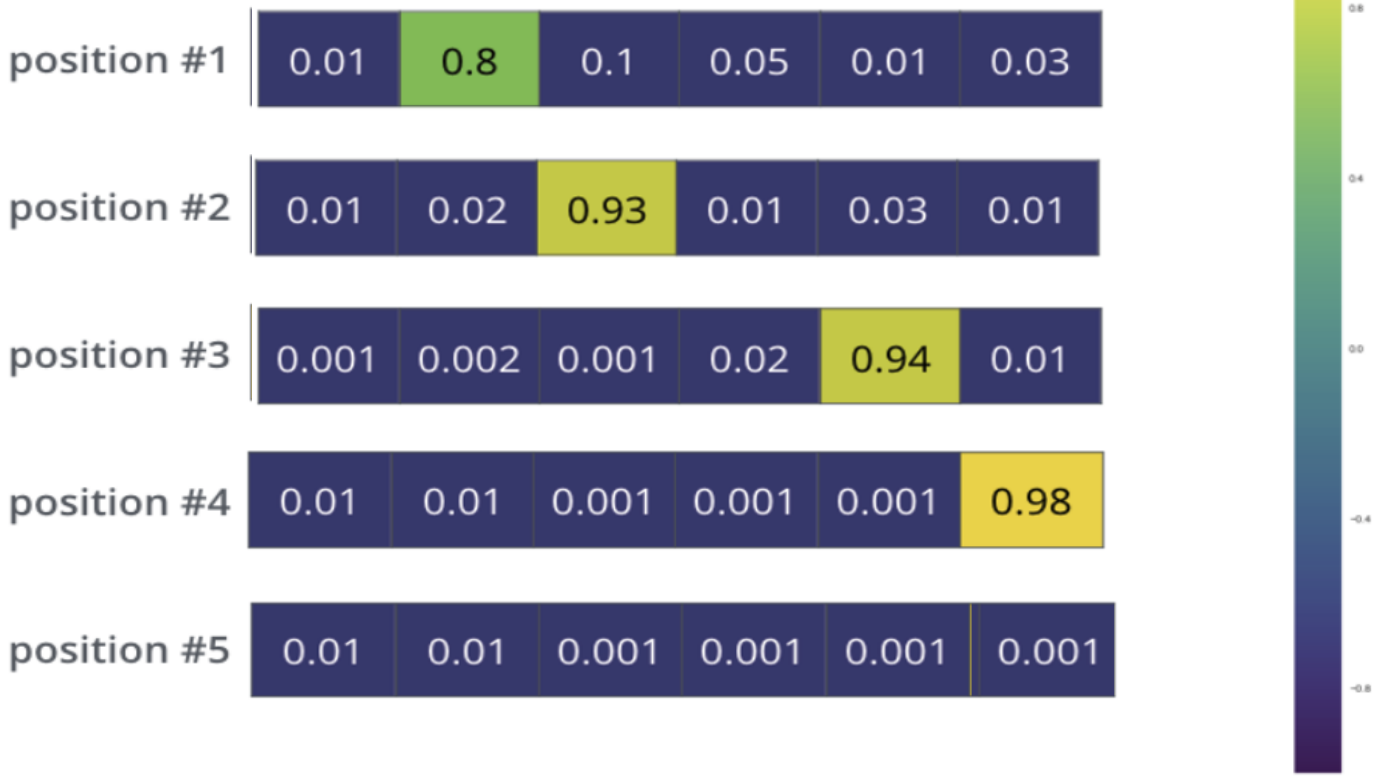
entrada soy estudiante politécnico

salida anterior Я студент політехніки

Transformers

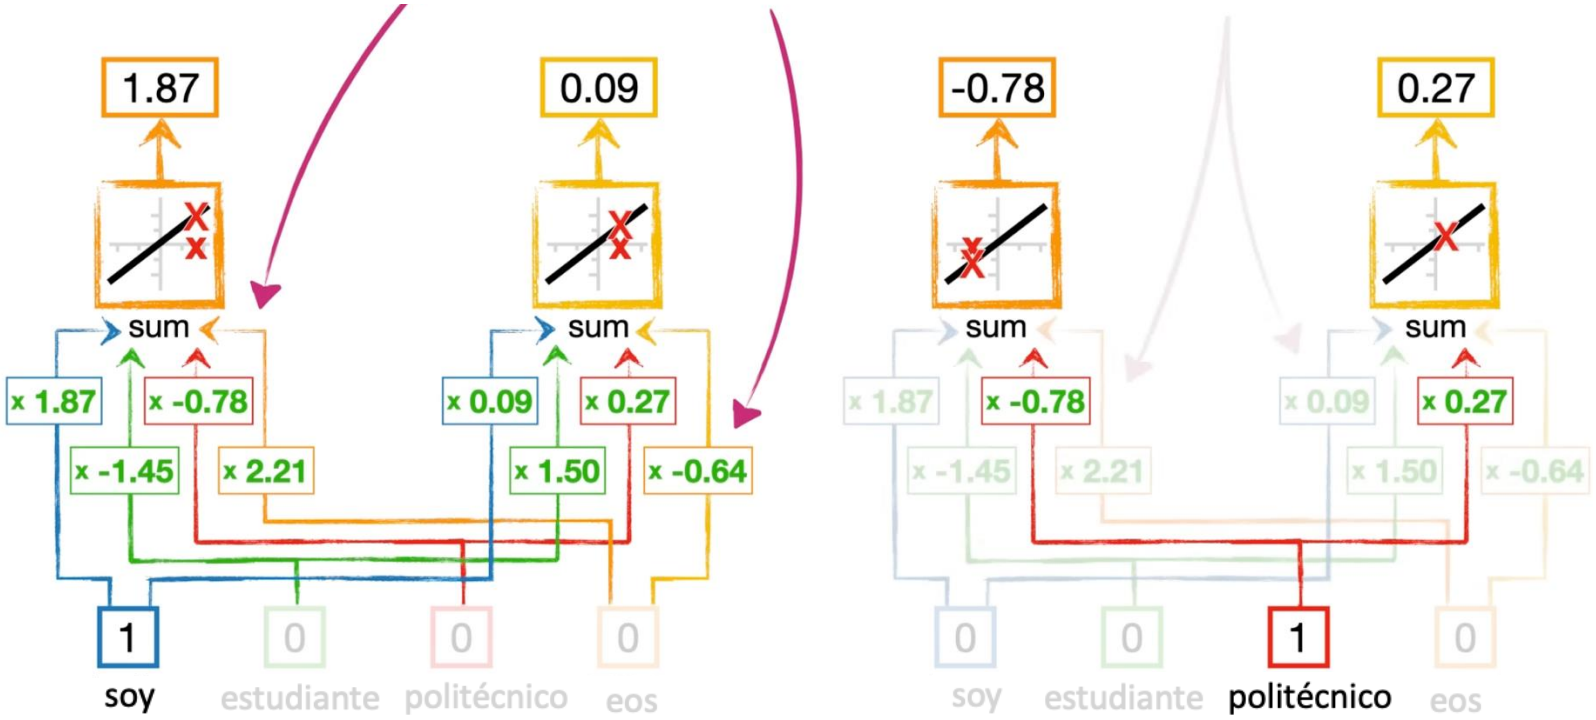
Salidas del modelo entrenado

Vocabulario salida: un soy estudiante de politécnico <eos>



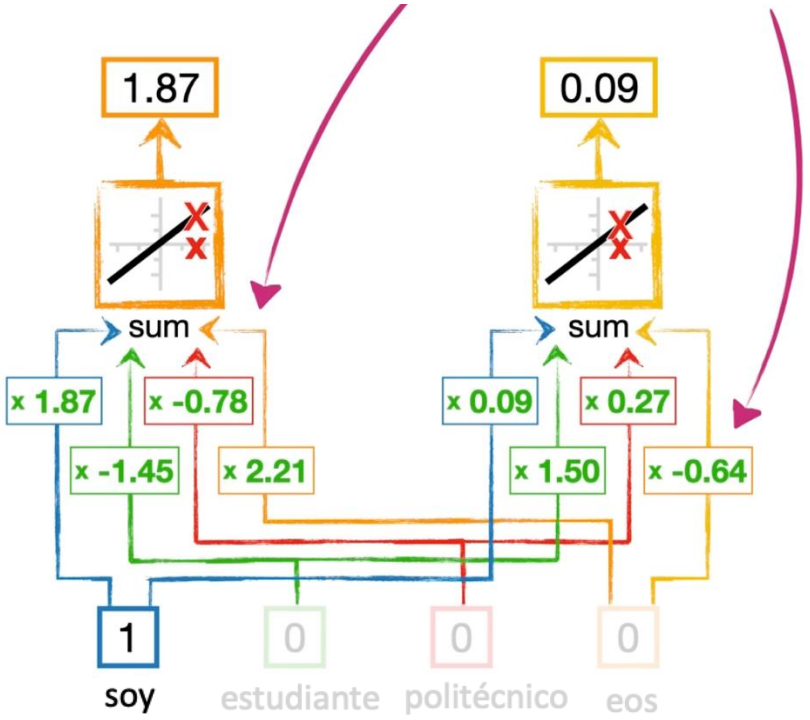
Transformers - embeddings

Esto es, los pesos en la red para ”soy”

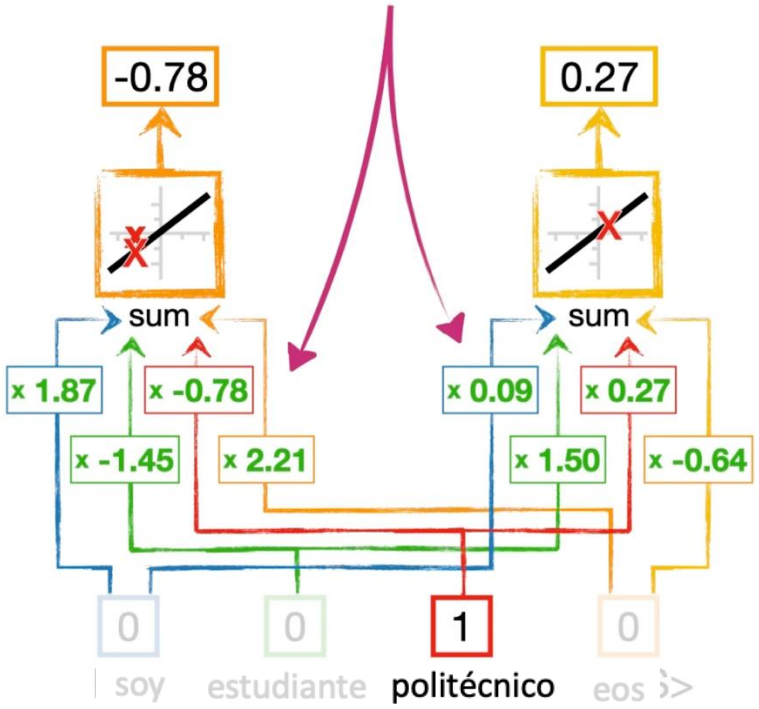


Transformers - embeddings

Esto es, los pesos en la red para ”soy”

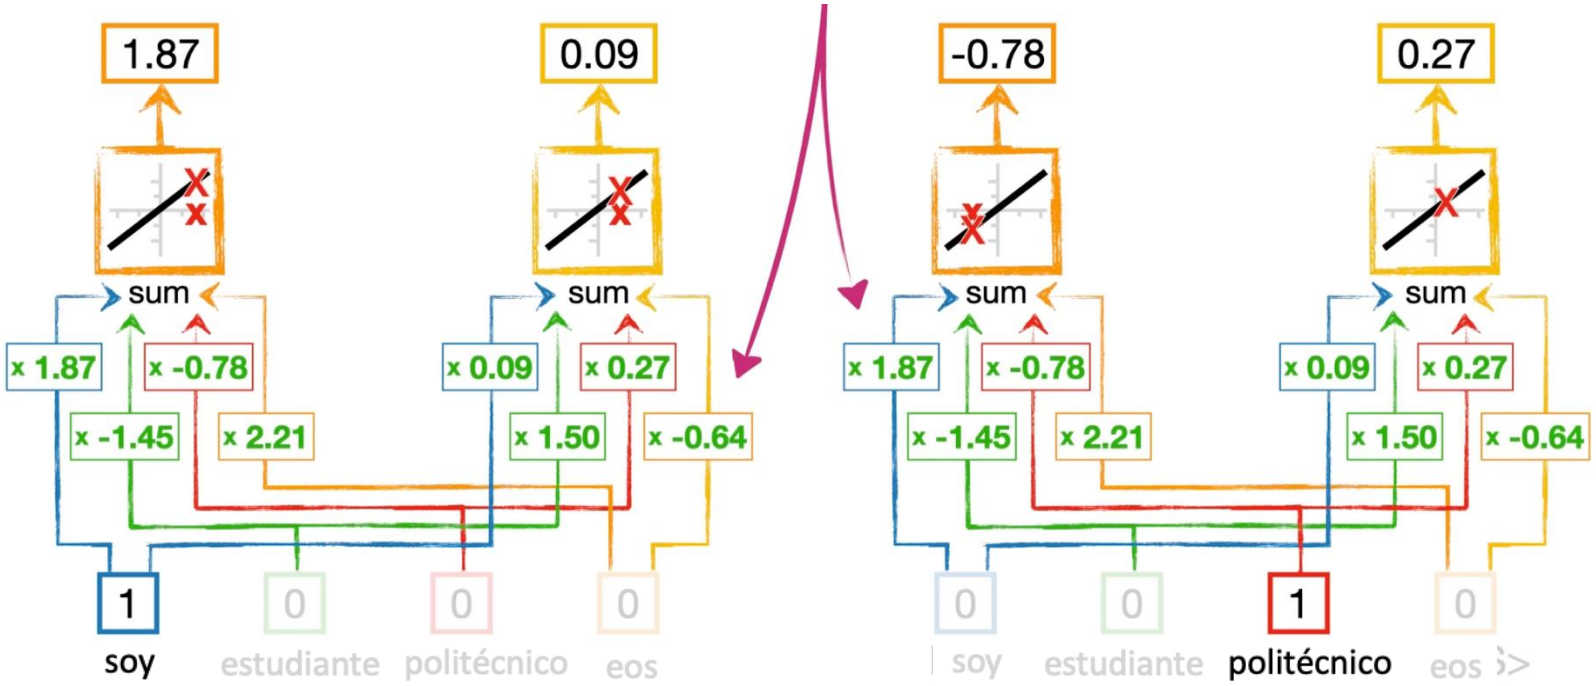


Son los mismos pesos que para ”politécnico”



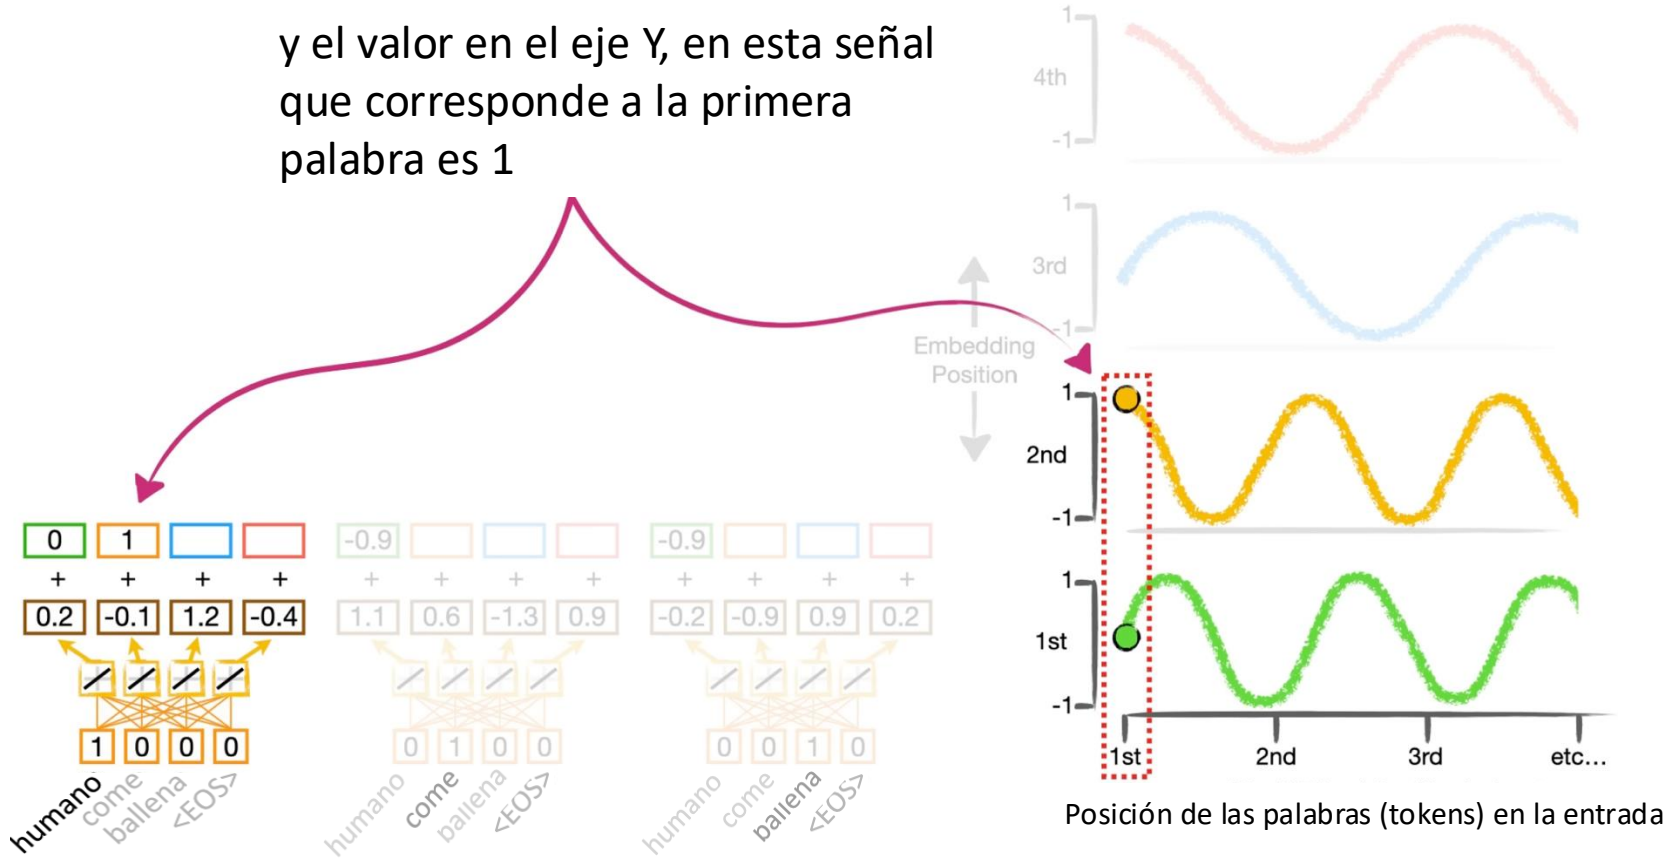
Transformers - embeddings

Además, recordar que son redes neuronales, por lo tanto la actualización de los pesos ocurre a través de back-propagation



Transformers – embeddings de posición

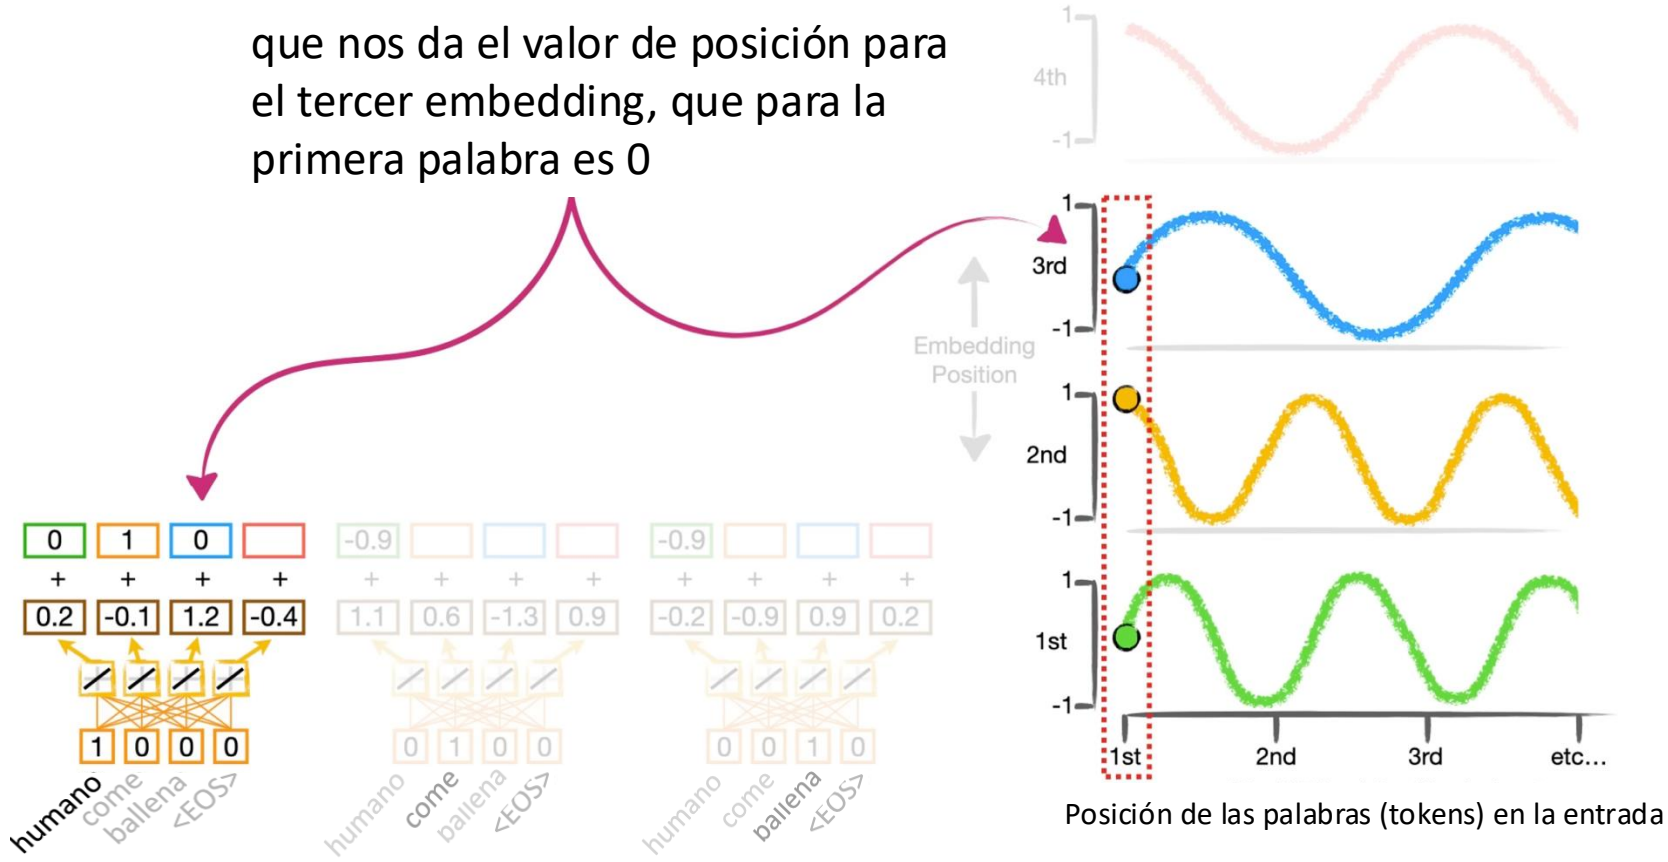
y el valor en el eje Y, en esta señal que corresponde a la primera palabra es 1



Posición de las palabras (tokens) en la entrada

Transformers – embeddings de posición

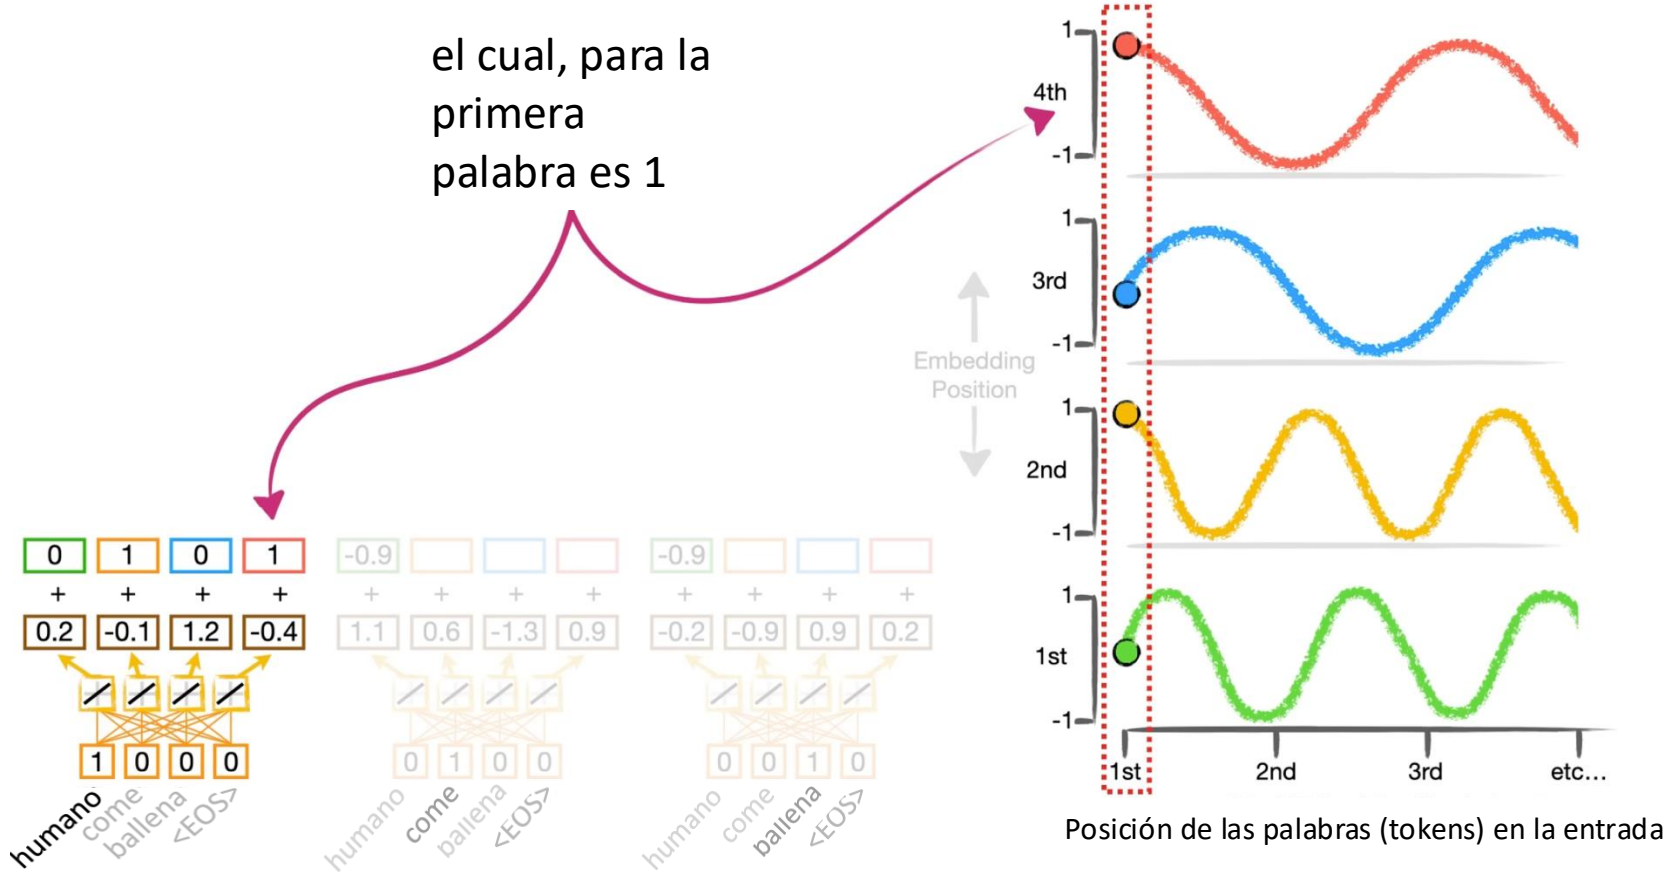
que nos da el valor de posición para el tercer embedding, que para la primera palabra es 0



Posición de las palabras (tokens) en la entrada

Transformers – embeddings de posición

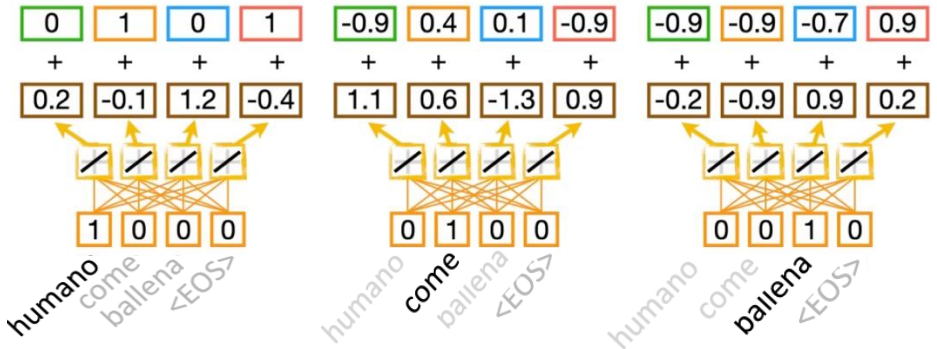
el cual, para la primera palabra es 1

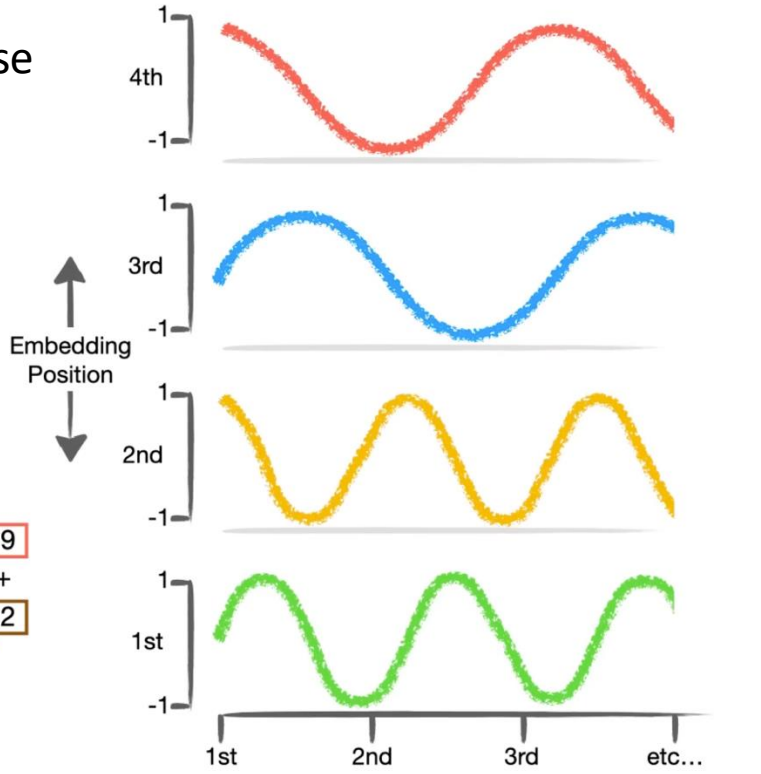


Posición de las palabras (tokens) en la entrada

Transformers – embeddings de posición

Notar que las señales Seno y Coseno se repiten, puede ocurrir que 2 palabras obtengan el mismo valor de posición

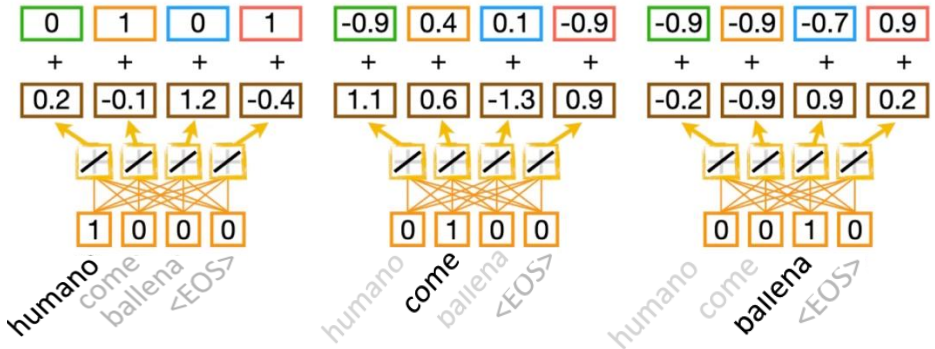


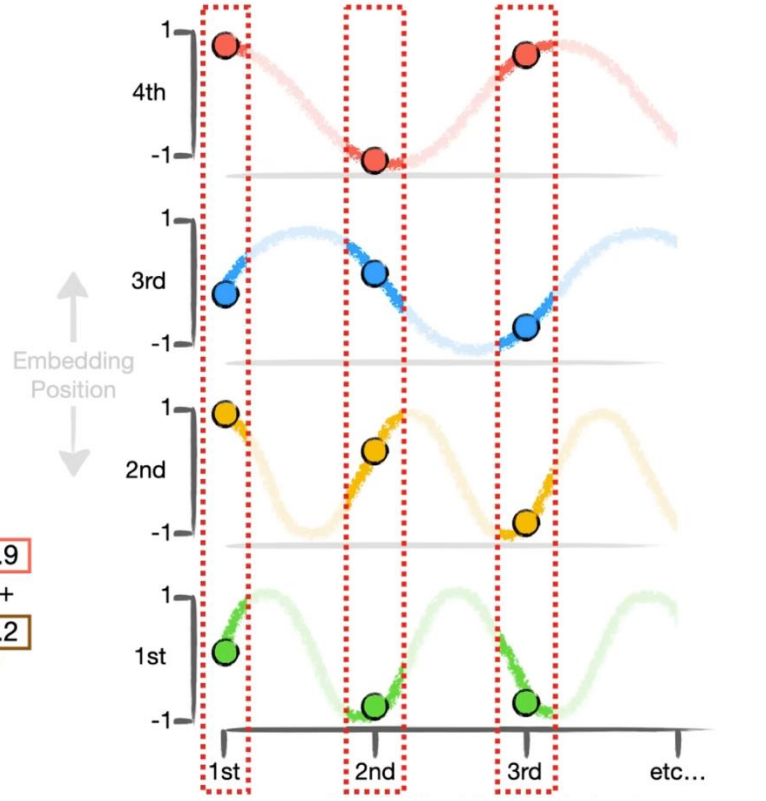


Posición de las palabras (tokens) en la entrada

Transformers – embeddings de posición

entonces, cada palabra en la entrada obtiene una secuencia única de valores de posición

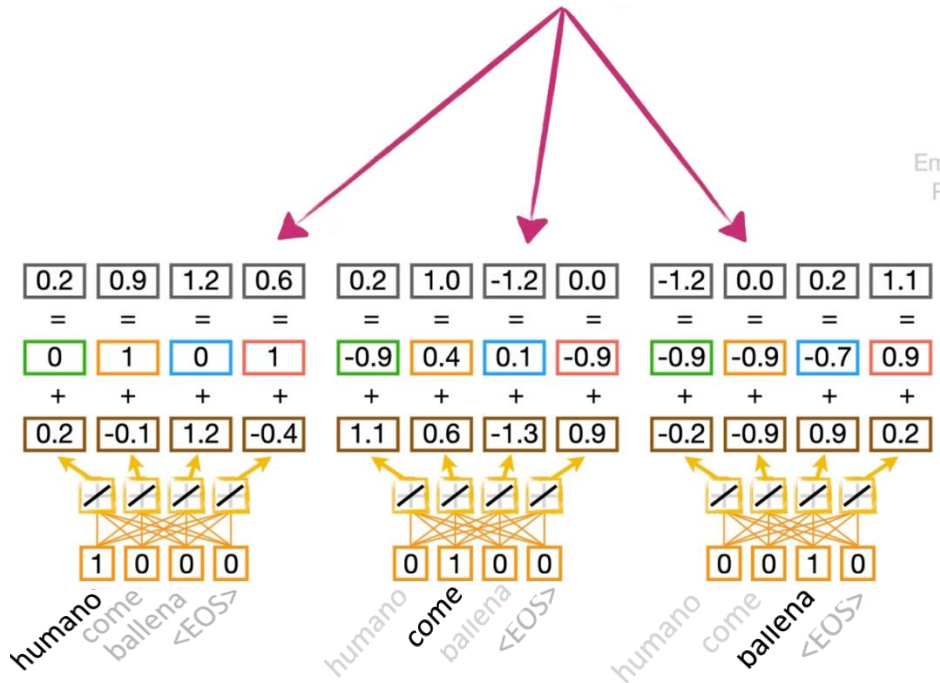


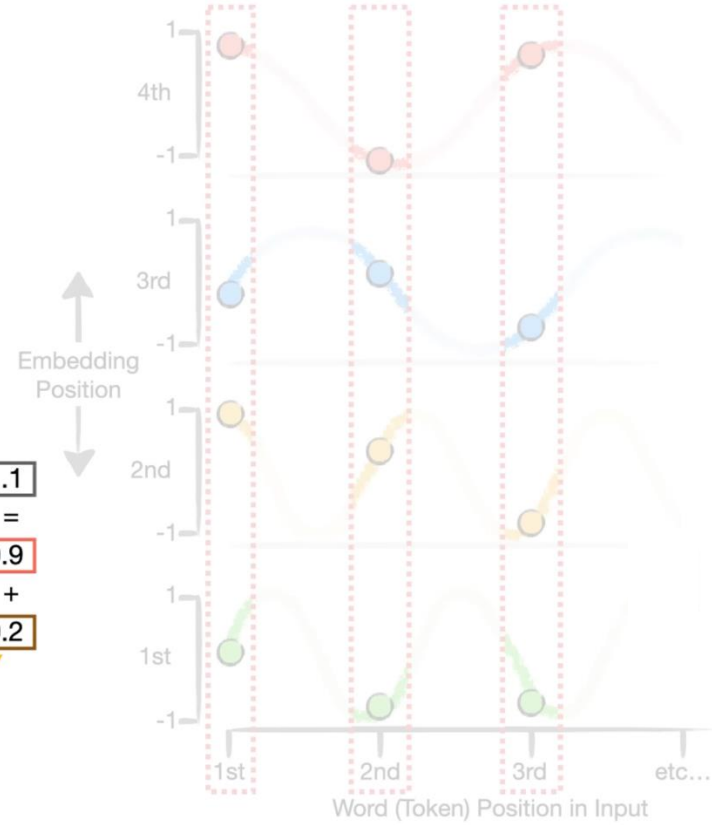


Posición de las palabras (tokens) en la entrada

Transformers – embeddings de posición

Luego, se suman los valores de posición a los valores embeddings

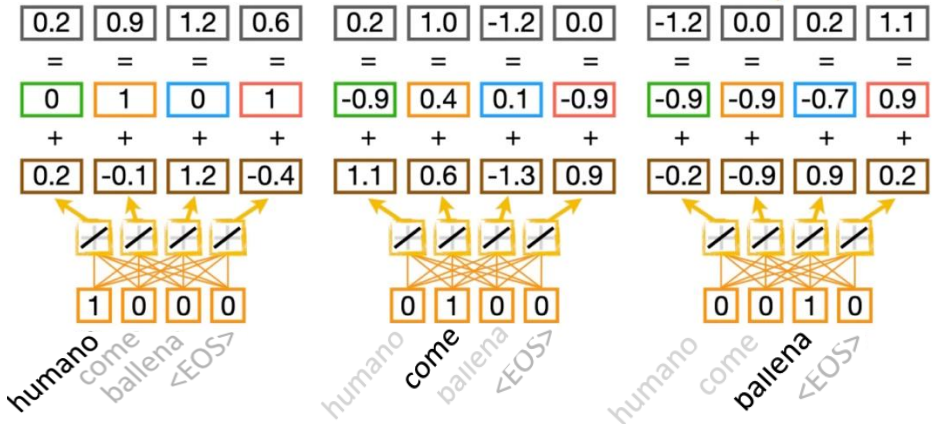


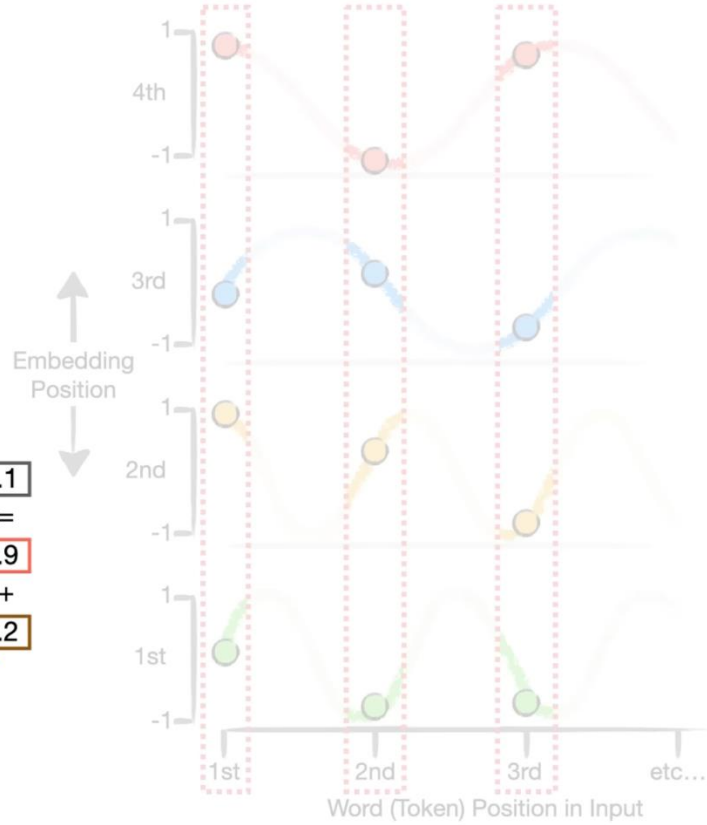


Transformers – embeddings de posición

Y este es el embedding de las palabras con positional encoding para toda la frase

“humano come ballena”





Métricas de evaluación del modelo

Partes de la matriz de confusión

- **Positivos verdaderos**: datos etiquetados como positivos que en realidad son positivos
- **Positivos falsos:** datos etiquetados como positivos que en realidad son negativos
- **Negativos verdaderos**: datos etiquetados como negativos que en realidad son negativos
- **Negativos falsos**: datos etiquetados como negativos que en realidad son positivos

		Real	
		Positivo	Negativo
Predicho	Positivo	Positivo verdadero	Positivo flaso
	Negativo	Negativo falso	Negativo verdadero

Métricas de evaluación del modelo

Métricas de la matriz de confusión:

- Exactitud (Accuracy): En general, mide la frecuencia con la que el clasificador es correcto ?

$$Exactitud = (TP + TN) / (TP + TN + FP + FN)$$

- Precisión: Cuando predice positivo, con qué frecuencia es correcta esa predicción?

  La precisión generalmente se usa cuando el objetivo es limitar el número de positivos falsos (FP).

$$Precisión = TP / (TP + FP)$$

- Recuperación (recall): Cuando es positivo real; con qué frecuencia lo predice correctamente?

$$Recuperación = TP / (TP + FN)$$, también conocido como sensibilidad.

- Puntaje f1: Es la media armónica de precisión y recuperación:

$$f1 - score = 2 * ((precisión * recuperación) / (precisión + recuperación))$$