Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 6 - PAO 2026 – I

Agenda

1. Ejemplo: Regresión multi variable
2. Regresión Logística
   2.1 Clasificación
   2.2 Regresión Sigmoidal
   2.3 Función de costo

Regresión Lineal - Múltiple variables (features)

- Para actualizar los parámetros w, aplicamos la regla de aprendizaje:

$$w_{j_{nuevo}} = w_{j_{anterior}} - \alpha \frac{\partial J}{\partial W_j}$$

$$J = (h_w(x) - y)^2$$
$$h_w(x) = w_0 + w_1 x_1 + w_2 x_2$$

- Donde:

  $w_{j_{nuevo}}$: valor despues de actualizarlo

  $w_{j_{anterior}}$: valor pasado

  α: velocidad de aprendizaje; **asumamos, α = 0.05**

  $\frac{\partial J}{\partial w_j}$: gradiente de J en w_j; esto es, la derivada parcial de J c.r.a. w_j

- Pero w_j afecta $h_w(x)$, entonces debemos utilizar la regla de la cadena para calcular dicho gradiente:

$$\frac{\partial J}{\partial w_j} = \frac{\partial J}{\partial h_w(x)} \cdot \frac{\partial h_w(x)}{\partial w_j}$$

Regresión Lineal - Múltiple variables (features)

Calculo de las derivadas

Si: $h_w(x) = w_0 + w_1 x_1 + w_2 x_2$

Y: $J = (h_w(x) - y)^2$

1. Derivada parcial de J, c.r.a. $h_w(x)$

$$\frac{\partial J}{\partial h_w(x)} = 2(h_w(x) - y)$$

2. Derivada parcial de $h_w(x)$, c.r.a. w_0

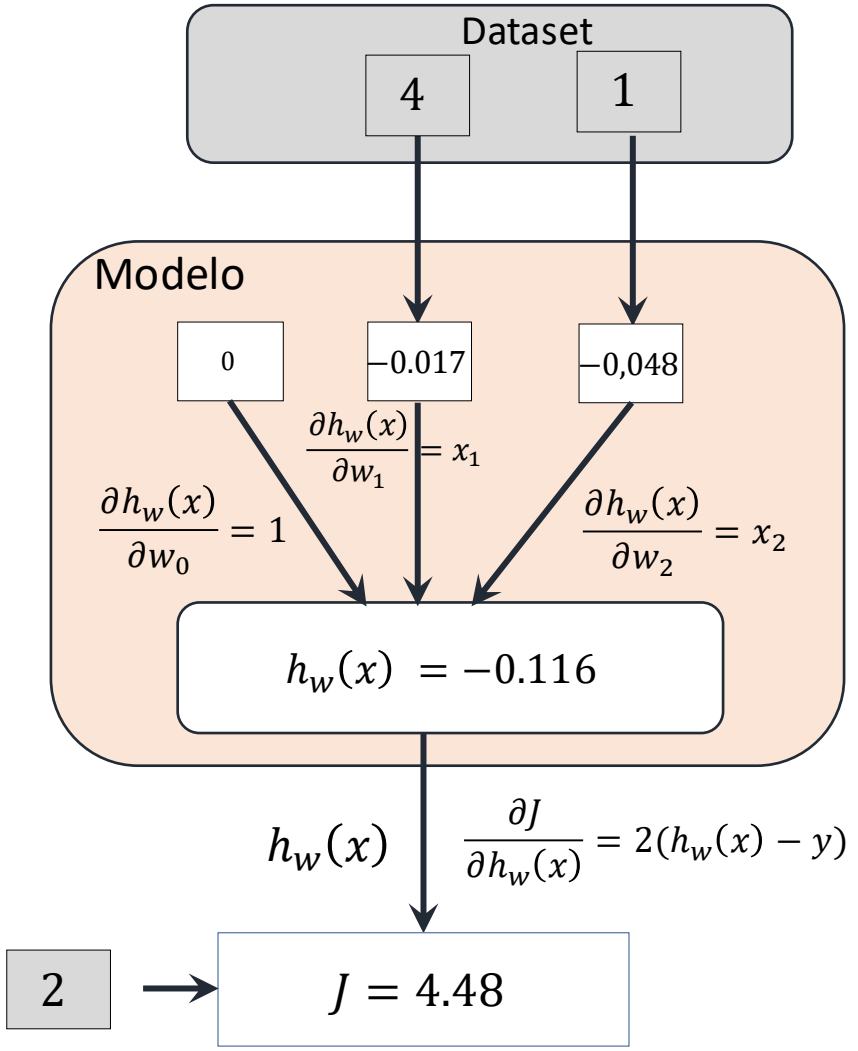
$$\frac{\partial h_w(x)}{\partial w_0} = 1$$

3. Derivada parcial de $h_w(x)$, c.r.a. w_1

$$\frac{\partial h_w(x)}{\partial w_1} = x_1$$

4. Derivada parcial de $h_w(x)$, c.r.a. w_2

$$\frac{\partial h_w(x)}{\partial w_2} = x_2$$



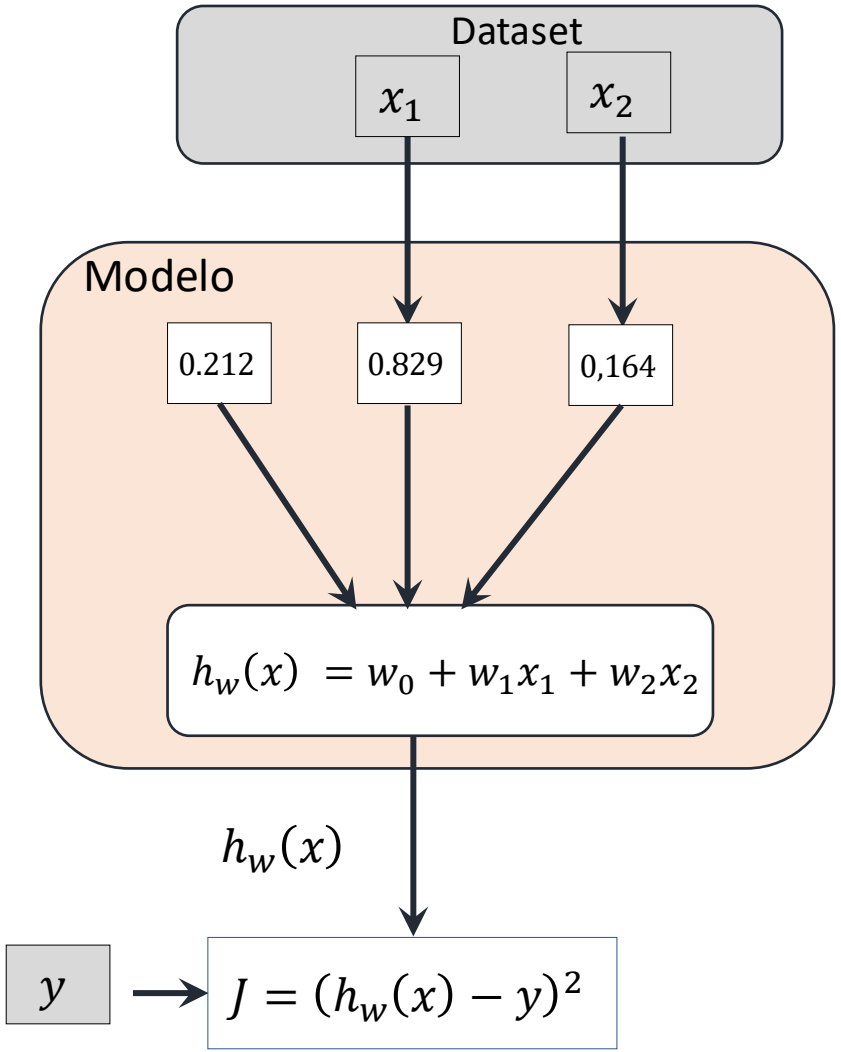
Regresión Lineal - Múltiple variables (features)

- Notar que los valores de las derivadas parciales corresponden a los valores del lote actual
- Esto es:

#	x_1	x_2	y
1	4	1	2

$w_1 = -0.017;\ w_2 = -0.048; w_0 = 0$

i) w_0 cambia de: 0.000 a 0.212
ii) w_1 cambia de: -0.017 a 0.829
iii) w_2 cambia de: -0.048 a 0.164



Regresión logística: Clasificación

- En RLineal, vimos que: $h_w(x)$ podía predecir valores > 0 o < 0
- Necesitamos un modelo que clasifique: $y = 0$ o $y = 1$
- Una función que pueda predecir valores $0 \leq h_w\ (x) \leq 1$, independientemente del valor x
- Una función que se comporta de esa forma es: La función “Logística”

$$g(z) = \frac{1}{1 + e^{-z}}$$

- De ahí el nombre: Regresión Logística



Clasificación

Regresión logística: Representación de la hipótesis

Modelo de Regresión Logística

Deseamos: $0 \leq h_w\ (x) \leq 1$

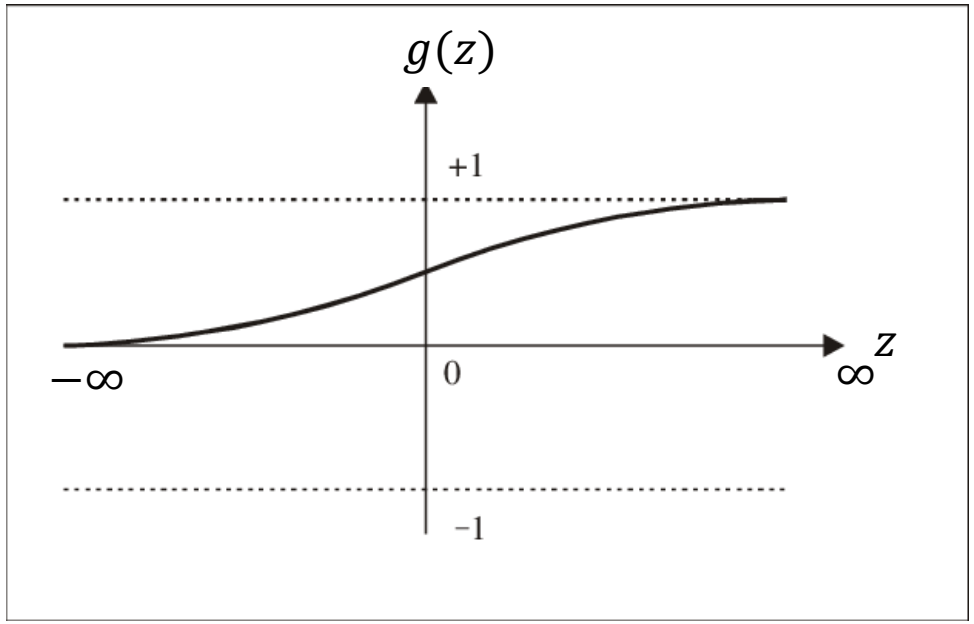
$$g(z) = \frac{1}{1 + e^{-z}}$$

$$z = w^T x$$

Recordar: $h_w(x) = w^T X$

$$h_w(x) = g(w^T x)$$

$$h_w(x) = \frac{1}{1 + e^{-w^T x}}$$



Función Sigmoidal
Función Logística

Regresión logística

Datos de entrenamiento: $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \cdots, (x^{(m)}, y^{(m)})\}$

m ejemplos: $x \in \begin{bmatrix} x_0 \\ x_1 \\ \cdots \\ x_n \end{bmatrix} \mathbb{R}^{n+1}$, $x_0 = 1, y \in \{0, 1\}$

$$h_w(x) = \frac{1}{1 + e^{-w^T x}}$$

Cómo escoger los parámetros w?

Regresión logística: Función de costo

$$J(W) = \frac{1}{m}\sum_{i=1}^{m} Costo\left(h_w\left(x^{(i)}\right), y^{(i)}\right)$$

$$Costo(h_w(x), y) = \begin{cases} -\log(h_w(x)) & Si\ y = 1 \\ -\log(1 - h_w(x)) & Si\ y = 0 \end{cases}$$

En forma simplificada

$$Costo(h_w(x), y) = -ylog\left(h_w(x)\right) - (1 - \mathrm{y})\log(1 - h_w(x))$$

En forma extendida

Notar que $y = 0\ o\ 1$, siempre

Si $y = 1$: $Costo(h_w(x), y) = -log\left(h_w(x)\right)$
Si $y = 0$: $Costo(h_w(x), y) = -\log(1 - h_w(x))$

Regresión logística: Gradiente descendiente

$$J(W) = -\frac{1}{m}\sum_{i=1}^{m} y^{(i)} \log h_w\left(x^{(i)}\right) + \left(1 - y^{(i)}\right) \log\left(1 - h_w\left(x^{(i)}\right)\right)$$

Deseamos: $\min_w J(W)$

Repetir hasta que converja

{

$$w_j := w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1, \dots, w_n)$$

}