Artificial Intelligence

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 7 - PAO 2026 – I

Agenda

1. Lección #1
2. Regresión Logística – continuación
   2.1 Función de error
   2.2 Clasificación multi-clase
3. Introducción a las Redes Neuronales
   3.1 El Perceptrón
   3.2 Funciones de transferencia, umbral o activación
   3.3 Un ejemplo

Regresión logística: Gradiente descendiente

$$J(W) = -\frac{1}{m}\sum_{i=1}^{m} y^{(i)} \log h_w\left(x^{(i)}\right) + \left(1 - y^{(i)}\right) \log\left(1 - h_w\left(x^{(i)}\right)\right)$$

Deseamos: $\min_w J(W)$

Repetir hasta que converja

{

$$w_j := w_j - \alpha \, \frac{1}{m}\sum_{i=1}^{m}\left(h_w\left(X^{(i)}\right) - y^{(i)}\right) \cdot x_j^{(i)}$$

}

$$h_w(x) = \frac{1}{1 + e^{-w^T x}}$$

Clasificación multi-clase: Una vs. todas

Clasificación de email /tagging: Trabajo, Amigos, Familia, Otros

$y = 1,\ y = 2,\ y = 3,\ y = 4$

Clima: Soleado, Nublado, Brumoso, Granizo

$y = 1,\quad y = 2,\quad y = 3,\quad y = 4$

Clasificación multi-clase: Una vs. todas (una vs. el resto)

- Dado que $y = \{0,1 \dots n\}$, dividimos el problema en $n + 1$ (+1 porque el índice comienza en 0) problemas de clasificación binaria; en cada uno, predecimos la probabilidad de que "y" corresponda a una de las 2 clases

$$y \in \{0, 1, 2, \dots, n\}$$

$$h_w^{(0)}(x) = P(y = 0|x; w)$$

$$h_w^{(1)}(x) = P(y = 1|x; w)$$

$$\dots$$

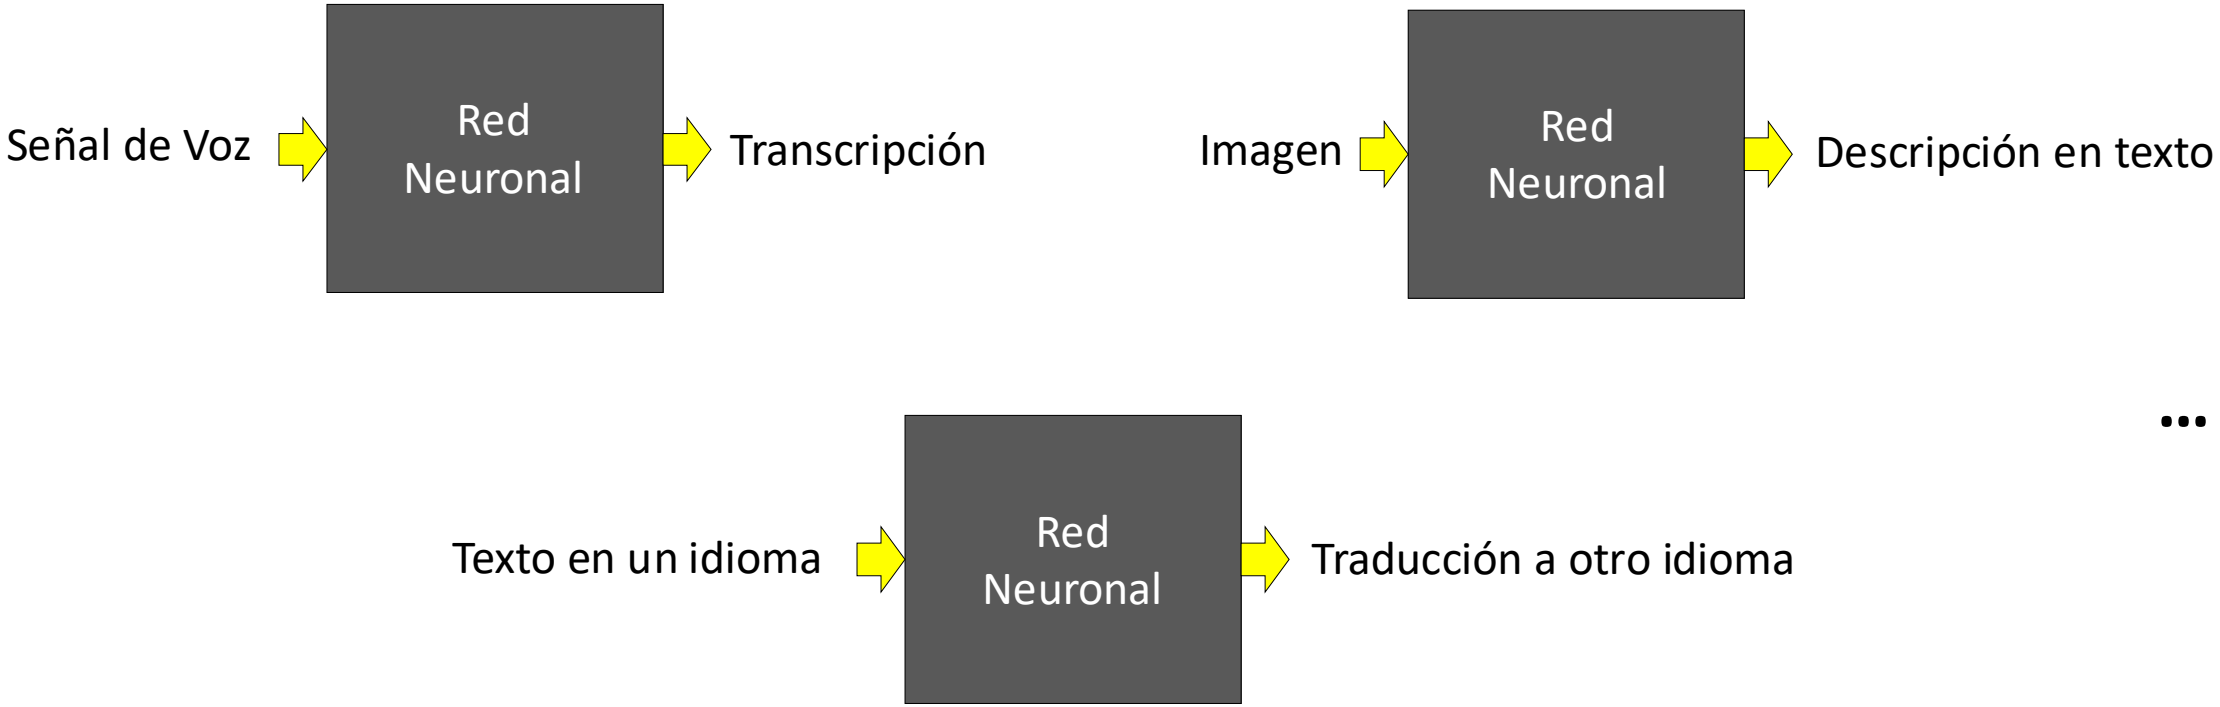
$$h_w^{(n)}(x) = P(y = n|x; w)$$

Predicción = $\max_i \left(h_w^{(i)}(x) \right)$

- Seleccionamos una clase y agrupamos todas las demás en una sola clase
- Hacemos esto repetidamente, aplicando regresión logística binaria a cada caso
- Al final, seleccionamos la hipótesis con el valor más alto

- Para una nueva entrada x, la predicción consiste en seleccionar la clase i con el máximo valor

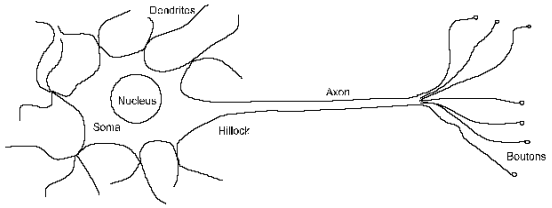
Que son las redes neuronales?



- Qué son esas cajas negras?

Neurona biológica – Cómo funciona

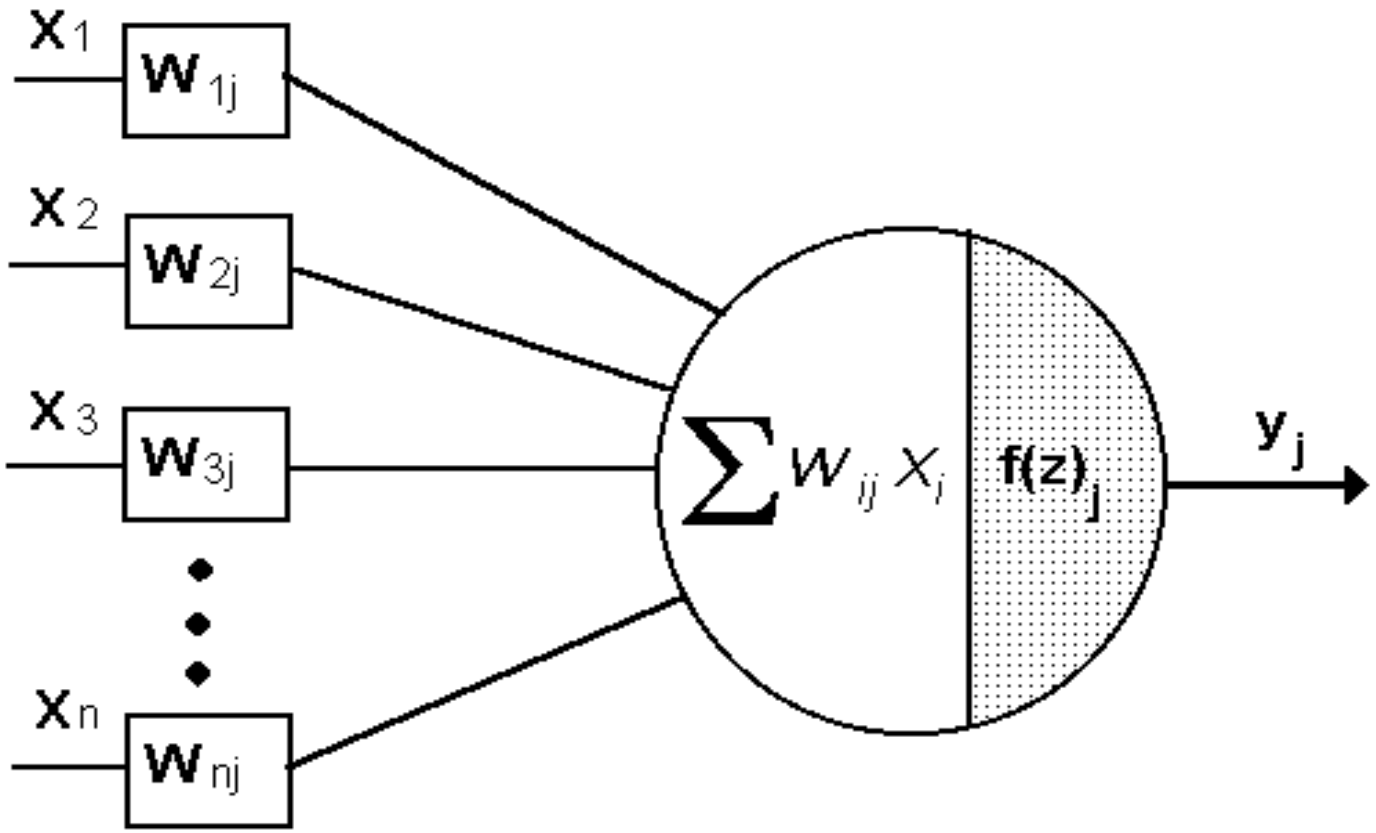
- El cerebro contiene alrededor de 10^{11} ”elementos” altamente interconectados (~10^4 conexiones por elemento), llamados neuronas.
- Los 4 componentes principales a los que nos vamos a referir: dendritas, cuerpo-núcleo de la célula o soma, el axón y la sinapsis.
- Las dendritas constituyen el árbol receptor de la red, cargan el cuerpo de la célula con señales eléctricas.
  - El cuerpo de la célula suma todas esas señales.
  - El axón conduce la señal desde el cuerpo de la célula hacia otras neuronas.



- El punto de “contacto” del axón de una célula con las dendritas de otra célula se conoce como sinapsis.
- La longitud de la sinapsis determina la intensidad de conexión

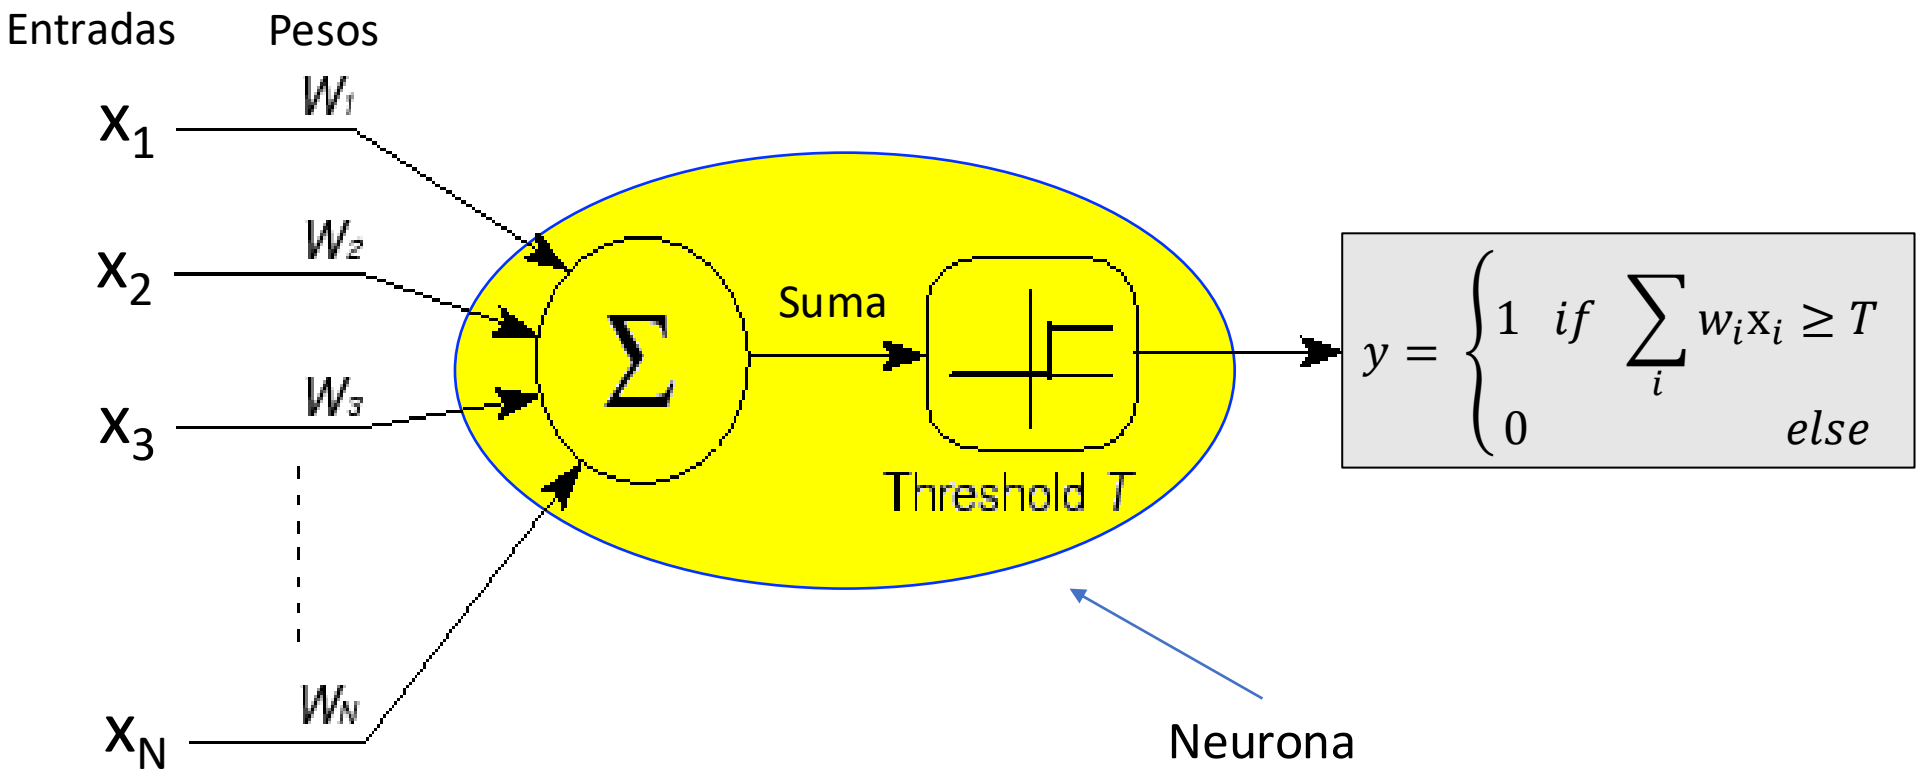
Neurona artificial - Perceptron

Dendritas: Entradas Sinapsis: Pesos Soma: Unidad de activación Axon: Salida



Este modelo es conocido como el Perceptron

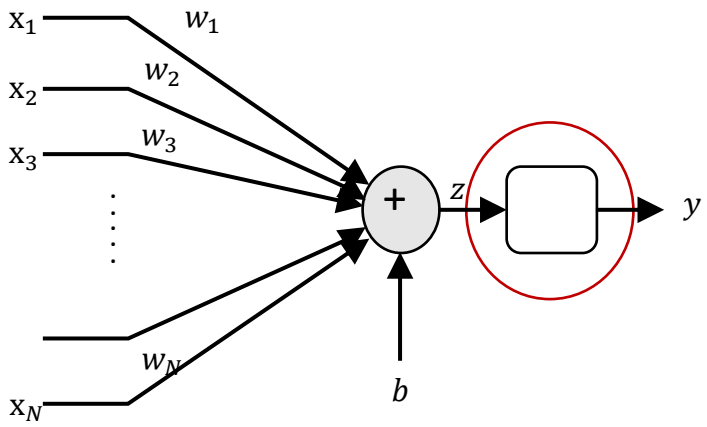
El perceptron



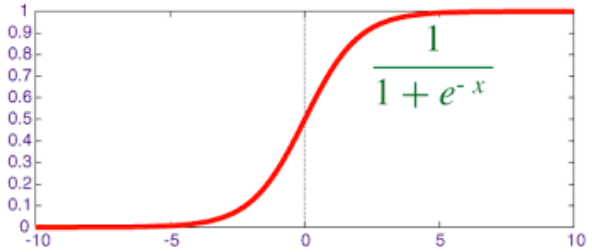
El perceptron: Otras funciones de activación

Nombre	Relación Entrada /Salida	Icono	Función
Limitador Fuerte	$a = 0 \quad n < 0$ $a = 1 \quad n \geq 0$		*hardlim*
Limitador Fuerte Simétrico	$a = -1 \quad n < 0$ $a = +1 \quad n \geq 0$		*hardlims*
Lineal Positiva	$a = 0 \quad n < 0$ $a = n \quad 0 \leq n$		*poslin*
Lineal	$a = n$		*purelin*
Lineal Saturado	$a = 0 \quad n < 0$ $a = n \quad 0 \leq n \leq 1$ $a = 1 \quad n > 1$		*satlin*
Lineal Saturado Simétrico	$a = -1 \quad n < -1$ $a = n \quad -1 \leq n \leq 1$ $a = +1 \quad n > 1$		*satlins*
Sigmoidal Logarítmico	$a = \frac{1}{1 + e^{-n}}$		*logsig*
Tangente Sigmoidal Hiperbólica	$a = \frac{e^{n} - e^{-n}}{e^{n} + e^{-n}}$		*tansig*
Competitiva	$a = 1 \quad$ *Neurona con n max* $a = 0 \quad$ *El resto de neuronas*		*compet*

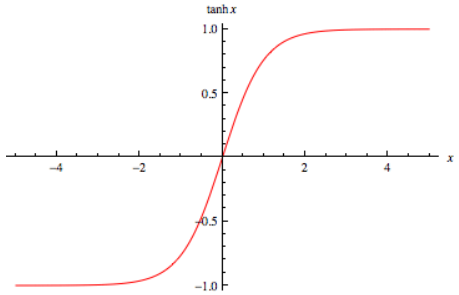
El perceptron: Funciones de activación



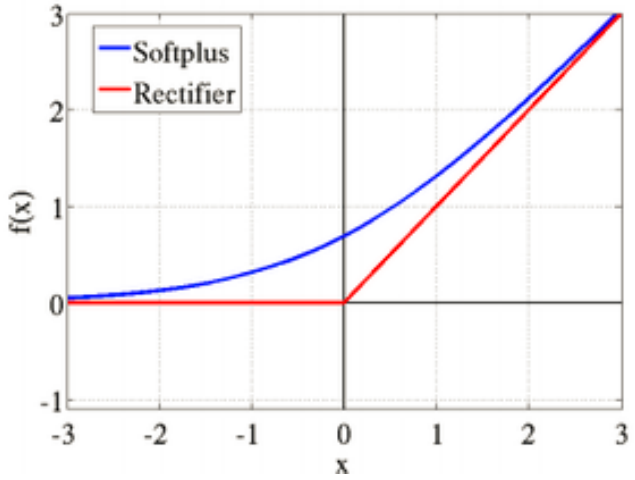
sigmoid



tanh

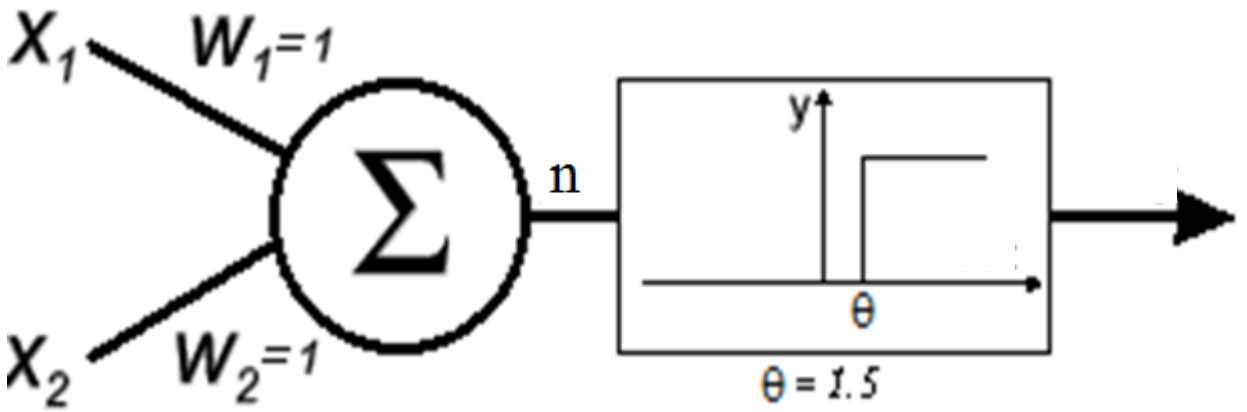


Relu



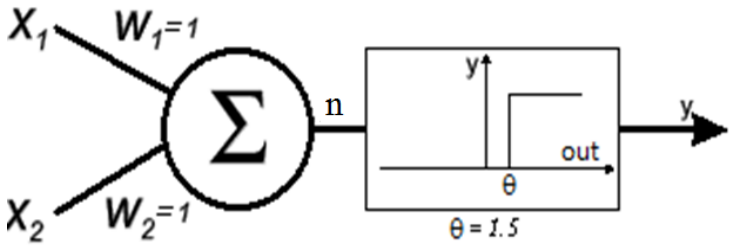
El perceptron: Ejemplo

- Consideremos la siguiente neurona, y *hardlim* como función de activación y la entrada es binaria.



$$y = \begin{cases} 1 & if\ out \geq \theta \\ 0 & if\ out < \theta \end{cases}$$

El perceptron: Ejemplo

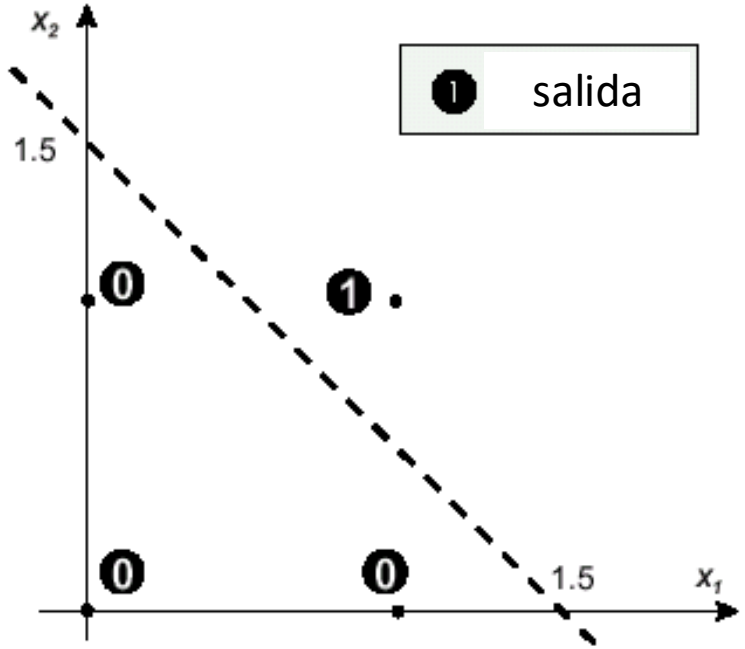


$x_1 w_1 + x_2 w_2 \geq 1.5$

$x_1 + x_2 = 1.5$

$w_1 = 1, w_2 = 1$ y threshold $\theta = 1.5$

x_1	x_2	n	Y
0	0	0	0
0	1	1	0
1	0	1	0
1	1	2	1



AND gate