Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

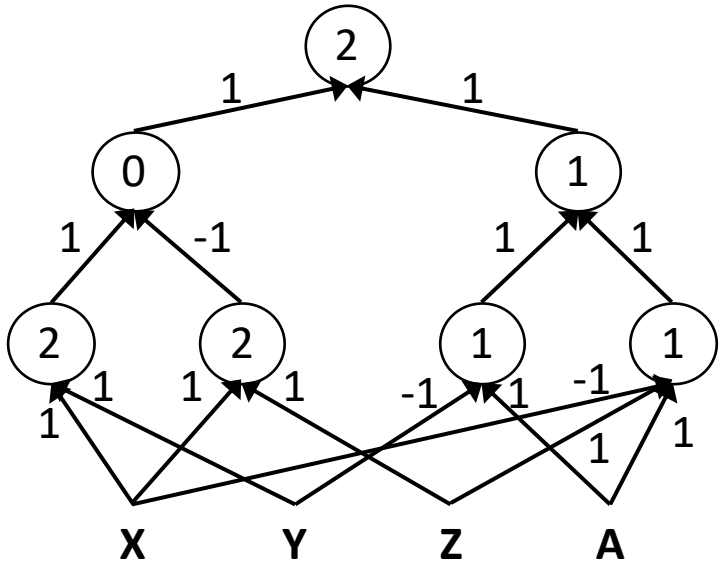
Clase # 9 - PAO 2026 – I

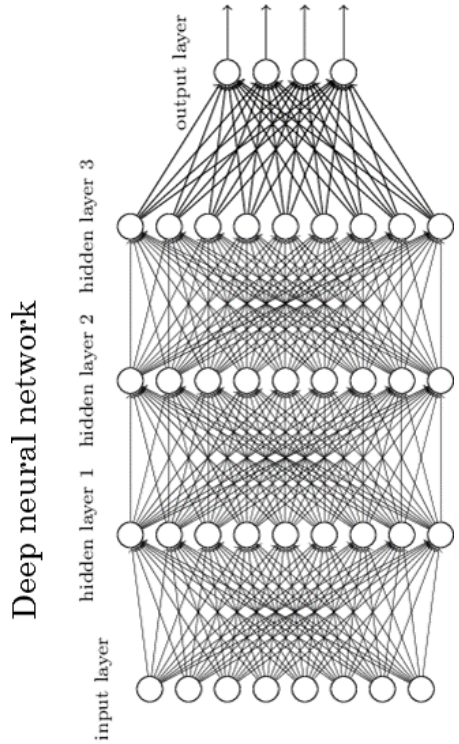
Agenda

1. Las redes MLP como función Boolean
2. Aprendizaje en las redes MLP
   - 2.1 Pesos
   - 2.2 Regla de aprendizaje Delta
   - 2.3 Otro ejemplo: Entrenamiento

MLP como función Boolean

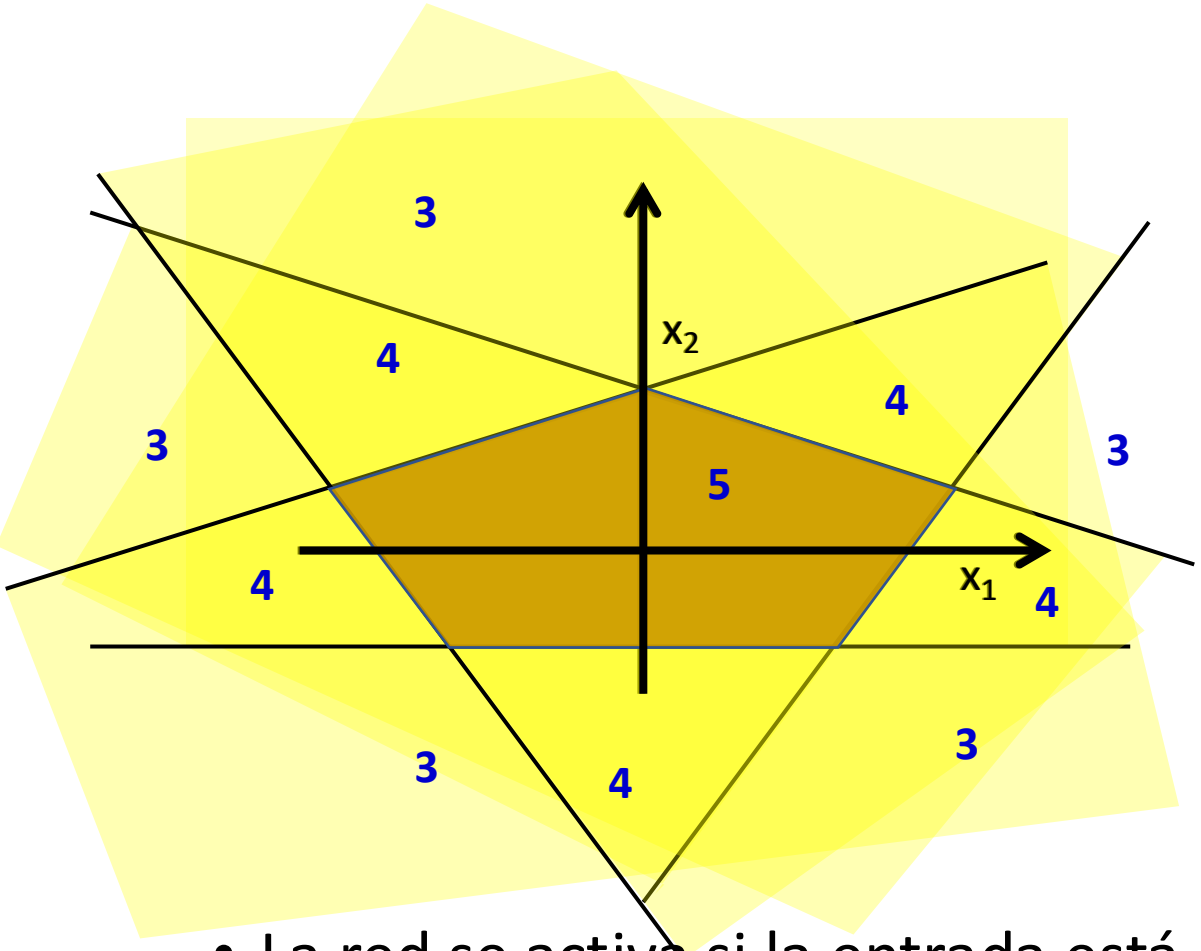
$$((A\&\bar{X}\&Z)|(A\&\bar{Y}))\&((X\ \&\ Y)|\overline{(X\&Z)})$$

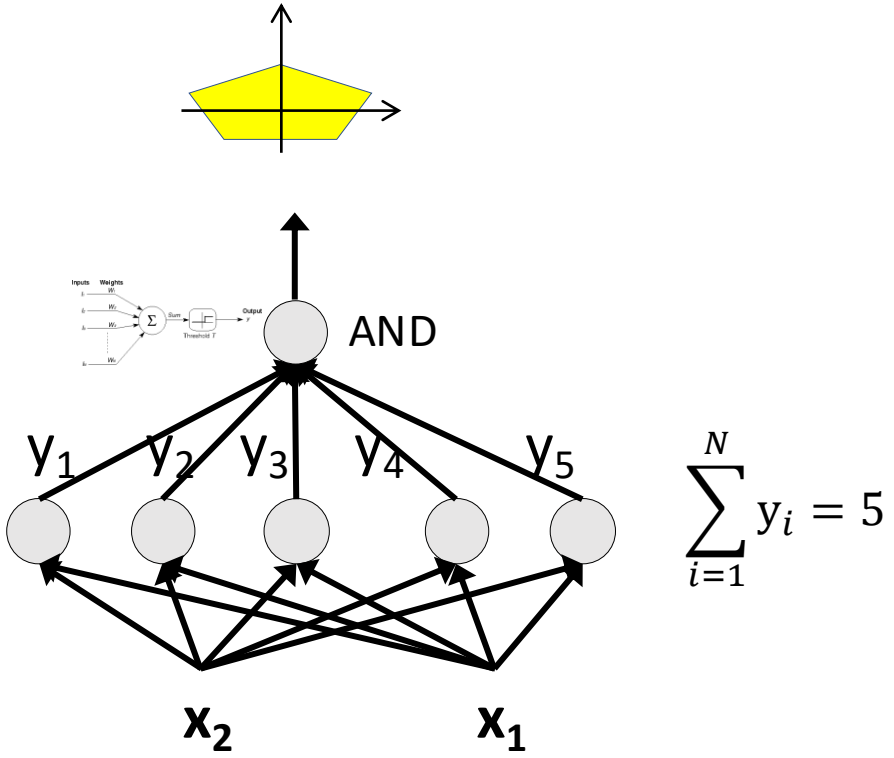




- MLPs como funciones “Boolean” universales
  - Pueden calcular cualquier función con cualquier numero de entradas y/o salidas
- Pero cuántas “capas” se necesitan?

Composición de bordes complejos

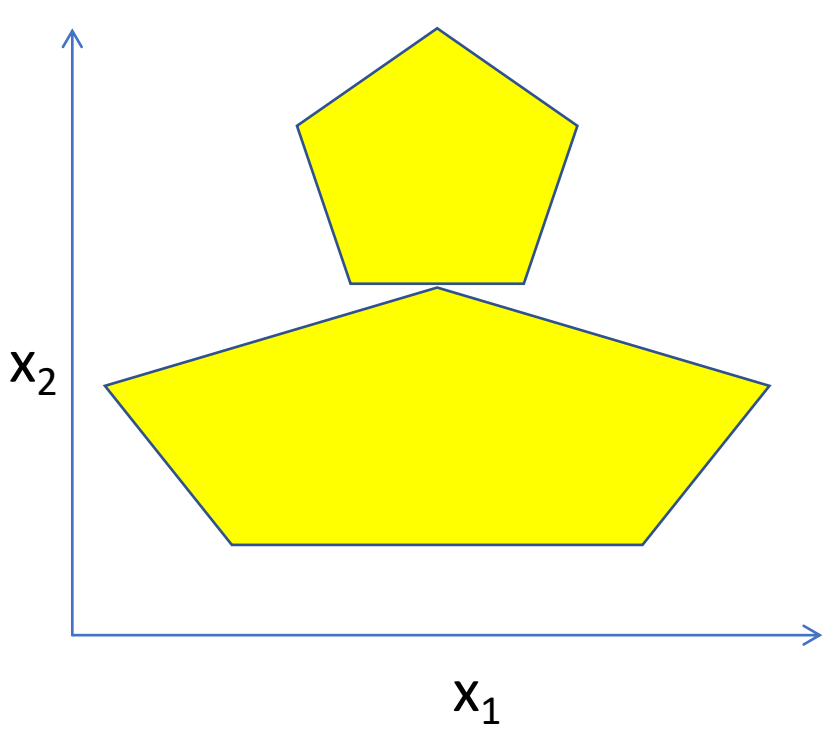


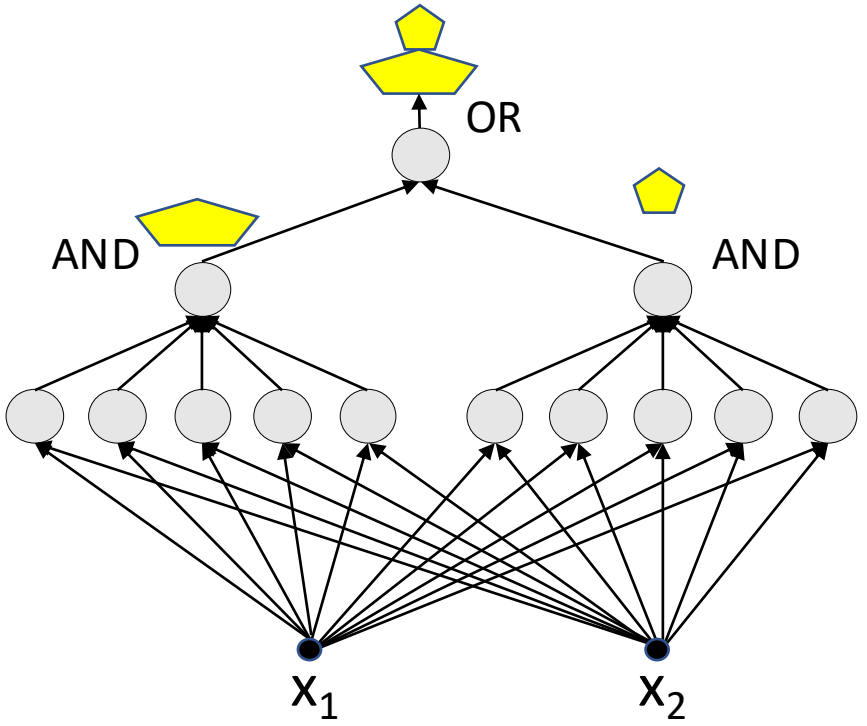


$$\sum_{i=1}^{N} y_i = 5$$

- La red se activa si la entrada está dentro del área amarilla

Bordes más complejos

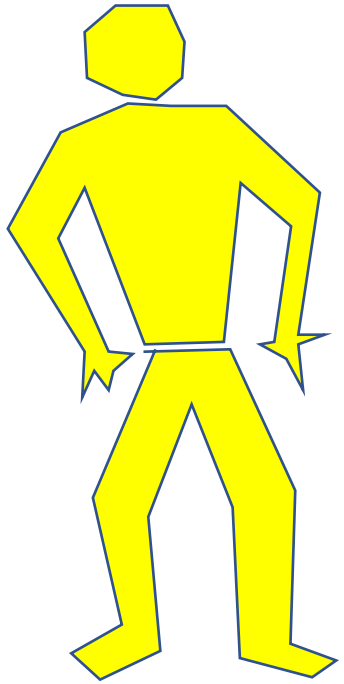


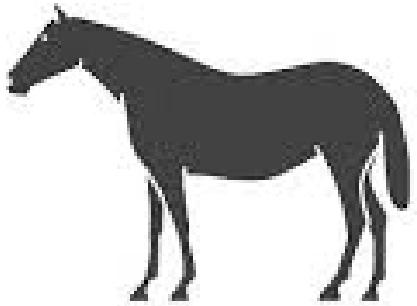


- La red se activa si la entrada está dentro del área amarilla
  - “OR” los 2 polígonos
  - Se requiere una tercera capa

Bordes más complejos







- Es posible componer bordes arbitrarios y complejos

Aprendizaje

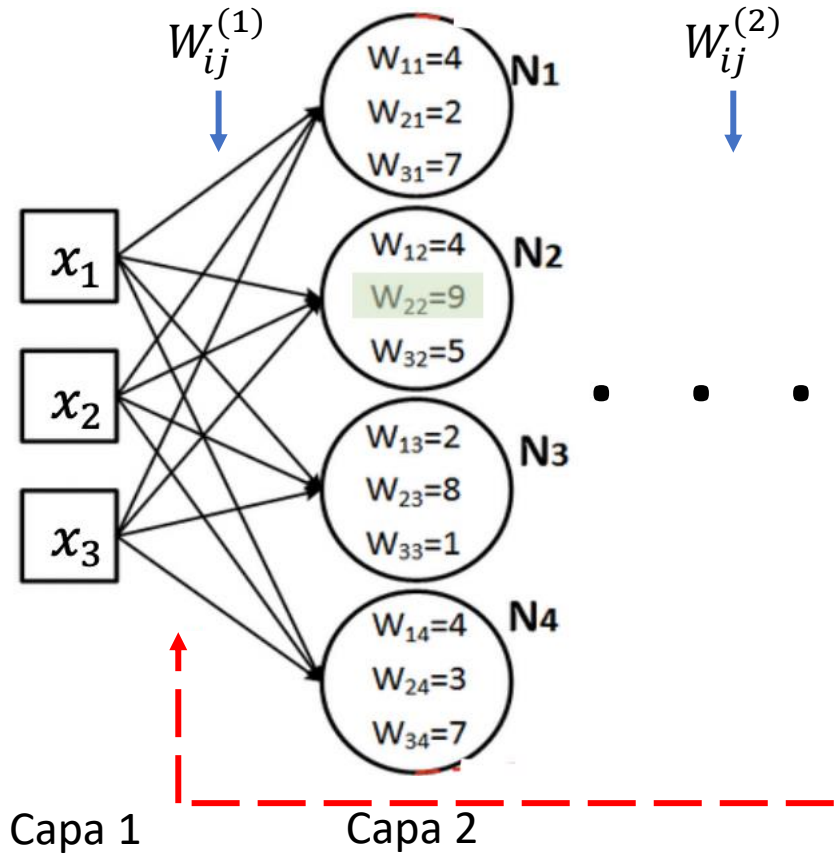
- A las RN se las conoce como funciones universales de aproximación
- Pueden modelar cualquier función Boolean
- Pueden modelar cualquier borde de clasificación
- Pueden modelar cualquier función de valores continuos

Redes Neuronales

Pesos

- El peso representa la intensidad de la conexión entre neuronas, generalmente es un valor real
- Cuanto mayor es el valor de la intensidad, mayor es el peso y más importancia le damos a la neurona que transmite esa intensidad
- En machine learning estos pesos se representan en un formato matricial

Redes Neuronales



W_{ij}^{k}

	N_1	N_2	N_3	N_4
x_0	W_{01}	W_{02}	W_{03}	W_{04}
x_1	$W_{11}=4$	$W_{12}=4$	$W_{13}=4$	$W_{14}=4$
x_2	$W_{21}=4$	$W_{22}=4$	$W_{23}=4$	$W_{24}=4$
x_3	$W_{31}=4$	$W_{32}=4$	$W_{33}=4$	$W_{34}=4$

$$W^{(k)} = L_{k+1} \times (L_k + 1)$$

$$W^{(1)} = L_{1+1=2} \times (L_1 + 1) = 4 \times 4$$

- Esta matriz se llama W^1. Cuando hay más capas, tenemos matrices de pesos, W^2, W^3, etc.
- En general, si una capa L tiene M neuronas y la siguiente capa $L + 1$ tiene N neuronas, la matriz de pesos es una matriz $N \times M$ (N filas y M columnas)

Redes Neuronales

Pesos

- Las RN pueden tener pesos fijos y adaptables
- Las RN con pesos adaptables utilizan leyes de aprendizaje para ajustar los valores de la conexión con otras neuronas
- Una vez que la RN aprende los parámetros (pesos), se fijan para realizar la tarea para la cual fue diseñada la red
- Los pesos adaptables son los que definen la función que estamos buscando con la RN

Redes Neuronales

Entrenamiento

- Buscamos una estrategia iterativa que permita a la neurona adapte sus parámetros (pesos) de conexión, cuando se presentan los datos de entrenamiento en la entrada de la red
- El entrenamiento del perceptrón se basa en una ley de aprendizaje general, conocida como la regla delta:
  - Para cada peso W se realiza un ajuste basado en un ΔW, y de acuerdo con la siguiente regla:

$$\Delta W_{ij} = \alpha (T_j - Y_j) Y_i$$

Donde:

α es la velocidad de aprendizaje. Un factor entre $0 < \alpha \leq 1$

Y_i valor de salida de la neurona i (o la entrada a la neurona a partir de la segunda capa)

T_j valor deseado, esperado o target conocido en la neurona j

Y_j valor de salida calculado por la neurona j

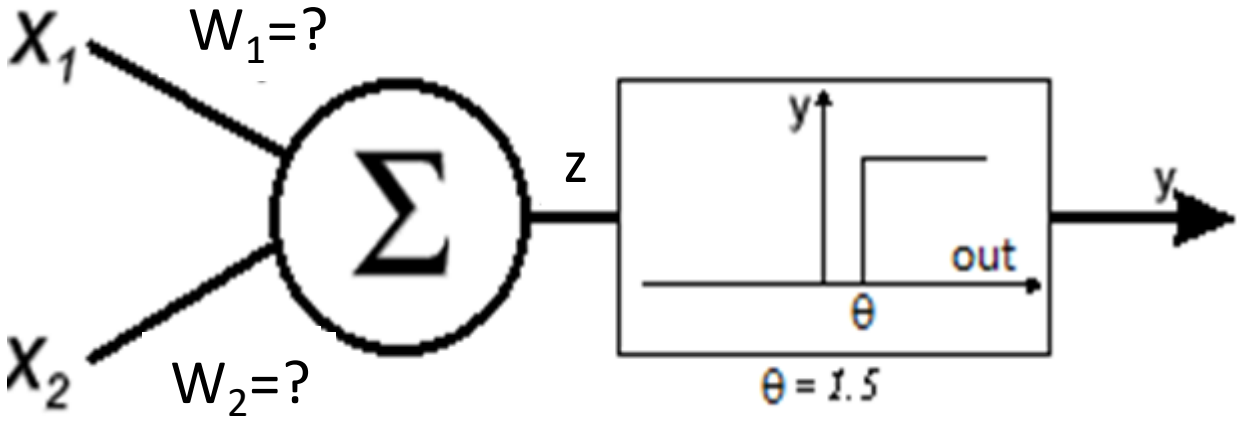
Aprendizaje

- Seleccionar α
- Inicializar los pesos con valores aleatorios (W)
- Mientras todos los ejemplos no sean clasificados correctamente
  - Ingresar un nuevo ejemplo a la red
  - Si el ejemplo fue incorrectamente clasificado
    - $W_{nuevo} = W_{anterior} + \alpha\,(t - y)\,x$

Aprendizaje: Ejemplo

- Entrenar un perceptron para que reconozca el patrón de comportamiento de la puerta AND
- Supongamos los siguientes parámetros:

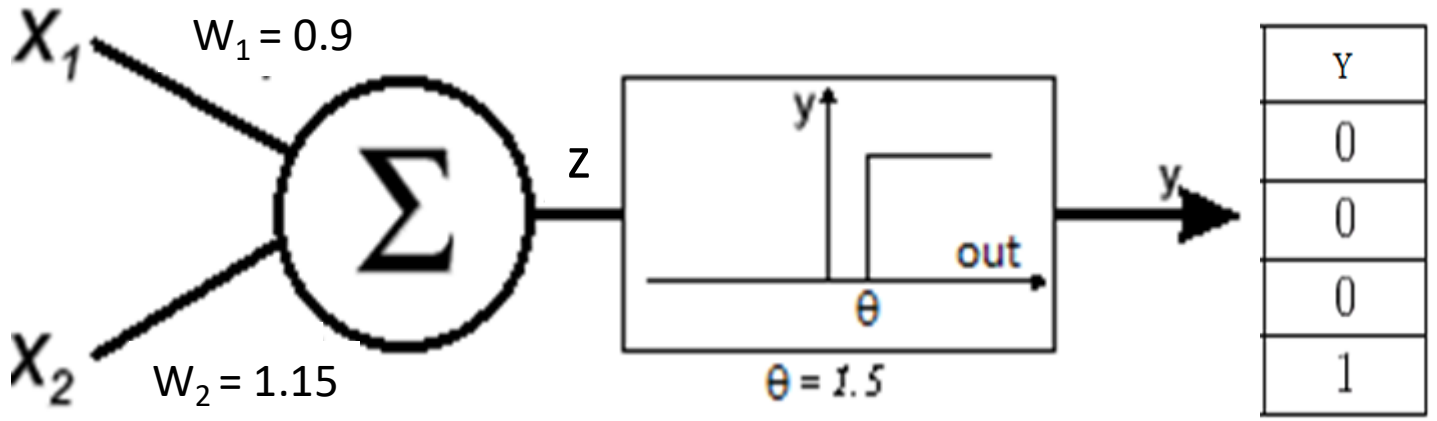
$\alpha = 0.3$
$\theta = 1.5$
$W_1 = 0$
$W_2 = 0.25$



Aprendizaje: Ejemplo

$\alpha = 0.3$
$\theta = 1.5$
$W_1 = 0$
$W_2 = 0.25$

x_1	x_2
0	0
0	1
1	0
1	1



Y
0
0
0
1