Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

Clase # 17 - PAO 2026 – I

Agenda

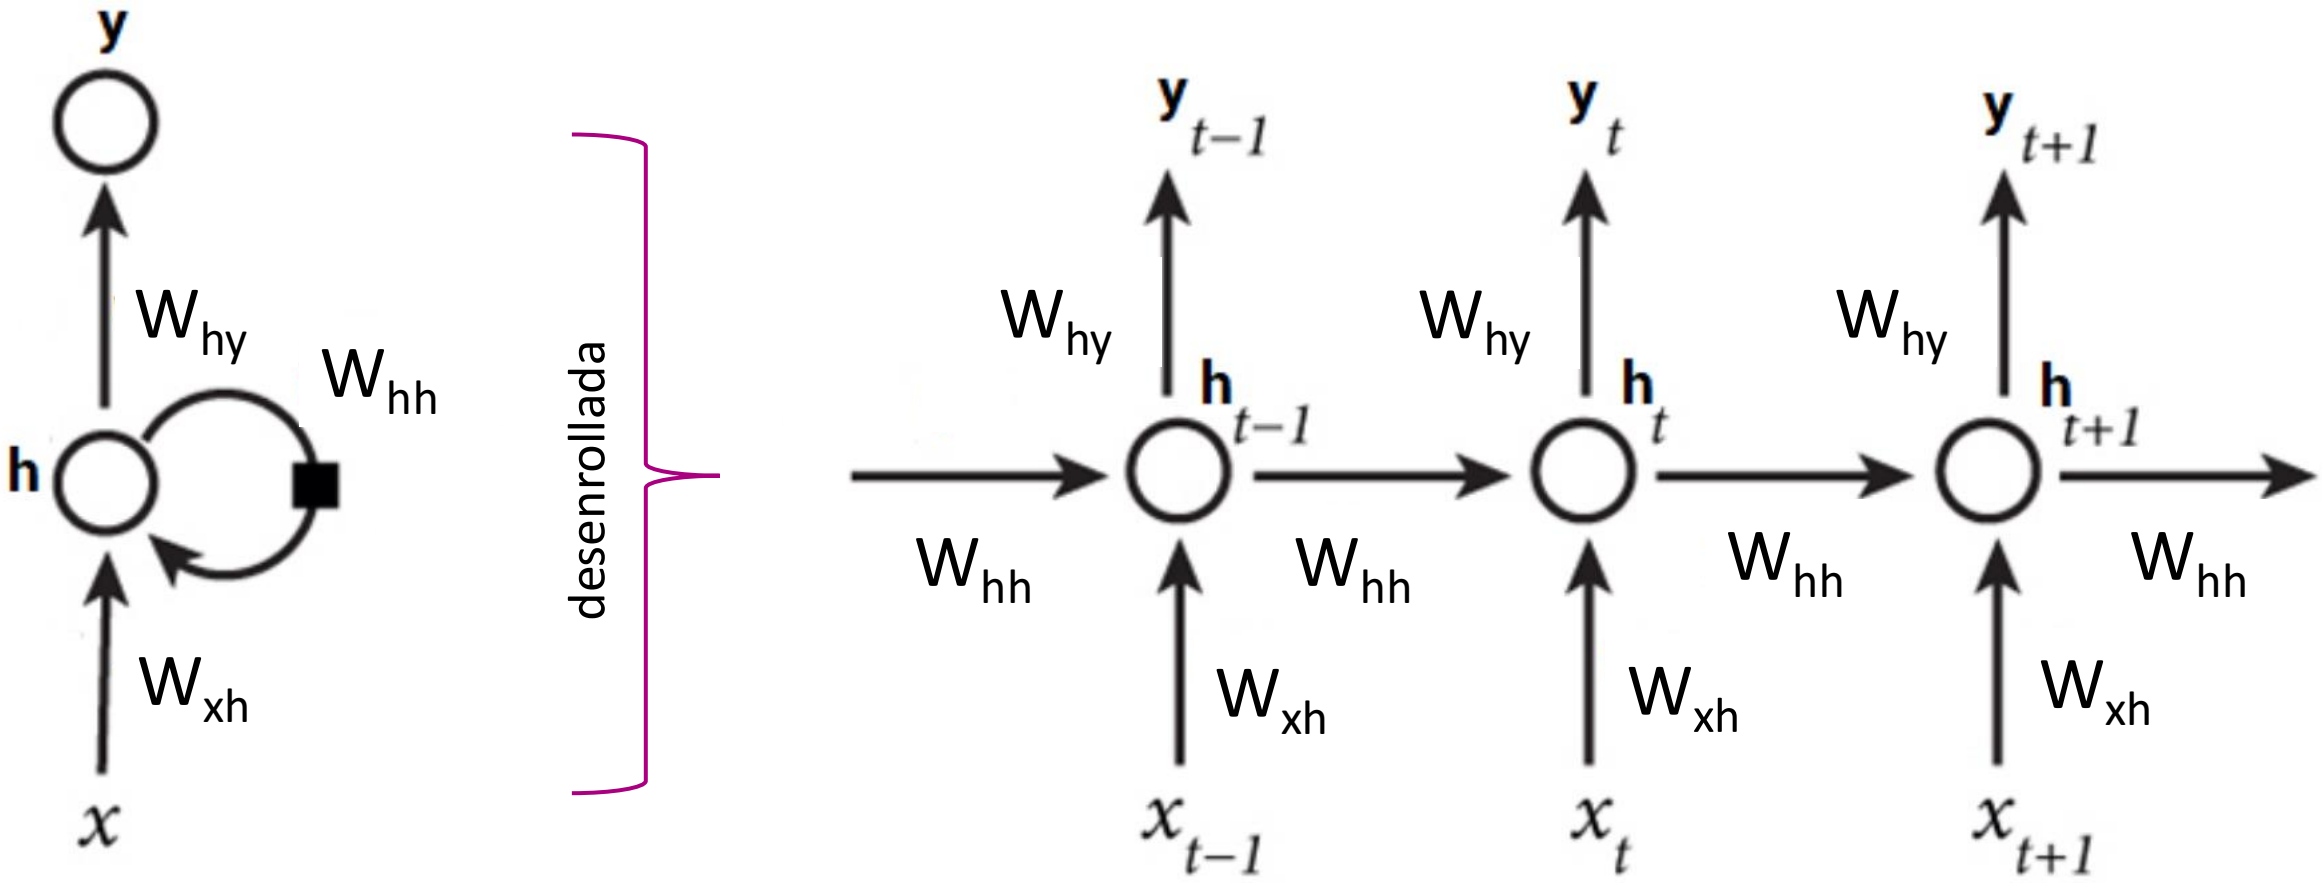
1. Redes recurrentes – RNN:
   1.1 Aprendizaje en las RNN – BPTT
   1.2 Desvanecimiento del gradiente
2. Introducción a las redes LSTM – Long-Short Term Memory

Redes neuronales recurrentes

- Back propagation en RNN – BPTT
  - Para entender y visualizar la propagación hacia atrás, desenrollemos la capa oculta de la red en todos los pasos de tiempo.
  - Recuerde que en una RNN podemos tener o no salidas en cada paso de tiempo.
  - En el caso de la propagación hacia delante (forward propagation), las entradas ingresan y avanzan en cada paso de tiempo.
  - En la propagación hacia atrás (back propagation), de manera figurativa, retrocedemos en el tiempo para cambiar los pesos, por eso se conoce a esta técnica como propagación hacia atrás a través del tiempo (Back Propagation Through Time - BPTT).

Redes neuronales recurrentes

- RNN desenrollada



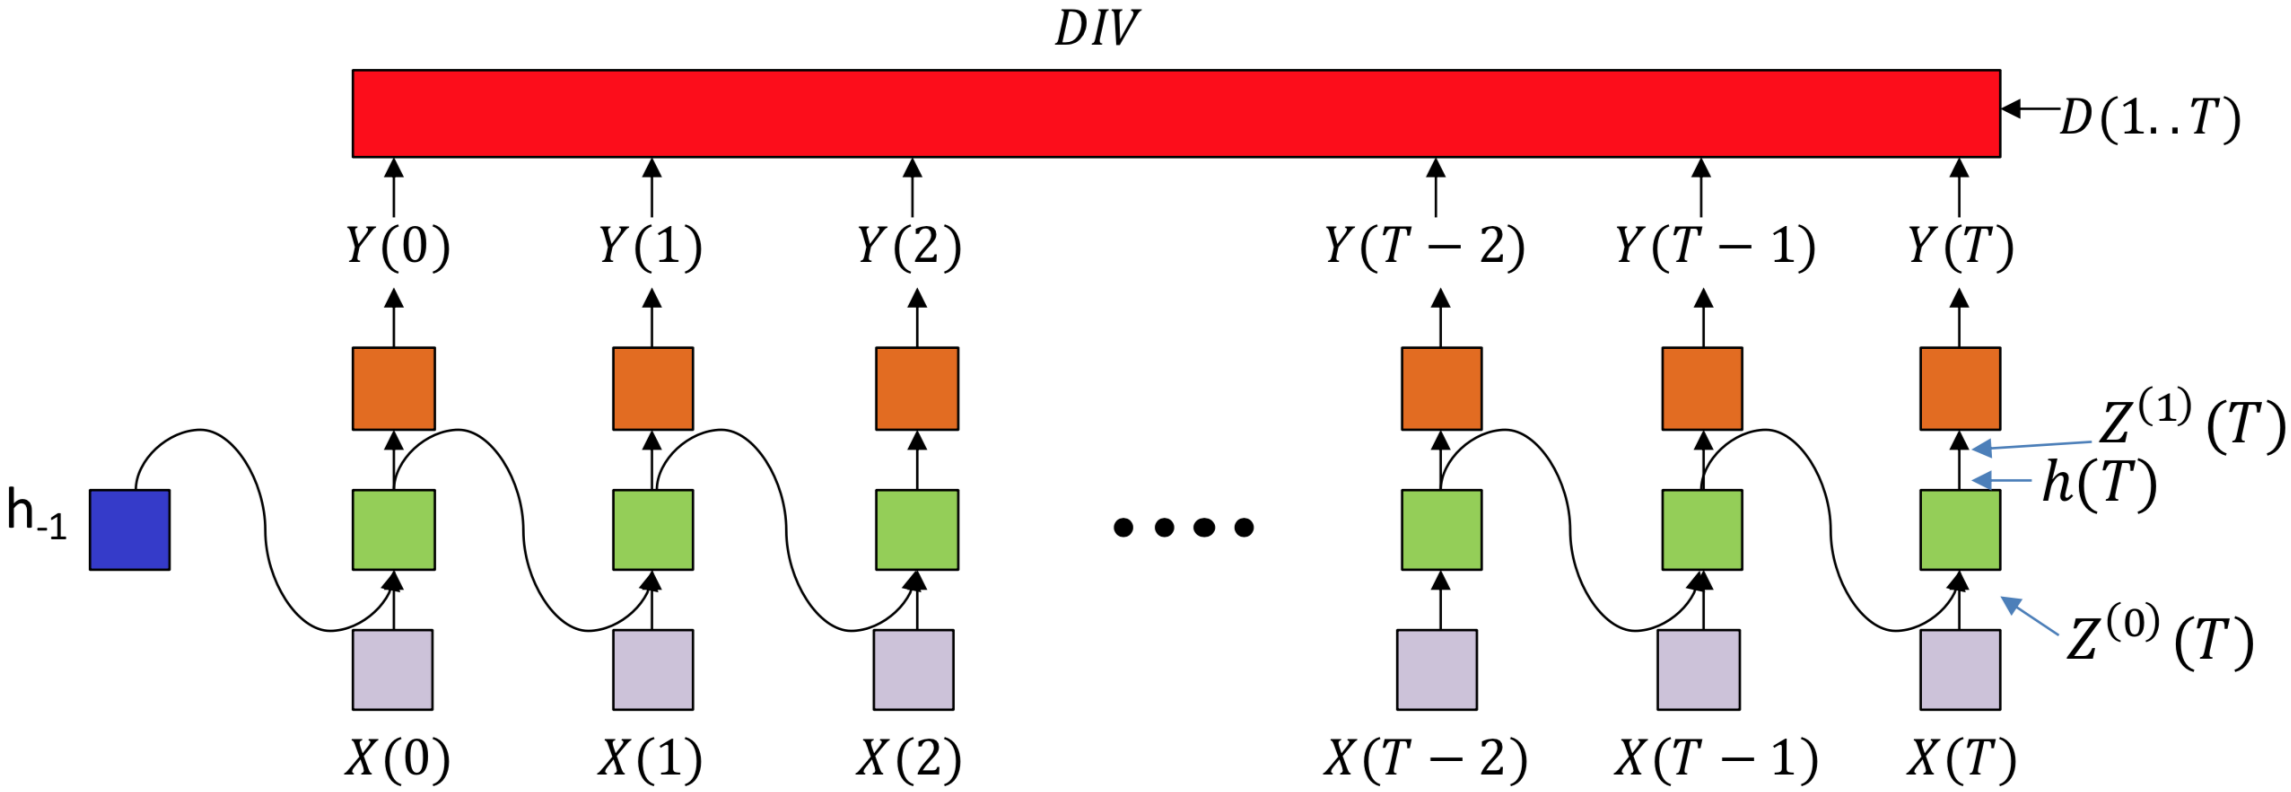
Redes neuronales recurrentes

- Procedimiento para el algoritmo BPTT:

1. Calculamos el error utilizando la salida actual y la salida esperada.
2. Desenrollamos todos los pasos de tiempo.
3. Para la red desenrollada, se calcula el gradiente para cada paso de tiempo con respecto a los pesos.
4. En el paso forward los pesos son los mismos para todos los pasos de tiempo, en backprop los gradientes se actualizan en cada paso.
5. Los pesos se actualizan para las neuronas recurrentes y las capas de salida.

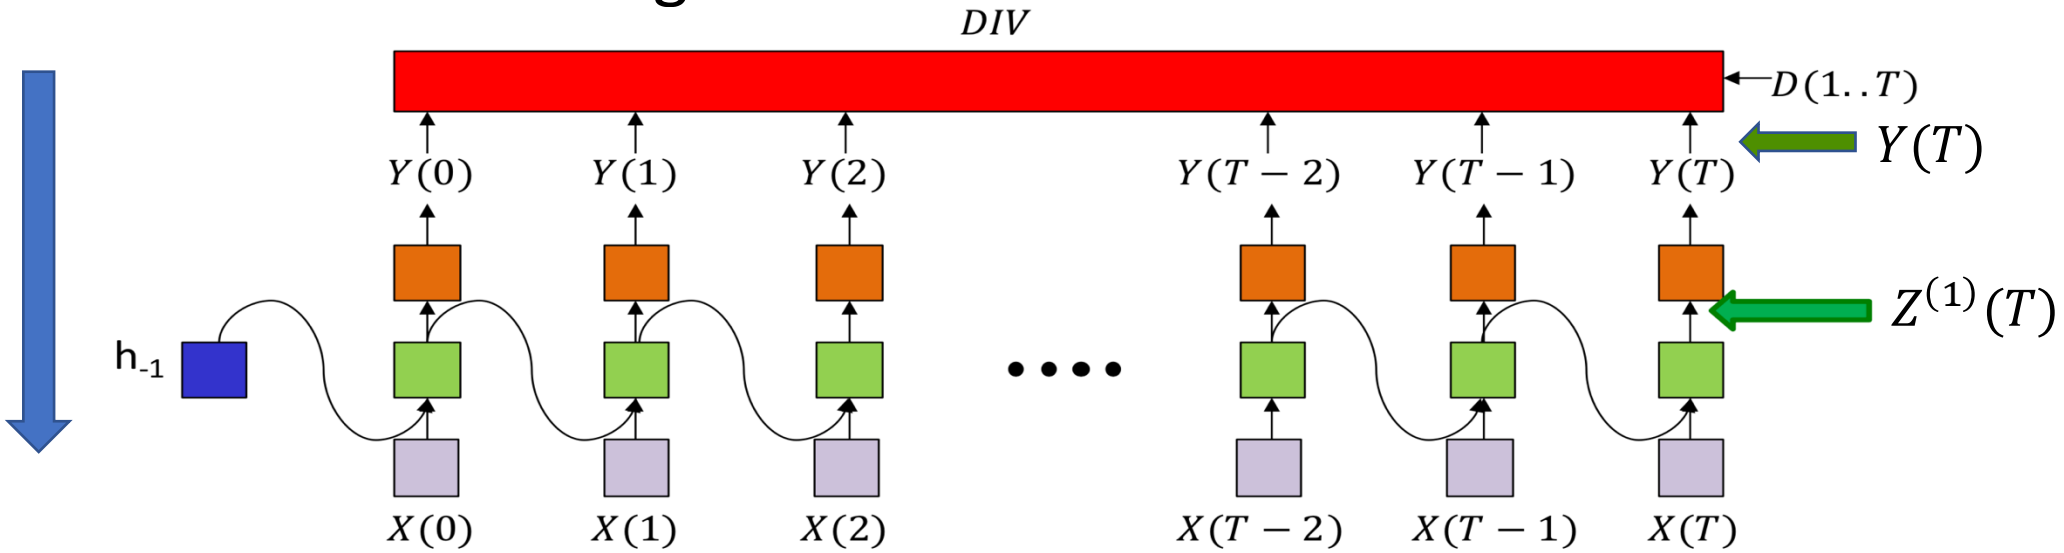
Redes neuronales recurrentes

- Cómo se calcula el gradiente en BPTT



Redes neuronales recurrentes

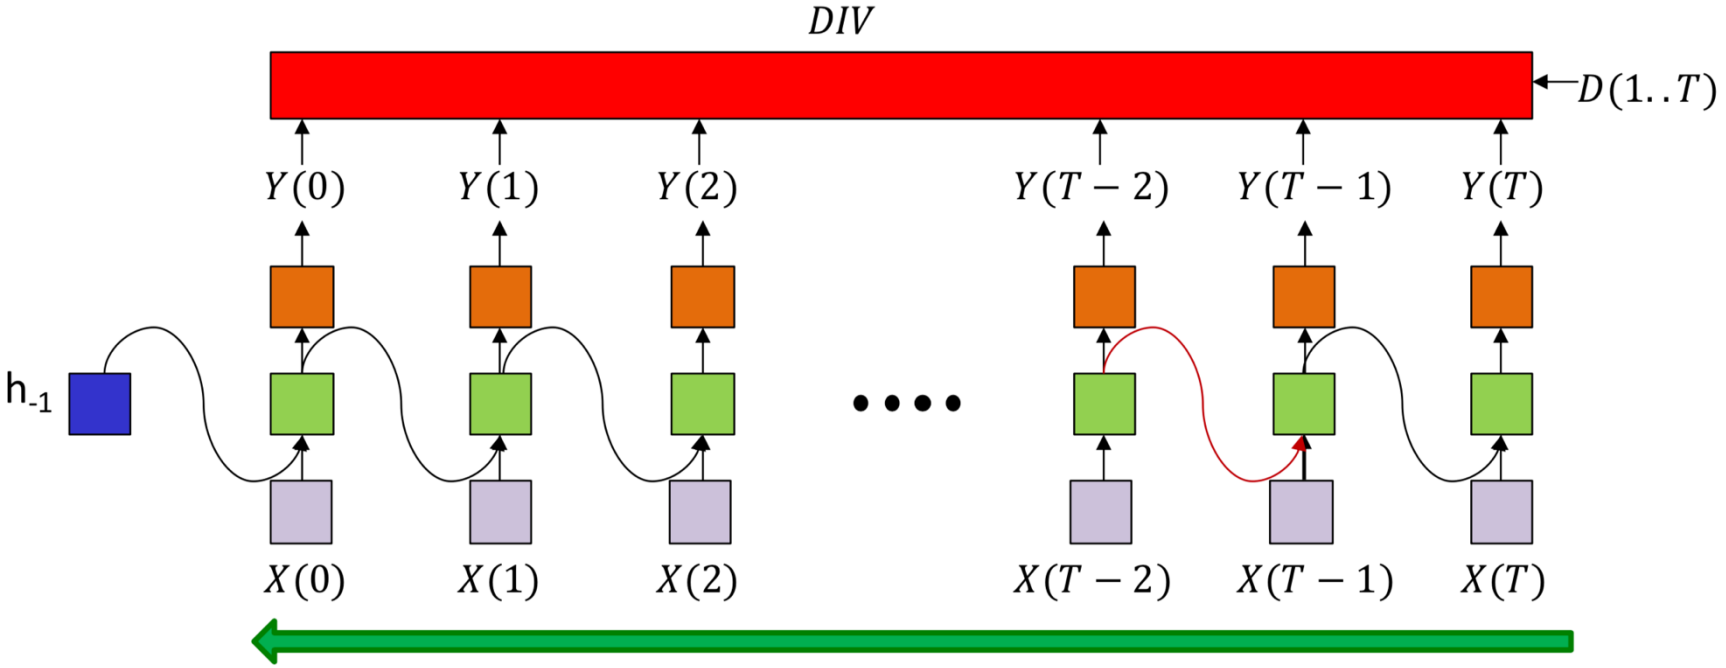
- Cómo se calcula el gradiente en BPTT



- Primer paso (Inicializar el gradiente): Calcular $\frac{dDIV}{dY_i(T)}$ para todas las i
- Luego: $\frac{dDIV}{dZ_i^{(1)}(T)} = \frac{dDIV}{dY_i(T)} \frac{dY_i(T)}{dZ_i^{(1)}(T)}$
- o el vector: $\frac{dDIV}{dZ_i(T)} = \sum_i \frac{dDIV}{dY_i(T)} \frac{dY_i(T)}{dZ_i^{(1)}(T)}$

Redes neuronales recurrentes

- Cómo se calcula el gradiente en BPTT



$$\frac{dDIV}{dY_i(T)}$$

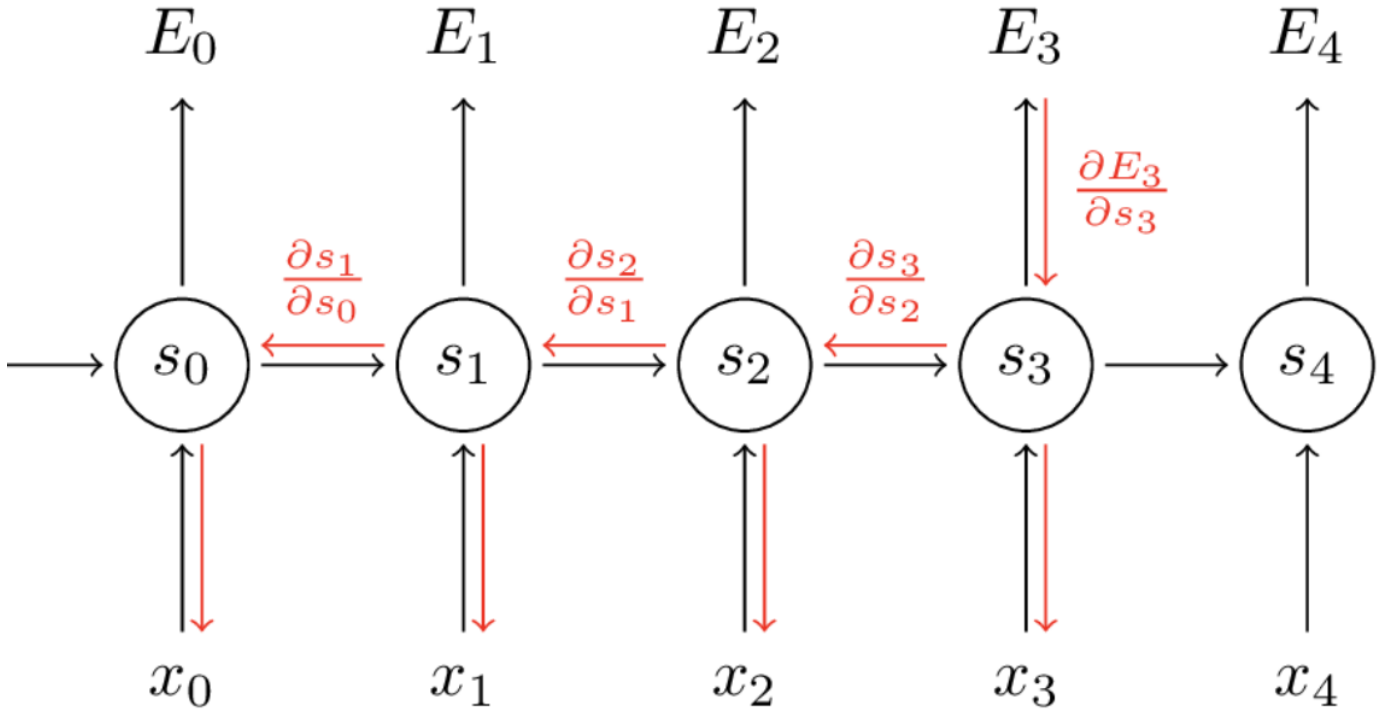
$$\frac{dDIV}{dh_{-1}} = \sum_j w_{ij}^{(11)} \frac{dDIV}{dZ_j^{(1)}(0)}$$

$$\frac{dDIV}{dw_{ij}^{(0)}} = \sum_t \frac{dDIV}{dZ_j^{(0)}(t)} X_i(t)$$

$$\frac{dDIV}{dw_{ij}^{(11)}} = \sum_t \frac{dDIV}{dZ_j^{(0)}(t)} h_i(t-1)$$

Redes neuronales recurrentes

- En otras palabras, debido a que W se usa en cada paso hasta la salida, necesitamos propagar los gradientes de regreso desde la salida a través de la red hasta $t = 0$.
- Por ejemplo: la propagación del error desde $t = 3$ es:



Redes neuronales recurrentes

- Desvanecimiento del gradiente
  - El gradiente se usa para hacer ajustes en los pesos de la red, lo que le permite aprender.
  - Pequeños gradientes significan pequeños ajustes, eso hace que las primeras capas no se ajusten, o aprendan.

$$W_{j_{nuevo}} = W_{j_{anterior}} - \alpha \frac{d}{dw_j} J(w_j)$$



Long Short Term Memory Networks - LSTM

- Las redes Long Short Term Memory - LSTM, resuelven este problema, son un tipo especial de RNN.
- Pero, son capaces de aprender dependencias a largo plazo.
- Fueron propuestas por Hochreiter y Schmidhuber en 1997.
- Funcionan bien en una gran variedad de problemas.
- Las LSTM también tienen esta estructura tipo secuencial, pero el módulo recurrente tiene una estructura diferente; en lugar de tener una sola capa de red neuronal, tienen múltiples “capas”, que interactúan de una manera particular.
- Las LSTM tienen 3 puertas: Una de entrada, una de olvido y una de salida.