Inteligencia Artificial

ENRIQUE PELÁEZ Ph.D.

Escuela Superior Politécnica del Litoral – ESPOL

Facultad de Ingeniería en Electricidad y Computación – FIEC

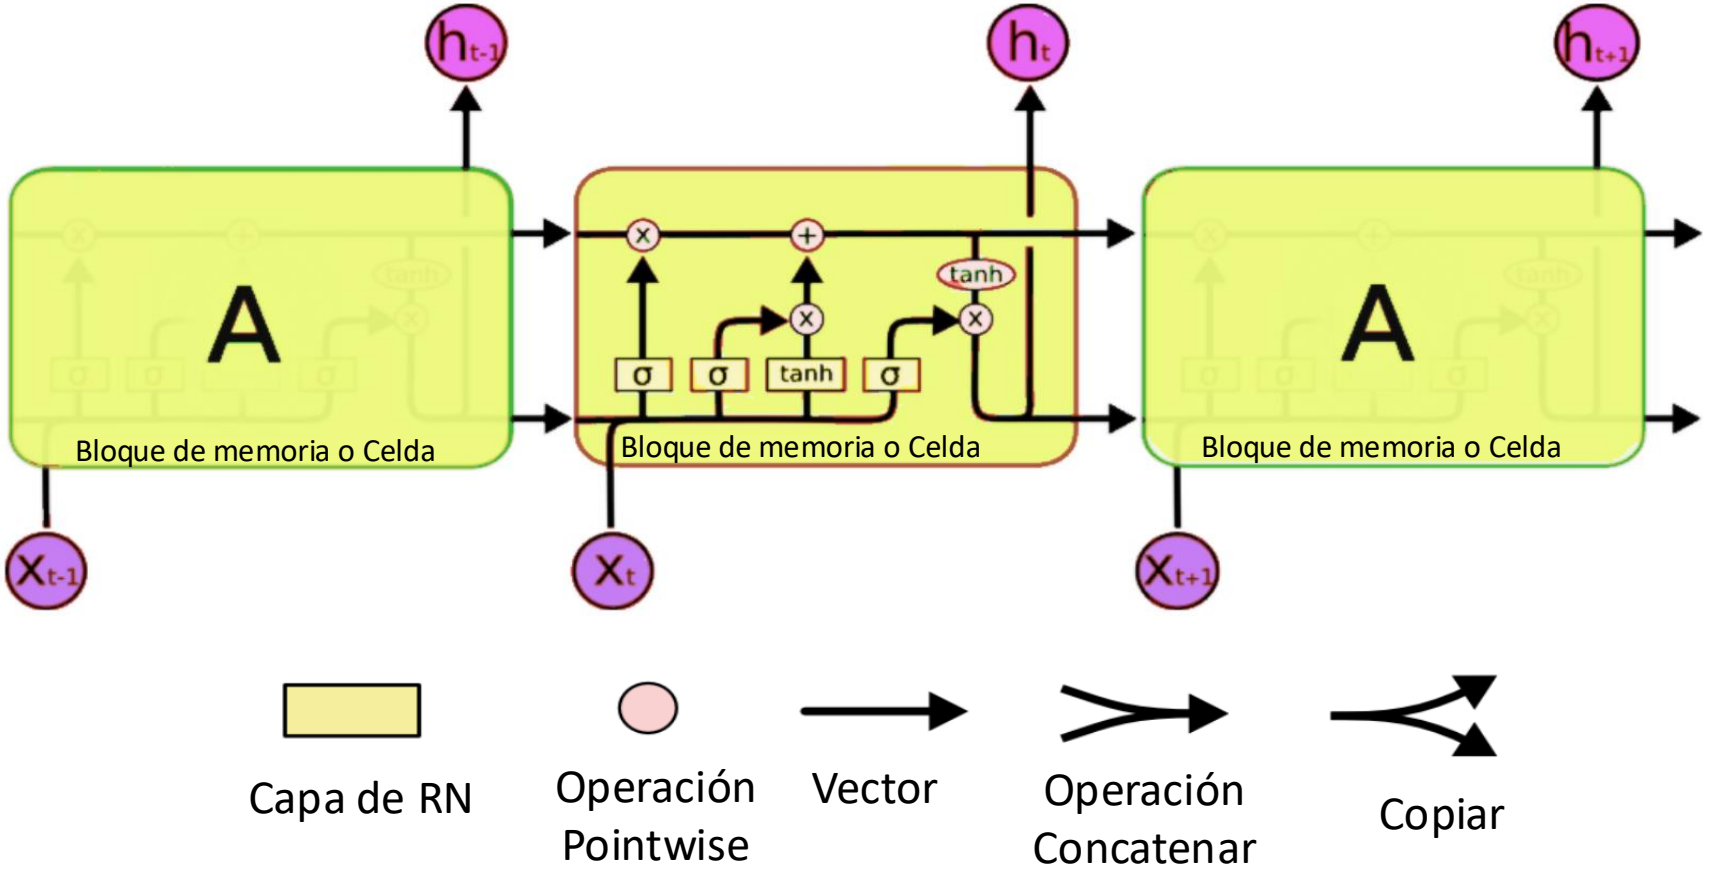
Clase # 18 - PAO 2026 – I

Agenda

1. Redes LSTM – Long-Short Term Memory
   1.1 Redes GRU
2. Transformers
   2.1 Qué son ?
   2.2 Encoder – Decoder
   2.3 Auto-atenttion
   2.4 Las matrices: K, Q, V
   2.5 Multi-heads
   2.6 Embeddings (texto y posición)

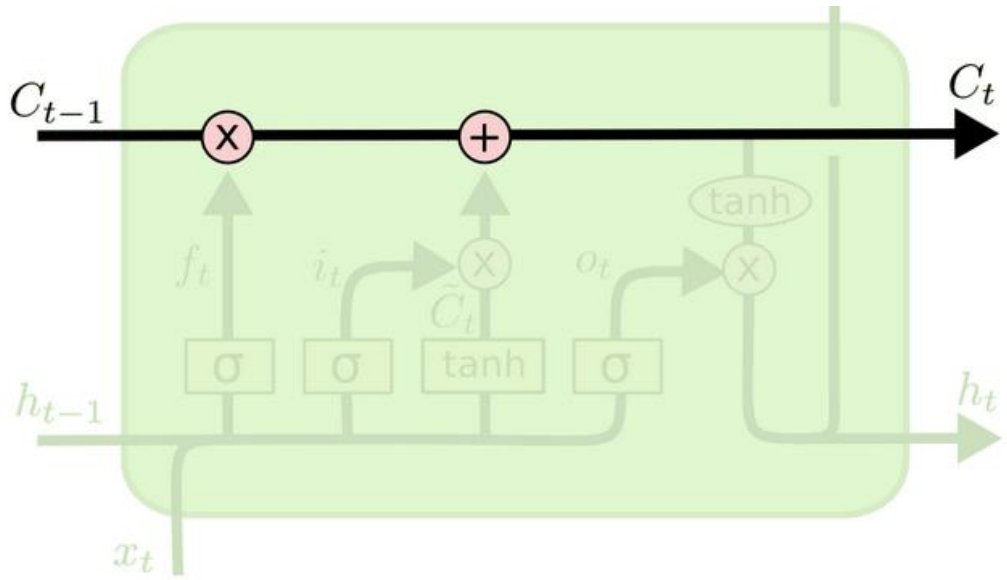
Long Short Term Memory Networks - LSTM

- Arquitectura de las LSTM



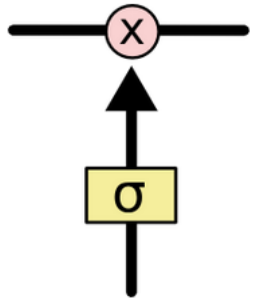
Long Short Term Memory Networks - LSTM

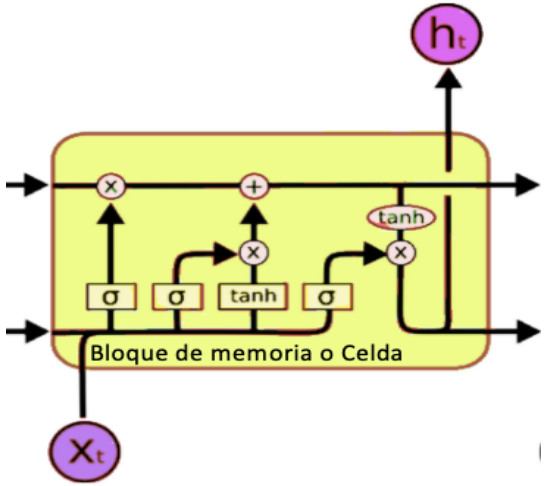
- En las redes LSTM el estado de la celda es la línea horizontal que recorre la parte superior del diagrama
- El estado de la celda recorre toda la cadena de celdas



Long Short Term Memory Networks - LSTM

- Las LSTM tienen la capacidad de eliminar o agregar información al estado de la celda, a través de estructuras llamadas compuertas (puertas o gates)
- Las puertas son una forma de pasar información de celda a celda y son RN de una capa con una función de activación tipo sigmoidal y operaciones pointwise
- Esta capa sigmoidal produce números entre 0 y 1, y deciden la información que cada celda debe dejar pasar
- 0 significa "no dejar pasar nada", 1 significa "dejar pasar todo”
- Las celdas LSTM tienen 3 de estas puertas, para proteger y controlar el estado de la celda: Olvido, entrada y salida.

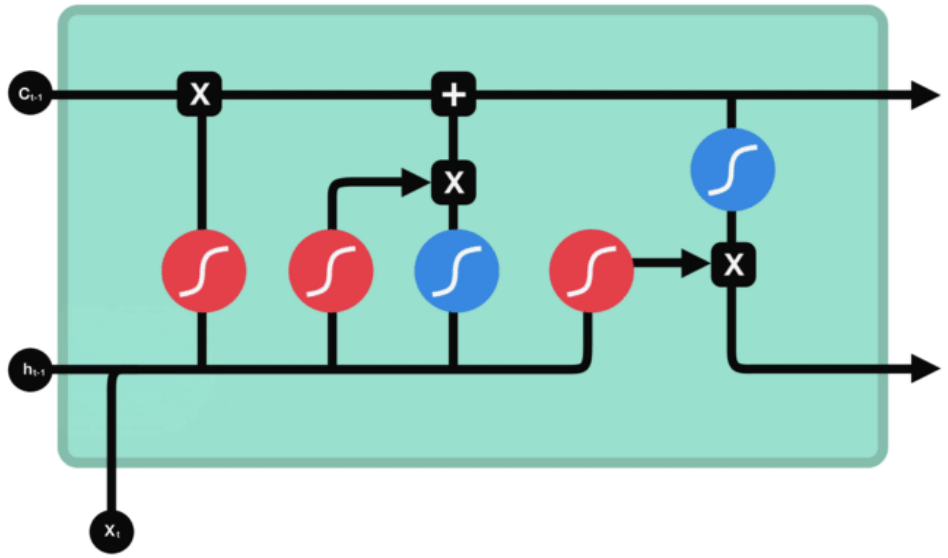




Long Short Term Memory Networks - LSTM

- El primer paso en la red LSTM es decidir qué información va a eliminar (si hay algo que eliminar) del estado de la celda
- Esta decisión la toma la capa sigmoidal llamada ”**puerta de olvido**”
- Esta puerta mira a h_{t-1} y x_t, y genera un número entre 0 y 1 para cada valor en el estado de celda C_{t-1}

- Esta puerta decide qué información se debe desechar o guardar
- Los valores salen entre 0 y 1. Cuanto más cerca de 0 olvidar, y más cerca de 1 mantener

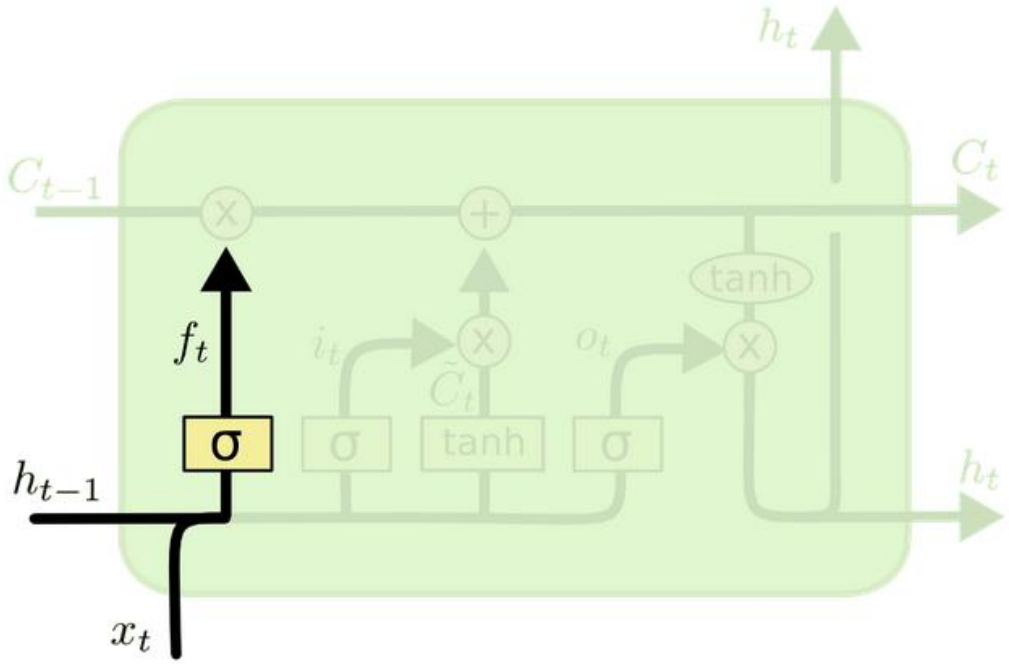


c_{t-1} estado previo de la celda

f_t salida de la puerta de olvido

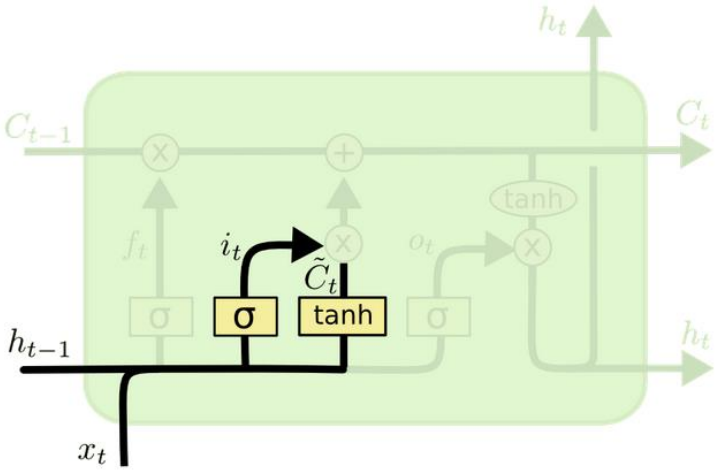
Long Short Term Memory Networks - LSTM

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right)$$



Long Short Term Memory Networks - LSTM

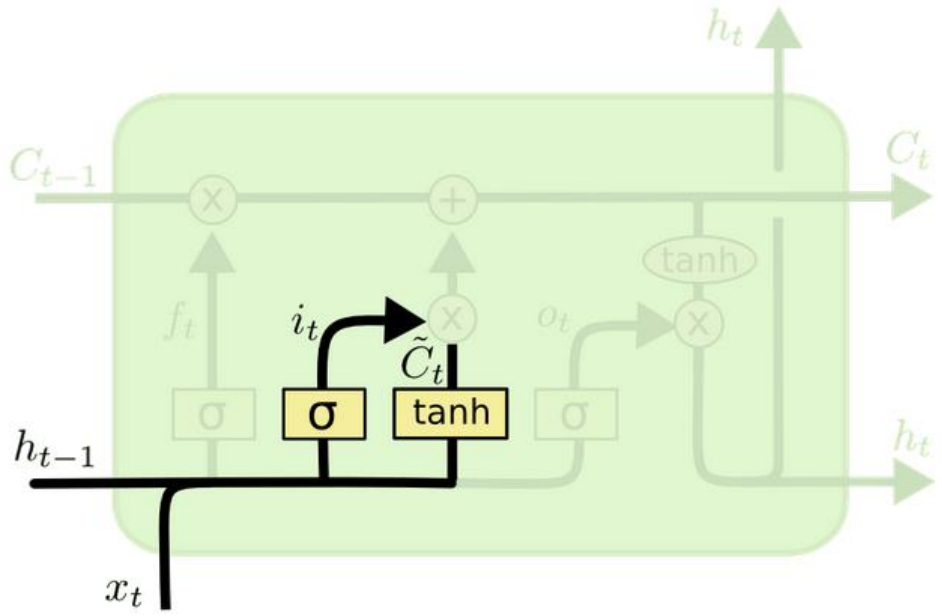
- El siguiente paso es decidir qué información nueva vamos a almacenar en el estado de la celda
- Este paso tiene dos partes:
  1. Una capa sigmoidal llamada "**puerta de entrada**", la cual decide qué valores actualizar
  2. Una capa $tanh$, la cual crea un vector con nuevos valores "candidatos", $\tilde{C}_t$, que podrían agregarse en este estado
- En el siguiente paso, se combinan las dos salidas para crear una actualización del estado



Long Short Term Memory Networks - LSTM

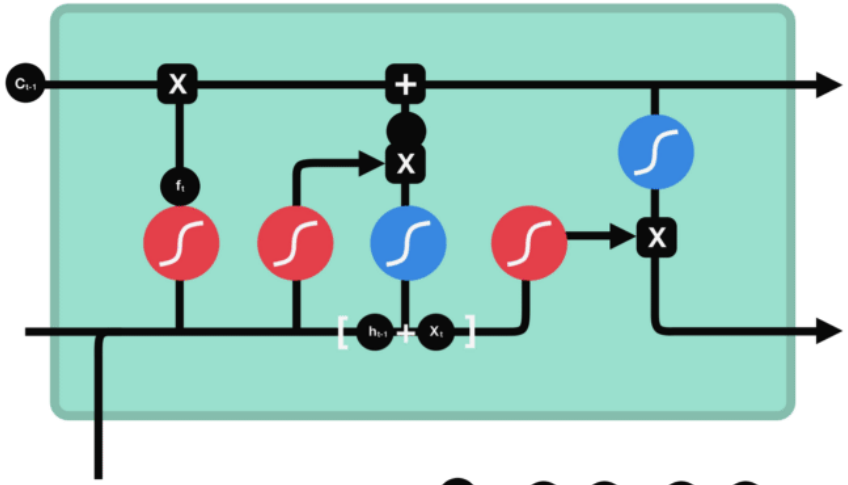
$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] + b_i\right)$$

$$\tilde{C}_t = tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$



Long Short Term Memory Networks - LSTM

- Estado de la celda
  - Con esta información se calcula el estado de la celda
  - El estado de la celda anterior se multiplica por el vector a olvidar; esto permite quitar valores en el estado actual de la celda si se multiplica por valores cercanos a 0
  - Luego tomamos la salida de la puerta de entrada y hacemos una suma element-wise; esto actualiza el estado de la celda con nuevos valores que la red encuentra relevantes, generando el nuevo estado de la celda



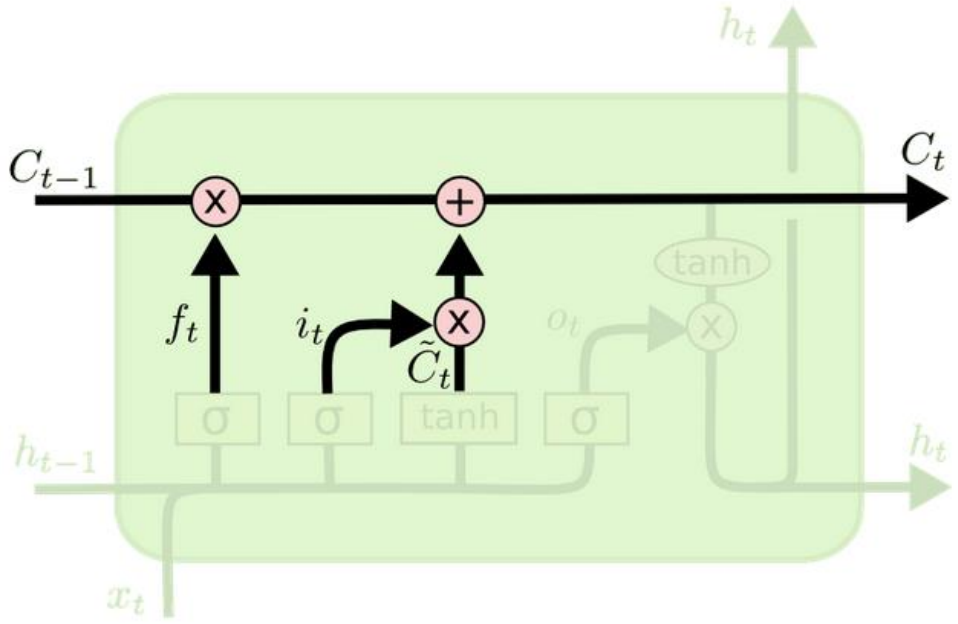
$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$

- C_{t-1} estado previo de la celda
- f_t salida de la puerta de olvido
- i_t salida de la puerta de entrada
- $\tilde{C}_t$ candidatos
- C_t nuevo estado de la celda

Long Short Term Memory Networks - LSTM

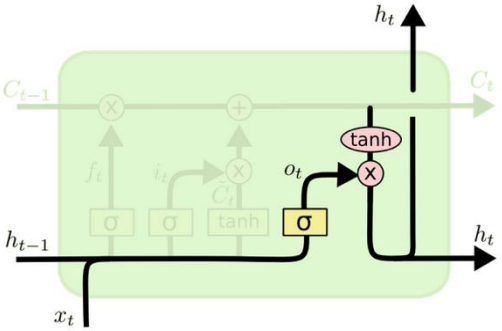
- En este estado también se agrega información, tal como se decidió en los pasos anteriores

$$C_t = f_t * C_{t-1} + i_t * \widetilde{C}_t$$



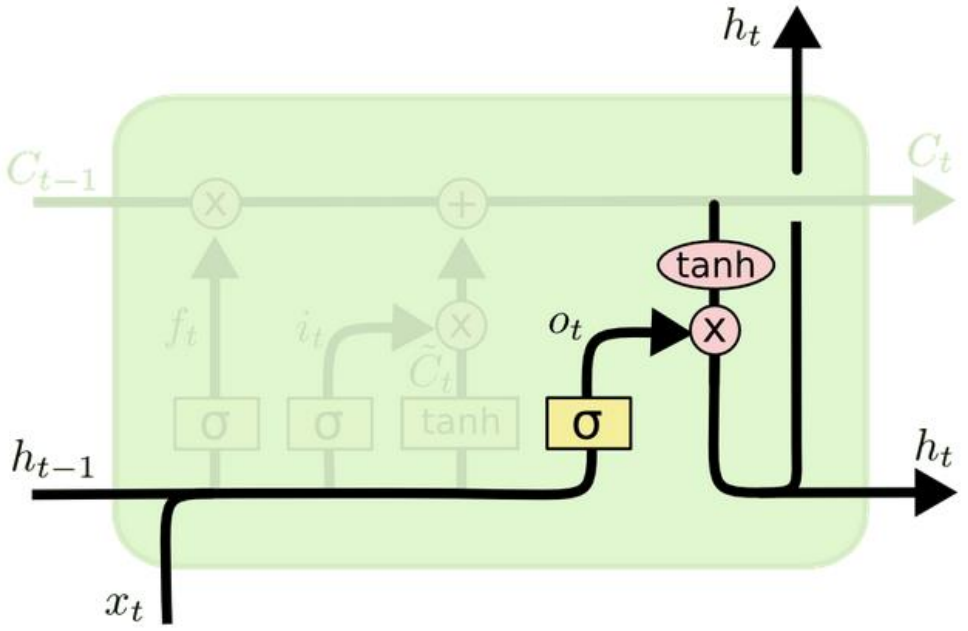
Long Short Term Memory Networks - LSTM

- Finalmente, debemos definir la salida
  - La salida depende del estado actual de la celda, pero como una versión filtrada
  - La **puerta de salida** decide, cuál debe ser el siguiente estado de la celda
  - Recuerde que el estado de la celda contiene la información de las entradas anteriores. El estado de la celda también se usa para predicciones
  - Primero, pasamos el estado anterior y la entrada actual a una función sigmoidal
  - Luego pasamos el estado de celda recién modificado por una función tanh
  - Multiplicamos la salida de tanh con la salida sigmoide para decidir qué información se debe pasar al siguiente estado
  - La salida es el nuevo estado de la capa oculta (estado de la red)
  - El nuevo estado de la celda y el nuevo estado de la red se transfieren al siguiente paso de tiempo



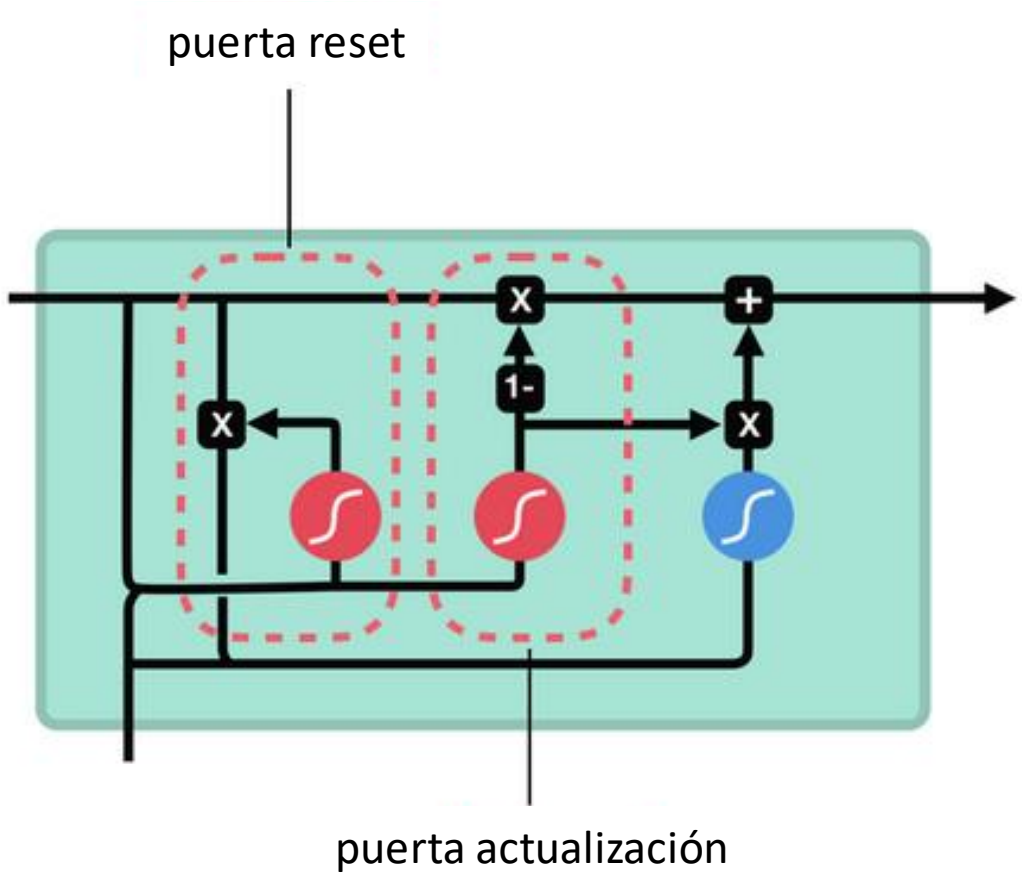
Long Short Term Memory Networks - LSTM

- $o_t = \sigma\left(W_o \cdot [h_{t-1}, x_t] + b_o\right)$
- $h_t = o_t * \tanh(C_t)$



Long Short Term Memory Networks - LSTM

- Gated Recurrent Unit - GRU:



Transformers

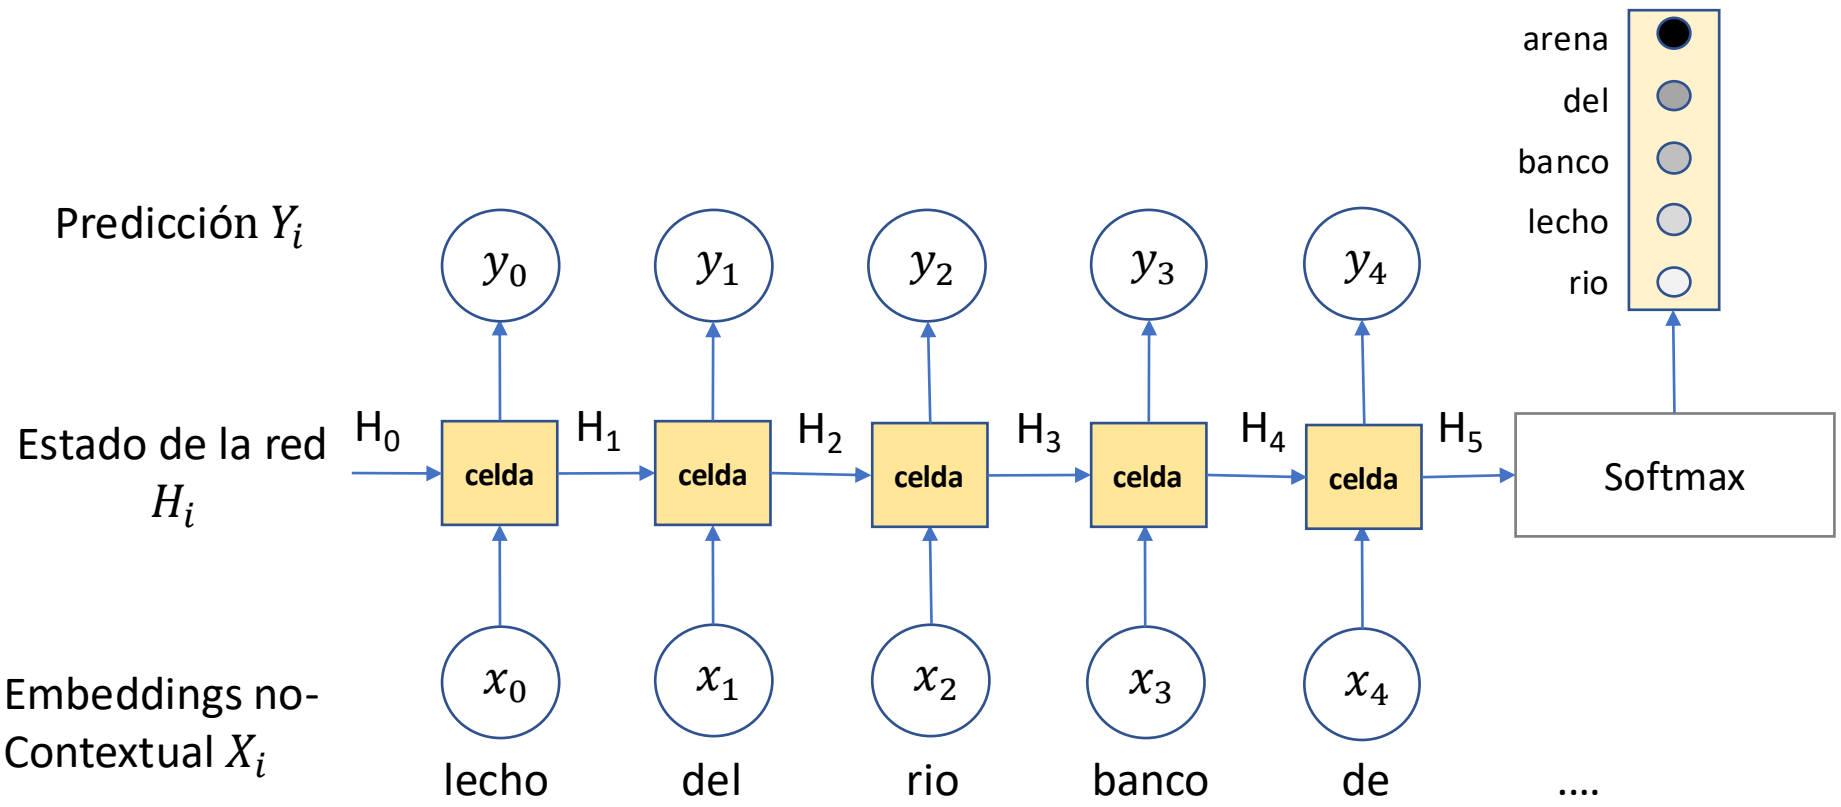
- 2013 – Word2Vec
- 2014 – RNNs modelos de lenguaje
- 2017 - Transformers

Transformers:

- Estándar de rendimiento en una variedad de tareas de NLP
- BERT (Bidirectional Encoder Representation Transformer),
- GPT (Generative Pre-trained Transformer) y otros,
- Estos modelos son capaces de captar sutilezas del lenguaje y generar texto

Transformers

- En las RNN

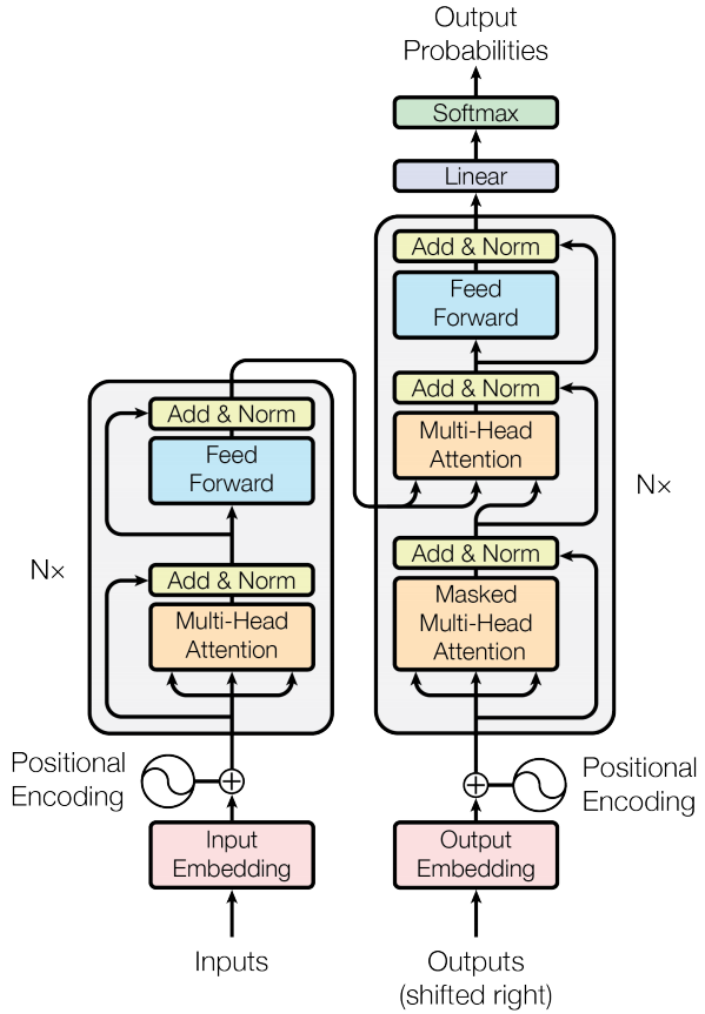


Retos:

- Lento O(N): N # de tokens
- Desvanecimiento del gradiente
- Unidireccional: Izquierda – derecha
  - Banco de arena vs.
  - Arena en el banco

Transformers – Qué son ?

- Es un tipo de RN para tareas tipo Seq2Seq.
- Arquitectura encoder-decoder.
- Sin desvanecimiento del gradiente.
- Sin problema con las dependencias largas.
- Utilizan **attention** para aumentarla precisión y velocidad de entrenamiento.
- Propuesto en “Attention is all you need”.
- Su mayor beneficio, la paralelización.
- Diponible en TensorFlow como parte de Tensor2Tensor.
- También está en PyTorch.



Transformers

