1. Descripción del problema

El 90% de la comunicación que realizamos día a día es no verbal, nuestros gestos faciales, entonación y lenguaje corporal son mucho más relevantes que el contenido transmitido en nuestras palabras. Pequeñas acciones como esconder las manos en los bolsillos o colocarlas en la espalda delatan inseguridad a la hora de realizar presentaciones, si sumamos a esto una postura encorvada con en una entonación débil, nuestra comunicación carecerá de confianza. [3]

Estos patrones negativos son perjudiciales para nuestro desempeño académico o laboral ya que en estos escenarios nos encontramos en situaciones donde debemos exponer nuestras ideas o avances de manera a un público diverso.

El problema es que la mayoría de estas acciones son realizadas sin que nos demos cuenta de que las ejecutamos, debido a que normalmente estamos mucho más concentrados en las palabras que usamos.

Los distintos patrones que realizamos posicionando las distintas partes de nuestro cuerpo al exponer pueden ser analizados para su clasificación, si la postura del expositor es o no es efectiva, y si no es efectiva que parte del cuerpo es la que está fallando. Realizar este análisis utilizando únicamente computer vision es complicado debido a la necesidad de generalizar los distintos puntos clave para el cuerpo de todos los seres humanos, por lo que implementar un modelo de inteligencia artificial que aprenda los buenos y malos patrones para su clasificación es la alternativa más eficiente.

2. Objetivo

Clasificar las posturas buenas o malas de un expositor, a partir del análisis de videos de exposiciones verbales, utilizando técnicas de Inteligencia Artificial

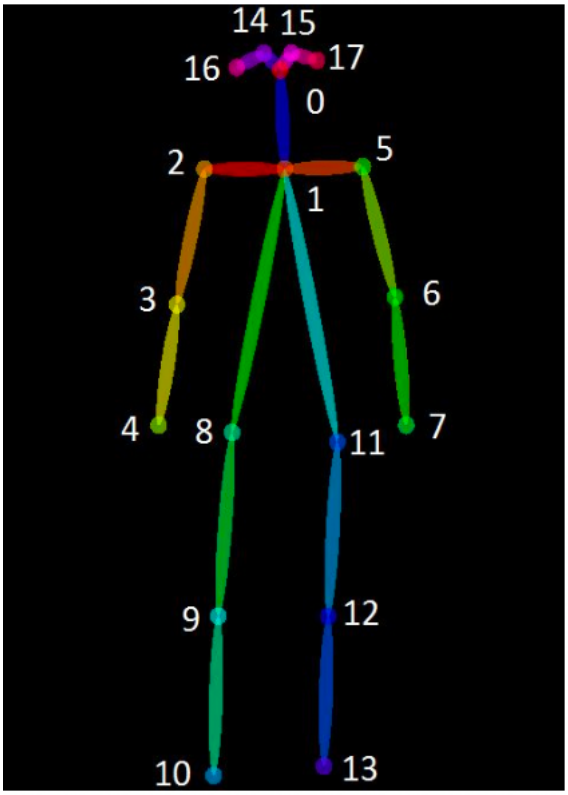
3. Propuesta de solución

Para el desarrollo de la solución a la problemática planteada se tendrá primero que identificar como obtener cada una de las posiciones de las articulaciones por cada fotograma del video. Para esta parte será utilizado un modelo pre-entrenado llamado PoseNet, el cual se basa en el uso de técnicas de DL conocidas como redes neuronales convolucionales para la clasificación de imágenes en categorías y estimar un objetivo que en este caso sería la identificación del tipo de postura. PoseNet nos da un total de 16 articulaciones desde nuestros ojos y oídos hasta las rodillas y tobillos.

Tabla 1: Descripción de cada coordenada

ID	Nombre	Descripción
0	Nose	Nariz
1	RShoulder	Hombro Derecho
2	RElbow	Codo Derecho
3	RWrist	Muñeca Derecha
4	Lshoulder	Hombro Izquierdo
5	Lelbow	Codo Izquierdo
6	Lwrist	Muñeca Izquierda
7	RHip	Cadera Derecha
8	Rknee	Rodilla Derecha
9	Rankle	Tobillo Derecho
10	Lhip	Cadera Izquierda
11	Lknee	Rodilla Izquierda
12	Lankle	Tobillo Izquierdo
13	Reye	Ojo Derecho
14	LEYE	Ojo Izquierdo
15	Rear	Oreja Derecha
16	LEar	Oreja Izquierda

Ilustración 1:Cada articulación encontrada por PoseNet



La salida que nos proporciona PoseNet con la ubicación de cada articulación servirá como entrada al modelo que se creará basándose en redes neuronales multicapa para la clasificación por multiclase, este tipo de clasificación involucra el entrenamiento de varias instancias para distintas

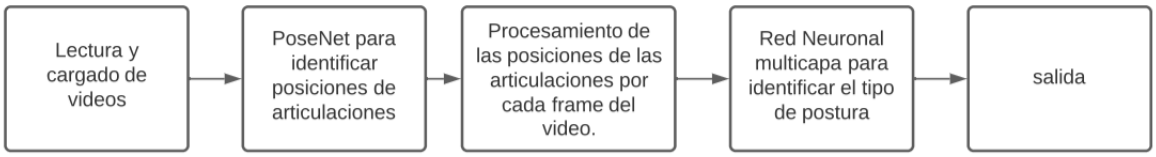
categorías con el objetivo de poder identificar categorías para instancias desconocidas [1]. Los datos de entrenamiento son provistos por la entidad que propuso el reto por lo que es trabajo del grupo el modelar en base a las series dadas; este training set cuenta con diferentes características entre las que se encuentran todas aquellas listadas en la TABLA 1. Como se trata de aprendizaje supervisado el training set cuenta con una columna donde, según los valores de las coordenadas de las características, se asigna un valor numérico entre 0 y 6 para clasificar el tipo de postura que se presenta en la entrada; remítase a la TABLA 2 para mayor detalle de los tipos de postura. Los valores de esta última columna representan los valores esperados, como se trata de clasificación se planea usar la función sigmoidal como función de activación.

Tabla 2: Tipo de posturas a clasificar

Postura	**Tipo de postura**
0	Manos en bolsillos
1	Brazos cruzados
2	Gesticulando
3	Manos abajo
4	Manos atrás
5	Manos juntas
6	Apuntando a las diapositivas

Los datos para el entrenamiento del modelo de multiclase serán por medio de un data set que fue entregados en el PyWeekend realizado en el año 2018 dentro de la ESPOL. En esta carpeta de Google drive, se encuentra un archivo llamado train.csv que cuenta con 32.302 observaciones donde cada una de estas observaciones contiene ubicaciones x, y de las articulaciones, la etiqueta acerca del tipo de postura que representa y si es una postura buena o mala. Las coordenadas de cada articulación se encuentran en el rango de 0-1280 en x, y 0-960 en y debido a que estos fueron extraídos de videos que contaban con una resolución de 1280x960.

Los componentes preliminares de la solución serian:



Delimitando el público objetivo únicamente a la comunidad politécnica, es válido destacar que los principales beneficiarios serían los estudiantes y los profesores. Por el lado de los estudiantes, se conoce que una parte importante que se toma en cuenta al momento de realizar una exposición oral sea esta el 5 *minutes pitch,* sustentación de tesis, etc. Es la postura y la manera de moverse, en pocas palabras el lenguaje corporal. Los estudiantes pueden practicar su presentación varias veces, pero no podrán recibir *feedback* inmediato y que es importante para realizar las correcciones necesarias, es ahí donde entra en juego la solución del proyecto. Los estudiantes podrán grabar su presentación, analizarla con el modelo y observar que gestos están considerados incorrectos, todo esto de manera inmediata.

En cuanto a los profesores, la carga de trabajo que conlleva el enseñar sobre la correcta manera de realizar una exposición oral más la carga de la materia que instruyen resulta en una falta de tiempo para aleccionar a cada estudiante por igual. El modelo busca aligerar dicha carga, y esto se haría proveyéndole del modelo al estudiante para que él sea quien analice que está mal en su postura a la hora de su presentación oral. El estudiante podrá discriminar las posturas inadecuadas y referirse al profesor por ayuda, este último le ayudará con instrucciones sobre qué hacer en esos casos. De esa manera el profesor tendrá tiempo suficiente para instruir a todos sus estudiantes por igual.

4. Modelos completos de análisis y definición del problema.

Escenario #1: Un escenario estándar donde un estudiante realiza una grabación de una presentación a cuerpo completo, pero el estudiante no sabe que tan efectiva fue su exposición sino hasta que observa el video con la retroalimentación.

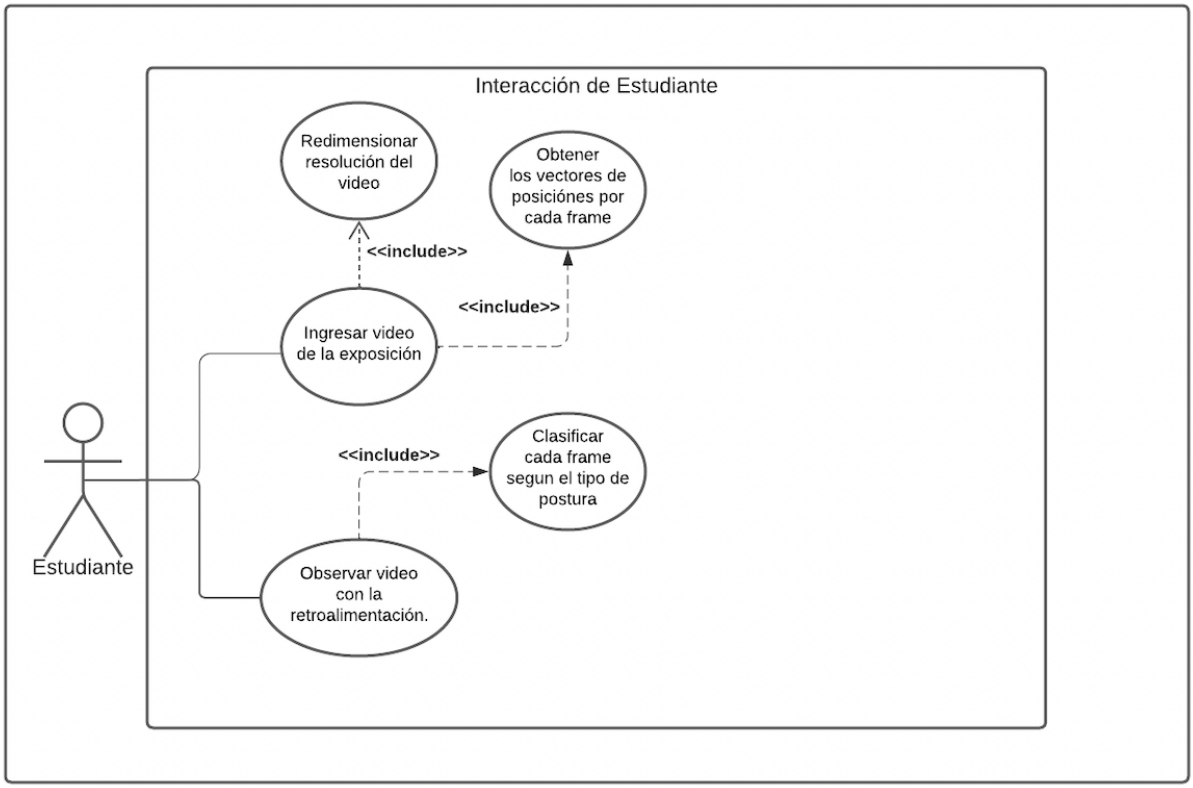


Ilustración 2 de uso# 1

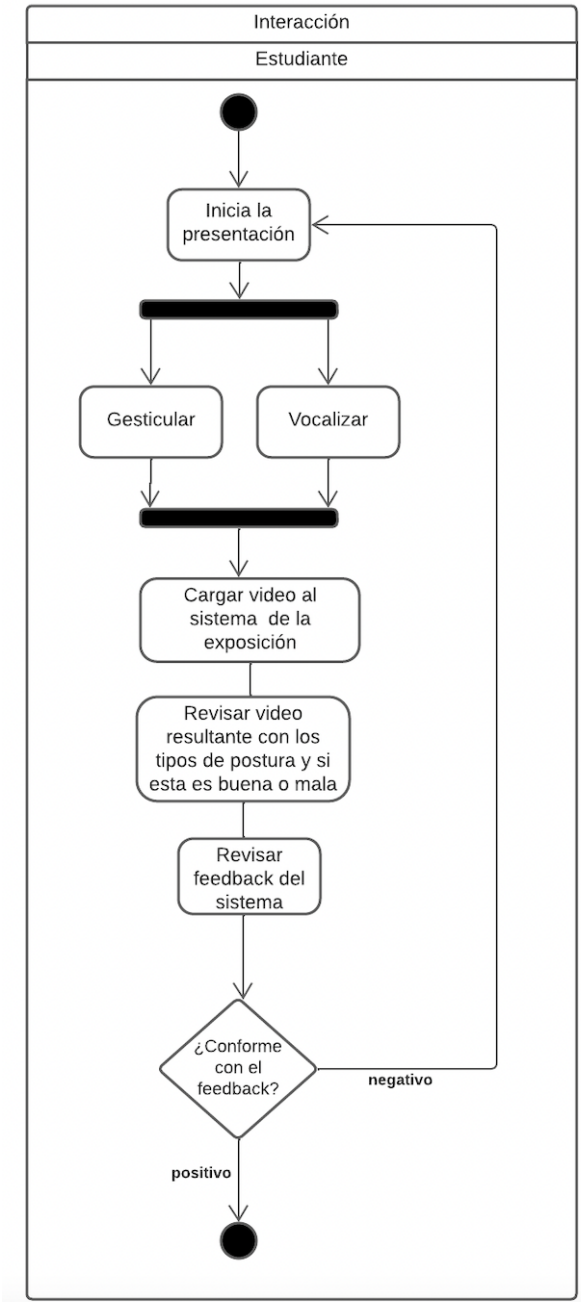


Ilustración 3:Diagrama de actividad

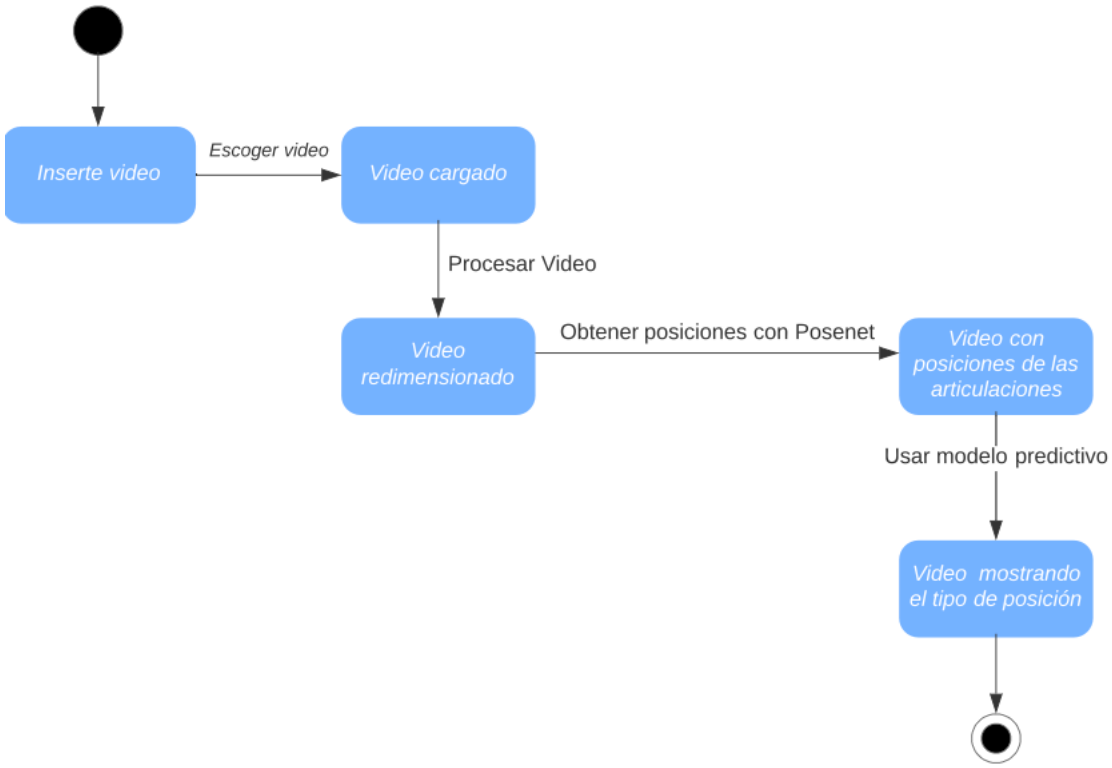


Ilustración 4:Diagrama de estados

Escenario #2: Un escenario donde un estudiante realiza una grabación de una presentación de medio cuerpo y el estudiante necesita saber que tan efectiva es su exposición.

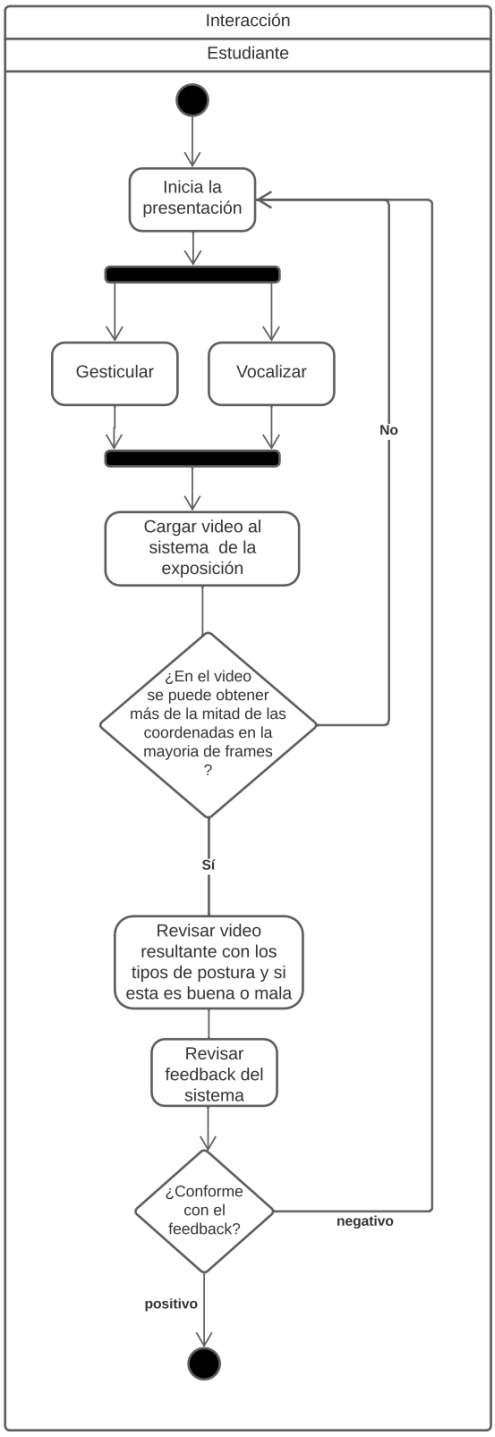


Ilustración 5:Diagrama de actividad#2

6. Modelo preliminar del diseño de la solución

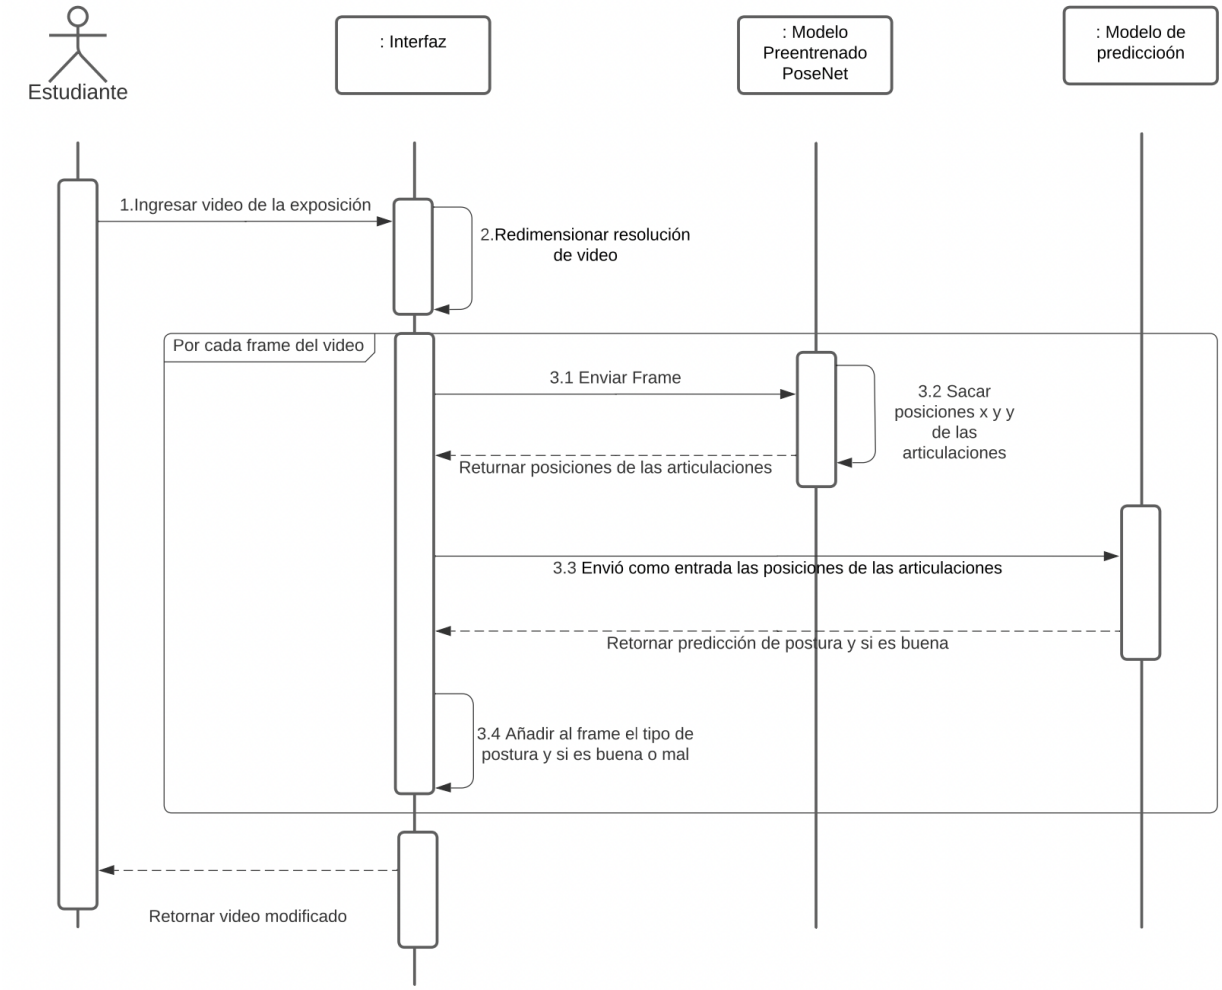


Ilustración 6:Diagrama de secuencias de la solución

Excelente - la secuencia de mensajes refleja la implementación

6.1. Diseño preliminar de la interfaz gráfica

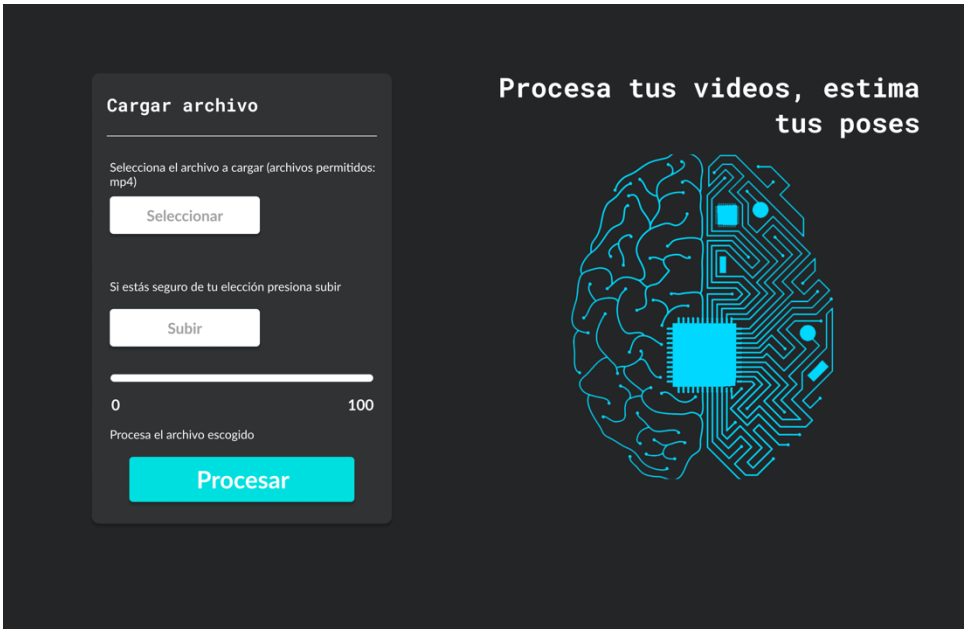


Ilustración 7:Pantalla de inicio

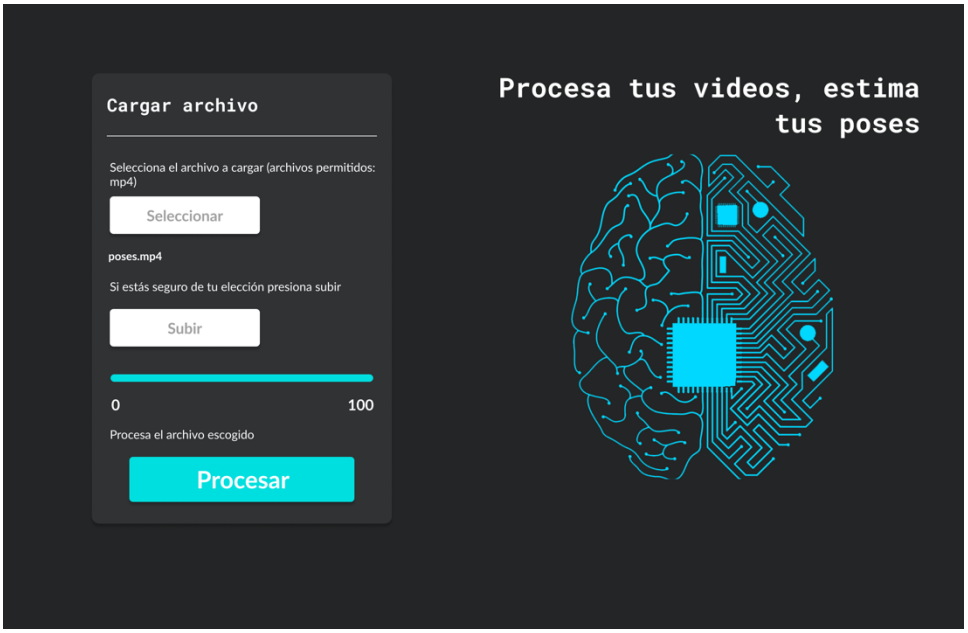


Ilustración 8:Pantalla una vez seleccionado un video

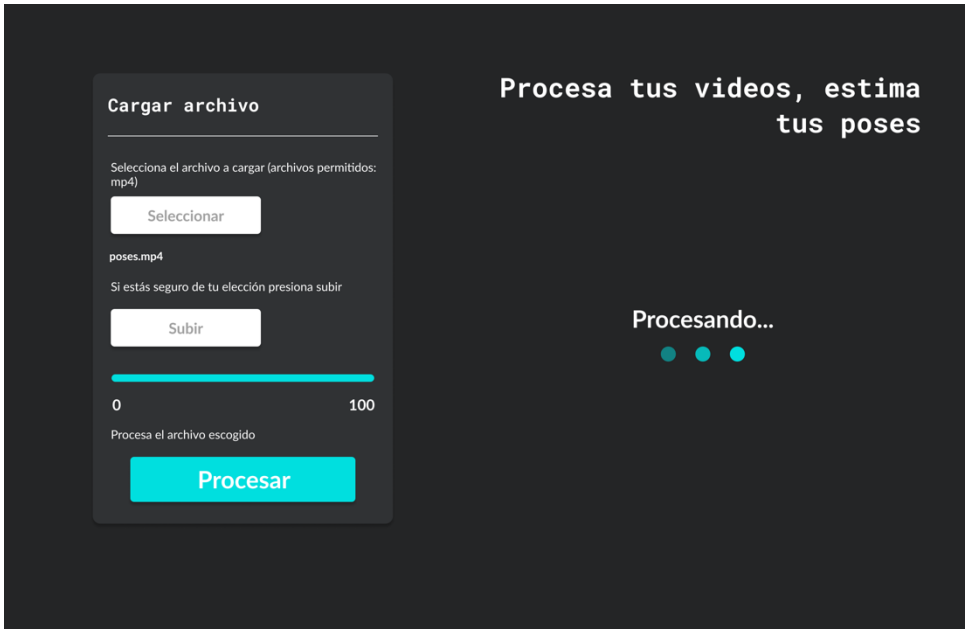


Ilustración 9:Cargando el video

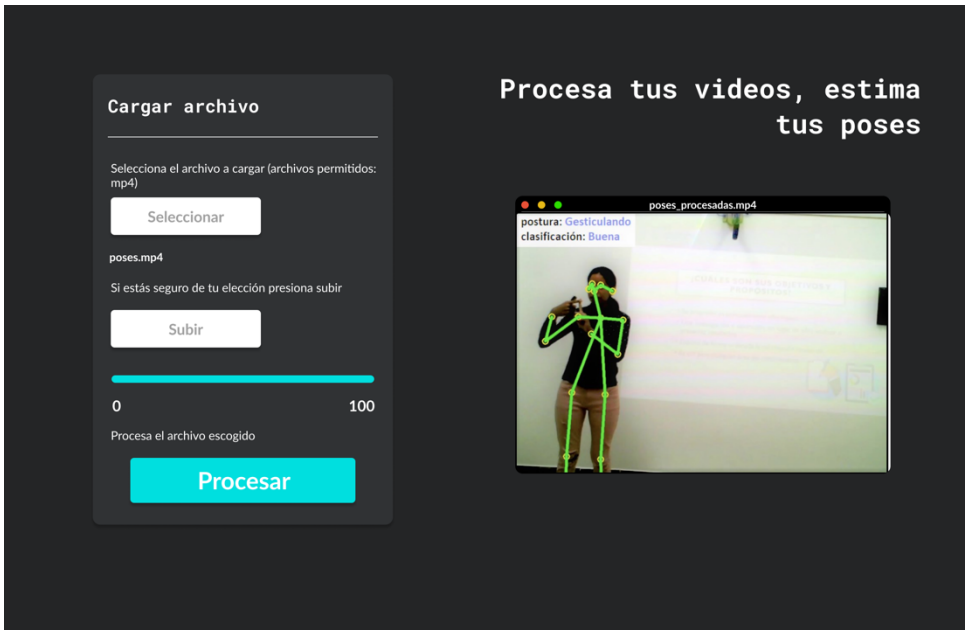


Ilustración 10:Resultado final

7. Modelos preliminares de la implementación

Para la implementación del diseño de la solución se tiene pensado utilizar como lenguaje de programación Python, concretamente la versión 3.9 debido a su alta compatibilidad con las diferentes librerías que se tiene en mente usar. Además, los miembros del grupo tienen un alto grado de conocimiento sobre este lenguaje lo que facilitaría el desarrollo.

Para una óptima implementación es necesario el uso de herramientas que ayuden a agilizar el desarrollo de la solución, por suerte para nosotros el lenguaje escogido cuenta con un alto número de librerías especializadas en machine learning, no toca volver a inventar la rueda. Las librerías que se tiene pensado usar son:

- **Numpy:** es una librería que resulta de suma importancia para el manejo de grandes cantidades de datos numéricos, pero sobre todo para la multiplicación de matrices. Machine learning es básicamente multiplicar matrices y si se busca una manera eficiente de hacerlo, numpy es la herramienta adecuada.
- **Keras:** es una librería que se presenta como una interfaz de alto nivel útil para trabajar con redes neuronales, con esta se planea realizar el levantamiento de la red neuronal y su posterior testeo, ayudándonos a definir el número de neuronas por capas, cuantas capas y sus funciones de activación respectivas.
- **TensorFlow:** es una de las librerías bases del machine learning debido a su enfoque en el entrenamiento de modelos, es por esto que se planea aprovechar su sencillez para entrenar la solución.
- **OpenCV:** se presenta como la librería de visión por computador ideal para la solución, por su enfoque en aplicaciones en tiempo real resulta de utilidad su velocidad para reconocer las posturas en los fotogramas.
- **Scikit-learn:** es una librería que provee acceso a varios algoritmos de machine learning entre los que se encuentran algoritmos de clasificación necesarios para la elaboración del modelo, así mismo cuenta con varias herramientas de preprocesamiento como el StandardScaler y el Train_test_split, que nos ayudará a preparar el data set para el entrenamiento.

Parámetros de la Red MLP:

Número de capas ocultas = 2

Número de neuronas por capa oculta = 80 y 80

Conectividad = Completamente conectadas.
Adicionalmente después de cada capa oculta se añadirá una capa de Dropout que permitirá realizar un mejor mapeo de features y evitar overfitting.
Se escogieron estas dimensiones debido a las características de nuestra clasificación y tamaño de ejemplos.
Se tienen 32.301 samples cada una con 34 features, siendo las coordenadas de los puntos clave en los movimientos del cuerpo humano, queriéndose agrupar en 1 de 7 categorías que serían las distintas poses en las que se puede encontrar el presentador.
Por lo que debido al alto número de features y categorías de agrupación se usaran 80 neuronas para la primera capa oculta, teniendo en cuenta que el input size es de 34.
En la segunda capa oculta se usaría el mismo número de neuronas de la primera capa debido a que es lo recomendado para realizar una mejor caracterización de los features[5].
Y en la parte final en la capa de salida 7 neuronas la misma cantidad de categorías a clasificar, lo que permite realizar correctamente el one-hot encoding.

Hiperparámetros del modelo:

Funciones de activación = “Relu” para las capas ocultas y “Softmax” para la capa de salida.
Learning Rate = 0.01
Momentum = 0.9
Nesterov Momentum = Verdadero
Épocas = 2000
Batch Size = 128
Por cómo funciona Thunder un modelo preentrenado de Tensorflow, permite conseguir las coordenadas de píxeles con las partes claves del cuerpo y en combinación del preprocesamiento del data set utilizando el escalamiento se decide utilizar la función de activación “Relu” para las capas ocultas ya que siempre se obtendrá un resultado para las dimensiones del video después del preprocesamiento.
Y debido a que el modelo es una regresión logística multinomial es vital el uso de la función “Softmax” en la capa de salida, ya que permitirá realizar la clasificación en one – hot encoding con las categorías.
El learning rate y momentum son seleccionados para asegurarse que no haya overshooting y que encuentre el mínimo global.

Utilizamos el Nesterov Momentum para actualizar los pesos con el promedio del cambio del gradiente proyectado en vez de la posición en sí misma, lo que permite la desaceleración de los cambios de los pesos cuando se aproxima al mínimo global evitando así que no lo encuentre o que se suceda overshooting [6].

Finalmente, la fórmula de actualización de los pesos W sería.

$$velocity = momentum * velocity - learningrate * gradient$$

$$w_{new} = w_{old} + momentum * velocity - learning_rate * g$$

Se selecciona un número grande de épocas y un batch size pequeño para asegurarse de la convergencia en la función de la función de costo al momento de entrenar el modelo.

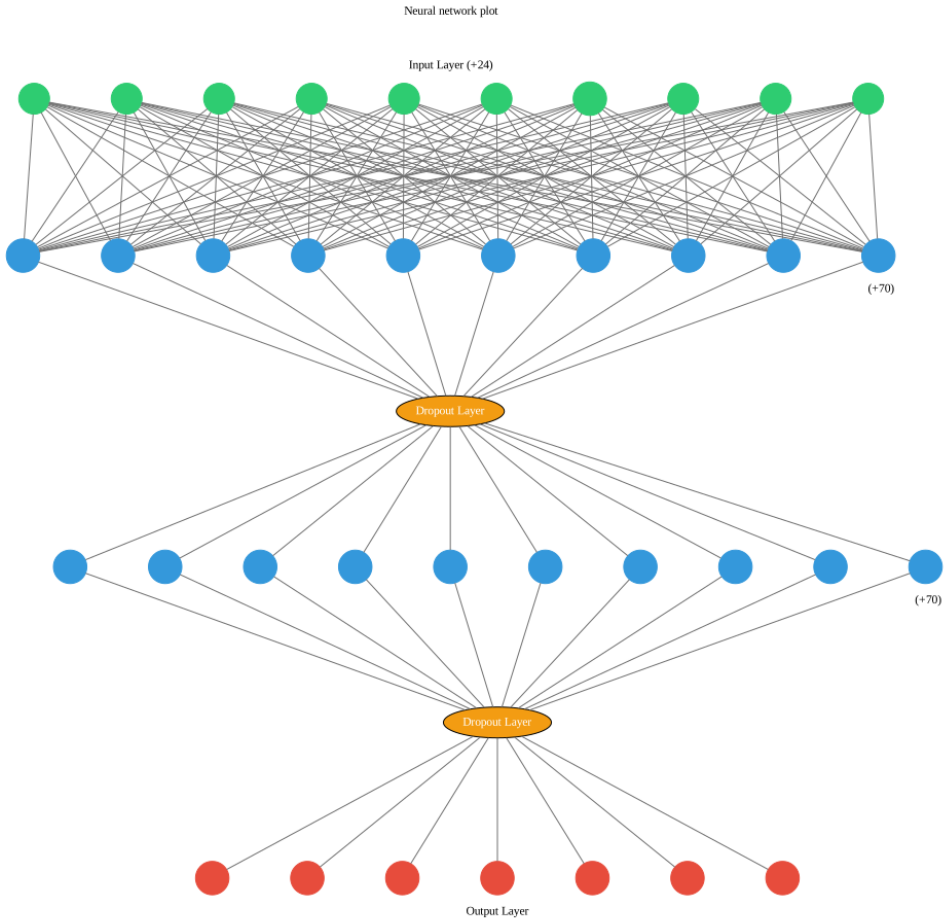


Ilustración 11:Modelo MLP

8. Resultados

Se desarrollaron y probaron dos modelos de clasificación el previamente mencionado modelo de redes neuronales MLP para la clasificación multiclase con función de activación Softmax y un modelo de Support Vector Machines para contrastar la certidumbre entre ambos modelos después del entrenamiento.

Con el modelo SVM se logró alcanzar una **certidumbre del 85%**, por lo que superó las expectativas al tratarse de un modelo relativamente simple. Pero el mayor problema que presento es que ciertas poses se le hacen mucho más difíciles de clasificar por lo que se puede ver en la siguiente matriz de confusión.

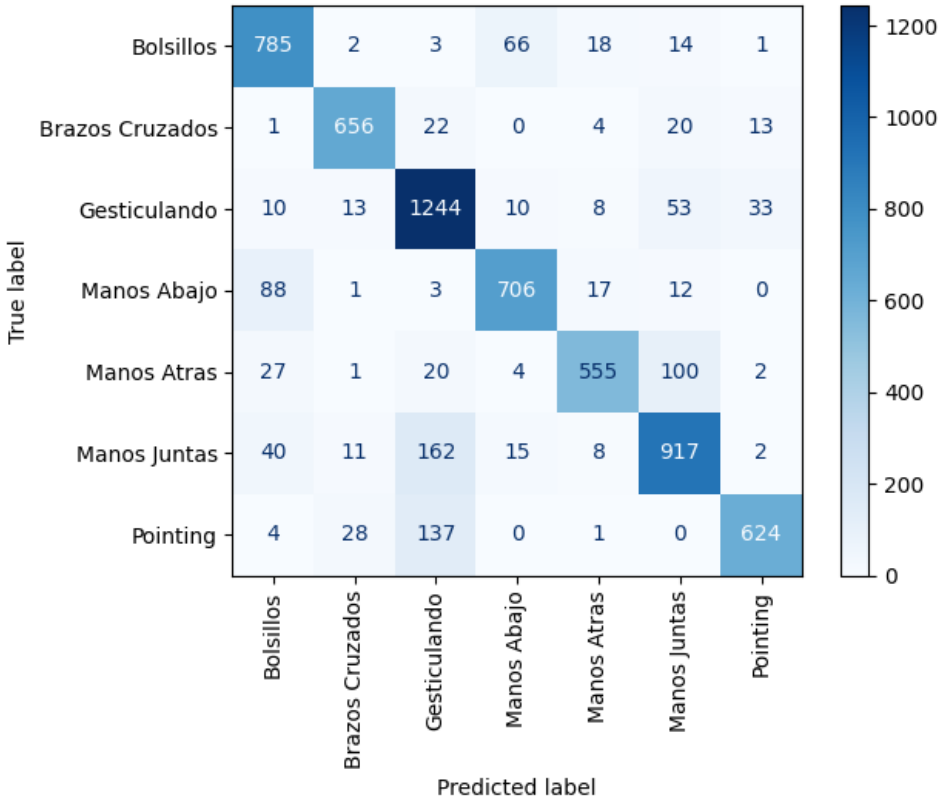


Ilustración 12:Matriz confusión svm

Podemos observar en la matriz que el modelo se inclina a clasificar erróneamente demás las poses de Gesticulando y Bolsillos, posibles razones para esto son la falta de ejemplos en el aprendizaje o el desbalanceo de las clases.

Las contribuciones más importantes a este modelo fueron la reducción de features con alta correlación y la decisión de usar la función de decisión “OVO” o One vs One para la clasificación de clases entre pares.

SVM fue un modelo sorprendentemente bueno pero el mejor modelo desarrollado y por lo tanto el escogido para integrarse con la aplicación fueron las redes neuronales MLP.

Se logró alcanzar una certidumbre del **91.2%,** lo que se pudo aumentar, pero al aumentar el número de neuronas ya nos acercábamos demasiado a realizar overfitting, podemos observar cómo la matriz de confusión con MLP clasifica mejor las poses.

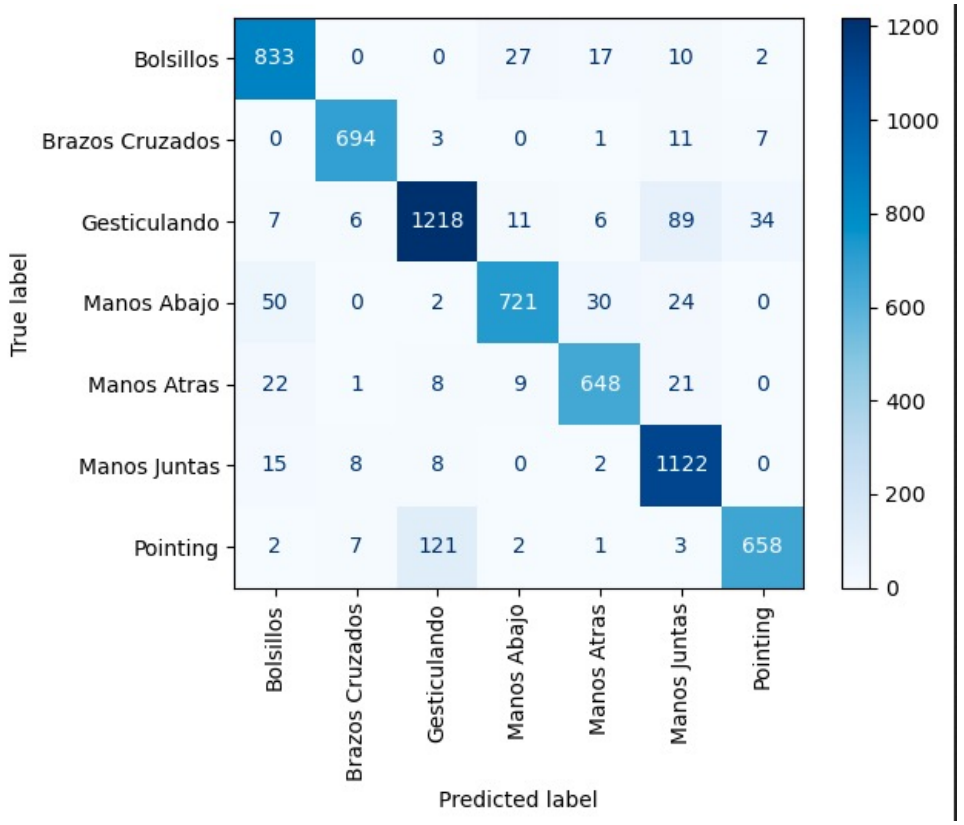


Ilustración 13:Matriz confusión MLP

Comparada con la del modelo SVM clasifica mejor las poses de Gesticulando y Bolsillos, aunque también presentan algo de dificultad.

La contribución al modelo son los hiperparámetros previamente mencionados, especialmente el uso del Nesterov Momentum para desacelerar el gradiente cuando se converge al mínimo global.

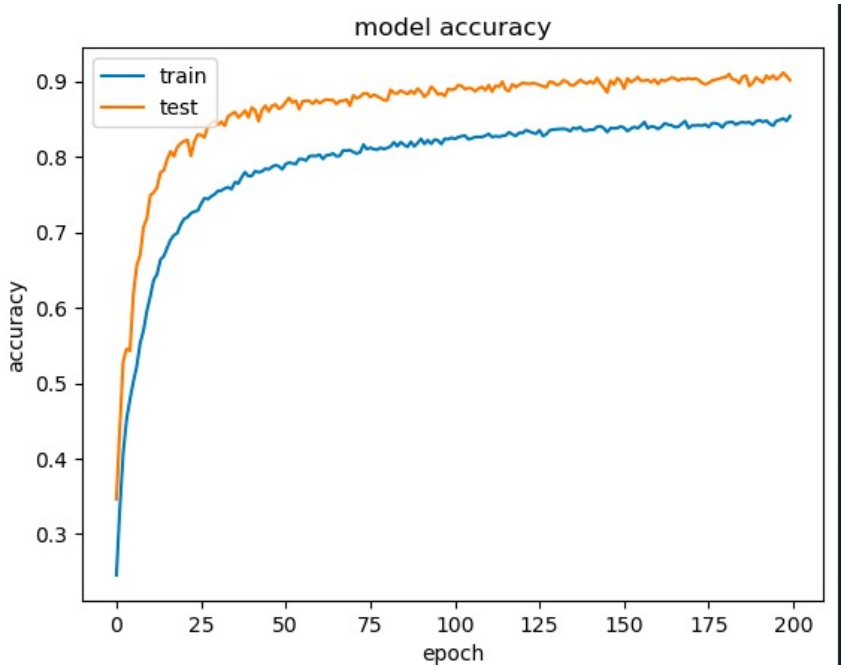


Ilustración 14:Gráfica del accuracy del modelo MLP

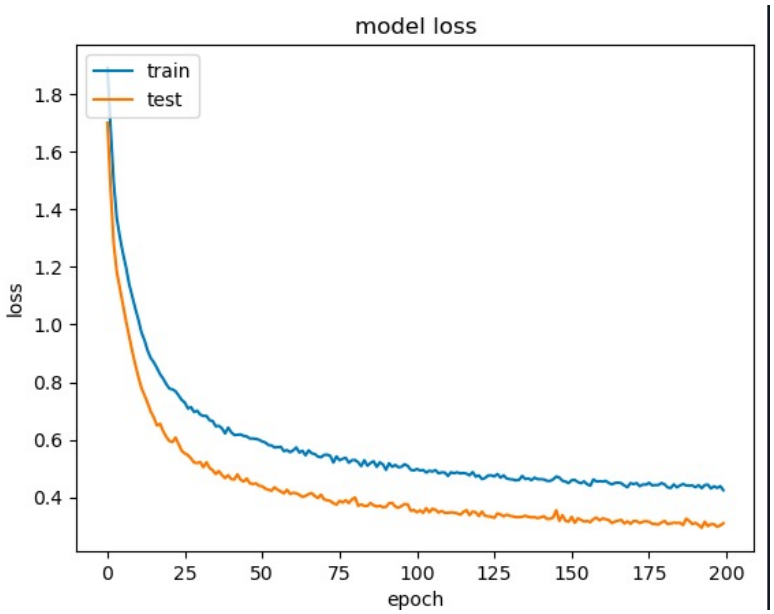


Ilustración 15:Gráfica del loss de MLP

Excelente desempeño de la red neuronal

Podemos observar cómo en ambos gráficos el modelo logra llegar a converger en un mínimo global en solo 200 épocas.

Adicionalmente el modelo finalmente logró dar un feedback de presentaciones tanto para videos pregrabados como en tiempo real, lo que demandó que el modelo sea altamente eficiente debido a

que cada segundo se procesa entre 30 y 60 predicciones dependiendo de los FPS demandando significante poder computacional. Profesores y estudiantes pueden usar la aplicación para determinar si los gestos usados en una presentación son positivos para comunicarse.

9. Conclusiones

- Distintos modelos de inteligencia artificial pueden tener el mismo objetivo, en este caso clasificación multiclase, pero dependiendo de cómo se caracterizan los features y la cantidad de categorías en el ouput, unos modelos se destacan sobre otros, por lo que es importante utilizar métricas de comparación como accuracy o visualizando la matriz de confusión.
- La flexibilidad de las redes neuronales es una herramienta formidable para el desarrollo de modelos de aprendizaje automático, pero hay que saber diseñar las correctas dimensiones de las redes para evitar el overfitting.
- Los modelos de IA una vez entrenados pueden ser serializados e incorporarlos en aplicaciones de escritorio o web para utilizar la matriz de parámetros aprendidos, siempre y cuando las dimensiones del input se mantengan
- Cuando se trabaja con imágenes o videos es vital considerar las dimensiones del training sample con el que se entrenó el modelo, ya que deben ser las mismas para realizar las predicciones por lo que es importante escalar el input una vez que se quiera predecir con el modelo entrenado.

Referencias

1. A. Bhardwaj, A. Tiwari, H. Bhardwaj, and A. Bhardwaj, “A genetically optimized neural network model for multi-class classification,” Expert Systems with Applications, vol. 60, pp. 211–221, 2016.
2. Qi, L., & Han, Y. (2021). Human Motion Posture Detection Algorithm Using Deep Reinforcement Learning. *Mobile Information Systems*, *2021*.
3. V. Tosaco (2014, marzo 5) Cómo usar tu cuerpo y manos al hablar en público. Disponible: https://tecnicashablarenpublico.com/blog/como-usar-tu-cuerpo-y-tus-manos-al-hablar-en-publico/
4. Calsius, F. (23 de agosto de 2019). *Medium*. Obtenido de https://medium.com/jstack-eu/using-machine-learning-to-analyse-body-language-and-facial-expressions-a779172cc98
   (Accessed: January 4,2023)
5. Determining the number of neurons in artificial neural networks for ... (no date). Available at: https://temjournal.com/content/94/TEMJournalNovember2020_1320_1329.pdf (Accessed: January 4, 2023).
6. Brownlee, J. (2021) *Gradient descent with Nesterov momentum from scratch*, *MachineLearningMastery.com*. Available at: https://machinelearningmastery.com/gradient-descent-with-nesterov-momentum-from-scratch/ (Accessed: January 3, 2023).